

---

Construção de um Robô Investidor baseado em Redes Neurais  
Artificiais e Preditores Econométricos

*Ciniro Aparecido Leite Nametala*

---



# Construção de um Robô Investidor baseado em Redes Neurais Artificiais e Preditores Econométricos

**Ciniro Aparecido Leite Nametala**

***Orientador:* Prof. Dr. Eduardo Gontijo Carrano**

Dissertação apresentada ao Programa de Pós-Graduação em Engenharia Elétrica (PPGEE) da Escola de Engenharia da Universidade Federal de Minas Gerais, como parte dos requisitos para obtenção do título de Mestre em Engenharia Elétrica.

**Universidade Federal de Minas Gerais – Belo Horizonte**  
**Fevereiro de 2017**



*Este trabalho é dedicado à minha mãe Maria de Fátima, à minha madrinha Maria Regina e  
ao meu pai Antônio de Pádua.*



# AGRADECIMENTOS

---

Agradeço à minha mãe Maria de Fátima, mulher de fibra, inteligente e batalhadora, que sempre preferiu se desfazer dos seus próprios sonhos em função dos meus. Minha base, pilar, fonte de segurança. Ensinou-me a importância em se ter objetivos, a desconfiar dos caminhos fáceis e a saber que as coisas mais importantes estarão sempre acima dos rótulos e das diferenças. Ao meu pai Antônio de Pádua Nametala, pessoa amorosa e simples que me ensinou a dar valor às lutas vencidas, às conquistas alcançadas e às pessoas que realmente importam. Aos meus irmãos que, cada um a seu modo e tempo, servem em alguns momentos como fonte de inspiração e, em outros, como fonte de alívio. À minha madrinha Maria Regina Leite, que com seu sorriso, otimismo e apoio incondicional, sempre esteve lá quando necessário. À minha cunhada Mara Ferreira, trabalhadora, presente e paciente, além das minhas duas sobrinhas lindas e alegres, Samira e Isis. Aos meus tios, primos e demais familiares que, de uma forma ou de outra, contribuíram ao longo da vida para meu crescimento pessoal.

Agradeço também aos vários amigos que pela minha vida passaram, que neste momento estão e os quais no futuro estarão. Especialmente os presentes que, nos últimos dois anos, ouviram pacientemente meus anseios, minhas histórias e, principalmente, segundo eles, minhas infundáveis reclamações.

Agradeço também outros amigos, companheiros acadêmicos, Prof. Dr. Alexandre Pimenta, Dr. Carlos Alberto Silva de Assis e Breno Rolindo Lara Moreira, grandes incentivadores com o quais passei muitas horas fazendo planos, comemorando conquistas de metas e revisando infinitas vezes os diversos momentos de falha com os quais aprendemos a crescer. Ao Prof. Dr. Eduardo Gontijo Carrano, excepcional orientador, paciente, dedicado, rápido nas respostas e sempre disponível. Graças a ele cada etapa deste trabalho pode tomar um rumo adequado, mesmo nos momentos mais difíceis. Poucas foram as vezes em que não me impressionei com seu brilhantismo e capacidade. Aos professores Dr. Felipe Campelo e Dr. Adriano César, pois, além de fornecerem grande parte dos conhecimentos necessários à pesquisa em suas respectivas disciplinas, contribuíram muito para o meu atual apreço pelas áreas de estatística e algoritmos para o mercado financeiro.

Por fim, agradeço ao Instituto Federal de Minas Gerais, em especial aos meus alunos que lá estão, pois sei que foi também por eles que, dia após dia, pude acordar motivado, sempre pensando na próxima aula, no próximo curso, na próxima possibilidade de passar a frente tudo que aprendi. Este trabalho não é meu, é deles.





*“Não devo ter medo. O medo mata o pensamento.  
O medo é a morte antecipada que nos aniquila.  
Hei de encarar meu medo, deixar que ele me  
perpasse, que me atravessasse, e quando houver  
passado, olharei bem dentro de mim para con-  
ferir seu trajeto. Por onde passou o medo, não  
haverá nada, restará apenas eu.”*

*(Frank Herbert)*



# RESUMO

NAMETALA, CINIRO A. L.. **Construção de um Robô Investidor baseado em Redes Neurais Artificiais e Preditores Econométricos**. 2017. 185 f. Dissertação (Mestrado em Engenharia Elétrica) – Programa de Pós-Graduação em Engenharia Elétrica (PPGEE/UFMG), Belo Horizonte – MG.

A previsão de tendências no mercado acionário é uma tarefa dificultosa, pois os bens negociados tendem a sofrer as mais diversas influências. Fatores observados em escala global como a política internacional e o movimento do câmbio são tão determinantes para a variação do valor de um ativo quanto fatores locais como a cultura de um dado país ou os índices financeiros de uma dada indústria. Essa complexidade percebida, entretanto, quando encarada por meio de técnicas de detecção de padrões e análise de séries temporais, permite a realização de diversos estudos que buscam modelar matematicamente as possíveis tendências existentes em séries especificadamente financeiras. Este campo de pesquisa é conhecido como Finanças Quantitativas e possui por característica principal ser interdisciplinar envolvendo áreas como estatística, economia e computação. Neste contexto, este trabalho apresenta uma estratégia de negociação automatizada (robô investidor) que combina previsões feitas por redes neurais artificiais e preditores econométricos por meio de seletores inteligentes e comitês de decisão diversos que, progressivamente no tempo, são otimizados gerando cenários lucrativos. Foi desenvolvida uma metodologia para seleção de ações que possuam histórico de alta liquidez e, aliado a isso, um algoritmo negociador que possui gestão de risco também otimizada temporalmente. Todos os dados das séries que serviram de base à pesquisa são reais, contudo o processo de negociação foi feito com capital simulado. Nos experimentos realizados o robô investidor utilizou um histórico de 3 anos para gerar estratégias de investimento aplicadas a dez ações de companhias nacionais e ao índice Bovespa simultaneamente. Em pregões ocorridos entre 2012 e 2013 foram obtidos resultados estatisticamente significantes tanto para taxa de acerto quanto para rendimento financeiro frente a todos os *benchmarks* utilizados, mesmo considerando-se custos de corretagem. Levando-se em conta o número de pregões neste período e a quantidade de ativos, o tempo de uso do robô em ambiente desconhecido correspondeu a um total de 22 anos. Comparações com diversas métricas foram feitas frente aos melhores preditores de cada classe quando aplicados individualmente, às médias das classes de preditores, à técnica de mercado *Buy and Hold* e a evolução do próprio índice Bovespa. As contribuições deste estudo se somam a outros trabalhos da área que, por ser considerada recente na literatura, vêm propor uma combinação de técnicas que modelam a volatilidade dos retornos e que, para encontrar parametrizações ótimas nos métodos, tomam por mecanismo principal técnicas clássicas de inteligência artificial e otimização.

**Palavras-chave:** Finanças Quantitativas, Econometria, Redes Neurais Artificiais, Otimização.



# ABSTRACT

NAMETALA, CINIRO A. L.. **Construção de um Robô Investidor baseado em Redes Neurais Artificiais e Preditores Econométricos**. 2017. 185 f. Dissertação (Mestrado em Engenharia Elétrica) – Programa de Pós-Graduação em Engenharia Elétrica (PPGEE/UFMG), Belo Horizonte – MG.

The forecast of stock market trends is a difficult task, as traded goods tend to suffer the most diverse influences. Factors observed on a global scale, such as international politics and exchange flow, are as determinant for variations in the value of an asset as local factors, such as the culture of a given country or the financial indices of a given industry. This perceived complexity, however, when viewed through techniques of pattern detection and time series analysis, allows the implementation of several studies that seek to mathematically model the possible trends in specific financial series. This field of study known as Quantitative Finance is interdisciplinary and involves areas such as statistics, economics and computing. In this context, this paper presents an automated negotiation strategy (robot investor) that combines predictions made by neural networks and econometric predictors through intelligent selectors and different decision committees that are progressively optimized in time to generate profitable scenarios. A methodology was developed for the selection of stocks with high liquidity history and, combined with that, a negotiation algorithm that has risk management was optimized temporarily. All the data of the series that served as the basis for the research are real, but the negotiation process was done with simulated capital. In the experiments the robot investor used a history of 3 years to generate the investment strategies applied to ten shares of several brazilian companies and to the Bovespa index simultaneously. In trading sessions that happened between 2012 and 2013, the results showed statistical significance for both the success rate and for financial return against all benchmarks, even with brokerage costs. Considering the number of trading sessions in the period and the number of assets involved, the working time of the robot in unknown environment refers to a time series of 22 years. The comparisons of several metrics were made against the best predictors of each class when applied individually, to the mean of classes, to the Buy and Hold market technique, and to the evolution of BOVESPA index. The contributions of this study add to other studies in the field which, for being considered recent in the literature, propose a combination of techniques that model the volatility of returns and that, to find optimal parameterizations in the methods, take as their main mechanism classic techniques of artificial intelligence and optimization.

**Key-words:** Quantitative Finance; Econometrics; Artificial Neural Networks; Optimization.



# LISTA DE ILUSTRAÇÕES

---

Figura 1 – Intermediação de acesso ao sistema BM&F Bovespa no modelo DMA 1 (tradicional). . . . .	5
Figura 2 – Comparativo percentual de negociações realizadas em Pregão Viva Voz e Pregão Eletrônico em 15 anos (1990 a 2005) de automação na bolsa. . . . .	7
Figura 3 – Crescimento percentual de negócios e volumes em transações realizadas por meio de <i>Home Brokers</i> na BOVESPA. . . . .	7
Figura 4 – Modelo de intermediação de ordens no modelo DMA 2 (via provedor). . . . .	12
Figura 5 – Projeção de crescimento do uso de robôs investidores em HFT nos mercados mundiais. . . . .	13
Figura 6 – Participação percentual ano a ano de operações de fundos ativos, passivos e HFT no mercado americano. . . . .	13
Figura 7 – Componentes de um gráfico de <i>candles</i> . . . . .	19
Figura 8 – Uso combinado de técnicas (bege), entradas (verde), aplicações (vermelho) e objetivos (roxo) no mercado financeiro. Análise de trabalhos publicados em jornais e conferências acadêmicas sobre finanças quantitativas entre 2009 e 2015. Nota-se um grande uso de redes neurais artificiais MLP, ao passo que, métodos estatísticos como GARCH e ARIMA foram poucas vezes considerados. Destaque também para entradas oriundas de análise técnica ( <i>candles</i> ) e, dentre os objetivos, a realização de previsão. . . . .	41
Figura 9 – Anatomia da modelagem econométrica. . . . .	44
Figura 10 – Representação da homoscedasticidade. . . . .	49
Figura 11 – Representação da heterocedasticidade. . . . .	49
Figura 12 – Em preto, o preço de fechamento; em azul uma SMA com janela de comprimento igual a 60 dias; e, em verde, uma SMA com janela de comprimento igual a 15 dias. Série do índice BOVESPA em <i>candles</i> diários. . . . .	56
Figura 13 – Rede Neural Artificial do tipo Perceptron Simples. . . . .	61
Figura 14 – Rede Neural Artificial do tipo Perceptron com Múltiplas Camadas. Na imagem duas camadas sendo uma, a intermediária, com dois neurônios com função de ativação sigmoide e, a outra, de saída com um neurônio com função de ativação linear. . . . .	62
Figura 15 – Arcabouço geral para sistemas de <i>trading</i> com previsão. . . . .	68
Figura 16 – Arquitetura raiz (nível zero) do robô investidor. . . . .	69
Figura 17 – Dinâmica de operação do robô (janelamento móvel). . . . .	74

Figura 18 – Preço de fechamento para BBAS3 nos 100 primeiros dias de 2011. . . . .	80
Figura 19 – Série de tendências para BBAS3 nos 100 primeiros dias de 2011. . . . .	81
Figura 20 – Comparativo entre os resíduos teóricos de uma distribuição normal frente aos gerados pelos tratamentos T1, T2 e T3 entre os anos de 2009 e 2011 para o ativo BBAS3. As caudas fora da área pontilhada vermelha nas imagens indicam a existência de caudas com possíveis <i>outliers</i> . . . . .	86
Figura 21 – Distribuição de preços absolutos (a) e distribuição de preços absolutos após tratamento T1 (b) no ativo BBAS3 entre 2009 e 2011 (inclusive). . . . .	87
Figura 22 – Detalhamento do fluxo de informações e sub-módulos do Módulo Negociador.	92
Figura 23 – Fluxo de dados e blocos que compõe os módulos do robô investidor. Neste diagrama estão detalhados os componentes dos módulos Extrator e Preditor.	95
Figura 24 – Análise de algoritmos de correção de erros para a rede neural MLP. (a) Média de épocas necessárias à convergência, (b) média dos erros quadráticos médios e (c) tempo de processamento médio (segundos). . . . .	98
Figura 25 – Convergência do erro quadrático médio ponderado ao longo de 20000 épocas para o ativo CSNA3 (usada como exemplo, visto que o comportamento foi similar em todas as séries) com uma MLP-LM em janela de 50 dias e 30 neurônios na camada escondida. . . . .	98
Figura 26 – Construção do conjunto de treinamento da RNA de tendência baseado nos passos da janela móvel. . . . .	100
Figura 27 – Construção dos conjuntos de treinamento da RNA de <i>candles</i> baseado nos passos da janela móvel. . . . .	102
Figura 28 – Evolução da taxa de acerto do preditor <i>rnaInc_j60_n40</i> (RNA de <i>candle</i> com janela de 60 dias e 40 neurônios na camada escondida) ao longo dos 248 dias de 2011 levando-se em conta a taxa de acerto dos últimos 5 dias (semana). .	105
Figura 29 – Evolução da taxa de acerto do preditor <i>rnaInc_j60_n40</i> (RNA de <i>candle</i> com janela de 60 dias e 40 neurônios na camada escondida) ao longo dos 248 dias de 2011 levando-se em conta a taxa de acerto dos últimos 15 dias (duas semanas). . . . .	105
Figura 30 – Evolução da taxa de acerto do preditor <i>rnaInc_j60_n40</i> (RNA de <i>candle</i> com janela de 60 dias e 40 neurônios na camada escondida) ao longo dos 248 dias de 2011 levando-se em conta a taxa de acerto dos últimos 31 dias (um mês e meio) e com média exponencial (EMA) de 15 dias. . . . .	106
Figura 31 – Evolução da taxa de acerto do preditor <i>rnaInc_j60_n40</i> (RNA de <i>candle</i> com janela de 60 dias e 40 neurônios na camada escondida) ao longo dos 248 dias de 2011 levando-se em conta a taxa de acerto dos últimos 31 dias (um mês e meio) avaliada de 10 em 10 dias e com média exponencial (EMA) de 15 dias.	106



Figura 32 – Evolução da taxa de acerto do preditor <i>rnaInc_j60_n40</i> ao longo de 867 dias compreendidos entre o último semestre de 2010 até o último dia 2013. Levando-se em conta a taxa de acerto dos últimos 31 dias (um mês e meio) avaliada de 10 em 10 dias e com EMA de 15 dias. . . . .	107
Figura 33 – Dinâmica de operação do momento de confiança CMTA. . . . .	108
Figura 34 – Distribuição dos retornos no ativo BVMF3 entre 04/01/2010 a 29/12/2011. Definição de tamanho de <i>stops</i> com proporção 1:3, sendo 15% para perdas e 45% para ganhos. . . . .	114
Figura 35 – Distribuição dos retornos no ativo BVMF3 entre 03/01/2011 a 28/12/2012. Definição de tamanho de <i>stops</i> com proporção 1:3, sendo 15% para perdas e 45% para ganhos. . . . .	115
Figura 36 – Quantidade de operações certas e erradas por estratégia no ativo VALE5 no ano de 2011. Em 2011 foram 249 dias úteis na bolsa, logo, 249 oportunidades de operação. . . . .	117
Figura 37 – Taxas de acerto por estratégia no ativo VALE5 no ano de 2011. . . . .	117
Figura 38 – Retornos percentuais por estratégia com e sem corretagem no ativo VALE5 no ano de 2011. . . . .	118
Figura 39 – Quantidade de operações certas e erradas por ativo em 494 oportunidades de pregões entre os anos de 2012 e 2013. . . . .	122
Figura 40 – Taxas de acerto obtidas pelo robô nas previsões geradas no período simulado em todos os ativos. . . . .	124
Figura 41 – Taxa de acerto média do robô investidor, das classes e dos melhores preditores em cada classe. . . . .	127
Figura 42 – Retornos percentuais do robô para análises sem corretagem, com corretagem e com todas as taxas de operação. . . . .	131
Figura 43 – Gráfico de dispersão dos retornos percentuais sem corretagem obtidos pelo robô, pelos melhores preditores de cada classe, pelo índice Bovespa e pela técnica de mercado <i>Buy and Hold</i> . . . . .	133
Figura 44 – Rendimentos percentuais médios do robô, dos melhores preditores de cada classe, do índice Bovespa e da técnica de mercado <i>Buy and Hold</i> . . . . .	134
Figura 45 – Evolução dos retornos sem corretagem ajustados com o ativo BBAS3. . . . .	136
Figura 46 – Evolução dos retornos sem corretagem ajustados com o ativo BBDC4. . . . .	136
Figura 47 – Evolução dos retornos sem corretagem ajustados com o ativo BOVA11. . . . .	137
Figura 48 – Evolução dos retornos sem corretagem ajustados com o ativo BVMF3. . . . .	137
Figura 49 – Evolução dos retornos sem corretagem ajustados com o ativo CSNA3. . . . .	137
Figura 50 – Evolução dos retornos sem corretagem ajustados com o ativo CYRE3. . . . .	138
Figura 51 – Evolução dos retornos sem corretagem ajustados com o ativo GGBR4. . . . .	138
Figura 52 – Evolução dos retornos sem corretagem ajustados com o ativo ITSA4. . . . .	138
Figura 53 – Evolução dos retornos sem corretagem ajustados com o ativo PETR4. . . . .	139

Figura 54 – Evolução dos retornos sem corretagem ajustados com o ativo USIM5. . . .	139
Figura 55 – Evolução dos retornos sem corretagem ajustados com o ativo VALE5. . . .	139
Figura 56 – Dispersão dos retornos percentuais sem corretagem em todos os ativos para os melhores preditores em cada classe, a técnica de mercado <i>Buy and Hold</i> , o índice Bovespa e o robô investidor. . . . .	140
Figura 57 – Dispersão das taxas de acerto em todos os ativos para os melhores preditores em cada classe e o robô investidor. . . . .	141
Figura 58 – Gráficos descritivos do preço de fechamento do ativo BBAS3. . . . .	165
Figura 59 – Gráficos descritivos do preço de fechamento do ativo BBDC4. . . . .	166
Figura 60 – Gráficos descritivos do preço de fechamento do ativo BOVA11. . . . .	167
Figura 61 – Gráficos descritivos do preço de fechamento do ativo BVMF3. . . . .	168
Figura 62 – Gráficos descritivos do preço de fechamento do ativo ITSA4. . . . .	169
Figura 63 – Gráficos descritivos do preço de fechamento do ativo GGBR4. . . . .	170
Figura 64 – Gráficos descritivos do preço de fechamento do ativo USIM5. . . . .	171
Figura 65 – Gráficos descritivos do preço de fechamento do ativo CSNA3. . . . .	172
Figura 66 – Gráficos descritivos do preço de fechamento do ativo CYRE3. . . . .	173
Figura 67 – Gráficos descritivos do preço de fechamento do ativo PETR4. . . . .	174
Figura 68 – Gráficos descritivos do preço de fechamento do ativo VALE5. . . . .	175
Figura 69 – Comparação da evolução dos retornos acumulados sem corretagem entre 2012 e 2013 (período de operação) entre todos os ativos. . . . .	176
Figura 70 – Significância estatística da correlação entre séries de preço de fechamento dos ativos. . . . .	177
Figura 71 – Frequências das correlações. . . . .	177
Figura 72 – Interface de trabalho do <i>Metatrader 5</i> . . . . .	180
Figura 73 – Interface de trabalho do <i>RStudio</i> . . . . .	181

# LISTA DE QUADROS

---

Quadro 1 – Períodos de operação do robô por ativo. . . . .	70
Quadro 2 – Períodos de operação do robô na carteira. . . . .	71
Quadro 3 – Listagem de todos os preditores embarcados no robô investidor da categoria econométricos. . . . .	71
Quadro 4 – Listagem de todos os preditores embarcados no robô investidor da categoria redes neurais artificiais. . . . .	72
Quadro 5 – Resultados possíveis para tipo de operação. . . . .	90
Quadro 6 – Tipos de modelos adotados conforme otimização dos parâmetros no Seletor SARIMA. . . . .	94
Quadro 7 – Configuração e topologia definida, após experimentos, para as redes neurais artificiais do robô. . . . .	99
Quadro 8 – Combinação de sinais e estados para os momentos de confiança ETA e CMTA. . . . .	107
Quadro 9 – Combinação de sinais e estados para o momento de confiança MTA. . . . .	107
Quadro 10 – Situações de uso do comitê média (CM) ou no comitê voto majoritário (CV) . . . . .	110
Quadro 11 – Combinação de sinais por preço ou tendência nos comitês CM ou CV . . . . .	110
Quadro 12 – Combinação de sinais dos comitês CM e CV com o uso do comitê híbrido de média e voto majoritário (CMV) . . . . .	111
Quadro 13 – Melhores estratégias por ano e colocação das melhores estratégias no ano seguinte, por ativo. . . . .	118
Quadro 14 – Total de ocorrências das estratégias como mais rentáveis (1º lugar) nos ativos por ano. . . . .	119



# LISTA DE TABELAS

---

Tabela 1	– <i>Ranking</i> de ocorrências de ativos entre os 10 primeiros em 2009, 2010 e 2011 para volume financeiro. . . . .	78
Tabela 2	– <i>Ranking</i> de ocorrências de ativos entre os 10 primeiros em 2009, 2010 e 2011 para volume de <i>ticks</i> . . . . .	78
Tabela 3	– Médias ano a ano no período histórico (2009 a 2011) de BBAS3 para os tratamentos P, RP, T1, T2 e T3 e respectivos desvios padrão das médias de cada. . . . .	84
Tabela 4	– Desvios padrão ano a ano no período histórico (2009 a 2011) de BBAS3 para os tratamentos P, RP, T1, T2 e T3 e respectivos desvios-padrão, dos desvios padrão, de cada. . . . .	84
Tabela 5	– Desvio médio para todos os ativos do <i>dataset</i> levando-se em conta os desvios padrão das medias nos anos de 2009, 2010 e 2011 em cada um dos tratamentos P, RP, T1, T2 e T3. . . . .	85
Tabela 6	– Desvio médio para todos os ativos do <i>dataset</i> levando-se em conta os desvios padrão, dos desvios padrão, nos anos de 2009, 2010 e 2011 em cada um dos tratamentos P, RP, T1, T2 e T3. . . . .	85
Tabela 7	– Tamanhos de <i>stop</i> definidos para cada um dos ativos nas distribuições dos retornos com proporção 1:3. Os valores 2010-2011 foram usados em 2012 e os valores 2011-2012 foram usados em 2013. . . . .	115
Tabela 8	– Quantidades de operações certas e erradas por ativo. Robô investidor contra os preditores mais rentáveis de cada classe de preditores. . . . .	123
Tabela 9	– Comparativo das taxas de acerto do robô investidor frente aos preditores mais rentáveis em cada classe de preditor. . . . .	125
Tabela 10	– Comparativo das taxas de acerto do robô investidor frente as medias de todos os preditores e desvio padrão, separados por classe. . . . .	126
Tabela 11	– Retornos financeiros e percentuais para todos os ativos sem corretagem. . . . .	128
Tabela 12	– Retornos financeiros e percentuais para todos os ativos com corretagem por ordem. . . . .	128
Tabela 13	– Cálculo de custos de negociação por ativo no período simulado. . . . .	129
Tabela 14	– Retornos líquidos e percentuais com subtração de todas as taxas existentes em operações no mercado. . . . .	130
Tabela 15	– Rendimentos percentuais sem corretagem do robô investidor contra os melhores preditores em cada classe, ao índice Bovespa e a técnica de mercado <i>Buy and Hold</i> . . . . .	133



# LISTA DE SIGLAS

---

*PVV — Pregão Viva Voz*

*CATS — Computer Assisted Trading System*

*CBLC — Companhia Brasileira de Liquidação e Custódia*

*CLC — Companhia de Liquidação e Custódia*

*CVM — Comissão de Valores Mobiliários*

*BM&F — Bolsa de Mercados e Futuros*

*DMA — Direct Market Access*

*PE — Pregão Eletrônico*

*CORE — Close-Out Risk Evaluation*

*S&P — Standard & Poor's*

*NYSE — Bolsa de Nova York*

*MIT — Massachusetts Institute of Technology*

*HFT — High Frequency Trading*

*ECN — Eletronic Communication Networks*

*SEC — Security and Exchange Comission*

*TSE — Bolsa de Tokyo*

*OMS — Order Management System*

*HME — Hipótese do Mercado Eficiente*

*CAPM — Capital Asset Pricing Model*

*APT — Arbitrage Pricing Theory*

*RNA — Redes Neurais Artificias*

*SMA — Simple Moving Average*

*AIC — Akaike Information Criteria*

*ARMA — Autoregressive Moving Average*

*ARIMA — Autoregressive Integrated Moving Average*

*SARIMA — Seasonal Autoregressive Integrated Moving Average*

*GARCH — Generalized Autoregressive Conditional Heteroskedasticity*

*EQM — erro quadrático médio*

*RBF — Radial Basis Function*

*MLP — MultiLayer Perceptron*

*BP — Backpropagation padrão*

*POCID — Percentage of Change in Direction*

*ETA — evolução da taxa de acerto*

*EMA — Exponencial Moving Average*

*CMTA — capacidade de manutenção das taxas de acerto em períodos de tamanho fixo*

*MTA — Combinação dos dois seletores ETA e CMTA*

*CM — Comitê baseado na média das previsões de preço de fechamento e tendência*

*CV — Comitê baseado no resultado do voto majoritário para direção do movimento no preço de fechamento e tendência*

*CMV — Combinação dos dois comitês CM e CV*

*SL — Stoploss*

*TP — Takeprofit*

*ANOVA — Análise de Variância*

*ADX — Average Direcional Index*

*MACD — Moving Average Convergence and Divergence*

*OBV — On Balance Volume*

*IFR — Índice de Força Relativa*

*ROC — Rate of Change*

*FI — Force Index*

*ARFIMA — Autoregressive Fractionally Integrated Moving Average*

*MAPE — Média Absoluta Percentual dos Erros*

*SSE — Soma dos Quadrados dos Erros*

*SDE — Desvio Padrão dos Erros*

*ME — Erro Médio*

*MAE — Média Absoluta de Erros*



*RMSE* — Raiz do Erro Quadrático Médio

*SVM* — *Support Vector Machines*

*PGD* — Processo Gerador de Dados

*FRP* — Função de Regressão Populacional

*FRA* — Função de Regressão Amostral

*MQO* — Mínimos Quadrados Ordinários

*SIC* — *Schwarz Information Criteria*

*DF* — *Dickey-Fuller*

*ADF* — *Augmented Dickey-Fuller*

*KPSS* — *Kwiatkowski-Phillips-Schmidt-Shin*

*BJ* — *Box-Jenkins*

*ARCH* — *Autoregressive Conditional Heteroskedasticity*

*MQG* — Mínimos Quadrados Generalizados

*DFP* — *Davidon-Fletcher-Powell*

*BFGS* — *Broyden-Fletcher-Goldfarb-Shanno*

*MT5* — *Metatrader 5*

*POCID* — *Percentage of Change in Direction*

*P* — Preço absoluto

*PL* — Preço absoluto logtransformado

*PC* — Preço absoluto com remoção de tendência por clusterização

*PLC* — Preço absoluto logtransformado com remoção de tendência por clusterização

*RP* — Retornos do preço absoluto

*RPL* — Retornos do preço absoluto logtransformados

*RPC* — Retornos do preço absoluto com remoção de tendência por clusterização

*RPLC* — Retornos do preço absoluto logtransformado com remoção de tendência por clusterização

*RPLSO* — Retornos do preço absoluto logtransformados com detecção/ajuste de *outliers*

*RPCSO* — Retornos do preço absoluto com remoção de tendência por clusterização e com detecção/ajuste de *outliers*

*RPLCSO* — Retornos do preço absoluto logtransformado com remoção de tendência por clusterização e com detecção/ajuste de *outliers*

*T1* — Retornos do preço absoluto logtransformado com detecção/ajuste de *outliers* e com normalização no intervalo entre 0 e 1

*T2* — Retornos do preço absoluto com remoção de tendência por clusterização, com detecção/ajuste de *outliers* e com normalização no intervalo entre 0 e 1

*T3* — Retornos do preço absoluto logtransformado com remoção de tendência por clusterização, com detecção/ajuste de *outliers* e com normalização no intervalo entre 0 e 1

*RSNNS* — *R Stuttgart Neural Network Simulator*

*SNNS* — Stuttgart Neural Network Simulator

*BP* — *Backpropagation* padrão

*BRS* — *Backpropagation* resiliente

*BM* — *Backpropagation* com termo de *momentum*

*LM* — *Backpropagation* com algoritmo *Levenberg-Marquardt*

*CM – ETA* — Comitê por Média com momento de confiança baseado em Evolução da Taxa de Acerto

*CM – CMTA* — Comitê por Média com momento de confiança baseado em Capacidade de Manutenção da Taxa de Acerto

*CM – MTA* — Comitê por Média com momento de confiança baseado em análise Mista da Taxa de Acerto

*CV – ETA* — Comitê por Voto Majoritário com momento de confiança baseado em Evolução da Taxa de Acerto

*CV – CMTA* — Comitê por Voto Majoritário com momento de confiança baseado em Capacidade de Manutenção da Taxa de Acerto

*CV – MTA* — Comitê por Voto Majoritário com momento de confiança baseado em análise Mista da Taxa de Acerto

*CMV – ETA* — Comitê por Média e Voto Majoritário com momento de confiança baseado em Evolução da Taxa de Acerto

*CMV – CMTA* — Comitê por Média e Voto Majoritário com momento de confiança baseado em Capacidade de Manutenção da Taxa de Acerto

*CMV – MTA* — Comitê por Média e Voto Majoritário com momento de confiança baseado em análise Mista da Taxa de Acerto

# SUMÁRIO

---

<b>1</b>	<b>INTRODUÇÃO</b>	<b>1</b>
<b>1.1</b>	<b>Contextualização</b>	<b>1</b>
<b>1.1.1</b>	<i>Breve histórico da automação eletrônica no mercado brasileiro</i>	<b>1</b>
<b>1.1.2</b>	<i>Mercado eletrônico e negociação algorítmica</i>	<b>8</b>
<b>1.1.3</b>	<i>Desafios no uso de robôs investidores</i>	<b>14</b>
<b>1.1.3.1</b>	<i>Eficiência de mercado</i>	<b>14</b>
<b>1.1.3.2</b>	<i>Métodos de análise de mercado</i>	<b>17</b>
<b>1.2</b>	<b>Justificativa e proposta</b>	<b>21</b>
<b>1.3</b>	<b>Objetivos</b>	<b>25</b>
<b>1.3.1</b>	<i>Objetivo geral</i>	<b>25</b>
<b>1.3.2</b>	<i>Objetivos específicos</i>	<b>25</b>
<b>1.4</b>	<b>Estrutura da dissertação</b>	<b>26</b>
<b>1.4.1</b>	<i>Material complementar online</i>	<b>27</b>
<b>2</b>	<b>REVISÃO DE LITERATURA</b>	<b>29</b>
<b>2.1</b>	<b>Métodos de mercado</b>	<b>29</b>
<b>2.1.1</b>	<i>Teoria de Dow</i>	<b>29</b>
<b>2.1.2</b>	<i>Análise Técnica</i>	<b>31</b>
<b>2.1.3</b>	<i>Análise Fundamentalista</i>	<b>32</b>
<b>2.2</b>	<b>Trabalhos Relacionados</b>	<b>33</b>
<b>2.2.1</b>	<i>Métodos computacionais e estatísticos</i>	<b>33</b>
<b>2.2.1.1</b>	<i>Redes Neurais Artificiais aplicadas a predição de séries temporais</i>	<b>34</b>
<b>2.2.1.2</b>	<i>Estudos comparativos entre RNA's e preditores econométricos</i>	<b>36</b>
<b>2.2.2</b>	<i>Métodos híbridos</i>	<b>39</b>
<b>3</b>	<b>REFERENCIAL TEÓRICO</b>	<b>43</b>
<b>3.1</b>	<b>Conceitos de econometria</b>	<b>43</b>
<b>3.1.1</b>	<i>Séries temporais</i>	<b>45</b>
<b>3.1.2</b>	<i>Estacionariedade</i>	<b>48</b>
<b>3.1.3</b>	<i>Critérios de informação</i>	<b>50</b>
<b>3.1.4</b>	<i>Testes de Raiz Unitária</i>	<b>53</b>
<b>3.2</b>	<b>Modelos econométricos para séries temporais</b>	<b>54</b>
<b>3.2.1</b>	<i>Médias móveis simples e exponenciais</i>	<b>55</b>

3.2.2	<i>Modelos ARMA, ARIMA e SARIMA</i>	56
3.2.3	<i>Modelo GARCH</i>	58
3.3	<i>Redes Neurais Artificiais</i>	60
3.4	<i>Clusterização de dados</i>	62
3.5	<i>Otimização com métodos Quasi Newton</i>	64
4	<b>METODOLOGIA</b>	67
4.1	<b>Visão geral</b>	69
4.1.1	<i>Quantidade de ativos</i>	69
4.1.2	<i>Período de operação</i>	69
4.1.3	<i>Preditores, classes e categorias de preditores</i>	71
4.1.4	<i>Métricas de avaliação</i>	72
4.1.5	<i>Dinâmica geral de operação</i>	73
4.1.5.1	<i>Módulo Extrator</i>	74
4.1.5.2	<i>Módulo Preditor</i>	75
4.1.5.3	<i>Módulo Negociador</i>	75
4.2	<b>Detalhamento dos módulos</b>	76
4.2.1	<b>Módulo Extrator</b>	76
4.2.1.1	<i>Seleção de ativos por análise de liquidez</i>	76
4.2.1.2	<i>Seleção de tipo de tratamento de dados</i>	79
4.2.1.2.1	<i>Tratamento de dados para RNA de tendência</i>	79
4.2.1.2.2	<i>Tratamento de dados para RNA de candles</i>	81
4.2.2	<b>Módulo Negociador</b>	88
4.2.2.1	<i>Modelo de negociação</i>	88
4.2.2.2	<i>Simulação</i>	89
4.2.3	<b>Módulo Preditor</b>	92
4.2.3.1	<i>Otimização dos preditores</i>	93
4.2.3.1.1	<i>Preditores econométricos</i>	94
4.2.3.1.2	<i>Preditores baseados em Redes Neurais Artificiais</i>	96
4.2.3.2	<i>Momentos de confiança</i>	103
4.2.3.2.1	<i>Evolução da taxa de acerto (ETA)</i>	104
4.2.3.2.2	<i>Capacidade de manutenção da taxa de acerto (CMTA)</i>	107
4.2.3.2.3	<i>Combinação de momentos ETA e CMTA (MTA)</i>	108
4.2.3.3	<i>Comitês de decisão</i>	109
4.2.3.3.1	<i>Comitê de decisão por média (CM)</i>	109
4.2.3.3.2	<i>Comitê de decisão por voto majoritário (CV)</i>	110
4.2.3.3.3	<i>Comitê de decisão por média e voto majoritário (CMV)</i>	111
4.2.3.4	<i>Gerador de cenários</i>	112
4.2.3.5	<i>Otimizador de stops</i>	112
4.2.3.6	<i>Construtor de estratégias</i>	114

4.2.3.7	<i>Considerações finais</i>	119
5	<b>APRESENTAÇÃO E ANÁLISE DE RESULTADOS</b>	121
5.1	Oportunidades de operação	122
5.2	Taxas de acerto	124
5.3	Retornos financeiros	127
5.4	Evolução dos retornos	135
5.5	Avaliação estatística	140
6	<b>CONCLUSÕES</b>	143
6.1	Limitações e propostas de continuidade	144
6.2	Produção bibliográfica	145
	<b>REFERÊNCIAS</b>	147
	<b>APÊNDICE A CARACTERIZAÇÃO DAS SÉRIES</b>	163
A.1	Situação do mercado no período de simulação	163
A.2	Séries de preços	165
A.2.1	<i>BBAS3: Ação ordinária do Banco do Brasil</i>	165
A.2.2	<i>BBDC4: Ação preferencial do Bradesco</i>	166
A.2.3	<i>BOVA11: Índice Bovespa</i>	167
A.2.4	<i>BVMF3: Ação ordinária da BM&amp;F BOVESPA</i>	168
A.2.5	<i>ITSA4: Ação preferencial do Itaú</i>	169
A.2.6	<i>GGBR4: Ação preferencial da Gerdau</i>	170
A.2.7	<i>USIM5: Ação preferencial classe A da Usiminas</i>	171
A.2.8	<i>CSNA3: Ação ordinária do Companhia Siderúrgica Nacional</i>	172
A.2.9	<i>CYRE3: Ação ordinária da Cyrela Realton</i>	173
A.2.10	<i>PETR4: Ação preferencial da Petrobrás</i>	174
A.2.11	<i>VALE5: Ação preferencial classe A da companhia Vale</i>	175
A.3	Comparativo entre as séries do <i>dataset</i>	176
	<b>APÊNDICE B PLATAFORMAS TECNOLÓGICAS</b>	179
B.1	<i>Metatrader 5</i>	179
B.2	Linguagem de programação R	180
B.3	Plataformas de <i>hardware</i>	182
	<b>ANEXO A CARTEIRA TEÓRICA DO IBOVESPA</b>	183



---

# INTRODUÇÃO

---

Este capítulo apresenta uma introdução às finanças quantitativas por meio de uma contextualização desta área de pesquisa. São expostos também os motivos que justificam a dissertação, a proposta de solução desenvolvida, bem como os objetivos almejados durante o processo de elaboração do trabalho. Por fim, apresenta-se a estrutura dos capítulos juntamente com algumas recomendações para leitura.

## 1.1 Contextualização

Métodos computacionais aplicados à negociação de ativos financeiros utilizam-se de princípios de diversas áreas do conhecimento. Com esta seção pretende-se introduzir os principais conceitos de mercado e negociação algorítmica. Para isso é feita uma contextualização que inclui um breve histórico da automação eletrônica nas bolsas, definições de mercado eletrônico e, valendo-se dos desafios na tarefa de se operar ações com base em métodos preditores de séries temporais, o problema de interesse é caracterizado.

### 1.1.1 Breve histórico da automação eletrônica no mercado brasileiro

Até o início da década de 90 a bolsa de valores brasileira, popularmente conhecida por BOVESPA, tinha por principal método para execução de transações<sup>1</sup> entre investidores o chamado Pregão Viva Voz (PVV) (BM&F Bovespa, 2015). No PVV o interesse em negociar um determinado ativo, seja comprando ou vendendo, era demonstrado verbalmente pelo operador durante o período de funcionamento da bolsa. A oferta de um ativo em dado preço e o aceite deste por uma outra parte interessada eram então registrados em cartões perfurados com horário

---

<sup>1</sup> Transação é uma operação concretizada na bolsa de valores. Nesta, uma das partes interessadas concorda em vender ou comprar um ativo de um terceiro que também está disposto a negociar. O termo “transação” é também conhecido no mercado como *tick*, *trade*, *deal*, *match*, negócio ou operação.

e data, estes cartões, mais tarde também chamados de “fitas”, foram introduzidos em 1970 em substituição aos boletos de papel.

O preço de uma ordem feita naquele dado instante era também escrito à giz em uma lousa. Essa prática deu origem a expressão “preço que está na pedra” usada até os dias hoje para fazer referência ao valor da primeira cotação existente na fila de ordens enviadas. Somente ao fim do dia de operações passava-se a processar essas informações. Após o processamento (que levava algumas horas para ocorrer) definia-se como cotação para o mercado, em cada ativo negociado naquele dia, o valor utilizado na última negociação. Além disso, somente após o processamento era possível consolidar a quantidade de papéis pertencentes a cada um dos investidores (FLORIDIA, 2012). O termo “papel”, a propósito, nesta época era adequado visto que as ações de uma companhia disponíveis para negociação eram, até então, nada mais que títulos impressos que davam direito a uma fração de sociedade em determinada companhia (Mundo Trade, 2016). Nesse sentido, utiliza-se frequentemente em mercado de capitais os termos “ação”, “papel” ou “ativo” para referenciar um título societário.

Muitos dos presentes em um PVV não eram necessariamente investidores interessados em utilizar capital próprio. Uma das figuras principais na bolsa de valores nesta época era a do operador de pregão. O operador de pregão podia representar diversos clientes diretamente ou por meio de um segundo operador, o operador de corretora. Ao longo do dia o operador de pregão executava transações baseado em solicitações recebidas do cliente diretamente ou do operador de corretora. Muitas vezes os operadores de pregão tinham a confiança dos seus solicitantes e, por isso, podiam representá-los nas negociações tomando decisões sobre vender, comprar ou manter posições<sup>2</sup>. Neste sentido Floridia (2012) elenca alguns problemas observáveis no PVV:

- Limitação de participantes: Como o espaço era físico, existia uma quantidade máxima de pessoas operando ao mesmo tempo em um PVV. Outro ponto é que o número de clientes atendidos pelo mesmo operador de pregão também era limitado, ou seja, nem todo interessado podia participar de operações na bolsa. Por exemplo, Demarco (2016) cita que no início da década de 90 a bolsa chegou a contar com cerca de 1500 operadores de pregão trabalhando simultaneamente.
- Capacidade de processamento: Por ter ordens geridas por humanos em um espaço físico, o PVV era limitado quanto ao número máximo de ordens diárias. Segundo Demarco (2016), no auge das operações com PVV, eram realizadas cerca de 30 mil operações por dia. Por mais que um ser humano fosse capaz de processar e registrar as ordens solicitadas, ainda assim, essa capacidade era bastante inferior ao que é possível com o uso de computadores. Ainda quanto a processamento, o número de ordens precisava ter um limite visto também que, após a finalização do pregão, a quantidade de tempo entre o fechamento do dia atual

<sup>2</sup> Posição em termos financeiros refere-se ao compromisso firmado entre duas partes em uma negociação, por exemplo, uma parte assume o interesse de compra e outra parte o interesse de venda (UEMATSU, 2012).



e a abertura no dia seguinte era menor do que 24 horas (com exceção dos fins de semana e feriados).

- **Pessoalidade nas relações:** Com limitações de participantes e quantidade de ordens diárias, as transações muitas vezes eram influenciadas pela personalidade nas relações entre os operadores (de pregão e de corretora) e os investidores. Neste sentido, enquanto existiu o PVV, muitos investidores podem ter sido desfavorecidos ou favorecidos baseado na importância que um operador dava ao seu cliente ou a um dado negócio.
- **Alto custo de transação:** Devido à necessidade de diversos tipos de intervenção manual no processo de execução de uma negociação entre partes, o custo das operações em um PVV não era composto apenas pelo interesse dos envolvidos no processo, mas também, pelo custo operacional da burocracia até então existente na bolsa.

Em complemento a [Floridia \(2012\)](#), pode-se citar ainda que, somado a todos estes fatores, existe o risco associado aos possíveis erros humanos envolvidos no processo. Aqui, vale ressaltar, por exemplo, a necessidade de implementação no triênio 1997-1999 de um mecanismo chamado *circuit breaker*. Segundo a versão atualmente regente do Manual de Procedimentos Operacionais de Mercado da BOVESPA ([BM&F Bovespa, 2010a](#)), caso ocorram movimentos bruscos e atípicos de mercado, oriundos de crises globais, notícias impactantes ou, no caso do PVV, de erros humanos, diversas medidas visando o controle da volatilidade<sup>3</sup> dos preços passaram então a poder ser aplicadas (a mais comum delas é interromper todas as negociações durante 30 minutos).

Houve também ainda nesta mesma época uma tendência de automatizar-se os processos relativos às transações eletrônicas envolvendo valores financeiros. Isto não somente nas bolsas de valores do Brasil e do mundo, mas também, na oferta de serviços como *Internet Bankings*, *E-commerces*, *E-bussiness* e outras plataformas que permitiam facilitar a compra e venda de serviços entre clientes e empresas usando a internet ([AMORIM et al., 2011](#)). Assim, no ano de 1990 foi adquirido da bolsa de Toronto o *Computer Assisted Trading System* (CATS). Este sistema inaugurou as negociações eletrônicas em renda variável na BOVESPA. [Amorim et al. \(2011\)](#) cita que com o uso do CATS, houve um crescimento de 1000% na quantidade de negociações diárias e uma redução de 96% na quantidade de operadores de pregão atuando no modelo PVV. Em seguida, atendendo à necessidade de incluir instituições bancárias na bolsa para oferta de uma estrutura de câmara de compensação<sup>4</sup>, o CATS foi substituído por um novo sistema chamado MegaBolsa. O MegaBolsa era utilizado pela *Nyse Euronext*, a bolsa de Paris.

<sup>3</sup> Volatilidade é uma medida associada ao risco no mercado. Diz respeito a magnitude da dispersão dos retornos em torno de uma média em um determinado período de tempo ([Investopedia, 2016](#)). Diz-se que os mercados estão mais voláteis quando existem grandes variações nos retornos dos preços em comparação com períodos nos quais estas foram menores ([SIEGEL, 2009](#)).

<sup>4</sup> A câmara de compensação é uma central por meio da qual instituições financeiras trocam instruções de pagamento ou outras obrigações financeiras (Ex.: Valores mobiliários). As instituições liquidam os instrumentos trocados em um momento determinado com base em regras e procedimentos específicos de bancos ([Banco do Brasil S.A., 2016](#)).

Neste momento a BOVESPA passou a operar de forma híbrida com transações eletrônicas e, ao mesmo tempo, outras em PVV. Foi criada também a Companhia Brasileira de Liquidação e Custódia (CBLC).

Apesar das automações realizadas na BOVESPA e, neste sentido, ter-se iniciado um processo de resolução dos problemas existentes com o PVV, até o ano 2000 ainda existiam oito bolsas de valores operantes em território nacional. Assim, neste mesmo ano, apoiado pela automação eletrônica até então implementada, foram integradas todas as demais bolsas. Essa junção permitiu, após também a aquisição da Companhia de Liquidação e Custódia (CLC) sediada no Rio de Janeiro, que a BOVESPA se tornasse uma plataforma única de acesso para realização de transações em mercado de ações no Brasil. Este foi um importante passo, pois foi possível incluir no pregão outras companhias consideradas menos líquidas<sup>5</sup> e, principalmente, desde então foi possível que sociedades corretoras de valores surgissem por todo o país (BM&F Bovespa, 2015).

Uma corretora de valores, segundo definição dada pela Comissão de Valores Mobiliários (CVM)<sup>6</sup>, deve intermediar transações entre partes interessadas nos mercados de valores mobiliários regulamentados. Corretoras devem prestar serviços que possibilitem a execução de ordens de compra e venda para seus clientes, sendo atividades atribuídas a estas:

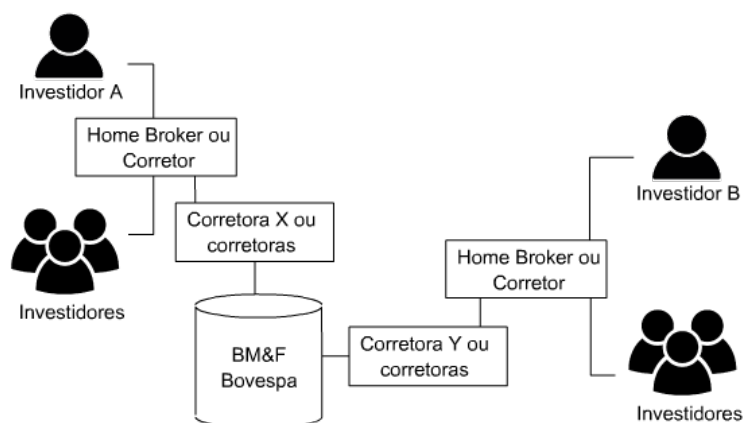
- Realização de análises de investimento;
- Gestão de carteiras e fundos de investimentos e;
- Realização de custódias de ativos financeiros conforme autorizações específicas de seus clientes.

A existência das corretoras possibilitou que pessoas físicas e jurídicas de menor porte, até então impossibilitadas de negociar facilmente na BOVESPA, também pudessem ter acesso ao mercado. Consequentemente, com o crescimento deste segmento, as corretoras ao longo dos anos vêm se desenvolvendo e ofertando, motivadas pela concorrência entre elas, serviços mais diversificados, melhores taxas de operação e, principalmente, ferramentas que facilitam a realização de operações no mercado. Essa modernização das corretoras ocorreu, especialmente, após a unificação de toda plataforma nacional de negociação em mercado de capitais no ano de 2008 quando a Bolsa de Mercados e Futuros (BM&F) foi também integrada a BOVESPA criando-se assim a atual BM&F Bovespa (referenciada a partir deste ponto do texto apenas como BOVESPA).

<sup>5</sup> O termo “liquidez” ou “mercado líquido” é usado para designar a facilidade com que, em um dado ativo, seja possível entrar e sair de posições, ou seja, relaciona-se com a disposição dos operadores em negociar aquela companhia (UEMATSU, 2012) (SIEGEL, 2009).

<sup>6</sup> Autarquia vinculada ao Ministério da Fazenda instituída pela Lei nº 6.385, de 07 de dezembro de 1976 que tem por objetivo criar regras e fiscalizar o mercado de valores mobiliários no Brasil (Comissão de Valores Mobiliários, 2016).

Figura 1 – Intermediação de acesso ao sistema BM&amp;F Bovespa no modelo DMA 1 (tradicional).



Fonte: Elaborada pelo autor.

Outro grande destaque no histórico da automação eletrônica do mercado de capitais brasileiro foi a disponibilização dos *Home Brokers* a partir de 1999. Estes são *softwares* que possibilitam que um dado investidor envie ordens de compra e venda ao mercado, intermediado pela corretora que ele escolheu. As conexões entre os participantes no processo de uso de um *Home Broker* (via Internet) ou por meio de uma solicitação de ordem feita a um corretor é semelhante ao apresentado no diagrama da Figura 1. Pode-se notar que um investidor ou um grupo de investidores (por exemplo, os membros de um clube de investimento<sup>7</sup>) não possuem acesso direto ao sistema da bolsa. Necessariamente estes devem estar vinculados a uma corretora de valores por meio de uma conta. Caso o investidor queira então adquirir uma posição no mercado (compra ou venda de um determinado ativo), este deve comunicar à corretora por meio de um corretor ou utilizando-se de um sistema de *Home Broker*. A corretora, por sua vez, intermedia o processo e, neste momento, aplica custos previstos em contrato que devem ser arcados pelo investidor. Após a ordem ser enviada ao sistema da BOVESPA, esta será inserida em uma fila chamada de “livro de ofertas”. Neste as ordens entram e saem conforme a liquidez e o volume de negócios naquele instante, com quantidades e preços dados pelos investidores. Caso o sistema identifique uma oferta de preço condizente com uma oferta de compra, é então realizada uma operação. Logicamente, antes desta etapa são avaliadas as prioridades de execução das ordens que são (BM&F Bovespa, 2010a; Bússola do Investidor, 2016):

1. Possuem prioridade as ordens com preço mais próximo da cotação atual (último preço negociado);
2. Possuem prioridade as ordens que foram enviadas primeiro ao livro de ofertas, para o caso de existirem ordens com o mesmo preço e;

<sup>7</sup> Clubes de investimento são formados por no mínimo 3 e no máximo 50 investidores. Possuem por objetivo reunir interessados na realização de investimentos em conjunto por meio de corretoras de valores. São regulados pela Instrução CVM nº 494 e pelo Regulamento de Clubes da BM&F Bovespa.

3. O volume de uma ordem não afeta sua prioridade, entretanto, uma mesma ordem, por exemplo, com grande volume, pode ser executada em ofertas diferentes até ser completada.

O sistema da BOVESPA pode emitir diferentes respostas após a solicitação de uma posição do investidor feita pela corretora (ordem executada, pendente, cancelada, dentre outras). Essa resposta é então devolvida pela corretora ao investidor que, baseado na flutuação dos preços, nos indicadores de seu interesse e nela mesma, pode tomar novas decisões e, assim, continuar ou não realizando suas negociações. Este modelo é também conhecido como *Direct Market Access* (DMA) tradicional ou DMA 1.

A intermediação eletrônica de operações por corretoras é utilizada hoje em bolsas de valores de todo o mundo. Este processo é frequentemente referenciado na literatura como *E-brokerage* (GUTMAN; JOIA; JUNIOR, 2014). Outros trabalhos como em Sharma e Bingi (2006), Dasgupta (1998) e Costa e Joia (2003) discutem detalhadamente este modelo onde existe a substituição do PVV pelo, como conhecido no Brasil, Pregão Eletrônico (PE).

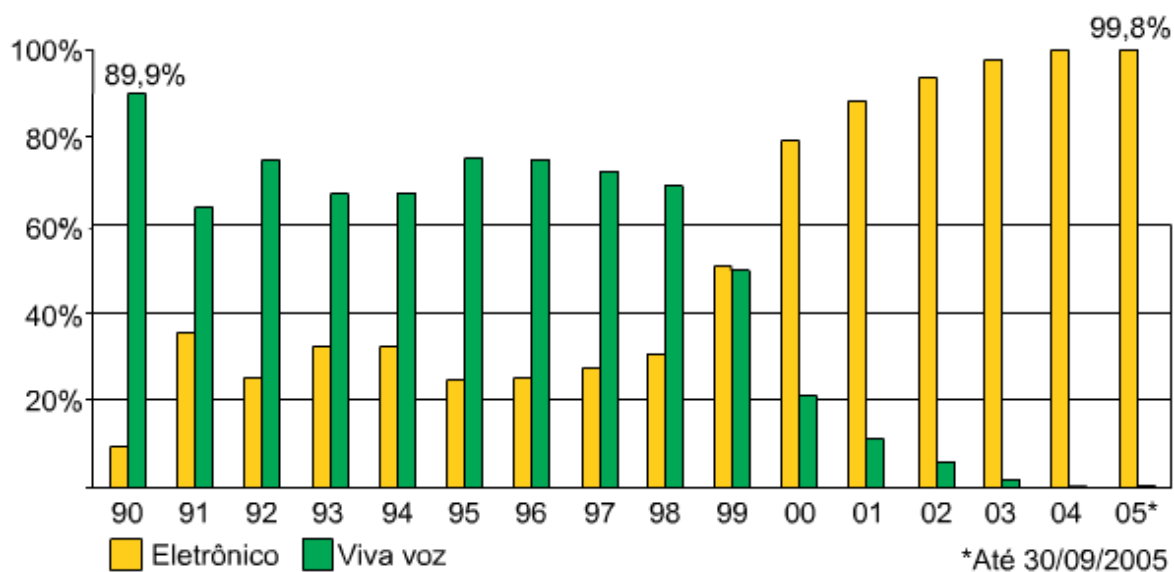
O PE, apesar de possuir um modo de operação bastante específico e peculiar, apresenta vantagens frente ao PVV, pois elimina a necessidade de várias etapas manuais e agentes intermediários (BAKOS *et al.*, 2005). Neste sentido, Amorim *et al.* (2011) cita diversas vantagens na adoção dos *Home Brokers* no mercado de ações brasileiro como praticidade e rapidez nas negociações, acompanhamento da carteira, acesso às cotações em tempo real, envio de ordens pela Internet, consulta às posições financeiras, acesso a custos de operação e outras que não eram possíveis no PVV.

A consolidação do uso do pregão eletrônico foi crescente após a sua implantação gradual desde a década de 90. O gráfico da Figura 2 demonstra um comparativo entre o percentual de negociações realizadas em PVV e PE ao longo de 15 anos. Observa-se que a partir da sua implantação, os dois modelos coexistiram por mais de dez anos, entretanto, em 2005 quase 100% das operações já eram realizadas exclusivamente via PE. Conforme informado em Federação Brasileira de Bancos (2006) o volume negociado na BOVESPA em 1994 era de aproximadamente R\$ 200 milhões ao dia, ao passo que, em 2005, com a maioria das operações ocorrendo eletronicamente, esse valor passou a ser cerca de R\$ 2 bilhões ao dia. Esse crescimento também pôde ser observado quanto ao número de negociações, sendo que estas aumentaram de, em média, 10 mil ao dia, para, em média, 100 mil ao dia.

O gráfico da Figura 3 é outro indicativo do crescimento das operações de forma eletrônica no Brasil. O mesmo foi utilizado para demonstrar o aumento percentual de negociações realizadas exclusivamente via *Home Broker* na apresentação anual de 2010 realizada pelo departamento de Relações com os Investidores da BOVESPA (BM&F Bovespa, 2010b). Pode-se notar que a adoção dos *Home Brokers* cresceu substancialmente ao longo dos últimos 10 anos.


O último dia de operação da bolsa brasileira utilizando o modelo PVV ocorreu em 30 de agosto de 2005 e foi noticiado pelos principais meios de comunicação e jornais naquele ano.

Figura 2 – Comparativo percentual de negociações realizadas em Pregão Viva Voz e Pregão Eletrônico em 15 anos (1990 a 2005) de automação na bolsa.



Fonte: [Federação Brasileira de Bancos \(2006\)](#).

Figura 3 – Crescimento percentual de negócios e volumes em transações realizadas por meio de *Home Brokers* na BOVESPA.



Fonte: [BM&F Bovespa \(2015\)](#).

Neste dia o pregão contava com apenas 40 operadores ([Federação Brasileira de Bancos, 2006](#)). O último negócio realizado em PVV na BOVESPA foi registrado em vídeo e pode ser assistido no site *YouTube* conforme [link](#) da referência [Strauss \(2009\)](#). Desde 2008, com a consolidação da automação eletrônica na BOVESPA e a resposta positiva dada pelos investidores a essas mudanças, outros momentos importantes ainda podem ser destacados como:

- Em 2011: Implantação da plataforma multimercado *PUMA Trading System* para transações

de derivativos e câmbio na bolsa. Adoção da arquitetura multiativo e multimercado *Close-Out Risk Evaluation* (CORE) que permite melhor gestão de riscos na alocação de capital.

- Em 2012: Início da construção do *data center* de Santana do Parnaíba com o objetivo de reorganizar todos os *data centers* da bolsa. Adoção da listagem cruzada de minicontratos de soja com os contratos futuros do índice *Standard & Poor's* (S&P) 500.
- Em 2013: Implantação do módulo de ações do *PUMA Trading System*, unificando os dois principais mercados administrados pela bolsa: ações e derivativos. Adoção de uma metodologia diferenciada para o cálculo do índice Bovespa.
- Em 2014: Finalização do *data center* de Santana do Parnaíba. Implantação da plataforma iBalcão que permite gerenciar outras opções de investimentos como CDB's e LCI's.

A automação da bolsa de valores no Brasil, em decorrência dos diversos motivos até aqui expostos, foi acompanhada também por outras bolsas ao redor do mundo. Esse processo permitiu que o acesso aos dados de mercado fosse facilitado não somente para consultas, como também para manipulação e auxílio na tomada de decisões de compra e venda. Na próxima seção são explicados os conceitos de mercado eletrônico e como a sua recente existência gerou novas possibilidades de negociações por meio do uso de algoritmos.

### 1.1.2 Mercado eletrônico e negociação algorítmica

A possibilidade de se negociar ativos financeiros à distância por meio de sistemas eletrônicos permitiu que uma categoria diferente de investidores pudesse ter acesso ao mercado (XAVIER, 2009). Essa evolução, como argumenta Madeo *et al.* (2012), foi inevitável pois a presença da tecnologia da informação nas bolsas de valores foi instrumento utilizado para desenvolver diferencial competitivo numa época em que houve enorme aumento de demanda de investidores e de número de transações diárias. Para ilustrar esta situação, pode-se citar que em 1967 a Bolsa de Nova York (NYSE) negociava diariamente um volume próximo de 11 milhões de ações. Diante da complexidade deste cenário foi necessário fechar a bolsa às quartas-feiras e reduzir o seu tempo de funcionamento. Mesmo assim, toda essa quantidade de transações representa apenas 0,001% do total de ações negociadas em 2008 (ano com recorde de negociações na NYSE) (NYSE, 2016) (MADEO *et al.*, 2012). O período compreendido entre 1967 e 1970 é conhecido por *Paperwork Crisis* (do inglês, “Crise da Papelada”) (HOLTON, 2002). Esse termo foi utilizado para demonstrar que, já nesta época, não era mais possível o funcionamento da NYSE sem o apoio de um sistema de informação eletrônico.

No livro *Market Wizards* de Jack Schwager (SCHWAGER, 1989) são entrevistados diversos operadores de pregão e investidores famosos (chamados na obra de *top traders*) que estavam atuando no mercado durante a *Paperwork Crisis*. O autor cita Ed Seykota, um engenheiro eletricitista formado pelo *Massachusetts Institute of Technology* (MIT) como desenvolvedor do



primeiro sistema automatizado para negociações no mercado. Cox (1993) e Hartle (1992) também citam *Ed Seykota*, inclusive acrescentam que com este sistema o autor conseguiu obter lucros expressivos principalmente no ano de 1972. Em sua entrevista em Schwager (1989), *Ed Seykota* afirma que a ideia de mecanizar um sistema de negociação foi inspirada nas cartas sobre mercado escritas por *Richard D. Donchian*. *Donchian* foi um investidor de *commodities* em *Wall Street*, além de ser considerado o “pai” das estratégias seguidoras de tendência. É um dos pioneiros no uso de médias móveis para se identificar movimentos de mercado. Seu interesse por negócios e análise gráfica surgiu após ler o livro *Reminiscences of a Stock Operator* de *Jesse Livermore* (The Richard Davoud Donchian Foundation, 2002). Ele compilou em 1934 um guia de negociação contendo 20 regras que, segundo ele, serviriam para se operar de forma correta no mercado de *commodities*. Dixon (1978), em outra biografia feita deste investidor, esta publicada na Revista *Commodities*, conta que *Donchian* recuperou em 1966 o guia de regras e percebeu que as mesmas ainda eram válidas, mesmo 32 anos depois.

*Donchian* e *Seykota* deram os primeiros passos no que se tornaria mais tarde a negociação por meio de algoritmos. *Donchian* contribuiu elencando regras definidas de operação e *Seykota*, por sua vez, criou um sistema computacional que operava na bolsa. Outros investidores como *Warren Buffet* (Warren Buffet, 2016), *George Soros* (George Soros Philanthropy, 2016) e *James Simons* (Simons Foundation, 2016) também ficaram famosos na história das bolsas de valores por usar dados de mercado e regras definidas de operação para obter lucros consistentes ao longo dos anos. Estes inclusive são citados respectivamente como 3º, 23º e 50º homens mais ricos do mundo no *ranking* de bilionários da Revista *Forbes* de 2016 (Forbes, 2016). Aqui, cabe destaque a *James Simons*, pois no interesse do tema desta dissertação, este matemático formado no MIT e doutor pela Universidade de *Berkeley* desenvolveu em 1982, junto a *Shiing-Shen Chern* (também matemático), o atualmente mais rentável fundo de investimento do mundo, o *Renaissance Technologies* (Renaissance Technologies, 2016). Este fundo, que opera a partir de métodos matemáticos e estatísticos, movimenta mais que US\$ 60 bilhões em ativos e se mantém estável com retornos superiores a 35% (ao ano) nos últimos 27 anos (Octafinance, 2015). Uma vertente do *Renaissance* é o fundo *Medallion* que, entre 1994 até 2014, obteve um retorno médio de 71,8% ao ano (sem taxas de operação). O *Medallion* é quase que inteiramente de propriedade dos próprios funcionários da *Renaissance*, em sua grande maioria cientistas de destaque em suas respectivas áreas de atuação (RUBIN; COLLINS, 2015).

O livro *Quants*, lançado em 2010 e de autoria do jornalista *Scott Patterson* (PATTERSON, 2011), apresenta o termo “fundo quântico” para se referir aos fundos de investimento que se utilizam de computação, matemática, física, estatística e outras ciências exatas para, a partir de previsões de movimentos no mercado, acionar sinais de compra e venda, alocar recursos, selecionar ativos em carteiras e outras atividades que buscam gerar lucros operando em bolsa de valores. Neste livro também são citados outros proeminentes proprietários de fundos quânticos como *Ken Friffin* da *Chicago Citadel LLC*, *Boaz Weinstein* do *Deutsche Bank*, *Clifford S. Asness* e *Aaron Brown* da *AQR Capital* e *Peter Muller* da *Morgan Stanley*. O livro se tornou *best-seller*

na lista do *The New York Times* e foi citado em diversos meios de comunicação, inclusive na *Scientific American Magazine* (PATTERSON, 2012) apesar de não ser uma fonte oriunda de pesquisa acadêmica.

Finanças quânticas ou finanças quantitativas são termos equivalentes e observados em diversas literaturas da área. Ambos se referem à métodos e ferramentas computacionais que realizam análises de mercado e negociam ativos baseados em decisões feitas por algoritmos. Neste caso, referem-se também por consequência, as definições dadas aos termos negociação algorítmica, negociação por algoritmos ou, do inglês, *algorithmic trading* ou, simplesmente, *algo trading*. Neste sentido, Hendershott e Riordan (2012) conceituam a negociação algorítmica como a tomada automática de decisão de negociação, com submissão de ordens ao mercado e gerenciamento das respostas a estas ordens enviadas, por meio do uso de algoritmos computacionais. Já Portnoy (2011) diz que a negociação algorítmica se trata da análise estatística do histórico de um dado ativo e, baseado também na condição corrente do mercado, esta busca antecipar a direção do movimento nas séries de preços e, assim, identificar oportunidades de ganhos realizando operações baseadas nas previsões. Segundo Aldridge (2013) é comum observar-se confusão no emprego dos termos relacionados a negociação algorítmica. Esta autora, além de Araujo e Montini (2013), argumenta que os termos *Eletronic Trading*, *Algorithmic Trading* e *High Frequency Trading* (HFT) são muitas vezes usados como sinônimos, apesar de tratarem de aplicações distintas. A negociação eletrônica (*eletronic trading*) trata-se da capacidade de transmitir ordens de mercado de forma eletrônica, pela Internet por exemplo, sem o uso de viva-voz, telefone ou por escrito. A negociação algorítmica (*algorithmic trading* ou *algo trading*) aborda o uso de algoritmos computacionais para a realização do processo de negociação no mercado de capitais. Por fim, a negociação em alta frequência (HFT) se refere ao uso de negociação algorítmica para realizar uma dada quantidade de operações de mercado que, em muitas das vezes, podem acontecer na ordem de até milissegundos. Chlistalla (2011) destaca que na negociação algorítmica as transações podem ser realizadas (caso autorizadas) sem a interferência humana em nenhuma etapa do processo. Finalmente, Smith (2010) comenta que sistemas de negociação algorítmica, quando ainda nos primórdios da automação eletrônica das bolsas, podiam somente negociar carteiras de ações. Nesta época o nome dado a estes sistemas era o de *Program Trading*, termo que hoje está em desuso.

Baseado nestas referências, deste ponto em diante do texto, o termo negociação algorítmica será adotado conforme as definições feitas por Aldridge (2013). Também é importante ressaltar ao leitor que o sistema de negociação baseado em algoritmos, ou seja, todo o arcabouço computacional que compõe as etapas de negociação automatizadas, será referenciado na maioria das vezes como robô investidor. O termo “robô investidor” ou “robô trader” é comumente observado em comunidades de discussão sobre negociação algorítmica na Internet e usado também por empresas brasileiras do ramo. Além disso este termo é recorrente tanto em trabalhos acadêmicos mais recentes, como Hu *et al.* (2014), quanto em mais antigos, como Krolak, Lindahl e Herndon (1973). Geralmente as referências em inglês são feitas à *robo-advisor*, *expert* ou *investor robot*.



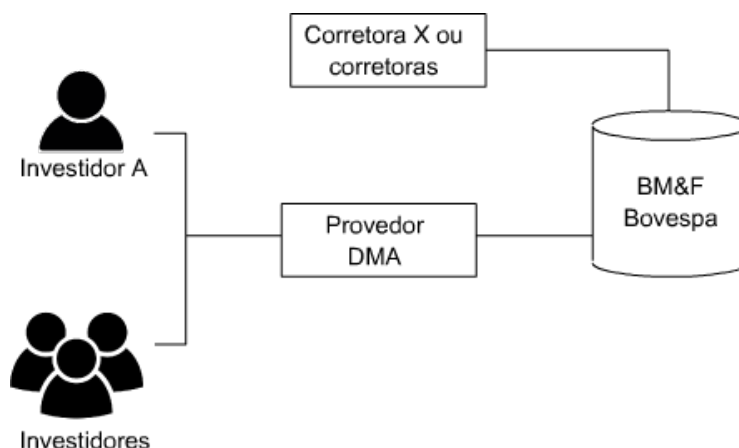
A adoção de robôs investidores para negociação, principalmente em alta frequência, teve início nos EUA a partir de 1990 quando a *Electronic Communication Networks* (ECN) foi aprimorada e a *Security and Exchange Commission* (SEC) deu permissão para a combinação de ordens de compra e venda sem intermediários financeiros de títulos e moedas independentes ou comissionados (*dealers e brokers*) (ALDRIDGE, 2013). Segundo Smith (2010), a partir deste momento novas estratégias começaram a ser desenvolvidas pelos *traders* pois a adoção do HFT aumentou de 30% em 2005 para 75% das operações em 2009. Na Bolsa de Tokyo (TSE), onde é possível contratar planos para alocação de computadores servidores ao lado dos mesmos onde ficam os sistemas de transação da própria TSE, desde 2010 o valor das ações negociadas via robôs investidores triplicou para aproximadamente 270 trilhões de ienes. O número de transações feitas via negociação algorítmica também cresceu sendo que em 2010 representavam 10% de todas as ordens. Já em 2014 este registro foi de 72% (NAKAMURA; HASEGAWA, 2015). Mesmo em países com regulamentações de mercado com mais influência governamental, como é o caso da África do Sul, em 2015 a quantidade de transações feitas por robôs investidores representou 80% do volume total (PLANTING, 2015). Buscando uma regulação para este tipo de operação, outros países como Índia e a Alemanha têm proposto legislações específicas para o uso de algoritmos no mercado (CHAKRABORTY, 2016) (WILSON; WIESMANN, 2013). Inclusive é discutida a adoção da política alemã (caso aprovada) para toda a União Europeia (MADEO *et al.*, 2012). Já no Brasil, de 2011 a 2013, segundo dados da BM&F Bovespa (2013), o uso de HFT cresceu 47,1% chegando a representar 10,6% de todas as negociações realizadas na bolsa no primeiro semestre de 2013 e 9,5% no segundo. Além disso, conforme ofício circular nº 28 de agosto de 2010 da BOVESPA, existem incentivos por parte da CVM para que operações feitas com robôs investidores HFT sejam adotadas<sup>8</sup>. Esses incentivos se dão por meio de descontos dados nas taxas para investidores que realizam grandes quantidades de operações diariamente (BM&F Bovespa, 2010b). Outro grande estímulo na bolsa brasileira foi a disponibilização do modelo DMA. Segundo BM&F Bovespa (2016a) e Malheiros (2012), atualmente este está dividido em quatro categorias, a saber:

- DMA 1 (tradicional): É o modelo possibilitado pelo uso dos *home brokers*, como discutido na seção anterior. Foi disponibilizado a partir de 1999 e segue o fluxo observado na Figura 1.
- DMA 2 (via provedor): Neste modelo (conforme pode ser observado na Figura 4) a corretora, que está vinculada ao sistema da bolsa, autoriza e controla o acesso do *trader* ao chamado *Order Management System* (OMS). Isto é necessário pois o investidor não acessa mais diretamente a corretora para enviar ordens a bolsa e sim, um provedor DMA que é responsável por rotear as ordens. Está disponível desde agosto de 2008.

<sup>8</sup> Não foram encontrados dados para robôs como um todo, as referências feitas pela BOVESPA tratam apenas de operações HFT

- DMA 3 (via conexão direta): Mesmo modelo do DMA 2, contudo, neste caso, não existe a figura do provedor DMA. O acesso do *trader* é feito diretamente ao OMS.
- DMA 4 (*co-location*): O DMA 4 segue a mesma infraestrutura do DMA 3, com a diferença de que os computadores servidores que embarcam o robô investidor do *trader* ficam fisicamente instalados dentro dos *data centers* da própria BOVESPA. Os planos de contratação deste tipo de serviço dão garantias de que a velocidade de entrada das ordens no livro de ofertas seja aumentada, logicamente, devido a diminuição da distância física (MALHEIROS, 2012). O tempo entre o envio de uma ordem e a resposta dada a esta é chamado de latência. No caso do DMA 4, este é o plano que oferece menor tempo de latência dentre todos, sendo também, o mais caro do ponto de vista financeiro. Tanto o DMA 3 quanto o 4 foram disponibilizados no segundo semestre de 2010.

Figura 4 – Modelo de intermediação de ordens no modelo DMA 2 (via provedor).




Fonte: Elaborada pelo autor.

Como se pode perceber é crescente a utilização dos robôs investidores nos mercados mundiais assim como no Brasil. Essa tendência foi projetada em um relatório oriundo de pesquisa do *TABB Group* e *Boston Consulting Group* solicitada pela SEC em 2011 (U.S. Securities and Exchange Commission, 2011). A Figura 5 mostra a previsão de aumento do uso de robôs investidores em HFT nos mercados da Ásia, Estados Unidos e Europa. Em novo relatório do mesmo grupo de pesquisa, desta vez solicitado e publicado pela financeira *Credit Suisse* em 2015, a projeção foi confirmada quanto ao aumento do uso dos robôs como pode ser visto na Figura 6 (TOM *et al.*, 2015). Muitos dos autores consultados comentam o crescimento na adoção de robôs investidores por meio de diversas outras pesquisas realizadas nos últimos anos. Uma revisão bibliográfica completa sobre o tema com foco em uso de computação evolucionária foi feita por Hu *et al.* (2015). Outra com foco no mercado brasileiro pode ser vista em Madeo *et al.* (2012). Malheiros (2012) também apresenta dados sobre este crescimento. Além destas fontes, informações oriundas de outras pesquisas são publicadas anualmente em relatórios oficiais obrigatórios feitos pelas próprias bolsas. Os relatórios da BOVESPA trazem dados relevantes

sobre o uso de robôs investidores no Brasil e podem ser consultados em [BM&F Bovespa \(2016d\)](#) e [BM&F Bovespa \(2016b\)](#).


Por fim, sugere-se ao leitor visualizar um vídeo feito pela empresa americana de *market data* *NANEX LLC*. Este mostra, em uma animação, a evolução das operações feitas via robôs HFT em diversas bolsas do mundo de 2007 até 2013. Durante o filme fica clara a proporção no aumento do uso da negociação algorítmica pelos investidores no mercado de capitais. O *link* do vídeo pode ser visto na referência [Nanex LCC \(2013\)](#).

Figura 5 – Projeção de crescimento do uso de robôs investidores em HFT nos mercados mundiais.



Fonte: [U.S. Securities and Exchange Commission \(2011\)](#).

Figura 6 – Participação percentual ano a ano de operações de fundos ativos, passivos e HFT no mercado americano.



Fonte: [Tom et al. \(2015\)](#).

Posta a possibilidade de negociar ativos financeiros por meio de algoritmos, diversos trabalhos têm proposto o uso de métodos de inteligência artificial para tentar obter lucros consistentes no mercado. Na próxima seção são comentados os desafios que permeiam esta tarefa, cenário no qual se insere também o objeto fundamental desta pesquisa, a construção de um robô investidor.

### **1.1.3 Desafios no uso de robôs investidores**

#### **1.1.3.1 Eficiência de mercado**

Um dos grandes desafios existentes e encarados por profissionais do mercado de capitais é a realização da previsão de comportamento de determinado ativo dia a dia. O mesmo é influenciado por fatores sociais, econômicos e políticos e, por isso, uma das visões deste campo de estudo afirma que o mesmo possui intrínseca à sua natureza a característica da imprevisibilidade (KARA; ACAR; BAYKAN, 2011). É conhecida entre operadores de mercado a chamada Hipótese do Mercado Eficiente (HME), proposta inicialmente por Fama (1969) e Cootner (1964). Essa diz que qualquer técnica de previsão de preços é, pelo menos a princípio, inútil, pois a variação de preços apresenta comportamento aleatório independentemente do mercado onde o ativo está sendo negociado. Esta teoria ganhou força a partir do trabalho *The Theory of Finance* (FAMA; MILLER, 1972) onde, segundo Cova (2011), é feita uma apologia ao acolhimento da HME com a afirmação de que a eficiência do mercado possui sustentação empírica. Em Borges (2010) vê-se uma interpretação desta definição dizendo que a imprevisibilidade de movimentos existe, pois os preços dos ativos refletem todas as informações disponíveis no mercado e, dado que todos os investidores possuem acesso às mesmas informações e todos possuem o mesmo objetivo de lucrar, logo o valor de uma cotação será sempre justo. Já Cova (2011) cita também que a suspeita de existência desta característica já era percebida nos mercados no século passado, quando Bachelier (1900) em um dos primeiros estudos sobre o tema afirmou que as cotações de mercado são aleatórias, teoria que é conhecida hoje como *Market Random Walk* (Passeio Aleatório de Mercado). Este mesmo autor, como também Paiva (2014), afirma que a principal contribuição do trabalho de Bachelier foi reconhecer que os movimentos observados em uma série financeira são de origem *browniana*, o que garantiria a esta uma característica aleatória e independente. O movimento *browniano* é um caso de processo estocástico de Markov específico (GALVAO, 2006) formalizado por Osborne (1962).

Apesar deste posicionamento, outros autores não compactuam com esta visão de eficiência no mercado, pois muitos afirmam que investidores não agem sempre racionalmente. Com isso a HME só prevaleceria sob determinadas condições (ELDER, 2006). Uma destas condições é a possibilidade de que exista correlação entre os valores dos títulos negociados no mercado em um dado instante (PETERS, 1991). Além disso, com o trabalho de Osborne (1962) e outros que iniciaram a difusão do uso de ferramental estatístico para previsão em séries financeiras, principalmente tomando-se por base o pressuposto de normalidade com média estável e variância

finita, foi possível que novas pesquisas surgissem explorando conceitos e métodos baseados no Teorema do Limite Central (COVA, 2011). Dá-se ênfase neste ponto aos trabalhos de:

- *Harry Max Markowitz*, que propôs um modelo de mitigação de riscos de investimento baseado na diversificação de ativos em carteiras;
- *William Forsyth Sharpe*, criador do *Capital Asset Pricing Model* (CAPM), método que possibilita realizar análises de investimento por meio da projeção de expectativa de ganhos;
- *Fisher Black* e *Myron Scholes*, que desenvolveram um modelo para precificação de opções baseado na premissa de que os preços obedecem a tendências inclusas em movimentos brownianos e possuem volatilidade constantes (o método ficou conhecido como *Black-Scholes*) e;
- *Stephen A. Ross*, criador do *Arbitrage Pricing Theory* (APT), uma versão generalizada do CAPM, que modela impactos de preço baseados em acontecimentos inesperados de mercado.

O pressuposto de normalidade na distribuição dos retornos das séries financeiras deu amparo ao surgimento de muitos métodos que, como os citados, mais tarde passaram a ser amplamente questionados. Esta dúvida incorre principalmente devido a diversos experimentos realizados no mercado que mostraram que, em vários ativos e bolsas, existe uma assimetria nas distribuições de retornos. Como exemplo, pode-se citar [Mandelbrot e Richard \(2004\)](#) que investigaram a variação dos preços no índice *Dow Jones* e constataram que não existiu no período do estudo aderência à uma distribuição normal. [Cova \(2011\)](#) cita que *Mandelbrot* em 1964, bem como [Cootner \(1964\)](#) e [Osborne \(1962\)](#), já haviam também observado esta característica em algumas de suas análises. [Grossman e Stiglitz \(1980\)](#) argumentam em seu trabalho que como as informações não estão disponíveis igualmente em tempo e integridade a todos os investidores, pode existir assimetria nos movimentos de mercado. [Paulos \(2004\)](#) afirma que as distribuições de probabilidades relacionadas a preços são melhores representadas quando incluem caudas “gordas” e alta curtose e, se isso não é uma premissa levada em conta, seria o mesmo que se estar assumindo a raridade de eventos como bolhas especulativas e crises financeiras, quando na verdade, apenas no século XX já foram registradas 48 ocorrências de oscilações acima de 7% na *Dow Jones* ([MANDELBROT; RICHARD, 2004](#)). Outros experimentos que buscaram detectar não somente assimetria, mas padrões que influenciam os movimentos no mercado são citados por [Borges \(2010\)](#) e [Cova \(2011\)](#). Alguns deles são relatados a seguir:

- Em dois períodos distintos, inicialmente de 1991 a 1996 e, na sequência, de 1997 até 1999, no trabalho de [Odean et al. \(2007\)](#) foi acompanhada a realização de transações feitas por 7 mil investidores buscando-se analisar a existência de tendências de comportamento.

Para isso os autores utilizaram como métrica o percentual de compra de ativos anteriormente vendidos pelo mesmo investidor (recompra). Os resultados desta investigação revelaram que, neste experimento, os ativos que geraram lucro com vendas no passado foram recomprados duas vezes mais do que ativos que geraram prejuízos.

- A pesquisa do Prof. Dr. *Daniel Kahneman*, ganhador do Prêmio Nobel de Economia, averiguou o comportamento dos investidores sob condições de incerteza. Foi verificado que quando estes estavam frente a uma condição de perda certa ou de perda provável, os mesmos optavam preferencialmente pela perda provável, mesmo que esta os expusessem a maior risco (KAHNEMAN, 2003).
- Em outro experimento da equipe de *Terrance Odean*, [Borges \(2010\)](#) cita que foi avaliada a relutância de investidores em assumir perdas frente à possibilidade de se fechar posições quando estes estavam ganhando. A análise foi feita entre 1995 e 1999 na Bolsa de Taiwan. Os resultados mostraram que, nesta amostra, os negociadores venderam as posições que acusavam ganhos 84% mais do que quando estes estavam em posições que acusavam perdas.
- Segundo [Karsten \(2009\)](#), em palestra feita pelo Dr. *Kahneman* no 5º Congresso Anbid de Fundos de Investimento ocorrida no Brasil, este citou várias vezes os estudos de [Odean et al. \(2007\)](#). Motivados pelas aplicações possíveis, *Jan Karsten* resolveu empreender pesquisa semelhante na BOVESPA. Foram analisadas 12 mil contas de pessoas físicas e jurídicas em operações realizadas entre 2001 e 2004. Os resultados foram muito semelhantes aos obtidos na pesquisa de *Terrance Odean*.
- A fim de analisar o comportamento da volatilidade de retornos diários, [Turner e Weigel \(1992\)](#) realizaram um extenso estudo compreendendo o período que vai de 1928 a 1989. Usaram como base o índice S&P 500. Estes autores notaram evidências de não normalidade na distribuição dos retornos neste índice.

Com base nestas pesquisas até então desenvolvidas e, para muitos investidores que operam diariamente, fica evidenciado que padrões de mercado existem, mesmo que em dados momentos o preço justo seja praticado e, nestas ocasiões, prevaleça a eficiência do mercado. Diversos métodos foram criados e, por se encaixar em períodos onde pressupostos específicos são validados, em muitas das vezes sua aplicação é útil. Contudo, como alerta [Cova \(2011\)](#), a previsibilidade de mercado a longo prazo é uma tarefa complexa e, por isso, nenhuma destas ferramentas é perfeita, acabada ou possui capacidade de explicar os movimentos dos preços com total acurácia. Nesse sentido, qualquer método escolhido deve ser usado com cautela e critério, pensando-se mais nestes como mecanismos analíticos do que como “bolas de cristal”. Com relação à HME, este mesmo autor ainda afirma que:



“Os mercados não são eficientes na forma sugerida por Fama, pois os preços não estão refletindo a cada momento as novas informações disponíveis” (...) “Assim, se for confirmada a noção de que investidores não reagem de forma linear em face das novas informações recebidas, a natureza do comportamento dos mercados financeiros pode ser bastante distinta daquela que a doutrina majoritária tem caracterizado”.

Por fim, sobre a discussão em torno desta validade ou não da HME, principalmente quando usada como argumento contra o surgimento de novos métodos que buscam prever os movimentos do mercado, cabe citação direta a fala do mais rico investidor de todos os tempos, Warren Buffet:

“Eu seria um mendigo vagando pelas ruas com uma caneca nas mãos se os mercados fossem sempre eficientes” (LOWE, 2008).

#### 1.1.3.2 Métodos de análise de mercado

Muitos esforços têm sido empregados na modelagem de séries temporais ao longo dos últimos anos com a finalidade de se obter lucros no mercado, em especial, após o desenvolvimento de métodos de análise de volatilidade em séries especificamente financeiras e não estacionárias (ENGLE, 1982; BOLLERSLEV, 1986). Outro ponto de destaque é que, com a evolução dos computadores, foi possível o processamento de uma quantidade de cálculos antes apenas teorizados. Além disso, foi possível também o desenvolvimento e aplicação de técnicas que envolvem algoritmos baseados em inteligência artificial.

Em relação a métodos para análise de movimentos no mercado, normalmente observa-se uma divisão feita em três vertentes (PIMENTA *et al.*, 2014):

- Os métodos ditos convencionais, que tratam da utilização de estatística de séries temporais e econometria;
- Os métodos de mercado, que tratam da aplicação de análise fundamentalista, análise técnica, *candlestick*, *tape reading*, dentre outros e;
- Os métodos computacionais, que em geral, fazem uso de algoritmos focados em inteligência artificial para, combinando ou não técnicas convencionais e de mercado, realizar previsões.

Outras abordagens têm ganhado notoriedade na comunidade científica e são também vistas em publicações mais recentes. Pode-se citar neste meio, estudos como finanças comportamentais, econofísica, hipótese dos mercados fractais, análise de sentimento de mercado, aplicação de cadeias ocultas de *Markov* dentre outros, além de estudos (como o aqui presente), que combinam ou usam técnicas clássicas de inteligência artificial (ou de outros ramos da ciência)

como métodos de clusterização, otimização mono e multiobjetivo, algoritmos evolucionários, sistemas nebulosos, redes neurais artificiais, máquina de vetores de suporte e afins.

Independente de qual vertente e método o investidor se utilize para operar no mercado, o mesmo geralmente é classificado com base na frequência com que realiza transações de compra e venda. Segundo [Xavier \(2009\)](#) e [Debastiani \(2008\)](#), os tamanhos dos intervalos entre as operações geram as seguintes modalidades:

- *Daytrade* ou *Intraday*: Diz respeito ao investidor que faz diversas operações dentro de um mesmo pregão. Isso pode ocorrer no intervalo de horas ou minutos, situação normalmente observada em operadores de ações que se utilizam de análise técnica. Em minutos ou segundos, frequência observada normalmente (mas não exclusivamente) em adeptos da técnica *tape reading* para operar minicontratos<sup>9</sup>, e milissegundos, como é o caso dos robôs investidores que operam em alta frequência.
- *Swing trade*: Posicionamento que o investidor assume ao atuar no mercado em intervalos de poucos dias, por exemplo, a cada 3, 4 ou 5 dias. Este tipo de investidor normalmente não se dedica integralmente a atividade de operar e, baseado em gráficos, notícias, índices ou outras fontes pode identificar oportunidades (geralmente semanais) no mercado.
- *Position trade*: Quando o operador realiza transações pensando em longo prazo, geralmente, meses ou anos. Nesta classificação ainda podem ser incluídos os operadores que praticam a técnica *Buy and Hold*<sup>10</sup>. Normalmente, os *position traders* utilizam-se de análise fundamentalista para realizar suas operações.

Em qualquer uma dessas, os principais indicativos observados para avaliar-se retorno e risco, diariamente num pregão, em qualquer ativo são: (a) o preço de abertura; (b) o preço de fechamento; (c) o preço mínimo; (d) o preço máximo; e (e) o volume. Existem dois tipos de volume: (i) o volume financeiro, que trata do valor total envolvido nas negociações em moeda local operados em um dia e; (ii) o volume de transações (também chamado de volume de *ticks*), que trata da quantidade de negócios realizados. Por exemplo, pode-se dizer que num dia com alto volume financeiro não houve necessariamente alto volume de transações, pois neste caso, seria provável que foram realizadas poucas operações, contudo estas, envolvendo altos valores financeiros. No presente estudo é utilizado como medida de volume a que trata de número de transações, ou seja, volume de *ticks*. Logo, qualquer referência a volume, sem explicitar volume financeiro, se refere ao volume de transações.


<sup>9</sup> Quando um investidor não possui recursos para adquirir um contrato padrão do índice Bovespa ou de Dólar em mercado à vista, este tem por opção, comprar apenas parte do investimento através da modalidade chamada “minicontrato”. Os minicontratos possuem alta liquidez mas necessitam de uma garantia (compensação financeira como margem previamente depositada na conta da corretora) para serem operados ([KASSAI, 2008](#)).

<sup>10</sup> A técnica *Buy and Hold* consiste em adquirir determinado ativo e, na espera de sua valorização, manter a custódia do papel até o final de determinado período ou quando um objetivo de ganho pré-estabelecido for atingido ([MURPHY, 1999](#)) ([BORGES, 2010](#)).



Abertura, fechamento, mínima, máxima e volume são as informações fundamentais de uma cotação. Dessas cinco dimensões, quatro são utilizadas para compor uma das ferramentas de análises financeiras mais antigas e conhecidas, o *candle*. Um *candle* (conforme [Figura 7](#)) têm esta denominação em decorrência do formato gráfico que o mesmo apresenta quando se dispõe as dimensões a serem analisadas no chamado “gráfico de velas”. Neste esquema, diferencia-se um pregão de alta e um de baixa por meio da cor inserida no corpo do *candle*, sendo normalmente utilizado branco para altas e preto para baixas. Além disso, pode-se também incluir o volume em um gráfico de barras que se situa de forma alinhada e abaixo do *candle* gerado no mesmo pregão. O estudo dos *candles* para previsão de tendências é chamado de *candlestick* ([DEBASTIANI, 2007](#)). A técnica foi desenvolvida pelos japoneses e as primeiras referências datam do século 18, quando voltadas para análises de movimentos do mercado de arroz na província de Osaka no Japão ([KAMO; DAGLI, 2009](#)). Apesar de ser uma técnica antiga, esta é pouco conhecida no ocidente, onde é mais comum o uso de análise fundamentalista e de indicadores de análise técnica derivados dos elementos básicos do *candle* ([DEBASTIANI, 2007](#)). As análises fundamentalista e técnica, por sua relevância e adesão entre investidores, são explicadas com mais detalhes no [Capítulo 2](#).

Figura 7 – Componentes de um gráfico de *candles*.



Fonte: Elaborada pelo autor.

Em relação aos elementos que servem de entrada para métodos preditores de tendência, diversas bibliografias, como em [Adelbiyi et al. \(2012\)](#) e [Guresen e Kayakutlu \(2011\)](#), buscam obter sinais para apoio a tomada de decisão quanto à compra e venda com base em índices diversos derivados dos elementos do *candle*, ou seja, são realizados cálculos utilizando-se estas dimensões básicas para gerar novas que, segundo seus adeptos, são mais confiáveis. Analistas de mercado frequentemente referem-se a estes como indicadores. Indicadores são, assim por

consequência, métricas que muitas vezes podem inclusive ser combinadas a outras informações oriundas de vertentes distintas de estudo. Por exemplo, [Murphy \(1999\)](#) combina, no âmbito da análise técnica, indicadores seguidores de tendência com indicadores osciladores. Já [Paiva \(2014\)](#) e [Martinez et al. \(2009\)](#) utilizam os indicadores da análise técnica como entrada para Redes Neurais Artificiais. Já em [Pimenta et al. \(2014\)](#) é utilizada a técnica de programação genética com indicadores diversos para que sejam geradas regras de compra e venda. [Lam \(2004\)](#), por sua vez, integra a análise fundamentalista com a análise técnica para, por meio também de Redes Neurais Artificiais, gerar e avaliar previsões. Em [Blackledge e Murphy \(2011\)](#) é desenvolvido um algoritmo em linguagem MQL implementado por meio da ferramenta *Metatrader*<sup>11</sup>, que se utiliza de conceitos baseados na Hipótese dos Mercados Fractais. Utilizando-se de métodos de aprendizagem de máquina e otimização, o trabalho de [Andersen e Mikelsen \(2012\)](#) avalia a qualidade na mitigação de risco na construção de carteiras de investimento. Outros trabalhos como [Padhiary e Mishra \(2011\)](#) ou [Patel e Yalamalle \(2014\)](#) analisam o comportamento das Redes Neurais Artificiais (RNA) como índices puramente alimentados pelos elementos básicos do *candle*. Citando-se um outro cenário hipotético, no caso por exemplo de se decidir utilizar somente análise técnica, [Cobel \(2003\)](#) explica como calcular e aplicar mais de 250 indicadores diferentes. Neste sentido, observa-se (de forma geral) que este campo de estudo oportuniza o uso diversas abordagens, no entanto, nota-se também a complexidade envolvida, pois sendo uma área interdisciplinar torna-se necessário conhecer além da proposta de um dado método escolhido, o seu potencial de gerar bons resultados no problema de aplicação. Em outras palavras, é necessário o domínio de conceitos e habilidades nos campos de economia, computação, engenharia, administração e outros ao mesmo tempo. Este requisito é importante não somente para se desenvolver um novo método, mas principalmente para avaliar sua eficiência frente a outros já existentes.

Até o momento sabe-se que métodos para predição de séries temporais são incertos e sua eficácia está diretamente ligada com o tipo de série ao qual estes estão sendo submetidos. Isso ocorre pois, seja no domínio temporal ou de frequências, modelos probabilísticos e estocásticos baseiam-se na aleatoriedade de uma variável num certo período de tempo. Logo, seu valor num próximo instante não pode ser precisamente determinado, somente estimado ([BUSCARIOLLI; EMERICK, 2011](#)). [Morettin e Toloi \(2006\)](#), já no âmbito das séries especificamente financeiras, citam que estas apresentam algumas características de difícil modelagem como tendências, sazonalidade, pontos influentes (atípicos), heterocedasticidade condicional e não linearidades. Além destes fatores, os retornos em séries de preços, além de não serem sempre aderentes a uma distribuição normal (como já discutido), apresentam outra característica incomum, pois, diferentemente de séries de juros ou taxas de câmbio, nestes raramente vê-se momentos de tendências evidentes ([MORETTIN; TOLOI, 2006](#)).

<sup>11</sup> O *Metatrader* é uma plataforma *Homebroker* multimercado que permite, por meio da linguagem de programação MQL, desenvolver algoritmos para o mercado financeiro. A ferramenta é mantida pela empresa *MetaQuotes* ([MetaQuotes Software Corporation, 2016](#)) e está atualmente na versão 5. Mais informações podem ser vistas no Apêndice B.

O interesse inicial no estudo de uma série temporal é a determinação de sua classificação como estacionária ou não estacionária (BUENO, 2011). A estacionariedade evidencia que uma série apresenta valores aleatórios situados ao redor de uma média constante no decorrer de um dado período de tempo (MORETTIN; TOLOI, 2006). Essa característica é importante pois séries estacionárias são análogas às séries convergentes da matemática. Por outro lado, séries não estacionárias podem ser divergentes, o que dificulta o seu estudo (BUENO, 2011). No caso de não estacionariedade, muitas vezes em econometria são aplicadas análises aos resíduos da série e não à série propriamente dita. Para isso são realizadas, por exemplo, diferenciações ou transformações de dados. Isto é necessário, pois somente quando a estacionariedade é constatada, os testes estatísticos envolvidos podem gerar confiança na estimação de médias e variâncias. Estas, por sua vez, neste tipo de série, quando diferenciadas até a estacionariedade passam a ser, por estimativa, “menos inconstantes” ou, em outras palavras, “mais previsíveis” ao longo do tempo.

Séries de preços (como as utilizadas neste estudo) são consideradas na maioria das vezes séries não estacionárias (BUENO, 2011). Em razão disso à modelagem e análise destas cabe a aplicação de técnicas que focam o tratamento de não linearidades e, principalmente, tenham capacidade de detecção, generalização e regressão universal a partir de um conjunto de padrões, a princípio, desconhecido. Para tanto, conforme será apresentado, é proposta uma combinação de métodos econométricos e técnicas de inteligência artificial (em especial as que envolvem reconhecimento de padrões e otimização) que se adequam a estas e outras condições. Os métodos foram selecionados visando os desafios de se estimar com a máxima precisão possível os movimentos futuros em séries temporais, além de também lidar com riscos financeiros inerentes e impostos pelo próprio mercado.

Na próxima seção é abordada a justificativa da pesquisa e, de forma breve e resumida, o arcabouço proposto para este problema na forma de um robô investidor.

## 1.2 Justificativa e proposta

Como apresentado na seção anterior, a automação eletrônica no mercado de capitais como um todo, teve início somente a partir da década de 70 e, no Brasil, somente a partir da década de 90. A popularização do uso de algoritmos para negociação foi um evento ainda mais recente, pois somente nos últimos anos é que corretoras de valores começaram a disponibilizar plataformas *Home Brokers* para seus clientes. Somando-se a isso, desde o surgimento deste campo de estudo, muitas pesquisas na área podem ter sido desmotivadas pela força que teve a Hipótese do Mercado Eficiente junto à comunidade científica, além do que, não levando em conta o fenômeno da assimetria nas distribuições dos retornos, muitas outras empreenderam grandes esforços em metodologias que, apoiadas no Teorema do Limite Central, mais tarde tornaram-se contestáveis (COVA; BASTOS; MACHADO, 2011). Modelos que buscam modelar

com rigor estatístico a volatilidade dos retornos levando em conta características importantes como assimetria e heterocedasticidade condicional só foram introduzidos na década de 80. O uso de técnicas de inteligência artificial para a realização de previsões em séries financeiras só pôde ser empreendido, também, a partir do momento em que a capacidade de processamento dos computadores permitiu a realização de uma quantidade de cálculos mais elevada, como as iterações necessárias à correção de erros em uma rede neural ou às gerações de populações em um algoritmo evolucionário. Revisões bibliográficas de trabalhos neste tema também são recentes, como vê-se em [Atsalakis e Valavanis \(2009\)](#), [Fraenkle e Rachev \(2009\)](#), [Treleaven, Galas e Lalchand \(2013\)](#), [Hu \*et al.\* \(2015\)](#) e [Cavalcante \*et al.\* \(2016\)](#). Neste sentido, este trabalho vem somar-se a outros estudos que envolvem a combinação de modelos estatísticos para séries estacionárias e não estacionárias, além do uso da modelagem de comportamentos não lineares por meio de Redes Neurais Artificiais. Neste contexto o mesmo justifica-se pelo fato de que, sendo esta uma área recente, novas abordagens podem servir de referência à futuras pesquisas, especialmente às aplicadas especificadamente ao mercado brasileiro.

Dado que muitos modelos e publicações ainda fazem referência a HME, este trabalho também se justifica pois, nos ativos operados e no período de aplicação, serve de instrumento e evidência quanto a discussão de sua validade.

Neste capítulo de introdução, com a finalidade de caracterizar o problema e, no segundo capítulo, buscando-se um aprofundamento apenas na aplicação dos métodos econométricos escolhidos e nas Redes Neurais Artificiais, é feita uma breve revisão bibliográfica dos trabalhos até então publicados. Contudo, apesar de notar-se neste levantamento diversas abordagens diferentes envolvendo econometria e técnicas de reconhecimento de padrões, não foi observado nenhum estudo que, particularmente, procurasse criar um elo entre a teoria estatística, os métodos de inteligência computacional e as técnicas de otimização em questão, com a finalidade de criar um ambiente que levasse em conta as seguintes características específicas implementadas neste estudo:

- Metodologia para seleção automática de ativos de alta liquidez. Levando-se em conta volume financeiro e volume de *ticks* dos 3 anos anteriores ao período de operação “cega”<sup>12</sup> do robô, com base nas 50 maiores participações percentuais na carteira teórica do índice Bovespa.
- Caracterização das séries com a finalidade de selecionar um tratamento de dados que, dado um conjunto previamente existente de tratamentos, permita aderir o melhor possível as distribuições dos preços (após tratados) à uma distribuição normal.
- O tratamento prévio dos dados por meio de técnicas de suavização e clusterização buscando diminuir ruídos tanto nas Redes Neurais Artificiais quanto nos métodos econométricos.

<sup>12</sup> Operação cega diz respeito ao período de operação em que o robô tomou decisões e realizou negociações de forma independente em um segmento de série desconhecido.

- Um método para conversão da série de preços de fechamento para uma nova série que denota tendência.
- Uso de três classes diferentes de preditores econométricos sendo:
  - *Simple Moving Average* (SMA) para lidar com tendências acumuladas. Estão incluídas no robô 6 tamanhos diferentes de SMA.
  - Seletor automático baseado em parametrização otimizada por meio do uso do algoritmo BFGS buscando-se minimizar o *Akaike Information Criteria* (AIC) envolvendo os métodos a seguir listados. Foram utilizados 5 tamanhos diferentes de janelas. O mesmo será referenciado no texto apenas como “Seletor SARIMA”.
    - \* *Autoregressive Moving Average* (ARMA) para janelas que denotem estacionariedade;
    - \* *Autoregressive Integrated Moving Average* (ARIMA) para janelas que denotem não estacionariedade e, por isso, necessitem de diferenciações (processo de integração); e
    - \* *Seasonal Autoregressive Integrated Moving Average* (SARIMA) que, além do propósito já exposto no método ARIMA, expande sua aplicabilidade avaliando também correlação temporal em frequências mensais.
  - *Generalized Autoregressive Conditional Heteroskedasticity* (GARCH) que possui capacidade de modelar variâncias de volatilidade passadas de forma condicional, ou seja, através do tempo. Esse modelo lida com a previsão de volatilidade dos retornos pois embarca na sua estratégia o pressuposto de que a incerteza varia conforme a dispersão observada em *clusters* maiores ou menores de volatilidade. O método GARCH no robô têm seus parâmetros fixados para manter sua utilização, e é também atrelado a um modelo ARMA que é otimizado também pela minimização da métrica AIC. São incluídos 3 tamanhos de janelas diferentes para o GARCH.
- Uso de Redes Neurais Artificiais distintas para propósitos distintos sendo:
  - RNA específica para previsão de tendência baseada em série de tendência e janela clusterizada e;
  - RNA específica para previsão de retornos baseada nos retornos tratados das dimensões do *candle* com volume de *ticks*.
- Otimização das topologias das Redes Neurais Artificiais por meio de:
  - Tipo de rede, algoritmo de correção de erros, taxa de aprendizagem e convergência: Tomando-se por base métricas que avaliam tempo de processamento, época máxima de convergência e erro quadrático médio (EQM). Testes em todos os ativos durante 100 dias num período escolhido aleatoriamente em cada um. Testes de redes neurais

do tipo *Radial Basis Function* (RBF), *MultiLayer Perceptron* (MLP), *Elman* e *Jordan* em séries tratadas. Por fim, algoritmos de correção *Backpropagation* padrão (BP), BP com termo de *momentum*, BP resiliente e BP com algoritmo *Levenberg-Marquadt*;

- Quantidade de neurônios: Por meio da métrica *Percentage of Change in Direction* (POCID) que avalia a acurácia na capacidade de previsão da direção dos movimentos de preço de fechamento, tanto para redes de *candles* quanto para redes de tendência. Foram avaliadas as quantidades de 5, 10, 15, 20, 25, 30, 35 e 40 neurônios na camada escondida; e
  - Tamanho das janelas móveis: Por meio de testes exaustivos em redes de *candles* (foram testadas janelas de 10, 20, 30, 35, 40, 45 e 60 dias) e por meio da clusterização na série de tendências em redes de tendências com um algoritmo K-médias otimizado pelo método de *Elbow*.
- Construção de estratégias rentáveis baseadas em:
    - Seleção otimizada e temporal de preditores (direito a voto) com base em:
      - \* Seletor que realiza análise diária da evolução da taxa de acerto (ETA) baseado na *Exponencial Moving Average* (EMA) desta métrica;
      - \* Seletor que avalia a capacidade de manutenção das taxas de acerto em períodos de tamanho fixo (CMTA) e;
      - \* Combinação dos dois seletores ETA e CMTA (MTA).
    - Seleção otimizada e temporal de tipos de comitê de decisão sendo:
      - \* Comitê baseado na média das previsões de preço de fechamento e tendência (CM);
      - \* Comitê baseado no resultado do voto majoritário para direção do movimento no preço de fechamento e tendência (CV) e;
      - \* Combinação dos dois comitês CM e CV (CMV).
    - Otimização de *stops*<sup>13</sup> ano a ano em cada ativo, com base na distribuição de retornos dos últimos dois anos de negociações.
  - Desenvolvimento de um algoritmo simulador de negociações para operações em *candles* diários.

Os detalhes sobre cada um dos módulos e testes feitos durante o processo de implementação do robô são discutidos no [Capítulo 4](#), referente a metodologia.

<sup>13</sup> *Stops* são limitações colocadas nas perdas e nos ganhos em uma dada operação. Normalmente vê-se o uso de *Stoploss* (SL) que trata da saída da operação quando se atinge um limite de prejuízos e *Takeprofit* (TP) que é equivalente ao SL mas diz respeito a saída no limite de lucros.

Por fim, o estudo presente se faz importante pois, o interesse em diminuir os riscos e aumentar os retornos com operações no mercado, mesmo quando não havia o apoio de ferramentas como as aqui utilizadas, já era notório. Nesse sentido, qualquer contribuição que venha a diminuir a lacuna entre teoria e experimentação neste campo é válida, dado que o comportamento do mercado é um problema muito complexo. Neste sentido, o método aqui não se limitaria somente a aplicação em séries financeiras, mas também, a qualquer série que tenha características semelhantes independentemente de sua origem. Por este motivo é também justificável o estudo, pois, este porventura poderia, com poucas adaptações, contribuir em outras áreas.

Feita esta argumentação quanto aos motivos que justificam a existência deste trabalho procurou-se, durante o desenvolvimento da dissertação, atingir os objetivos listados na próxima seção.

## 1.3 Objetivos

Este estudo propõe atender ao objetivo geral e aos objetivos específicos descritos a seguir.

### 1.3.1 *Objetivo geral*

Propor um método computacional na forma de um robô investidor que seja capaz de selecionar ativos líquidos no mercado, realizar previsões a partir das dimensões dos *candles* destes, usar as previsões para operar no mercado e, frente aos *benchmarks* escolhidos, apresentar na medida do possível e nas métricas de avaliação, um desempenho superior.

### 1.3.2 *Objetivos específicos*

São objetivos específicos deste trabalho:

1. Revisar a literatura referente a negociação algorítmica, especialmente os trabalhos que envolvem métodos econométricos e Redes Neurais Artificiais aplicados, principalmente, a BOVESPA, a fim de dar suporte ao entendimento dos conceitos usados na construção de um robô investidor.
2. Analisar, selecionar e testar métodos que sejam adequados a cada etapa do processo de operação de um robô investidor.
3. Construir o arcabouço computacional que permita selecionar ativos, realizar previsões e operar no mercado por meio de ferramentas tecnológicas adequadas (linguagens de programação, mecanismos de extração e armazenamento de dados, geradores gráficos e outros).

4. Avaliar os resultados de cada módulo e em cada etapa do processo com a finalidade de gerar dados que permitam direcionar as decisões de implementação.
5. Executar testes e realizar comparações frente aos *benchmarks* de interesse.
6. Delinear conclusões buscando-se entender os resultados obtidos e, neste sentido, contribuir com a área de pesquisa.

## 1.4 Estrutura da dissertação

Esta dissertação está estruturada em seis capítulos, dois apêndices e um anexo.

Neste primeiro capítulo foi contextualizado o problema de interesse, foram apresentados conceitos relevantes e os desafios existentes neste campo de estudo. Por fim, foram apresentados os objetivos que guiaram este trabalho de pesquisa.

No segundo capítulo é feita uma revisão bibliográfica de trabalhos correlatos. Foi dada preferência a seleção de trabalhos que estão no mesmo escopo da proposta aqui discutida, ou seja, que envolvam negociação algorítmica por meio de preditores econométricos e/ou Redes Neurais Artificiais aplicados a BOVESPA.

Após a revisão, no terceiro capítulo, é apresentado um referencial teórico que tem por objetivo explicar com detalhes cada um dos métodos que fazem parte do robô investidor. Ressalta-se que estes três capítulos iniciais têm por finalidade contribuir didaticamente com o tema, familiarizando o leitor com os tópicos abordados nos capítulos seguintes.

O quarto capítulo trata da metodologia. Logo, neste ponto encontra-se a principal contribuição desta dissertação. Pode-se ver, passo a passo, como opera o robô investidor desde a seleção dos ativos até a geração de resultados. São apresentados detalhes dos: (a) módulo extrator de dados, que trata da metodologia de seleção de ativos líquidos e do tratamento dos dados; (b) módulo preditor, que aborda a otimização de todos os preditores envolvidos no estudo, a seleção dos melhores preditores, o sub-módulo responsável pela construção de estratégias de negociação baseado nos cenários otimizados (seletores de preditores, comitês de decisão e definição de *stops*) e geração de sinais de compra ou venda; e (c) módulo negociador, que trata da estratégia de negociação diária integralizando lucros ou prejuízos ao longo do tempo e, a partir destes, gerando resultados na forma das métricas de interesse.

No quinto capítulo são apresentados os resultados práticos da aplicação do robô em ambiente simulado de forma analítica (por ativo) e sintética (médias gerais). Para isso são feitas inicialmente avaliações individuais do próprio robô como evolução dos retornos percentual e financeiro, taxas de acerto, quantidades de operações realizadas e o impacto das taxas de corretagem hoje praticadas pelo mercado nos resultados. Na sequência, podem ser vistas comparações do robô contra (a) as médias obtidas pelos preditores em cada classe de preditor (SMA, Seletor SARIMA, GARCH, RNA de *candles* e RNA de tendências); (b) os melhores preditores em



cada classe de preditor; e (c) contra todos os preditores aplicados individualmente. Ainda nos comparativos são apresentadas tabelas e gráficos de evolução dos rendimentos ao longo do período de avaliação. Por fim, pode ser vista uma avaliação estatística tanto em taxa de acerto quanto em rendimentos percentuais do robô contra os melhores preditores de cada classe e, também, com os melhores preditores entre si.

No sexto capítulo encontram-se as conclusões tidas durante todo o desenvolvimento do estudo. São apresentadas também algumas sugestões de continuidade para uso em trabalhos futuros, as limitações identificadas durante a pesquisa e, as publicações científicas já feitas com base nos resultados preliminares obtidos por protótipos deste robô construídos ao longo do programa de mestrado.

Ao final do sexto capítulo é disposta a lista das referências bibliográficas.

Os apêndices A e B complementam a dissertação com, respectivamente, a caracterização das séries selecionadas e as descrições das tecnologias utilizadas.

Finalmente, no anexo A, pode ser encontrada a carteira teórica do Ibovespa de 2010 utilizada como fonte das séries.

### **1.4.1 Material complementar online**

Diversos estudos gráficos complementares ao texto estão disponibilizados no *link* da referência [Nametala \(2016\)](#). Este material não foi incluído diretamente na dissertação por questões estéticas de apresentação. Quando for conveniente à consulta, na respectiva parcela do texto existirá menção a este conteúdo extra.



---

## REVISÃO DE LITERATURA

---

Este capítulo traz uma breve revisão bibliográfica que tem por objetivo apresentar o “estado da arte” no que se refere ao tema sob estudo. Para tanto, é feita inicialmente uma introdução aos principais métodos de mercado, sendo estes a análise técnica, a análise fundamentalista e a teoria de *Dow*, muito utilizadas nos últimos anos como base para alimentação de métodos computacionais e estatísticos. Os métodos computacionais e estatísticos são também discutidos em seguida, levando-se em conta estudos que envolvem, pelo menos em algum nível, as teorias que concernem a econometria e/ou as redes neurais artificiais. Todo este embasamento é feito com base em diversos trabalhos relacionados ao tema.

### 2.1 Métodos de mercado

Um analista técnico é aquele que, baseado no histórico da série de preços, busca operar quando se convence de que encontrou possíveis ciclos (repetições de padrões) (BREALEY; MYERS, 1992). Os primeiros registros de métodos para operação no mercado existem desde 1750 (BORGES, 2010) *apud* (BOTELHO, 1999) e, desde então, tiveram destaque os abordados nos tópicos a seguir.

#### 2.1.1 Teoria de Dow

*Charles Dow* foi um editor do *The Wall Street Journal* que publicou diversas ideias sobre os movimentos dos preços (ABE, 2009). A teoria de *Dow* enumera seis princípios, que são brevemente discutidos abaixo (RHEA, 1993; SHAN, 2012; ABE, 2009):

- 1º princípio - As médias descontam tudo: O primeiro princípio diz que todas as informações do mercado, sejam notícias, dados de relatórios de companhias, saúde econômica e outros já estão embutidos nos movimentos dos preços, logo, são inerentes as séries.

- 2º princípio - O mercado possui três tendências:
  - Tendência primária: Movimento de longo prazo que pode durar anos.
  - Tendência secundária: Movimento de médio prazo que pode durar meses.
  - Tendência terciária: Movimento de curto prazo que pode durar dias.
- 3º princípio - A tendência primária, distintamente na alta ou na baixa, se divide em três fases:
  - Movimento de alta - Acumulação: *Insiders*<sup>1</sup> identificam que uma empresa se manterá valorizada devido a uma eminente prosperidade e direcionam suas compras às ações desta, acumulando-as.
  - Movimento de alta – Alta sensível: Investidores atentos, como os analistas gráficos, logo após a fase de acumulação, conseguem detectar o início do movimento de alta e, então, iniciam após os *insiders*, também um processo de abertura de posições.
  - Movimento de alta – Euforia: Após a alta sensível, o comportamento de mercado em tendência crescente torna-se uma notícia amplamente divulgada. Esta então chama a atenção dos demais investidores. O excesso de otimismo atrai operadores amadores. Essa situação gera especulação. Neste momento os investidores profissionais abandonam suas posições pois entendem que há inflação de preços. Inicia-se o movimento de reversão.
  - Movimento de baixa – Distribuição: Detectada a euforia, investidores profissionais continuam a se desfazer de suas posições, contudo, com o mercado ainda otimista, muitos investidores amadores continuam a acreditar na tendência de alta.
  - Movimento de baixa – Baixa sensível: A deflação dos preços é notada pelos analistas técnicos que, no sentido inverso da alta sensível, iniciam um processo de venda das ações. Investidores amadores continuam a não perceber a iminente reversão de movimento. Inicia-se a instauração da tendência de baixa.
  - Movimento de baixa – Pânico: Investidores amadores tornam-se pessimistas e começam a tomar decisões irracionais devido a percepção de perdas. Notícias negativas sobre o mercado começam a ser divulgadas e, neste sentido, muitos começam a fechar posições devido ao medo de ter perdas aumentadas. O ciclo inicia-se novamente voltando a acumulação.
- 4º princípio - Volume confirma tendência: Este princípio diz que quando uma tendência é iniciada, seja de alta ou de baixa, o volume das negociações também aumenta. Próximo de uma reversão de uma tendência, o volume por sua vez diminui.

<sup>1</sup> *Insider* é um termo utilizado no mercado para se referir a um investidor que detém informações privilegiadas oriundas de fontes ainda não publicadas (ABE, 2009).

- 5º princípio - Reversões de tendência são confirmadas por rompimentos de suportes, sendo considerados dois tipos:
  - Suporte de fundo: É o menor preço estabelecido na série histórica no último ciclo de tendências. Se o preço corrente ultrapassar este valor, então espera-se que a tendência seja revertida.
  - Suporte de topo: É o preço máximo atingido no último ciclo. Caso o preço atual rompa o limite estabelecido por este último preço máximo, então espera-se que a tendência seja também revertida.
- 6º princípio - Um “pivô” é sinal definitivo de reversão de tendência: Pivô é um “padrão” que se forma quando o preço corrente se aproxima de um dado suporte (fundo ou topo) mas não o rompe, para na sequência, mover-se em direção ao suporte contrário e rompê-lo.

Autores que mais tarde se envolveram com o desenvolvimento da análise técnica se embasaram na teoria de *Dow* para construir os indicadores técnicos usados até os dias de hoje (SHAN, 2012).

### 2.1.2 Análise Técnica

A análise técnica é aplicada ao mercado não necessariamente para tentar prever sua tendência, mas para dar evidências, por meio de formas geométricas padronizadas e/ou indicadores numéricos, de que a mesma já está estabelecida (COVEL, 2004). Em Martinez *et al.* (2009) é dito que a análise técnica pode ser dividida em duas abordagens, sendo que, a primeira, trata da tomada de decisão com base na análise de formações de desenhos que se repetem nos gráficos de preços. Essa é conhecida como análise gráfica ou análise grafista. Estes mesmos autores afirmam que essa primeira abordagem é altamente subjetiva pois depende diretamente da opinião pessoal do analista de mercado. A segunda abordagem diz respeito a um conjunto de fórmulas matemáticas que, com base nos elementos que compõem o *candle*, volumes e outros índices de mercado, geram resultados numéricos mais facilmente interpretáveis (os chamados indicadores técnicos, já discutidos no Capítulo 1).

Goldberg e Nitzsch (2001) citam que o objetivo principal da análise técnica é o de identificar tendências, pois os modelos de maior sucesso são aqueles que conseguem definir quando uma tendência está consolidada. Debastiani (2008) agrupa os indicadores de análise técnica em três conjuntos distintos e faz as seguintes descrições de cada um:

- Rastreadores ou seguidores de tendência: São indicadores que estão sempre atrasados em relação ao mercado pois sua fórmula de cálculo apenas sintetiza informações históricas. São recomendados para investidores conservadores pois denotam confirmação de tendências. Estes permitem aproveitar apenas parcialmente as oportunidades de operação, já que

estão sempre atrasados. Enquadram-se neste grupo: Médias móveis diversas, *Average Directional Index* (ADX), *Moving Average Convergence and Divergence* (MACD), *On Balance Volume* (OBV), dentre outros.

- Osciladores: Indicam previsão de reversão ou esgotamento de uma tendência. São recomendados a investidores predispostos ao risco pois, como tentam prever acontecimentos futuros, não podem garantir a concretização de um dado movimento. Na categoria de osciladores pode-se citar, como exemplo, Índice de Força Relativa (IFR), *Rate of Change* (ROC), *Force Index* (FI), *Momentum*, Estocástico, dentre outros.
- Operadores por canais: Diz respeito a combinação de alguns operadores da classe de rastreadores com outros da classe de osciladores. Estes possuem por objetivo definir quando um preço está próximo ou distante do seu valor dito “devido” para um dado momento de interesse. São incluídos neste grupo Canais Simples, Envelopes de Médias Móveis, Bandas de *Bollinger* dentre outros.

Outros tipos de agrupamento destes indicadores podem ser vistos em [Elder \(2006\)](#), [Treleaven, Galas e Lalchand \(2013\)](#) e [Abe \(2009\)](#). Em uma revisão bibliográfica sobre o tema feita por [Hu et al. \(2015\)](#), este afirma que não existe até o momento uma taxonomia padrão e consistente para indicadores de análise técnica. Deste ponto de vista, o autor sugere um novo tipo de agrupamento, mais analítico.

Não é objetivo desta dissertação descrever fórmulas de indicadores técnicos, mesmo porque, estes não são utilizados no robô investidor em nenhuma etapa. Como discutido no [Capítulo 1](#), não existe também consenso científico até o momento sobre a aplicabilidade da análise técnica. Assim, caso seja de interesse do leitor conhecer mais sobre este método de mercado, recomenda-se consultar o trabalho de [Cobel \(2003\)](#), uma enciclopédia que traz fórmulas de 272 indicadores técnicos e os contextos aos quais seus adeptos recomendam aplica-los.

### 2.1.3 Análise Fundamentalista

A análise fundamentalista trata da tomada de decisão no mercado com base na saúde financeira das companhias nas quais pretende-se negociar suas ações. São avaliadas condições que envolvem desempenho econômico mundial e regional, humor dos mercados, dados fiscais, interpretação histórica do posicionamento de uma empresa em seu setor de atuação e outros ([JURICEK, 2014](#)). Em [Abe \(2009\)](#) são citados balanços patrimoniais, demonstrações de resultados de exercícios anuais, fluxo de caixa, notícias e outros instrumentos que, como estes, são usados para compor índices específicos da análise fundamentalista.

Os usuários desta vertente de atuação no mercado acreditam que os movimentos dos preços refletem a situação política, administrativa e macroeconômica na qual se inserem as empresas do ramo ([MARTINEZ et al., 2009](#)). Neste sentido, os dados oriundos deste tipo de

análise são utilizados para estimar movimentos futuros e, assim, operar principalmente a longo prazo.

Borges (2010) e Damoran (2007) citam que as estratégias a longo prazo possibilitadas pela análise fundamentalista se baseiam nas seguintes premissas:

- É possível medir as relações existentes entre o valor apresentado por uma ação e os índices de saúde de sua respectiva companhia;
- A relação “saúde da empresa-valor da ação” apresenta estabilidade ao longo do tempo e;
- Caso o valor do preço não retrate o mesmo suposto pela relação “saúde da empresa-valor da ação”, este então será corrigido a longo ou médio prazo para o “valor devido”.

Por fim, pode-se citar como proeminentes adeptos da análise fundamentalista os investidores *Benjamin Graham*, considerado o “pai” da diversificação de investimentos (CAVALCANTE *et al.*, 2016; HU *et al.*, 2015) e, o já citado, *Warren Buffet*, diretor da *Berkshire Hathaway*, uma companhia de fundos financeiros americana que tem crescimento médio de 20,3% ao ano e usa análise fundamentalista como base de operação (estudo compreendido no período que vai de 1965 até 2008) (Berkshire Hathaway Inc., 2008).

## 2.2 Trabalhos Relacionados

### 2.2.1 Métodos computacionais e estatísticos

As aplicações em mercado de capitais que se utilizam de redes neurais artificiais e preditores econométricos focados em tratamento de não linearidades como o GARCH, são bastante abrangentes. Podem ser vistos diversos trabalhos onde são feitos estudos comparativos entre as duas vertentes e, em menor quantidade, propostas de métodos híbridos (GAMBOGI, 2013). Pommerenzenbaum (2014) cita que neste universo de estudos feitos, poucos são os que investigaram o comportamento dos métodos utilizando como ambiente o mercado brasileiro. Neste sentido, autores de revisões bibliográficas mais recentes criticam uma das principais revisões da área feita por Atsalakis e Valavanis (2009). Estes dizem que a mesma, apesar de ser considerada um *survey* extenso e completo, contém apenas um trabalho aplicado a predições no índice Bovespa. Além disso, esta mesma revisão já pode ser considerada relativamente defasada dado que as pesquisas em finanças quantitativas são recentes (CAVALCANTE *et al.*, 2016).

Em Santos *et al.* (2016) é feita uma revisão bibliográfica dos últimos dez anos (126 trabalhos) com foco somente no Brasil e, quanto a técnica, abordaram o uso de redes neurais artificiais principalmente para finanças. Os autores concluíram que as pesquisas apresentaram aumento de 50% entre 2004 e 2013 usando como ambiente a bolsa de valores nacional. Além disso, os mesmos afirmam que quando foram utilizadas redes neurais artificiais, percebeu-se

uma melhora de resultados na maioria das vezes. Os mesmos também alegam que, por sua maleabilidade, a técnica de redes neurais artificiais tem sido empregada não somente em previsão de preços, como também, na previsão de falências, avaliação de crédito, previsão de insolvência, detecção de fraudes, avaliação de propriedades e outras do campo financeiro.

Ainda quanto a revisões bibliográficas, além de [Atsalakis e Valavanis \(2009\)](#) e [Santos et al. \(2016\)](#), merecem destaque os trabalhos de [Cavalcante et al. \(2016\)](#), [Murekachiro \(2016\)](#), [Hu et al. \(2015\)](#), [Soni \(2011\)](#), [Roshan, Gopura e Jayasekara \(2011\)](#), [Krollner e Finnie \(2010\)](#), [Paliwal e Kumar \(2009\)](#), [Gooiher e Hyndman \(2006\)](#) e [Zhang e Patuwo \(1998\)](#), todos comumente referenciados em artigos, dissertações e teses consultadas.

Alguns trabalhos desenvolvidos já foram citados no [Capítulo 1](#). Além destes, a seguir podem ser vistas pesquisas que tratam inicialmente do uso de redes neurais artificiais, unicamente. Na sequência, alguns estudos que buscaram comparar sua capacidade de previsão frente aos preditores econométricos são discutidos.

#### 2.2.1.1 Redes Neurais Artificiais aplicadas a predição de séries temporais

[Roman e Jameel \(1996\)](#) propuseram uma metodologia para construção de portfólios de investimento multimercados. Os autores defendem que a diversificação entre mercados é benéfica. No experimento utilizaram redes MLP e redes recorrentes *Elman* em um período simulado de quatro anos e em cinco bolsas diferentes. As conclusões dos mesmos denotam inexistência de diferenças substanciais entre os resultados obtidos quando foram comparados os dois tipos de redes empregadas.

[Zhang e Patuwo \(1998\)](#) analisaram e avaliaram diversos trabalhos que envolvem RNA's. Estes relataram em seu estudo que muitos dos trabalhos examinados apresentaram resultados inconsistentes devido a não observação de questões referentes a estrutura da rede neural ou devido à existência de linearidade nas funções mapeadas. O primeiro autor, neste mesmo ano, publicou em [Zhang e Hu \(1998\)](#) um estudo onde foram empregadas diversas configurações diferentes de redes MLP ao mercado de moeda inglesa e americana, incluindo a variação das entradas. As conclusões feitas tratam basicamente do quanto a topologia da rede usada é determinante para a geração de predições boas ou ruins.

[Patel e Marwala \(2006\)](#) aplicaram RNA's do tipo MLP e RBF na previsão de preço de fechamento dos índices *Dow Jones*, *Johannesburg Stock Exchange All Share*, *Nasdaq 100* e *Nikkei 225*. O melhor e o pior resultado obtido quanto a taxa de acerto no movimento (alta/baixa) destes índices foram de 72% e 64%, respectivamente.

O trabalho de [Martinez et al. \(2009\)](#) relatou um sistema de *trading* onde as entradas da RNA são médias móveis juntamente com o indicador técnico Bandas de *Bollinger*. Os autores afirmaram que a avaliação das redes por meio de métricas financeiras é uma abordagem mais adequada, dado que as RNA's podem ser consideradas sistemas “caixa-preta”, onde nuances não



necessariamente relativas a proximidade do valor real ao das predições podem ser capturadas. Os resultados deste trabalho mostraram que as RNA's, como propostas, foram melhores frente a todos os *benchmarks*, sendo que no melhor resultado o sistema dobrou o capital investido.

O trabalho de [Gambogi \(2013\)](#) apresentou um sistema de negociações que toma decisões de compra e venda no índice S&P 500 por meio de redes MLP. Foi utilizado um período de 5 anos para avaliação (2008 a 2012). Neste, o autor testou diversas configurações de RNA e escolheu as melhores com base nos conjuntos de treinamento. As que apresentaram taxas de acerto acima de 60% foram aplicadas ao período de operação. O sistema mostrou resultados superiores a evolução do próprio índice no período e, também, a técnica *Buy and Hold*.

[Paiva \(2014\)](#) realizou 630 mil simulações manipulando 28 ativos financeiros brasileiros distintos. Para tanto, utilizou-se do coeficiente de *Hurst*<sup>2</sup> para argumentar que com este é possível detectar padrões históricos nas séries (segundo ele, justificativa para o uso de RNA's). Após testar diversas configurações de RNA's alimentadas por indicadores técnicos e aplicar as melhores em quatro cenários diferentes de operação, o autor relatou que a rentabilidade do modelo proposto foi superior a rentabilidade de qualquer um dos ativos quando tomados individualmente. O mesmo citou também que “a diferença entre a rentabilidade do modelo de redes neurais artificiais e o melhor fundo de investimento de 2013 foi de aproximadamente 30%”.

[Pommeranzenbaum \(2014\)](#) variou a quantidade de neurônios na camada intermediária, os valores máximos para os pesos sinápticos e a taxa de aprendizagem em redes MLP. Este utilizou correlação cruzada entre as séries de máxima, mínima, fechamento e abertura para selecionar dados de entrada das redes. As séries utilizadas foram os índices de diversas bolsas mundiais e indicadores técnicos. O autor relatou que para preço de fechamento obteve uma acurácia de 60% em relação a série real e que, prevendo o valor do próximo dia, pôde superar a evolução do índice Bovespa.

[Thiele e Adami \(2016\)](#) combinaram três redes neurais artificiais buscando prever a direção do movimento para o dia seguinte ao período analisado. Foram utilizadas as séries dos ativos ITUB4, PETR4 e VALE5 no período de operação compreendido entre janeiro de 2011 a março de 2014. Os autores relataram em suas conclusões uma taxa de acerto próxima a 59% e, no sentido de validá-la como bom resultado, argumentaram que todas as séries que alimentaram o sistema apresentaram quedas no período do estudo. Citaram também os trabalhos de [Bahramy e Crone \(2013\)](#), que obteve taxa de acerto de 57% na previsão de cotação de moedas; de [Yildiz, Yalama e Coskun \(2008\)](#), que aplicado a previsão de índices do mercado de Istambul obteve taxa de acerto de 74,5%; e [Zhang, Jiang e Li \(2007\)](#), que operando no mercado de Xangai obteve taxa de 56,3%. Vale ressaltar que os trabalhos usados pelo autor para fins de comparação operaram em mercados e períodos diferentes.

---

<sup>2</sup> O coeficiente de *Hurst* é uma métrica estatística utilizada para medir a existência de memória de longo prazo em séries temporais ou em qualquer outra estrutura que dê evidências de padrões fractais ([QIAN; RASHEED, 2004](#)) ([MANSUKHANI, 2012](#)).

Giacometl (2016) em sua dissertação, com resultados iniciais também publicados em Giacometl, Galante e Pereira (2015), construiu dois comitês de decisão baseados em redes neurais artificiais com o objetivo de prever movimentos de mercado. O autor cita que a maioria dos estudos tenta prever o valor do próximo preço ou o retorno. No entanto, a previsão da direção pode gerar melhores resultados já que esta pode ser considerada suficiente para construção de uma estratégia de investimento. O sistema foi aplicado aos mercados brasileiro e americano utilizando, respectivamente, *candles* de 15 minutos no período compreendido entre 01/07/2014 e 18/09/2014 em nove ativos; e *candles* diários entre maio de 2008 e janeiro de 2015 em nove ativos. Reportou-se rendimento médio de 66% no mercado brasileiro e 88% no mercado americano. Esses resultados foram comparados com: (i) a técnica *Buy and Hold* que apresentou, respectivamente também nos ativos brasileiros e americanos, 11% e 55%; (ii) a análise trivial<sup>3</sup> que obteve os valores de 55% e 66%; (iii) uma rede neural de tendência que isolada obteve 33% e 88%; (iv) o indicador técnico SAR que obteve 44% em ambos os mercados e, finalmente; (v) uma rede neural temporal que acusou 77%, também nos dois mercados. Esse autor recomendou em suas conclusões o uso dos comitês de decisão pois, por meio destes, conseguiu identificar momentos de maior acurácia das redes neurais artificiais utilizadas.

Sathe *et al.* (2016) empregaram algoritmos diversos de regressão em conjunto com médias móveis para realizar previsões utilizando também redes neurais artificiais. Os autores relataram que melhoraram a acurácia dos métodos, quando aplicados individualmente, de 20% para até 60%, quando aplicados em conjunto.

Qiu, Song e Akagi (2016) aplicaram uma rede neural MLP com seleção de entradas baseada em lógica *fuzzy* para previsão de retornos tomando por base o *Nikkei 225*, um índice da bolsa japonesa. Testaram 900 combinações de parâmetros mantendo fixo o algoritmo de correção *backpropagation* padrão. Para a valoração dos pesos sinápticos e do *bias* utilizaram algoritmos com abordagem evolucionária. Os autores deste trabalho não fizeram uma análise financeira pois não acoplaram ao sistema de predição um módulo negociador. Contudo, relataram que o método abordado pela RNA em conjunto com a otimização dos parâmetros foi benéfico e, nesse sentido, superou os resultados das redes onde não houve a otimização de parâmetros.

#### 2.2.1.2 Estudos comparativos entre RNA's e preditores econométricos

Werbos (1988) realizou um estudo onde foi comparada a capacidade de modelagem de séries temporais feita pelas redes neurais artificiais recorrentes treinadas com *backpropagation* frente a métodos estatísticos diversos de regressão. O ambiente de aplicação foi o mercado de gás natural americano no ano de 1981. O autor constatou que, em seu estudo, as redes superaram os métodos estatísticos.

Shabri (2001) comparou o modelo ARIMA com uma rede neural MLP com *backpro-*

<sup>3</sup> A análise trivial ou previsão ingênua é um *benchmark* também encontrado em trabalhos da área que trata de tomar o valor do preço do próximo instante como o último valor conhecido na série temporal.

*pagation* padrão. Foram utilizadas cinco séries oriundas de setores comerciais diferentes sendo aviação, hotelaria, demanda de água, produção e comércio. Algumas das séries são de países diferentes e de épocas diferentes. Os dados foram normalizados antes de serem submetidos aos métodos de previsão e a métrica de avaliação foi o EQM. O autor concluiu que tanto a RNA quanto o ARIMA têm capacidade de produzir bons resultados em séries que apresentem tendências e sazonalidades. Já para as séries irregulares, o mesmo sugeriu o uso do método ARIMA.

Gomes (2005) utilizou dois tipos de séries, uma referente ao comportamento de solos e outra a valores de inflações de países desenvolvidos. Este autor comparou redes neurais artificiais recorrentes (*Elman, Jordan e Elman-Jordan*) e outras diversas com topologia *feedforward* com os métodos ARIMA e *Autoregressive Fractionally Integrated Moving Average* (ARFIMA). Em suas conclusões o autor afirmou que, considerando os erros absolutos obtidos em cada método, as redes neurais artificiais se apresentaram como boas alternativas nas séries referente a comportamento de solos e, nas séries de inflação, para quase todos os países, as redes neurais artificiais foram superiores aos métodos ARIMA e ARFIMA. O autor ainda propôs um novo algoritmo híbrido que, envolvendo redes neurais artificiais e uma heurística para ajuste dos pesos sinápticos, mostrou-se promissor.

Catalao *et al.* (2007) realizaram previsões de demanda de energia elétrica para o mercado espanhol e americano levando em conta os anos de 2000 e 2002. Para tanto aplicaram em sua pesquisa os métodos ARIMA, *Naive* e uma rede neural MLP com *backpropagation* associado ao algoritmo de *Levenberg-Marquardt*. As métricas envolvidas no estudo foram Média Absoluta Percentual dos Erros (MAPE), Soma dos Quadrados dos Erros (SSE) e Desvio Padrão dos Erros (SDE). Os cenários avaliados levaram em conta também as estações do ano como períodos de sazonalidade. Os autores concluíram que a rede neural foi superior em todos os cenários e em todas as métricas, seguido pelo método ARIMA e, por último, o *Naive*.

Miranda, Ceretta e Lopes (2012) utilizaram 3332 cotações compreendidas entre 02/01/1998 e 16/06/2011 da série de fechamento diária do índice Bovespa. Os autores realizaram o tratamento da série transformando-a em retornos e na sequência aplicando à mesma uma transformação logarítmica. Foi comparada a capacidade preditiva de uma RNA MLP contra o modelo ARMA. Para isso foram tomadas como métricas o EQM e o coeficiente de explicação  $R^2$  ajustado. Os autores concluíram que ambos os métodos se mostraram satisfatórios, contudo, a RNA mostrou-se sutilmente melhor nas duas análises.

Mohamed (2013) também comparou a capacidade preditiva das redes neurais artificiais frente aos métodos estatísticos. Em seu estudo, que envolveu a modelagem de retornos no mercado egípcio no período compreendido entre 01/01/2002 e 24/01/2011, este aplicou os métodos ARMA, GARCH e redes neurais artificiais diversas. O autor alega que as redes neurais artificiais apresentaram resultados superiores aos métodos postos a comparação.

O trabalho de Sousa e Menezes (2013) comparou a capacidade de previsão do modelo

ARIMA frente a uma rede neural recorrente *Elman*. Foram utilizadas quatro métricas de acurácia baseadas em erros diferentes, sendo Erro Médio (ME), Média Absoluta de Erros (MAE), Raiz do Erro Quadrático Médio (RMSE) e MAPE. Como objeto de aplicação foi tomada a série de preços, com observações mensais, referente ao custo do etanol no estado de Goiás entre janeiro de 2005 e dezembro de 2011. Na análise comparativa dos modelos relatou-se que o ARIMA foi superior nas medidas MAE e RMSE, ao passo que, a rede neural foi melhor em ME e MAPE. Foi também relatado que no segmento da série onde existia baixa volatilidade, tanto a rede quanto o ARIMA apresentaram desempenho similar. Os autores atribuíram esse ocorrido “à facilidade de captar-se o padrão de comportamento da série temporal” neste segmento específico.

Duarte (2014) aplicou os modelos ARMA, GARCH e redes neurais artificiais recorrentes à predição de demanda de banda em sistemas de rede para Internet. Foram realizadas análises baseadas em acurácia relativas as métricas de RMSE, em períodos com localização temporal e tamanhos diferentes. Foi afirmado pelo autor que a RNA, numa análise global, exibiu melhor acurácia para a maioria dos cenários simulados, dando destaque a diferença de 32% de RMSE obtida frente ao ARMA e ao GARCH. O mesmo também relatou que, na presença de alta volatilidade, o GARCH mostrou-se como melhor alternativa, pois exibiu uma diferença de 29% de RMSE frente aos outros modelos, incluindo a rede.

Nametalá *et al.* (2016) compararam os resultados obtidos por uma estratégia híbrida frente aos métodos *Buy and Hold*, SMA, ARMA, ARIMA, GARCH, compra e venda aleatória e uma RNA MLP com *backpropagation* padrão. Foram utilizadas as séries de preços dos ativos CMIG4, EMBR3 e ITUB4, da *commoditie* de Boi Gordo e do índice Bovespa, no período compreendido entre novembro de 2012 e novembro de 2013. A estratégia híbrida obteve retorno financeiro percentual médio (entre todos os ativos da carteira) de 22,99%, seguida pela RNA MLP com 17,51%. O *Buy and Hold* obteve 10,2%, na sequência vieram os métodos econométricos sendo, ARMA com 7,2%, SMA com 7,08%, ARIMA com 6,52% e GARCH com 0,2%. O pior resultado foi apresentado pelo modelo de operações aleatórias que apresentou um prejuízo de -23,79%.

Charef e Ayachi (2016) compararam predições realizadas por redes MLP, com diversas topologias, e o modelo GARCH parametrizado nas cotações do dólar, euro e iene no mercado tunisiano. A métrica selecionada para comparação foi o EQM. Levou-se em conta as fases de treinamento e validação das redes, antes de sua aplicação. Nas séries das três moedas avaliadas a rede neural obteve erros inferiores, mas muito próximos aos do modelo GARCH.

Diversos trabalhos que realizaram comparações entre os métodos estatísticos e as redes neurais artificiais podem ser consultados nas bases acadêmicas disponíveis na *web*. Pretendeu-se com esta seção dar ao leitor apenas uma visão geral por meio de estudos que buscam, em cenários diferentes, avaliar se existem diferenças ou semelhanças na aplicação de cada uma das vertentes. Nas revisões bibliográficas já referenciadas no início da [subseção 2.2.1](#) são abordadas também, de forma mais geral, outras análises mais completas.

### 2.2.2 Métodos híbridos

Após a difusão do uso de redes neurais artificiais para predição no mercado financeiro na década de 90, muitos foram os trabalhos que empreenderam análises e testes com diversas topologias. Prevaleceu também neste período o uso de redes MLP com algoritmo *backpropagation*. Pode-se observar, além disso, que a seleção de entradas era majoritariamente realizada privilegiando-se o uso de indicadores da análise técnica. Já a partir de 2000, nota-se um maior emprego das redes neurais artificiais junto à métodos estatísticos e/ou outras técnicas computacionais que não necessariamente são alimentadas com indicadores técnicos (GAMBOGI, 2013). Outro marco importante na década de 2000 foi o início da utilização de métricas relacionadas a ganhos financeiros e acerto na direção dos movimentos dos preços. Até então, métricas relativas a acurácia como EQM, RMSE, SDE e outros eram predominantes (POMMERANZENBAUM, 2014) (GAMBOGI, 2013) (MARTINEZ *et al.*, 2009). Por consequência, percebe-se também, em trabalhos realizados a partir de 2000, uma maior consideração quanto a construção de sistemas automáticos que levem em conta as premissas exigidas por alguns métodos estatísticos, como a estacionariedade e/ou uma distribuição específica constante.

A partir da revisão de Atsalakis e Valavanis (2009), já é considerável a quantidade de estudos que tentam se utilizar não somente do poder das redes neurais artificiais, como também de técnicas especializadas em certos contextos não lineares e com características sazonais, como a modelagem de volatilidade condicional. Desta perspectiva, Zhang e Patuwo (1998) já vislumbravam o potencial dos métodos híbridos ao afirmar que o uso de redes neurais artificiais e econometria, quando aplicadas individualmente, não produzem resultados conclusivamente melhores entre si. A análise bibliométrica com foco apenas no mercado brasileiro feita por Santos *et al.* (2016) têm como conclusão que “não é clara a diferença do desempenho de diferentes técnicas” e, por isso, é sugerida “a combinação de características de ambas as técnicas para melhorar a predição ou classificação de desempenho global dos resultados dos trabalhos. A este respeito, estas duas técnicas (...)” - estatística e redes neurais artificiais - “(...) tornam-se métodos para construção de modelos complementares, ao invés de serem considerados métodos concorrentes”.

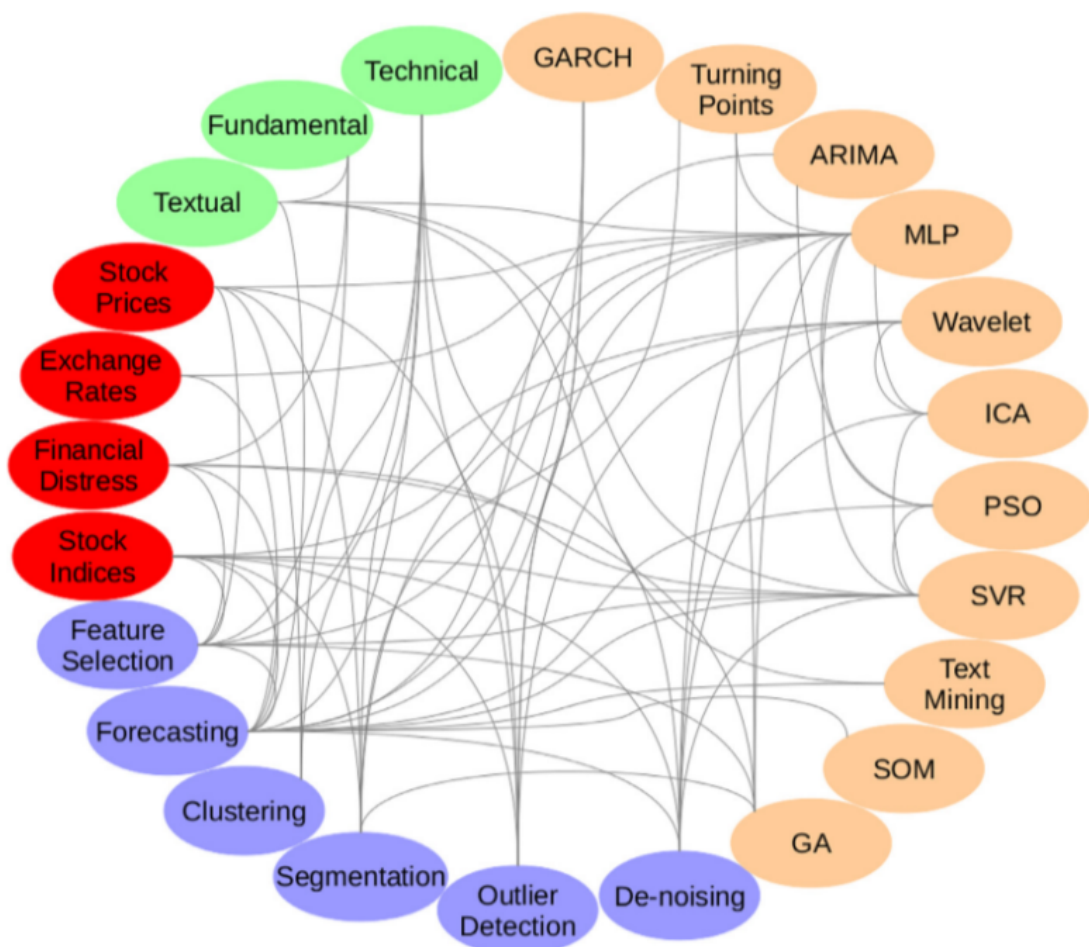
Por fim, Cavalcante *et al.* (2016), na mais recente e completa revisão bibliográfica consultada acerca de finanças quantitativas, argumentaram que o número de trabalhos que são desenvolvidos na área é grande, contudo poucos são publicados em jornais e conferências acadêmicas relevantes e, por isso, em sua análise, empregaram filtros buscando selecionar artigos meritórios a fim de obter-se apenas o que é considerado até então o “estado da arte”. Os autores abordaram os elementos básicos que servem à composição de um robô investidor. Reportaram estudos que abrangem pré-processamento de dados, detecção e remoção de ruídos, segmentação de séries temporais, clusterização temporal, modelos preditores e métodos de avaliação. Quanto aos modelos preditores é possível ver no artigo que as redes neurais artificiais são destaque na área juntamente as *Support Vector Machines* (SVM). São relatados diversos estudos que não

somente se utilizaram unicamente de redes neurais artificiais como outros que combinaram diferentes tipos de redes. Eles também relataram mecanismos híbridos que buscaram associar soluções individuais geradas por diferentes métodos oriundos de diferentes áreas. Segundo os autores, esta abordagem pode reduzir a quantidade de parâmetros que geram incerteza e estocasticidade nos modelos. Dentro deste escopo, de métodos híbridos, [Cavalcante et al. \(2016\)](#) citaram os trabalhos de [Liang et al. \(2009\)](#), [Wu e Shahidenpour \(2010\)](#), [Zhu e Wei \(2013\)](#), [Kourentzes, Barrow e Crone \(2014\)](#) e [Nayak, Mishra e Rath \(2015\)](#). É notório que todos os trabalhos referenciados são publicações recentes, dos últimos sete anos. Por consequência, os autores complementam ao dizer que a área em si não é totalmente nova, pois as pesquisas em séries temporais já têm muitas décadas de existência, entretanto as abordagens computacionais e, em especial, as híbridas, são recentes. Nesta revisão também pode-se ver abordada a importância do tratamento do fenômeno chamado de *concept drift* que trata da mudança de distribuição dos dados no decorrer do tempo e, neste sentido, da necessidade de que os métodos (neste caso, híbridos ou não) sejam capazes de se adaptar ao longo do processo de previsão temporal. Este ponto foi tratado, ao lado de *deep learning* e gerenciamento de portfólio, como um dos desafios e direções futuras necessárias à pesquisa. Finalmente, no interesse desta dissertação, pode-se observar na [Figura 8](#) um diagrama onde estão dispostas técnicas de previsão, parâmetros de entrada, áreas de aplicação e objetivos de cada método, todos catalogados na revisão bibliográfica de [Cavalcante et al. \(2016\)](#). As abordagens foram conectadas por linhas para demonstrar as relações existentes entre elas. Nota-se que a técnica de redes neurais artificiais MLP tem sido amplamente utilizada para geração de modelos preditores, ao passo que, os métodos estatísticos (como ARIMA e GARCH) não foram tantas vezes considerados em usos híbridos.

No referencial teórico do capítulo a seguir são explicados os modelos estatísticos empregados junto as redes neurais artificiais para a criação do robô investidor. Cada modelo é especialista em um tipo de previsão. Como também será demonstrado no [Capítulo 4](#), comitês de decisão são usados para avaliar a qualidade de cada preditor tempo a tempo, com o objetivo de aplicar um destes especialistas apenas quando o mesmo consegue demonstrar confiabilidade. O uso de comitês de decisão para mercado financeiro também é considerado uma abordagem recente por [Cavalcante et al. \(2016\)](#). Nesse âmbito os mesmos referenciaram trabalhos publicados a partir de 2010, como [Neto et al. \(2010\)](#), [Cavalcante e Oliveira \(2014\)](#), [Mabu, Obayashi e Kuremoto \(2015\)](#) e [Ballings et al. \(2015\)](#).



Figura 8 – Uso combinado de técnicas (bege), entradas (verde), aplicações (vermelho) e objetivos (roxo) no mercado financeiro. Análise de trabalhos publicados em jornais e conferências acadêmicas sobre finanças quantitativas entre 2009 e 2015. Nota-se um grande uso de redes neurais artificiais MLP, ao passo que, métodos estatísticos como GARCH e ARIMA foram poucas vezes considerados. Destaque também para entradas oriundas de análise técnica (*candles*) e, dentre os objetivos, a realização de previsão.



Fonte: Cavalcante *et al.* (2016).





---

## REFERENCIAL TEÓRICO

---

Este capítulo apresenta um referencial teórico acerca dos métodos específicos embarcados no robô investidor. São abordados, de forma sucinta, os conceitos de econometria, análise de séries temporais, a teoria por detrás de cada método e os algoritmos de inteligência computacional/otimização utilizados.

### 3.1 Conceitos de econometria

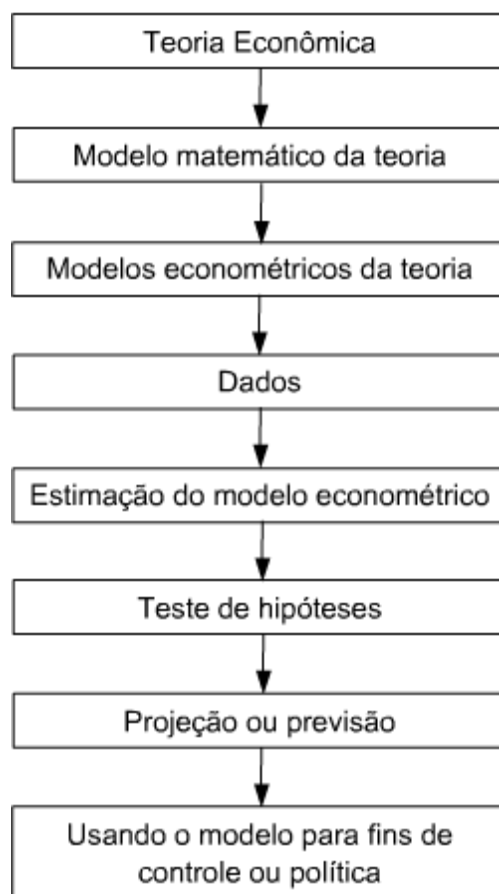
A econometria, em uma interpretação literal do termo feita por [Gujarati e Porter \(2008\)](#), possui o significado de “medição econômica”. Este mesmo autor cita em seu livro “Econometria Básica” outras conceituações importantes como a de [Samuelson, Koopmans e Stone \(1954\)](#), que dizem que a “econometria pode ser definida como a análise quantitativa dos fenômenos econômicos ocorridos com base no desenvolvimento paralelo da teoria e das observações e com o uso de métodos de inferência adequados”. Segundo [Tintner \(1968\)](#) a “econometria, resultado de determinada perspectiva sobre o papel da economia, consiste na aplicação da estatística matemática a dados econômicos para dar suporte empírico aos modelos formulados pela economia matemática e obter resultados numéricos”. Outra definição pode ser vista em [Goldberg \(1964\)](#), onde é dito que “a econometria pode ser definida como a ciência social em que as ferramentas da teoria econômica, da matemática e da inferência estatística são aplicadas à análise dos fenômenos econômicos”.

Baseado nestas definições e no âmbito da econometria, neste trabalho foram aproveitados os conceitos da chamada “estatística econômica”. A estatística econômica diz respeito a forma de planejar experimentos, coletar, processar e apresentar dados econômicos ([GUJARATI; PORTER, 2008](#)). Entretanto, certos tipos de dados de mercado não podem ser coletados com o rigor previsto em experimentos planejados clássicos. Nesse sentido, entra o papel do econometrista que, por meio de ferramentas especiais que combinam técnicas de economia, estatística e matemática, pode realizar análises personalizadas a cada caso, permitindo assim a execução de inferências

em fenômenos de ordem financeira (GOLDBERG; NITZSCH, 2001).

A concepção de um modelo matemático que possa explicar os dados contidos em uma amostragem de origem econômica, em especial e neste caso, os preços ou retornos de ações negociadas em bolsas de valores, pode ser sumarizado conforme a Figura 9. No robô investidor procurou-se automatizar os processos onde é necessária a intervenção humana, ou seja, do econometrista. Assim, dos passos vistos nesta figura, foram incluídos algoritmos que atuam na fase de “Dados”, “Estimação do modelo econométrico”, “Teste de hipóteses” e “Projeção ou previsão”. A etapa de “Modelos econométricos da teoria” também é utilizada, pois esta serviu de base para a escolha dos métodos empregados dentre tantos outros existentes. Nesse sentido, optou-se logicamente por métodos que trabalham com séries temporais, visto que os dados de preços das ações estão disponíveis apenas neste formato. Outros motivos que levaram a seleção de SMA, ARMA, ARIMA, SARIMA e GARCH são discutidos nos tópicos seguintes desta seção onde, também, os mesmos são explicados.

Figura 9 – Anatomia da modelagem econométrica.



Fonte: Gujarati e Porter (2008).

### 3.1.1 Séries temporais

Qualquer conjunto de observações dispostas de forma ordenada no tempo pode ser considerada uma série temporal (MORETTIN; TOLOI, 2006). Logo, na construção de uma série temporal, as observações coletadas devem ser realizadas em intervalos regulares (GUJARATI; PORTER, 2008).

Não é usual em referências de origem acadêmica observar autores que considerem séries temporais de ações como séries contínuas. Isso acontece pois, na maioria dos exemplos abordados em livros e artigos, as mesmas estão sempre discretizadas, conforme uma dada cotação para um dado momento (diária, mensal, anual ou outra). Contudo, sob ponto de vista prático do mercado, se os ativos que geram essas cotações forem altamente líquidos, a questão de considerar uma série de ações contínua ou discreta é discutível. Isso ocorre pois, dado que uma nova cotação (para uma dimensão qualquer do *candle*) pode ser gerada em intervalos menores que até milissegundos (e em intervalos irregulares), a definição do espaço de tempo  $\Delta t$  para coleta do valor da cotação é uma escolha a ser feita pelo próprio investidor. Nesse sentido, entende-se que *candle*, agora do ponto de vista das séries temporais, nada mais é do que uma concepção imaginária para preços de fechamento, abertura, mínima e máxima em um dado momento. Por consequência, pode-se afirmar que, “dentro” de um *candle* diário (como a coleta de cotação feita a cada 24 horas, por exemplo) existem inúmeros outros valores de cotações possíveis em intervalos de tempo diferentes e necessariamente menores (para 24 horas, por exemplo, de 3 em 3 horas, de 1 em 1 hora, 15 em 15 minutos e assim por diante). Caso um intervalo  $\Delta t$  seja convencionado, ou seja, esteja definido o período dos *candles*, neste caso ter-se-á então uma transformação da série, antes sem discretização definida, para, uma série discreta.

De forma geral, Morettin e Tolo (2006) formalizam o conceito de série temporal dizendo que, conforme representado na Equação 3.1, uma série poderá ser um vetor  $\mathbf{Z}(t)$ , de ordem  $r \times 1$ , onde, por sua vez,  $t$  é um vetor  $p \times 1$ . Neste caso, esta poderá ser multivariada (para  $r > 1$ ) e/ou multidimensional (para  $p > 1$ ). Dentro deste conceito, a representação de uma série de *candles* poderia ser feita como na Equação 3.2, sendo que nesta o vetor  $cn(t)$  é composto das variáveis preço de abertura ( $pa$ ), preço de fechamento ( $pf$ ), preço máximo ( $pn$ ), preço mínimo ( $px$ ) e volume ( $vl$ ), cada qual possuindo um vetor  $t$  com tamanho  $p$ . O valor  $p$ , neste caso, diz respeito a quantidade de observações coletadas a cada instante de interesse conforme intervalo  $\Delta t$  definido previamente pelo investidor.

$$\mathbf{Z}(t) = [Z_1(t), Z_2(t), \dots, Z_n(t)] \quad (3.1)$$

$$\mathbf{cn}(t) = [pa(t), pf(t), pn(t), px(t), vl(t)] \quad (3.2)$$

Levando-se em conta uma série de dados discreta e univariada tomada isoladamente de um conjunto  $\mathbf{Z}(t)$ , representada por um vetor temporal  $Y$  com  $t$  observações, pode-se representar

esta, por sua vez, segundo a [Equação 3.3](#). De modo análogo, pretendendo-se representar por exemplo, apenas o preço de fechamento, pode-se usar a [Equação 3.4](#). Neste caso,  $t$  foi considerado com valor 248 apenas para ilustrar a quantidade de dias úteis em um ano de operação da bolsa.

$$\mathbf{Y} = \{y(t_1), y(t_2), y(t_3), \dots, y(t_n)\} \quad (3.3)$$

$$\mathbf{pf} = \{pf(t_1), pf(t_2), pf(t_3), \dots, pf(t_{248})\} \quad (3.4)$$

Para entender-se os conceitos e premissas exigidas pelos métodos econométricos, antes é necessário que sejam conhecidas as convenções adotadas na literatura para o chamado Processo Gerador de Dados (PGD). O PGD é o objeto resultado de uma análise de dados sob determinada perspectiva econométrica que permite modelar não somente os dados da uma série temporal histórica, como também, para esta, realizar e avaliar previsões. Neste sentido, denomina-se “Análise de Séries Temporais” o estudo que busca gerar modelos que são capazes de explicar o comportamento de observações distribuídas temporalmente e, a partir destes, projetar para períodos futuros observações que possam ser consideradas utilizáveis conforme um nível de incerteza mensurável ([OLIVEIRA, 2007](#)).

Diversos fenômenos econômicos que tem por característica gerarem dados que podem ser dispostos temporalmente, podem ser matematicamente modelados por meio da estimação de termos independentes. Nesse sentido é explanada por [Gujarati e Porter \(2008\)](#) a Função de Regressão Populacional (FRP) ([Equação 3.5](#)) que, em séries temporais não finitas, sempre será considerada uma Função de Regressão Amostral (FRA) ([Equações 3.6 e 3.7](#)). Para estas funções os estimadores<sup>1</sup>  $\beta_1$  e  $\beta_2$  podem ser encontrados por meio de técnicas de Mínimos Quadrados Ordinários (MQO) ou critério de máxima verossimilhança. Já o termo  $u_i$ , diz respeito aos resíduos da estimação, sendo conhecido também por termo de erro ou ruído branco (o ruído branco será melhor detalhado a frente).

$$Y_i = \beta_1 + \beta_2 X_i + u_i \quad (3.5)$$

$$Y_i = \hat{\beta}_1 + \hat{\beta}_2 X_i + \hat{u}_i \quad (3.6)$$

$$Y_i = \hat{Y}_i + \hat{u}_i \quad (3.7)$$

O modelo de duas variáveis também pode ser generalizado para  $k$  regressores criando-se assim uma abordagem de regressão múltipla. Cada regressor, neste contexto, possui um papel

<sup>1</sup> A nomenclatura “estimador” é usada como sinônimo dos termos “regressor” ou “variável explanatória” em diversas literaturas consultadas, contudo é mais comumente visto o termo “autorregressor” quando o assunto abordado trata diretamente de modelos econométricos autorregressivos.

explicativo na geração das observações durante o tempo. Para tanto, considerando por exemplo a [Equação 3.8](#), nesta o termo  $\beta_1$  é o intercepto que adiciona um efeito médio em  $Y$  para quando  $X_2$  e  $X_3$  sejam iguais a zero. Os termos  $\beta_2$  e  $\beta_3$  são chamados coeficientes parciais de regressão e medem a variação no valor médio de  $Y$  quando procura-se estimar o valor de um dado regressor individualmente e, para isso, durante este processo de estimação, todos os outros regressores são mantidos como constantes.

$$Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i \quad (3.8)$$

A geração de um PGD baseado nestas premissas pode obedecer diversas formulações, sendo que a mais básica é a do passeio aleatório sem deslocamento ou passeio aleatório puro, demonstrada na [Equação 3.9](#). Nesta pode-se perceber que, qualquer ponto gerado na série temporal, é nada mais do que, o valor do instante  $t - 1$ , acrescido de uma realização estocástica, esta oriunda de uma população independentemente e identicamente distribuída segundo uma curva probabilística normal com média zero e variância constante. A geração do termo de erro, ou seja, do ruído branco neste caso, é  $u_i \sim IIDN(\theta, \sigma^2)$ . Este está relacionado intimamente com as premissas exigidas pelos métodos econométricos utilizados. O passeio aleatório é a regra primordial da Hipótese do Mercado Eficiente tratada no primeiro capítulo desta dissertação.

$$Y_t = Y_{t-1} + u_i \quad (3.9)$$

$$Y_t = \beta_1 + Y_{t-1} + u_i \quad (3.10)$$

$$Y_t = \beta_1 + \beta_2 t + Y_{t-1} + u_i \quad (3.11)$$

$$Y_t = \beta_1 + \beta_2 t + \beta_3 Y_{t-1} + u_i \quad (3.12)$$

Caso seja adicionado à equação do passeio aleatório puro o termo regressor  $\beta_1$ , como apresentado na [Equação 3.10](#), um efeito de tendência passará a existir, pois para  $\beta_1 > 0$ , a série tenderá com valor constante à forma crescente, ao passo que, para  $\beta_1 < 0$ , a mesma série tenderá com valor constante à forma decrescente. Esse efeito é chamado de tendência estocástica, pois, a variação do valor seguinte é determinada principalmente pelo processo estocástico de geração do ruído branco gaussiano mais a tendência. A adição do termo regressor  $\beta_2$ , em função do tempo  $t$ , pode aumentar a variância na série ao longo do processo de geração de novas observações. Nesse sentido, observa-se a denominada tendência determinística, pois, a definição do valor seguinte passa a ser também uma função do instante temporal  $t$ . Finalmente, caso o valor no instante  $t - 1$  tenha parcela na explicação do termo no instante  $t$ , pode-se adicionar mais um termo regressor

$\beta_3$  conforme visto na [Equação 3.12](#). Neste caso, observa-se o chamado processo com tendência determinística com componente autorregressivo.

É possível se adicionar mais termos explicativos relacionados a mais valores anteriores ao tempo  $t$ . No caso visto na [Equação 3.12](#), que trata apenas de um termo, a formulação é denominada  $AR(1)$ . Para situações com  $p$  termos autorregressivos existirá, por consequência, um modelo  $AR(p)$ . O modelo AR é melhor detalhado em um tópico específico deste capítulo.

### 3.1.2 Estacionariedade

A estacionariedade é uma propriedade desejável de séries temporais, pois esta viabiliza o uso de diversos métodos de predição. Isso acontece, pois, ao se estimar os termos de um modelo de regressão é possível eliminar as influências que não são oriundas de distribuições conhecidas ([BUENO, 2011](#)). Para tanto, devem ser compreendidos os conceitos de homoscedasticidade e de heterocedasticidade. As definições a seguir são as propostas por [Morettin e Toloi \(2006\)](#) e [Gujarati e Porter \(2008\)](#).

A homoscedasticidade em séries temporais está relacionada com a manutenção do mesmo valor de variância nos termos estocásticos ao longo de toda a série. Dado que a média do termo de erro  $u_i$  é definida conforme a esperança estatística da média para a sua distribuição e, a variância, trata-se da dispersão deste termo médio em relação a uma segunda esperança que, é decorrente dos valores não estocásticos gerados por  $X_i$ , têm-se que homoscedasticidade ou variância constante pode ser definida conforme as [Equações 3.13 e 3.14](#). Já a heterocedasticidade trata do conceito inverso, ou seja, nesta, conforme visto na [Equação 3.15](#), existe uma dispersão ou variância desigual ao longo do tempo dependente de  $X_i$ . Na [Figura 10](#) é mostrada uma representação geométrica da homoscedasticidade e, na [Figura 11](#), da heterocedasticidade.


$$var(u_i) = E [u_i - E(u_i|X_i)]^2 \quad (3.13)$$

$$var(u_i) = \sigma^2 \quad (3.14)$$

$$var(u_i|X_i) = \sigma_i^2 \quad (3.15)$$


Conhecidos estes conceitos, pode-se dizer que um processo estocástico gerará observações estacionárias se, no decorrer do tempo, para este: (a) for mantido o mesmo valor de média; (b) existir homoscedasticidade, e; (c) o valor da autocovariância entre observações separadas por uma defasagem  $k$ , depender não do tempo  $t$  mas, por sua vez, exclusivamente de  $k$ . As formulações referentes as premissas do processo estacionário são mostradas na [Equação 3.16](#)

Figura 10 – Representação da homoscedasticidade.



Fonte: Gujarati e Porter (2008).

Figura 11 – Representação da heterocedasticidade.



Fonte: Gujarati e Porter (2008).

que trata da média constante, na 3.17 que trata da homoscedasticidade e na 3.18 que trata da covariância independente de tempo.

$$E(Y_t) = \mu \quad (3.16)$$

$$\text{var}(Y_t) = E(Y_t - \mu^2) = \sigma^2 \quad (3.17)$$

$$\gamma_k = E[(Y_t - \mu)(Y_{t+k} - \mu)] \quad (3.18)$$

Os métodos econométricos utilizados dependem da premissa de estacionariedade, que geralmente não é válida. Nesse sentido, é necessário antes de se aplicar qualquer um deles, averiguar a existência ou não de estacionariedade. Existem diversos testes para se verificar a estacionariedade de uma série. Estes estão divididos basicamente entre duas abordagens: (a) análise gráfica, realizada por meio de gráficos de autocorrelação amostral e autocorrelação amostral parcial e; (b) testes de raiz unitária, tratados adiante neste texto. Caso pretenda-se aplicar os métodos econométricos tratados à uma determinada série, e nesta série, por exemplo, seja constatada a existência de não estacionariedade, deve-se então proceder a aplicação do denominado processo de integração da série. A integração refere-se à remoção da tendência existente entre as observações, que é feita por meio da diferença entre os valores existentes nos tempos  $t$  e  $t - 1$ . Isso extrai da série somente o termo de erro. Como já discutido, o termo de erro  $u_i$  é  $IIDN(\theta, \sigma^2)$ . Logo, uma série que contenha somente este termo, de forma geral, poderá ser considerada estacionária. A representação da ideia de integração pode ser vista na [Equação 3.19](#).

$$(Y_t - Y_{t-1}) = \Delta Y_t = u_t \quad (3.19)$$

A tomada das primeiras diferenças entre os valores de preços é chamada em finanças de retornos. Para fins matemáticos a mesma é representada como  $I(1)$ , ou seja, a série se torna estacionária com uma integração. Existem casos em que mais diferenciações<sup>2</sup> são necessárias até conseguir-se atingir a estacionariedade. Logo, podem ser observadas representações  $I(d)$  onde  $d$  diz respeito a quantidade de diferenças necessárias até obter-se a estacionariedade. Nesse sentido,  $I(0)$  sempre tratará dos preços absolutos,  $I(1)$  dos retornos e  $I(d)$  de diferenciações feitas, nível a nível, acima da série de retornos. Logicamente, para cada nível de diferenciação realizado, uma quantidade correspondente de observações é perdida (situação análoga aos graus de liberdade em testes estatísticos).

Por fim, vale ressaltar que os métodos econométricos abordados trabalham essencialmente com o logaritmo dos retornos. Essa transformação é preferida à série de preços absolutos pois, conforme observa [Morettin e Tolo \(2006\)](#), o  $\log(I(1))$  apresenta características estatisticamente mais interessantes como maior ergodicidade<sup>3</sup>, ser livre de escalas, além de como já dito, possuir na maioria das vezes a característica de estacionariedade.

### 3.1.3 Critérios de informação

Modelos econométricos como ARMA, ARIMA, SARIMA E GARCH são paramétricos, logo podem ser utilizados de forma flexível para séries diferentes. A escolha de uma parametrização específica é importante pois, dependendo da forma como esta for feita, poderá perceber-se

<sup>2</sup> O termo “diferenciação” é usado como sinônimo para integração visto que ao integrar-se uma série são tomadas as diferenças entre seus termos.

<sup>3</sup> Ergodicidade trata da possibilidade de estimação de eventos futuros com base na probabilidade estatística modelada por meio de dados oriundos de eventos passados ([DAVIDSON, 1999](#))([MOREIRA, 2006](#)).



melhor ou pior ajustamento das previsões às observações reais. Nesse contexto, se enquadram os critérios de informação. Estes têm por objetivo fornecer medidas numéricas que auxiliam na escolha e comparação entre modelos concorrentes para fins de previsão (GUJARATI; PORTER, 2008).

Dois dos critérios de informação mais utilizados na literatura econométrica são  $R^2$  e  $R^2$  ajustado. O  $R^2$  fornece uma medida situada entre 0 e 1, sendo que, para valores próximos de 1, observa-se melhor ajustamento. A sua formulação pode ser observada na Equação 3.23, sendo que nesta SQE diz respeito a soma do quadrado dos resíduos<sup>4</sup> explicados (definida conforme Equação 3.20) e SQT é a soma do quadrado dos resíduos totais (definida conforme Equação 3.22 em função de SQR (Equação 3.21) que trata da soma dos quadrados dos resíduos reais).

$$SQE = \sum \hat{u}_i^2 \quad (3.20)$$

$$SQR = \sum u_i^2 \quad (3.21)$$

$$SQT = SQE + SQR \quad (3.22)$$

$$R^2 = \frac{SQE}{SQT} \quad (3.23)$$

$$\bar{R}^2 = 1 - \frac{SQR/(n-k)}{SQT/(n-1)} \quad (3.24)$$

Alguns problemas podem ser observados no critério de informação  $R^2$ . O principal deles tem a ver com a pretensão do econometrista em sempre querer maximizar o seu valor. Para isso, este pode tentar incluir cada vez mais termos regressores ao seu modelo. Entretanto, como observa Morettin e Tolo (2006) e Bueno (2011), esta não é uma boa estratégia, pois em séries temporais o ajuste de modelos deve seguir o princípio da parcimônia. O princípio da parcimônia é um conceito geral da estatística que diz que, ao escolher-se um entre diversos modelos que possuem a mesma qualidade no ajuste aos dados, deve-se dar preferência ao que possui menor número de regressores. Isso é válido devido a dois pontos principais:

- Modelos com menor quantidade de parâmetros facilitam a compreensão do processo subjacente.

<sup>4</sup> “Resíduo” em séries temporais trata-se da diferença  $u_i$ , ou seja, o erro observado entre o valor predito e a média indicada pela função de regressão no instante  $t$ ; ou o valor real e a média indicada pela função de regressão no instante  $t$ . No primeiro caso faz-se referência ao erro estimado com um indicador “chapéu” sobre a variável.

- Modelos superparametrizados tendem a ser menos generalistas, neste sentido, se adequam de forma muito específica a amostra de dados (o que gera bom valor de  $R^2$  no passado), contudo, quando submetidos ao processo de previsão, geram observações futuras tendenciosas à série histórica e, neste caso, são pobres.

Com o intuito de melhorar o critério de informação pode-se optar pelo uso do  $R^2$  ajustado ao invés do  $R^2$  comum.  $R^2$  ajustado, visto na [Equação 3.24](#), leva em conta também a quantidade de regressores  $k$  em sua fórmula, além do total  $n$  de observações na amostra. Alguns autores, como [Gujarati e Porter \(2008\)](#) e [Morettin e Tolo \(2006\)](#) consideram que mesmo o  $R^2$  ajustado ainda é permissivo. Nesse sentido é bastante difundido o uso do chamado Critério de Informação de Akaike (AIC, do inglês, *Akaike Information Criteria*). Sua formulação pode ser vista na [Equação 3.25](#).

$$AIC = e^{2k/n} \frac{SQR}{n} \quad (3.25)$$

Segundo [Gujarati e Porter \(2008\)](#) são vantagens do AIC em relação ao  $R^2$  ajustado:

- AIC impõe uma medida corretiva mais “dura” aos modelos que são mais parametrizados.
- AIC é um modelo para qual se está interessado em minimizar valores. Logo, sua concepção fundamental é de mais fácil ajustamento a métodos de otimização que permitem minimizar valores.
- É frequentemente utilizado para determinar a extensão de modelos  $AR(p)$ .
- Visto que não inclui em sua formulação qualquer medida que envolva resíduos estimados (como SQE), pode ser utilizado para prever desempenho de modelos de regressão e não somente determinar a qualidade do ajustamento dentro de uma amostra.
- Pode ser utilizado em qualquer modelo econométrico de previsão. Logo, este é adequado a modelos com ou sem sazonalidade.

Existem outros critérios de informação, como por exemplo o *Schwarz Information Criteria* (SIC) que, como o AIC, também leva em conta o número de regressores na avaliação. Contudo, deve-se considerar que dentre os critérios de seleção de modelos, não existe nenhum estritamente superior, mas sim, aqueles que se ajustam melhor aos objetivos do econometrista ([GUJARATI; PORTER, 2008](#)). Nesse sentido, para esta dissertação, preferiu-se a aplicação do AIC frente ao  $R^2$  e  $R^2$  ajustado, visto que, primeiramente, dada a natureza intrínseca desta medida em gerar valores que são melhores quando minimizados, observa-se que os métodos de otimização selecionados (como o BFGS explicado mais a frente) podem ser mais facilmente acoplados. Em segundo lugar, a seleção de modelos com poucos parâmetros é especialmente

benéfica pois, visto que o robô se trata de uma implementação computacional, qualquer estrutura que possa ter sua complexidade diminuída gerará menor quantidade de processamento. Em relação ao CIS, a escolha se deu basicamente devido a facilidade de implementação do AIC frente a este, visto que, em teoria, ambos são bastante similares.

### 3.1.4 Testes de Raiz Unitária

Testes de raiz unitária são utilizados para averiguação de existência ou não de estacionariedade em uma série temporal (BUENO, 2011). Conforme visto na Equação 3.26, isso é possível pois, em um modelo de passeio aleatório, ao se inserir um termo  $\rho$  e estimá-lo, caso constate-se que este é valorado como 1, então o termo autorregressivo fica mantido sem alterações. A manutenção deste termo na equação garante que o valor seguinte da série será influenciado pelo valor anterior, ou seja, assume-se que o modelo não possui estacionariedade. Chama-se, portanto, o processo neste caso, de processo com raiz unitária<sup>5</sup> visto que  $\rho = 1$ .

$$Y_t = \rho Y_{t-1} + u_t \text{ sendo que } -1 \leq \rho \leq 1 \quad (3.26)$$

Existem diversos testes que geram valores de estatística teste específicos para averiguação de raízes unitárias. Dois dos mais conhecidos são *Dickey-Fuller* (DF) e *Augmented Dickey-Fuller* (ADF). Ambos são testes unilaterais que seguem a estatística  $\tau$  (*tau*) e, por isso, possuem tabela com valores pré-determinados para consulta (DICKNEY; FULLER, 1981). Nestes é feita uma manipulação algébrica para que o termo  $\rho$  seja transformado em um outro termo chamado  $\delta$ . Isso possibilita assumir as hipóteses mostradas na Equação 3.30, sendo que, caso não se rejeite a hipótese nula, toma-se por verdade então que existe raiz unitária e, conseqüentemente, a série é não estacionária.

$$\Delta Y_t = (\rho - 1) Y_{t-1} + u_t \quad (3.27)$$

$$\delta = (\rho - 1) \quad (3.28)$$

$$\Delta Y_t = \delta Y_{t-1} + u_t \text{ sendo que } \delta \leq 0 \quad (3.29)$$

$$\begin{cases} H_0 : \delta = 0 \\ H_1 : \delta \leq 0 \end{cases} \quad (3.30)$$

<sup>5</sup>  $\rho$  por convenção é chamado de *raiz*. Não existe relação alguma neste caso com as raízes (quadrada, cúbica e etc.) da matemática.

Os testes DF e ADF serviram de base ao desenvolvimento de outros testes com maior potência estatística (GUJARATI; PORTER, 2008). Um destes é o teste *Kwiatkowski-Phillips-Schmidt-Shin* (KPSS) publicado em 1992 (SHIN; SCHMIDT, 1992). Ao contrário de DF e ADF, neste a hipótese nula é de estacionariedade, ao passo que, a hipótese alternativa é de não estacionariedade, para tanto, ambas são mostradas na Equação 3.31.

$$\begin{cases} H_0 : Y_t \sim I(0) \\ H_1 : Y_t \sim I(p), \text{ com } p > 0 \end{cases} \quad (3.31)$$

O teste KPSS depende da soma parcial dos resíduos  $S_t$ , do tamanho amostral  $T$  e da chamada “variância de longo prazo”<sup>6</sup> definida pelo termo  $\hat{v}^2$ . A formulação que gera o resultado de sua estatística teste pode ser vista na Equação 3.32.

$$KPSS = \sum_{t=1}^T \frac{S_t}{T \hat{v}^2} \quad (3.32)$$

## 3.2 Modelos econométricos para séries temporais

A seguir são apresentados, no âmbito da econometria, os modelos utilizados no robô investidor. Como já discutido, alguns destes métodos admitem, antes de tudo, que as séries de preços podem ser diferenciadas até a estacionariedade, independentemente de quantas integrações sejam necessárias. Estes métodos foram escolhidos pois, cada um a seu modo possui especificidades no tratamento das séries, sendo:

- SMA e EMA: Estes métodos podem gerar observações futuras com base na tendência acumulada. Dependendo do tamanho da janela podem, inclusive, responder de forma rápida ou lenta a novos valores.
- ARMA, ARIMA e SARIMA: Modelam os termos dependentes por meio de termos autorregressores e, os termos de erros, por meio de médias móveis. Estes métodos podem trabalhar em janelas onde sejam observadas séries estacionárias e, inclusive, não estacionárias quando aplicado o processo de integração. O SARIMA, individualmente, ainda pode incluir, quando necessário, a análise da sazonalidade.
- GARCH: Pode modelar a volatilidade passada de forma condicional. Nesse sentido, segmenta as janelas e aplica modelagem específica ao momento de interesse, realizando assim, uma previsão mais especialista.

<sup>6</sup> O teste de raiz unitária de *Phillips e Perron* abordou antes da publicação do KPSS a forma de cálculo da variância de longo prazo. Detalhes sobre o método podem ser vistos em *Phillips e Perron (1986)*.

### 3.2.1 Médias móveis simples e exponenciais

As médias móveis simples (SMA, do inglês, *simple moving average*) e exponenciais (EMA, do inglês, *exponential moving average*) estão incluídas num grupo da econometria chamado de métodos de suavização exponencial. Gujarati e Porter (2008) citam que estes são, essencialmente, métodos com a capacidade de ajustar uma curva adequada aos dados históricos de uma dada série temporal.

As médias móveis simples são chamadas de “simples” pois tratam do cálculo de uma média aritmética simples entre os últimos  $n$  valores de interesse observados, e de “móveis” pois, a cada novo cálculo realizado desloca-se o intervalo da janela à uma distância  $k$ , alterando-se assim o ponto inicial e final da série que passa de  $[t; t + n]$  para  $[t + k; t + n + k]$ . A média móvel simples pode ser aplicada até o último valor da série histórica sempre sobrepondo a previsão mais antiga com uma nova média, conforme cada passo da janela se dá. Sua formulação é a mostrada na Equação 3.33, onde,  $X_{t+n+k+1}$  trata-se do valor de previsão para o dia seguinte ao intervalo do cálculo na janela móvel,  $X_i$  é o conjunto de observações contidas na janela móvel,  $t$  trata-se do instante onde está inserida a primeira observação de interesse,  $k$  é o termo de passo incremental (que em seu último valor também determina a quantidade de previsões a ser realizada) e  $n$  é o comprimento da janela móvel.


$$X_{t+n+k+1} = \frac{\sum_{i=t+k}^{t+n+k} X_i}{n} \quad (3.33)$$

O valor de  $n$  numa SMA pode determinar a velocidade com que esta responderá a uma tendência acumulada na série. SMA's com janelas de comprimento curto são mais influenciadas pelos valores recentes da série temporal. Por isso, novas observações tendem a induzir mais fortemente o valor predito. Já em janelas mais longas, existe maior suavização e maior demora na resposta. Pode-se citar, por exemplo, que isto é determinante quando se está interessado em averiguar reversões de tendência.

A EMA é bastante similar a SMA, apenas com a diferença de que as observações mais antigas da janela móvel contribuem menos para a previsão do que as mais recentes. Isso é feito adotando-se pesos a cada observação na janela.

SMA e EMA são frequentemente mencionadas não só na teoria econométrica, como também, na análise técnica. Na análise técnica estas são incluídas como indicadores do grupo de rastreadores. A Figura 12 mostra o gráfico de preços de fechamento para o ativo BOVA11 (índice Bovespa) com o cálculo de duas SMA's. Uma rápida (em verde) de 15 dias e outras lenta (em azul) de 60 dias.

Figura 12 – Em preto, o preço de fechamento; em azul uma SMA com janela de comprimento igual a 60 dias; e, em verde, uma SMA com janela de comprimento igual a 15 dias. Série do índice BOVESPA em *candles* diários.



Fonte: Elaborada pelo autor.

### 3.2.2 Modelos ARMA, ARIMA e SARIMA

Diversos modelos preditores em econometria devem ser construídos com base na seleção de variáveis econômicas no mercado. Estas variáveis são escolhidas conforme interesse e conhecimento prévio do econometrista e, por isso, muitas vezes o modelo pode se mostrar pobre devido a não relação das variáveis escolhidas com a que se pretende prever. Diversas teorias econômicas foram criadas para expressar a relação entre essas variáveis de mercado e, com isso, facilitar a construção de modelos matemáticos para previsão.

A metodologia *Box-Jenkins* (BJ) foi proposta na década de 70 por [Box e Jenkins \(1970\)](#). É também conhecida como processo autoregressivo integrado de médias móveis (ARIMA). Essa metodologia ganhou notoriedade pois, à época, possuía abordagem diferente dos métodos até então empregados. O ARIMA não gera modelos uniequacionais ou de equações simultâneas baseado nas relações de mercado preconizadas por qualquer teoria econômica, sendo considerado portanto *ateorético*. Com base apenas nos dados da própria série temporal a ser analisada, essa metodologia tem por objetivo modelar de forma probabilística ou estocástica as relações existentes entre as observações históricas da série temporal. Por consequência, conforme informa [Gujarati e Porter \(2008\)](#), “ao contrário de modelos de regressão, no qual  $Y_t$  é explicado pelos regressores  $kX_1, X_2, X_3, \dots, X_n$ , os modelos de séries temporais do tipo BJ permitem que  $Y_t$  seja explicado pelos valores passados (defasados) do próprio  $Y$  e dos termos de erro estocástico”.

O ARIMA é composto de outros três processos: O processo autoregressivo  $AR(p)$ , o processo de médias móveis  $MA(q)$  e a junção destes dois denominada  $ARMA(p, q)$ .

O processo autoregressivo  $AR(p)$ , representado na [Equação 3.34](#), diz respeito a qualquer modelo que necessita de  $p$  termos autorregressivos para ser explicado, ou seja, não depende de

influências de variáveis externas, apenas de suas próprias observações. Para tanto, o valor de  $Y_t$  é determinado por até  $p$  termos anteriores ao tempo  $t$ , com impacto de um valor de proporção  $\alpha$  e com a remoção do efeito das médias representadas por  $\delta$ . Ao valor obtido será adicionado o termo de erro gerado pelo ruído branco  $u_t$ .

$$(Y_t - \delta) = \alpha_1 (Y_{t-1} - \delta) + \alpha_2 (Y_{t-2} - \delta) + \dots + \alpha_p (Y_{t-p} - \delta) + u_t \quad (3.34)$$

O processo de medias móveis  $MA(q)$  está representado na [Equação 3.35](#). Este modela os termos de erros passados com base nos regressores  $\beta$  em até  $q$  defasagens. Para isso o modelo inclui também um valor de média constante  $\mu$ . Como se nota,  $MA(q)$  trata-se de uma combinação linear dos termos de erro.

$$Y_t = \mu + \beta_0 u_t + \beta_1 u_{t-1} + \beta_2 u_{t-2} + \dots + \beta_q u_{t-q} \quad (3.35)$$

Já o processo autorregressivo de medias móveis  $ARMA(p, q)$  permite modelar séries que possuam características autorregressivas e de médias móveis ao mesmo tempo, por consequência, os valores de  $p$  e  $q$ , dizem respeito respectivamente, aos modelos  $AR(p)$  e  $MA(q)$ . A determinação do termo  $Y_t$  pode ser feita conforme mostrado na [Equação 3.36](#), onde  $\theta$  é uma constante.

$$Y_t = \theta + \sum_{i=1}^p \alpha_i (Y_{t-i} - \delta) + \sum_{j=1}^q \beta_j u_{t-j} \quad (3.36)$$

O modelo ARMA exige como premissa que a série à qual este será aplicado seja estacionária. Entretanto, como já discutido, nem todas as séries são estacionárias em sua forma original e, para isso, existe o processo de integração. O modelo ARIMA nada mais é do que um ARMA com processo de integração. Portanto, possui formulação igual à do ARMA já apresentada na [Equação 3.36](#), apenas com a diferença de que na série temporal estudada, porventura não estacionária, devem ser aplicadas uma quantidade  $d$  de integrações. Os parâmetros  $p$  e  $q$  continuam a existir. Assim, portanto, representa-se o modelo como  $ARIMA(p, d, q)$ .

Os modelos ARMA ou ARIMA ainda podem ser expandidos para capturar efeitos da sazonalidade, denominando-se assim SARMA e SARIMA. A sazonalidade diz respeito a uma modelagem específica da componente da série temporal que trata de observações influenciadas por eventos. Estes eventos, por sua vez, possuem frequência pré-estabelecida. Como exemplos, podem-se citar as safras agrícolas, o clima, datas especiais e outras ([BUENO, 2011](#)). Em séries de preço como as aqui abordadas, é incomum ver-se efeito da sazonalidade, apesar que este ainda pode ocorrer em alguns momentos. Nesse sentido, sendo estas séries de preços univariadas (para somente a dimensão de preço de fechamento, no caso) pode-se aplicar a estimação do modelo com vias a inclusão do efeito sazonal.

Levando-se em conta que uma série temporal pode ser decomposta de forma aditiva ou multiplicativa, a modelagem da componente sazonal da série, extraída de forma multiplicativa<sup>7</sup>, pode ser adicionado o modelo  $ARMA(p, q)$ , para tornar-se  $SARMA(p, q)(P, Q)_{[f]}$ , conforme mostrado na Equação 3.37. Nesta observa-se que à modelagem ARMA são adicionados os modelos dependentes de  $P$  e  $Q$  que, respectivamente, tratam-se da quantidade de termos autorregressivos e quantidade de termos de médias móveis, ambos aplicados, neste caso, a componente sazonal da série temporal estudada. Os fatores de proporção estimados  $\Lambda_k$  e  $\lambda_l$  exercem papel similar aos de  $\alpha_i$  e  $\beta_j$  já explicados, porém aplicados somente à componente sazonal.

$$\Delta Y_t = \theta + \sum_{i=1}^p \alpha_i \Delta_{t-i}^d + \sum_{j=1}^q \beta_j u_{t-j}^d + \sum_{k=1}^P \Lambda_k \Delta_{t-k}^D + \sum_{l=1}^Q \lambda_l u_{t-l}^D \quad (3.37)$$

O termo  $[f]$  na formulação  $SARMA(p, q)(P, Q)_{[f]}$  diz respeito a frequência de interesse em capturar efeitos da sazonalidade conforme intervalo  $\Delta t$  usado na coleta dos dados. Numa série de preços de fechamento diária, por exemplo, pode-se pretender capturar efeitos sazonais anuais, para tanto,  $f = 248$ , visto que 248 é normalmente o número de dias úteis de funcionamento da bolsa de valores (dias no ano descontando-se feriados e finais de semana). Caso queira-se, como neste estudo, capturar efeitos mensais, deve-se utilizar  $f = 20$ .

O modelo SARMA, como o modelo ARMA, tem como premissa a condição de estacionariedade também na componente sazonal da série estudada. Portanto, caso não seja constatada esta propriedade, como já visto, deve-se proceder ao processo de integração. De forma similar à quando se realiza integrações no modelo  $ARMA(p, q)$  e este passa a ser referenciado como  $ARIMA(p, d, q)$  isso também ocorre no SARMA. Para tanto, quando se torna necessária a aplicação de  $D$  diferenciações na componente sazonal e  $d$  diferenciações na série principal, passasse a se referir ao modelo antes escrito como  $SARMA(p, q)(P, Q)_{[f]}$  como, finalmente,  $SARIMA(p, d, q)(P, D, Q)_{[f]}$ .

### 3.2.3 Modelo GARCH

A volatilidade nas séries financeiras é um fenômeno que se apresenta em *clusters*. Isso quer dizer que as oscilações de preço em alta e baixa magnitude dificilmente estão separadas temporalmente, existindo assim aglomerações de alta volatilidade, seguidas de aglomerações de baixa volatilidade. Esse fato dificulta a modelagem das séries temporais pois, para cada instante no tempo, podem existir modelos de regressão diferentes (GUJARATI; PORTER, 2008). Campbell, Lo e MacKinlay (1997) dizem que, para a maioria das séries financeiras, existe a sugestão de que os retornos sejam serialmente correlacionados e, por causa disto, em alguns casos pode torna-se ineficiente a aplicação de métodos que supõem que a volatilidade seja sempre constante. Esse fenômeno é conhecido em séries temporais como heterocedasticidade

<sup>7</sup> Para mais detalhes sobre decomposição de séries temporais, ver Morettin e Toloi (2006) ou (BUENO, 2011).



condicional e diz respeito a variância que varia no tempo, conforme condições impostas por eventos econômicos exógenos.

Campbell, Lo e MacKinlay (1997) separam os modelos com foco em heterocedasticidade condicional dos que não focam, sendo:

- Modelos para séries temporais lineares: Assume-se nestes que os resíduos dos retornos não são correlacionados e, por consequência, não são independentes e identicamente distribuídos.
- Modelos para séries temporais não lineares: Assume-se nestes que os resíduos dos retornos possuem correlação e, por este motivo, influenciam nos movimentos da série temporal observada.

Em Oliveira (2007) é citado que, para modelos de séries temporais não lineares, a principal abordagem trata de assumir que a aglomeração de volatilidade decorre do fato de que, em séries temporais financeiras, *outliers* aparecem em *clusters*. Estes decorrem principalmente das interpretações de notícias de mercado, crises econômicas e outras que tendem a durar semanas ou meses. Nesse sentido, é correto construir modelos para os próprios *outliers*. Outra motivação é que, em períodos mais voláteis existe também maior incerteza acerca das previsões realizadas e, por isso, modelos para séries temporais não lineares com heterocedasticidade condicional, como o GARCH, mostram-se especialmente aplicáveis.

O modelo GARCH, publicado por Bollerslev (1986), é uma extensão generalizada do modelo *Autoregressive Conditional Heteroskedasticity* (ARCH) de Engle (1982). O modelo GARCH é referenciado com seus parâmetros como  $GARCH(p, q)$ , onde,  $p$  diz respeito a quantidade de termos defasados do termo de erro quadrático e  $q$  refere-se a quantidade de termos das variâncias condicionais defasadas. A formulação do mesmo pode ser vista na Equação 3.38.

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i u_{t-i}^2 + \sum_{j=1}^q \alpha_j \sigma_{t-j}^2 \quad (3.38)$$

Ao estimar-se a série temporal de interesse, o modelo GARCH pode informar se algum dos termos vinculados às variâncias passadas possuem significância estatística (realizada por meio de teste  $t$ ). Caso isso seja constatado, os termos  $p$  e  $q$  são ajustados de forma empírica ou por meio da otimização de critérios de informação. Uma das formas de se realizar a estimação é por meio Mínimos Quadrados Generalizados (MQG). Vale ressaltar também que o modelo  $GARCH(p, q)$  é equivalente a um modelo  $ARCH(p + q)$  (DAVIDSON, 2000). Para casos em que o GARCH constatar aglomerações de volatilidade, deve-se, separadamente por *cluster*, escolher um modelo de regressão qualquer e aplicá-lo a fim de ajustar os dados e gerar previsões de forma individual.

### 3.3 Redes Neurais Artificiais

Baseando-se em processo prévio de aprendizado e num conjunto de dados fornecidos, uma rede neural artificial tenta encontrar um padrão ou uma resposta que corresponda corretamente ao esperado. Em outras palavras, uma rede neural artificial, inicialmente, se utiliza de um conjunto de dados como parâmetros de entrada. Na sequência, as entradas são processadas para gerar um conjunto de saídas. Estas então são comparadas às respostas esperadas e as diferenças entre o que foi calculado e o que era esperado são então utilizadas para corrigir a qualidade das respostas. Espera-se que a rede neural artificial, após este treinamento, passe a ser capaz de estimar saídas para conjuntos de entrada desconhecidos.

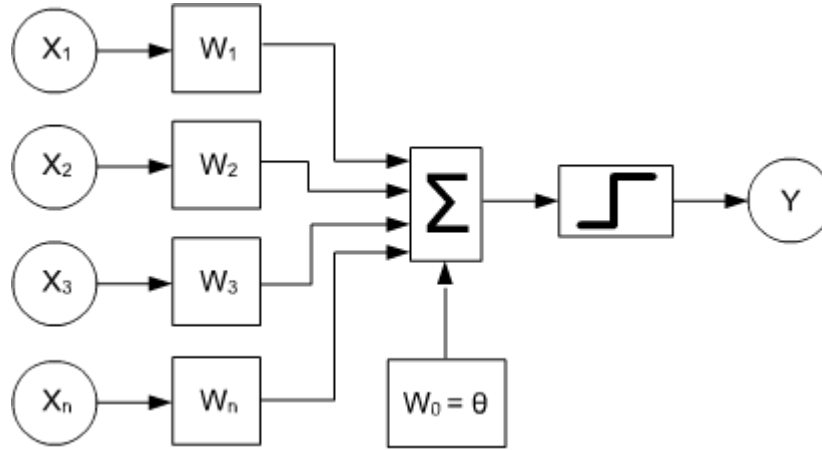
Redes neurais artificiais (RNA) podem ser conceituadas como um conjunto de unidades de processamento, caracterizadas pelos chamados “neurônios artificiais”, que são conectadas para permitir as “sinapses artificiais” (SILVA; SPATTI; FLAUZINO, 2010). Nesse sentido, Silva, Spatti e Flauzino (2010) citam características que as tornam relevantes, como adaptação por experiência, capacidade de aprendizado, habilidade de generalização, organização de dados, tolerância a falhas, armazenamento distribuído e facilidade de prototipagem. Braga, Carvalho e Ludernir (2007) e Haykin (2001) elencam suas diversas aplicações, com destaque para aproximação de funções, categorização em padrões, classificação de dados, estimação de parâmetros e, no interesse deste estudo, previsão em séries temporais.

Na literatura podem ser encontradas referências para diversos tipos de redes neurais artificiais diferentes. Um destes tipos é a rede neural *Perceptron*. A primeira menção a rede *Perceptron* foi feita por Rosenblatt (1958) e está é a configuração mais simples de implementação em uma RNA, pois possui somente uma camada e um neurônio. Como pode ser visualizado na Figura 13, diversos sinais de entrada podem servir para mapear um dado problema e, após processamento da rede, apenas uma saída é gerada. A principal base teórica que o *Perceptron* forneceu para estudos posteriores foi a da utilização dos pesos sinápticos e do limiar de ativação que, em geral, é feito em vários tipos de RNA's por meio de funções do tipo degrau, linear ou sigmoide. Na rede *Perceptron* não existe nenhuma realimentação e, por isso, classifica-se esta como de topologia *feedforward* (SILVA; SPATTI; FLAUZINO, 2010).

Uma evolução da rede *Perceptron* é a *Perceptron* com Múltiplas Camadas (MLP, do inglês, *Multilayer Perceptron*). A MLP possui por principal característica e, também, diferença para a *Perceptron* Simples, a implementação de uma ou mais camadas chamadas de intermediárias ou escondidas. A camada escondida fica entre a entrada da rede e a camada de saída. Em MLP's é comumente observada a utilização de funções sigmóides nos neurônios da camada escondida e, lineares ou sigmóides, nos neurônios da camada de saída. Esta rede foi inicialmente abordada na literatura sem qualquer tipo de realimentação, fato que, por não gerar previsões para dados novos, desmotivou a maioria das pesquisas da área na década de 70 (BRAGA; CARVALHO; LUDERNIR, 2007). Entretanto, a partir do fim dos anos 80, houve uma retomada dos estudos com RNA's, devido a publicação algoritmo de treinamento denominado *Backpropagation* no

livro *Parallel Distributed Processing* de [Rumelhart, Hilton e Willians \(1986\)](#).

Figura 13 – Rede Neural Artificial do tipo Perceptron Simples.



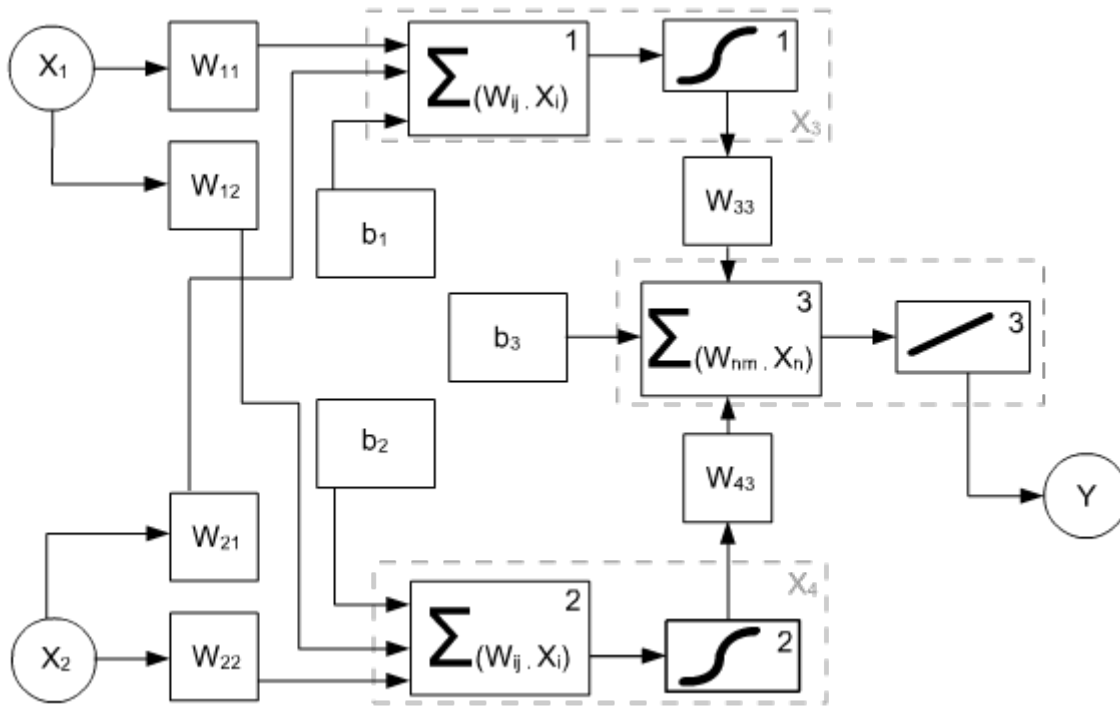
Fonte: Elaborada pelo autor.

O *Backpropagation* (conhecido também como Regra Delta Generalizada) treina a rede neural artificial com base em um conjunto de padrões em duas etapas. Na primeira etapa, chamada de *forward*, os sinais de entrada são inseridos na rede e, passando de camada para camada, vão sendo processados sem alterar qualquer configuração (pesos e limiares) até a geração da saída. Na segunda etapa, a saída obtida é então comparada a uma respectiva resposta esperada, o que resulta em um valor de diferença (erro). Este erro é então propagado no sentido contrário da rede, da saída para a entrada, na chamada fase *backward*. Essa propagação reversa ajusta a configuração dos pesos da rede que, na sequência, receberá uma nova entrada, que também será base para um novo ajuste e, assim por diante ([HAYKIN, 2001](#)). Em resumo, os ajustes realizados pelo *Backpropagation* são feitos conforme a regra geral apresentada na [Equação 3.39](#).

$$w_{ji}^n(t+1) = w_{ji}^n(t) + \eta \delta_j^n y_i^{n-1} \quad (3.39)$$

Com  $n$  sendo o índice de cada camada da MLP,  $t$  cada época iterada,  $w$  o vetor de pesos associado as entradas e as camadas,  $y$  o vetor de entradas na camada e  $\eta$  a taxa de aprendizagem. O valor de  $\delta_j^n$  para a camada de saída é calculado de forma baseada no desvio entre as saídas estimadas e as saídas esperadas. Já para as camadas escondidas o valor de  $\delta_j^n$  é obtido por meio da multiplicação dos valores de  $\delta_j^n$  obtidos nas camadas anteriores, com o somatório dos produtos obtidos, e por fim, pelos pesos que ligam cada um dos neurônios. A fase de *backward* é feita por meio das funções inversas das funções de ativação utilizadas nos neurônios na fase *forward*. O *Backpropagation* atua de época em época, até que um critério de parada (como tolerância máxima ao erro ou total de épocas) seja satisfeito. A topologia aproximada de uma MLP pode ser observada na [Figura 14](#).

Figura 14 – Rede Neural Artificial do tipo Perceptron com Múltiplas Camadas. Na imagem duas camadas sendo uma, a intermediária, com dois neurônios com função de ativação sigmoide e, a outra, de saída com um neurônio com função de ativação linear.



Fonte: Elaborada pelo autor.

### 3.4 Clusterização de dados

No âmbito da estatística multivariada, a análise de agrupamentos também é conhecida como agrupamento, classificação, análise de *clusters* ou análise de conglomerados. Dada uma amostra de dados, uma técnica de clusterização terá utilidade ao permitir separar as observações em grupos de forma que, em cada um destes, os elementos contidos sejam os mais similares possíveis entre si e, entre os grupos, os elementos sejam os mais diferentes possíveis entre si (MINGOTI, 2013).

Técnicas de clusterização geralmente utilizam-se de medidas de dissimilaridade pois, baseadas em um valor que denota a “distância” entre elementos, esta pode, por sua vez, minimizar a variância de quaisquer características de interesse nos indivíduos de um mesmo grupo. Uma das medidas de dissimilaridade mais utilizadas é a distância euclidiana. Considerando-se dois elementos  $X_l$  e  $X_k$ , sendo  $l \neq k$ , pode-se definir a distância euclidiana como na Equação 3.40. Percebe-se que nesta, os dois elementos são comparados entre si por meio do vetor de observações em cada variável.

$$d(X_l, X_k) = \left[ \sum_{i=1}^p (X_{li} - X_{ki})^2 \right]^{\frac{1}{2}} \quad (3.40)$$

A distância euclidiana, quando utilizada, deve ser associada a algum critério de qualidade vinculado ao vetor de elementos. Para tanto, a técnica de clusterização deve encontrar uma partição de  $n$  elementos, cada qual, vinculado a um grupo  $k$ . Nesse sentido, normalmente utiliza-se o termo  $k$  para se referir a quantidade total de partições a serem feitas em uma amostra. [Mingoti \(2013\)](#) cita que essa divisão deve satisfazer a dois requisitos básicos: coesão interna, que trata da semelhança entre elementos no mesmo grupo e; isolamento, que trata da separação das partições quando já estabelecidas. A autora ainda diz que essa abordagem é conhecida como agrupamento não hierárquico e que, o provavelmente mais conhecido e utilizado método desta categoria é o algoritmo K-médias.

O algoritmo K-médias foi publicado em 1979 por [Hartigan e Wong \(1979\)](#). Esse método busca minimizar a distância de um ponto amostral (métrica de qualidade de um dado elemento) para um dado centroide por meio de iterações que buscam, rodada a rodada, calcular o local no espaço onde existe a mínima variância dentro de um mesmo grupo. O K-médias possui operação dividida em quatro etapas:

1. Define-se a quantidade de grupos  $k$  e, para cada grupo, cria-se um centroide correspondente que, a seguir, deve ser posicionado aleatoriamente entre os elementos da amostra.
2. Compara-se cada centroide a cada elemento por meio de uma medida de dissimilaridade (como distância euclidiana) e, por sua vez, aloca-se o elemento ao grupo para o qual tem-se a menor distância.
3. Para cada grupo formado executa-se novamente o cálculo do passo 2 e, realoca-se cada um dos elementos que nesta iteração tiveram seus centroides alterados.
4. Repete-se os passos 2 e 3 até que um critério de parada, como mínima variância entre grupos, seja satisfeito.

Um dos problemas enfrentados quando se utiliza o K-médias é a definição do valor de  $k$  adequado para uma dada amostra. Um dos métodos que auxilia nesta definição é o método de *Elbow* ([OGAWA, 1987](#)) que está formulado na [Equação 3.41](#).

$$SSE = \sum_{i=1}^K \sum_{x \in c_i} d(x, c_i)^2 \quad (3.41)$$

Esse método computa a soma dos quadrados dos erros de cada operação variando-se de 1 a  $k$ . A cada novo teste ele compara a qualidade da alocação por meio da variância elementos-grupos. Se em um novo experimento, como um novo valor de  $k$ , não for observada contribuição frente ao valor obtido no experimento anterior, então as iterações são interrompidas, informando dessa forma o valor atingido, logo, o melhor valor para  $k$  obtido.

No robô investidor é utilizado o K-médias, com distância euclidiana e com  $k$  ótimo obtido por meio do método de *Elbow* nas séries de tendência.

### 3.5 Otimização com métodos *Quasi Newton*

Existem diversos métodos que buscam realizar otimizações em funções monotônicas diferenciáveis. Dois dos tipos mais difundidos são os métodos baseados em gradiente e os métodos de *Newton*. Os métodos de gradiente possuem maior simplicidade ao passo que, por meio dos métodos de *Newton* pode-se atingir soluções de forma mais rápida. Entretanto, mesmo possuindo estas características, estes métodos precisam fazer uso do cálculo da matriz hessiana e também de sua inversa, fato que, em certos cenários, pode dificultar sua aplicação ou deixar o processo de execução do algoritmo mais lento que o aceitável. Nesse sentido, coloca-se como proposta o uso dos algoritmos chamados *Quasi Newton*.

Os algoritmos *Quasi Newton* buscam balancear as características de qualidade do modelo e simplicidade de cálculo, ou seja, estes buscam um meio termo entre os métodos de gradiente e os métodos de *Newton*. Isso se dá pois nos métodos *Quasi Newton*, o cálculo da matriz hessiana e sua inversa não ocorre diretamente, mas em um processo iterativo finito. Logo, neste caso, mantém-se a possibilidade de convergência rápida buscada pelos métodos de *Newton* mas, em contrapartida, é também agregada velocidade na estimativa da matriz hessiana.

Diversos métodos são classificados como membros da família *Quasi Newton*. Dentre eles merece destaque o *Davidon-Fletcher-Powell* (DFP), publicado por [Fletcher e Powell \(1963\)](#), que mais tarde serviu de base ao desenvolvimento do *Broyden-Fletcher-Goldfarb-Shanno* (BFGS) publicado em [Shanno \(1985\)](#). O método BFGS é um algoritmo que possui por premissa possibilitar a otimização em problemas irrestritos não lineares por meio da aproximação iterativa da matriz hessiana. O BFGS utiliza correção simétrica de posto dois e, para encontrar a inversa da hessiana, utiliza a fórmula de *Sherman-Morrison* onde a matriz hessiana não é avaliada diretamente, mas aproximada por meio das avaliações do seu próprio vetor gradiente.

A correção utilizada no BFGS é dada pela [Equação 3.42](#).

$$C_k^{BFGS} = \left(1 + \frac{r_k' H_k r_k}{r_k' v_k}\right) \frac{v_k v_k'}{v_k' r_k} - \frac{v_k r_k' H_k + H_k r_k v_k'}{r_k' v_k} \quad (3.42)$$

A fórmula de atualização para a estimativa da inversa da matriz hessiana é a descrita na [Equação 3.43](#).

$$H_{k+1} = H_k + C_k(\alpha) \quad (3.43)$$

Neste caso, para  $\alpha = 0$  têm-se o método DFP, enquanto que, para  $\alpha = 1$  o método BFGS.

Segundo [Takahashi \(2007\)](#) pode-se citar alguns fatos a respeito deste tipo de correção:

- Por inspeção pode-se verificar que a correção é de posto dois.
- A matriz  $H_k$  preserva sua propriedade definida positiva.
- $v_i$  e  $v_j$  são F-ortogonais.
- Dado  $i$  tal que  $0 \leq i \leq k$ ; então  $H_{k+1}Fv_i$ .

A formulação, como apresentada na referência original, é aplicada neste trabalho. No entanto existem variações do BFGS publicadas, como as de [Yuan \(1991\)](#), [Li e Fukushima \(2001\)](#) e [Yuan e Wei \(2008\)](#).





---

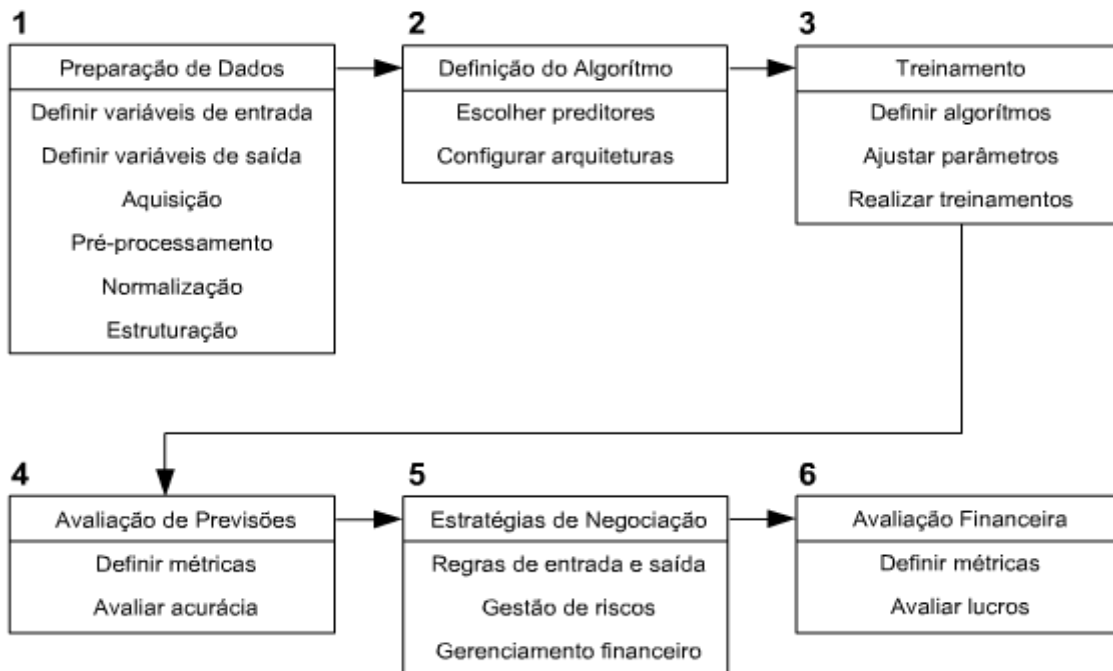
## METODOLOGIA

---

Sistemas de negociação algorítmica são, acima de tudo, sistemas de informação. Por isso, antes de dar-se início a sua implementação, torna-se necessário o desenvolvimento de um projeto de *software*. Normalmente, no âmbito da engenharia de *software*, são dispostos diversos modelos de arquitetura de sistemas, alguns mais genéricos e outros mais especialistas. Contudo, arcabouços com foco em sistemas de *trading* foram pouco vistos nos trabalhos levantados durante a revisão bibliográfica. Nesse sentido, [Vanstone e Finnie \(2010\)](#) alegam que, apesar da pesquisa sobre negociação algorítmica já estar consolidada como ramo da ciência, ainda não está bem estabelecida e testada qualquer metodologia que descreva os passos para a criação de um robô investidor. Este autor ainda especula dizendo que uma das possíveis razões para esta lacuna ainda existir é o fato de que não há comunicação suficiente entre a comunidade científica e os investidores no mercado. Em [Aldridge \(2013\)](#) é discutido um fluxo para desenvolvimento de modelos econométricos com robôs para HFT, mas a autora não aprofunda a discussão. Em [Labadie e Lehalle \(2010\)](#) e [Leite \(2014\)](#) são abordados os modelos *Black Box Trading* que, segundo estes autores, são divididos em três partes sendo: (a) módulo preditor, responsável por estimar os parâmetros dos modelos automaticamente com base nos dados de mercado e, a partir destes, realizar previsões; (b) módulo otimizador, que distribui os recursos financeiros nos ativos de interesse gerando uma carteira de investimento e; (c) o módulo negociador, que executa ordens de compra e venda no mercado. [Vanstone e Finnie \(2010\)](#) propõem um arcabouço para robôs investidores que é constituído dos módulos de: (a) Preparação de dados, onde é feita a extração, pré-processamento, normalização e estruturação das séries; (b) definição do algoritmo, onde são escolhidos os preditores e suas arquiteturas são configuradas; (c) treinamento, módulo responsável por selecionar algoritmos, ajustar parâmetros e realizar treinamentos e; (d) avaliação de previsões, onde métricas de avaliação são definidas e os preditores são testados. Mais tarde, [Cavalcante et al. \(2016\)](#) estendeu o arcabouço de [Vanstone e Finnie \(2010\)](#) depois de realizar uma extensa revisão bibliográfica da área e o reconstruiu conforme demonstrado na [Figura 15](#). Nesta nova modelagem foram acrescentados dois módulos extras, sendo que o primeiro, é responsável

por construir e gerenciar estratégias de investimento baseadas nas previsões realizadas e, o segundo, avalia a qualidade conforme métricas relacionadas a lucros e prejuízos, ou seja, de forma financeira.

Figura 15 – Arcabouço geral para sistemas de *trading* com previsão.

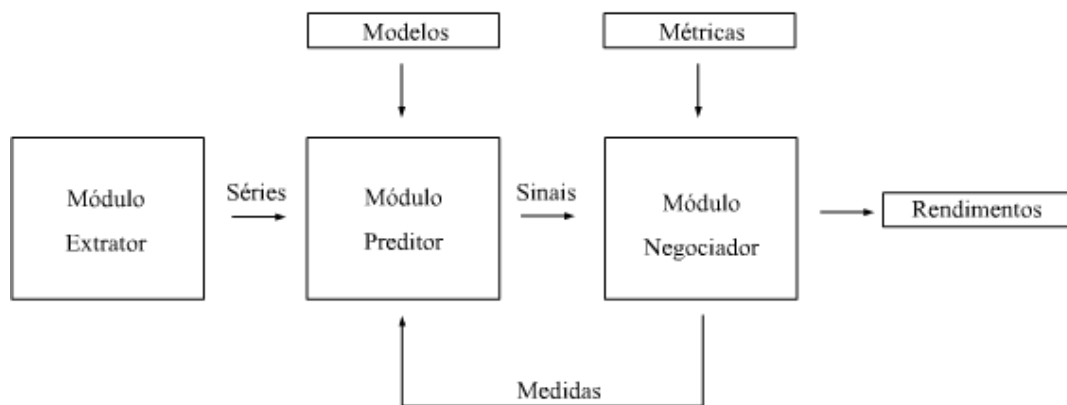


Fonte: Adaptada de [Cavalcante et al. \(2016\)](#).

Neste capítulo serão apresentados os métodos e procedimentos adotados para o desenvolvimento do robô investidor. Para tanto, baseado indiretamente nas contribuições dos autores citados no parágrafo anterior, bem como outros, foi também elaborado um arcabouço para o desenvolvimento do sistema de *trading* ora presente. Todas as etapas dispostas na concepção de [Cavalcante et al. \(2016\)](#) foram contempladas, outras novas foram inseridas e, algumas modificadas. Por isso, uma abordagem mais concisa foi utilizada como ponto de partida para construção do sistema, sendo que a mesma foi dividida em três grandes módulos principais, como mostrado no nível zero da arquitetura do sistema disposta na [Figura 16](#).

Cada um destes módulos será explicado detalhadamente e de forma separada. Entretanto, pede-se a atenção do leitor ao fato de que os mesmos não estão dispostos no texto na ordem sequencial com que aparecem no diagrama da [Figura 16](#). Isso foi feito pois, para o entendimento do Módulo Preditor, é necessário antes ter-se uma visão geral de alguns conceitos aplicados na operação do robô, na sequência, entender-se como são extraídas e tratadas as séries temporais, responsabilidade do Módulo Extrator e, finalmente, como são avaliadas financeiramente as estratégias otimizadas por meio do Módulo Negociador. Portanto, a sequência de apresentação é a seguinte: Visão geral, Módulo Extrator, Módulo Negociador e, por fim, Módulo Preditor.

Figura 16 – Arquitetura raiz (nível zero) do robô investidor.



Fonte: Elaborada pelo autor.

## 4.1 Visão geral

Alguns pontos fundamentais para o entendimento da dinâmica de operação do robô são discutidos na sequência.

### 4.1.1 Quantidade de ativos

Quanto a quantidade, apenas por convenção, definiu-se que o número de ativos selecionados seria de 10 (dez) e, também, junto destes, o índice Bovespa. A inclusão do índice Bovespa de forma compulsória no estudo deve-se ao fato de que este representa uma medida geral de todos os setores negociados na bolsa, ou seja, previsões realizadas neste índice podem servir quando deseja-se levar em conta o comportamento geral do mercado. Outro ponto é que o índice Bovespa, por ser uma medida temporal composta de diversas séries, sofre influências de mais fontes econômicas do que séries individuais. Nesse sentido, este pode ao mesmo tempo ser suavizado pela calma de alguns setores, como pode ser bruscamente alterado pela volatilidade de outros. Estes fatos fazem dele um bom *benchmark* para comparação.

### 4.1.2 Período de operação

Inicialmente pretendeu-se selecionar de forma fixa uma fase do mercado que, antes de tudo, apresentasse diversos tipos de movimento, ou seja, altas, lateralizações e baixas. Esses movimentos deveriam estar explícitos graficamente nas séries selecionadas. Contudo, com o avanço do trabalho foi notado que a liquidez dos ativos selecionados era um ponto mais importante para o sucesso do robô e, neste sentido, com a posterior implementação do Módulo Extrator, houve por consequência, a inserção de dinamismo na seleção dos ativos. Essa seleção automatizada impossibilitou a escolha de séries específicas. Com isso, foi ajustada uma janela no período compreendido entre 2009 e 2013 a fim de se obter ativos os mais heterogêneos

possíveis, não somente em movimento mas também em volatilidade (a representatividade do *dataset* selecionado é melhor discutida no [Apêndice A](#)).

Outro ponto determinante na seleção do período de operação foi a garantia de integridade dos dados extraídos da BOVESPA. Para isso optou-se pelo uso da ferramenta *Metatrader 5* (MT5) já citada na [subseção 1.1.3.2](#). A interface entre o MT5 (na condição de uso por pessoa física) e a bolsa se deu em formato DMA1, com uma corretora brasileira fazendo a conexão. Durante o processo de extração das séries e conferência da qualidade dos dados, percebeu-se situações onde haviam certos problemas como campos faltantes ou trocados, datas faltantes ou trocadas, campos ou datas em formato não reconhecível, dentre outros. Após pesquisa e aplicação das correções possíveis, verificou-se que o período anterior a 2014 apresentava uma quantidade menor de erros, o que levou a duas estratégias:

- Seleção de um período que estivesse necessariamente compreendido antes de 2014 e;
- Neste intervalo, inserção de regras automatizadas no Módulo Extrator para averiguação da integridade dos dados antes da fase de operação.

Portanto, nos casos em que algum ativo apresentou problemas de integridade, este foi automaticamente excluído do *dataset* por violar alguma das restrições incluídas no Módulo Extrator (as restrições são comentadas na [subseção 4.2.1.1](#)).

Entre 2009 e 2013, nos experimentos realizados, o robô investidor manipulou séries referentes a cinco anos de dados reais de 11 ativos líquidos negociados na BOVESPA. Os *datasets* possuíam início em 02/01/2009 e fim em 30/12/2013. Destes cinco anos, os três primeiros foram utilizados como dados históricos com a finalidade de realizar as atividades de estimação, otimização e definição dos modelos de previsão. Logo, as observações contidas entre 02/01/2009 e 29/12/2011 não foram consideradas na fase de operação. Após este período, operou-se com janelamento móvel, com a operação cega do robô ocorrendo entre 02/01/2012 e 30/12/2013, sempre se deslocando a janela histórica em um dia até o final do *dataset*. Levando-se em conta os 11 ativos e os dois anos de operação cega em cada um deles, têm-se que os resultados apresentados nesta dissertação dizem respeito a um total de 22 anos de operação, ou seja, 5.434 dias úteis de operação na bolsa com 10 ações distintas e um índice de mercado (carteira). Esses períodos são sumarizados nos quadros 1 e 2.

Quadro 1 – Períodos de operação do robô por ativo.

Período	Tempo (ativo/ano)	Observações	Finalidade
02/01/2009 a 30/12/2013	5 anos	1.236	Período completo
02/01/2009 a 29/12/2011	3 anos	742	Histórico
02/01/2012 a 30/12/2013	2 anos	494	Operação cega

Quadro 2 – Períodos de operação do robô na carteira.

Período	Tempo (ativos/ano)	Observações	Finalidade
02/01/2009 a 30/12/2013	55 anos	13.596	Período completo
02/01/2009 a 29/12/2011	33 anos	8.162	Histórico
02/01/2012 a 30/12/2013	22 anos	5.434	Operação cega

### 4.1.3 Preditores, classes e categorias de preditores

No robô investidor são utilizadas duas categorias de preditores, os econométricos e as redes neurais artificiais. Estas duas categorias estão divididas respectivamente em três e duas classes sendo que, na categoria dos econométricos, tem-se as classes de SMA, Seletor SARIMA (ARMA, ARIMA E SARIMA) e GARCH. Já na categoria das redes neurais artificiais, tem-se as classes de RNA's de *candles* e RNA's de tendência. Em cada uma destas classes de preditores existem configurações diferentes para cada preditor, ou seja, existem *setups* que alteram o mesmo de forma que este possa gerar resultados específicos. Nesse sentido, deste ponto em diante do texto, o uso da palavra “preditor” dirá respeito a uma dessas configurações individualizadas, ao passo que, ao se referir a todos os preditores de uma determinada classe, será referenciado então como “classe de preditor”.

Nos quadros 3 e 4 estão sumarizados todos os preditores, todas as classes e todas as categorias existentes no estudo.

Quadro 3 – Listagem de todos os preditores embarcados no robô investidor da categoria econométricos.

Classe do preditor	Tamanho da janela móvel (dias)	Nome do preditor
SMA	9	sma_9
	21	sma_21
	30	sma_30
	45	sma_45
	60	sma_60
	120	sma_120
Seletor SARIMA	31	sarima_31
	62	sarima_62
	124	sarima_124
	186	sarima_186
	248	sarima_248
GARCH	124	garch_124
	248	garch_248
	370	garch_370

A coluna “Nome do preditor” nos quadros 3 e 4 é importante, pois, em diversas tabelas e gráficos apresentados neste e no próximo capítulo, quando necessária a referência a um preditor específico, este *label* será utilizado.

Quadro 4 – Listagem de todos os preditores embarcados no robô investidor da categoria redes neurais artificiais.

Classe do preditor	Tamanho da janela móvel (dias)	Quantidade de neurônios na camada escondida	Nome do preditor
RNA's de <i>candles</i>	10	5	A composição do nome da RNA de <i>candle</i> é feita conforme a regra $rna1nc\_j[dias]\_n[neurônios]$ . Existem 64 combinações possíveis.
	20	10	
	30	15	
	35	20	
	40	25	
	45	30	
	50	35	
	60	40	
RNA's de tendência	Os preditores desta classe possuem janela de tamanho determinado dinamicamente ao longo do processo de operação.	5	rna2_n5
		10	rna2_n10
		15	rna2_n15
		20	rna2_n20
		25	rna2_n25
		30	rna2_n30
		35	rna2_n35
		40	rna2_n40

#### 4.1.4 Métricas de avaliação

Como já visto na revisão bibliográfica, diversos trabalhos, especialmente os mais recentes, têm adotado como métricas de avaliação em sistemas de negociação algorítmica as que possuem foco na qualidade financeira. Isso se traduz em não selecionar um determinado preditor baseado, necessariamente, na sua capacidade de prever um valor que seja o mais próximo possível do real. Como também é discutido na seção que trata do Módulo Negociador, o modelo de negociação adotado exige apenas que a direção do movimento seja prevista, ou seja, não importa se o valor previsto esteja distante ou próximo do valor real, o que importa é que este valor, em relação ao último valor conhecido, indique uma direção correta no movimento dos preços. O resultado de interesse nesse caso é um sinal de alta ou um sinal de baixa.

A métrica adotada neste trabalho para avaliação da qualidade dos preditores (principalmente na fase de otimização) é o *Percentage of Change in Direction* (POCID) aplicada segundo os trabalhos de [Azevedo \(2014\)](#) e [Paiva \(2014\)](#). Esta métrica avalia a capacidade de um determinado modelo preditor em acompanhar a mudança da direção dos movimentos ([MITSA, 2010](#)), logo, em estratégias que dependam de sinal de operação, quanto melhor seu resultado maior o lucro aferido. [Paiva \(2014\)](#) *apud* [Neto \(2008\)](#) argumenta que o POCID é importante para aplicações com foco em finanças pois a partir deste pode-se medir subidas e descidas nas cotações dos preços.

Sua formulação é a apresentada na [Equação 4.1](#), sendo que  $y_i$  diz respeito ao valor previsto e  $d_i$  ao valor real. O resultado do POCID é um valor entre 0 e 1, sendo que quanto mais

próximo de 1 melhor é a qualidade da previsão.

$$POCID = \frac{1}{n} \sum_{i=1}^n a_i \text{ em que } \begin{cases} a_i = 1, \text{ se } (y_i - y_{i-1})(d_i - d_{i-1}) > 0 \\ a_i = 0, \text{ se } (y_i - y_{i-1})(d_i - d_{i-1}) \leq 0 \end{cases} \quad (4.1)$$

Uma variação do POCID também muito empregada neste trabalho é a chamada “taxa de acerto”. A taxa de acerto nada mais é do que o valor de POCID multiplicado por 100. Logo, este valor diz respeito a quantidade percentual de acertos de um determinado preditor (ou do robô) ao anunciar previsões para um dado intervalo de tempo. Como exemplo, pode-se ilustrar o uso do POCID e da taxa de acerto dizendo que, supondo um dado intervalo de tempo onde foram feitas 100 previsões e, após 100 dias, apurou-se os 100 valores reais. Com relação a tendência notou-se 60 previsões certas 40 previsões erradas. Nesse exemplo o POCID é 0,6 e a taxa de acerto é 60%.

Outras medidas explicitamente financeiras foram também utilizadas. Quando estas forem citadas estarão cotadas em moeda brasileira (R\$).

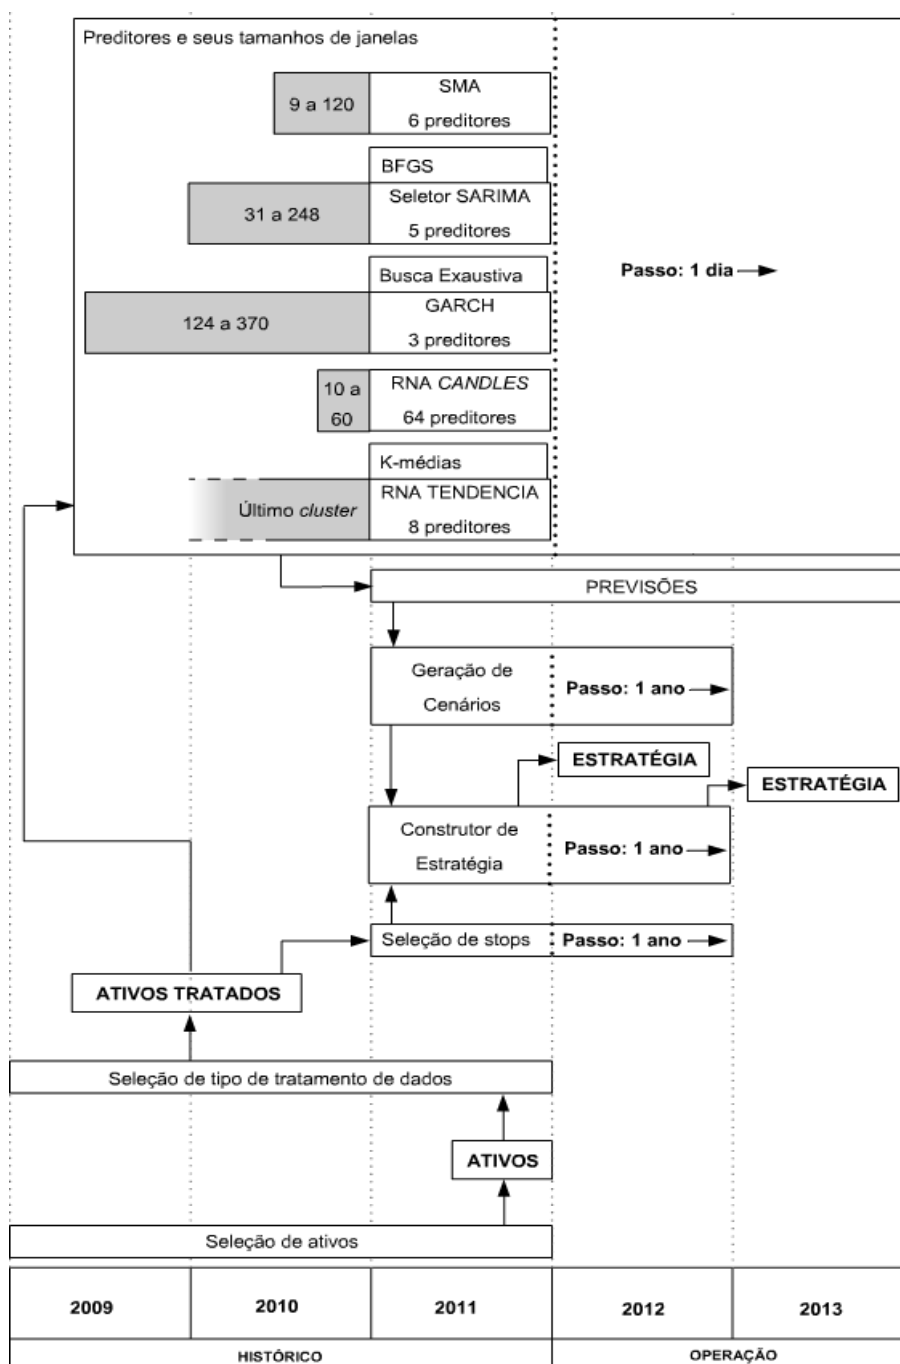
#### 4.1.5 Dinâmica geral de operação

A dinâmica geral de operação do robô investidor consiste em realizar o deslizamento dos métodos preditores e otimizadores sobre a série temporal. Esse deslizamento faz com que o intervalo que possui as observações necessárias a realização das previsões desloque-se no tempo. Esse deslocamento garante que cada preditor receberá a informação ajustada para o segmento da série de interesse no tempo correto. Essa técnica é denominada janelamento móvel e é realizada de formas diferentes para as diferentes classes de preditores existentes no robô.

Na categoria dos preditores econométricos, a sua concepção (como já abordado na [seção 3.2](#)) não está dissociada do uso do janelamento móvel, logo, quando da aplicação, essa técnica é encarada como condição obrigatória de uso para a realização de duas ou mais previsões. Já as redes neurais artificiais, atuando da mesma forma, podem ser aplicadas desde que a cada nova janela exista um retreino. O uso do janelamento móvel foi feito pois possibilita a adaptação dos métodos às condições mais recentes do mercado. Essa mesma abordagem já foi utilizada em diversos trabalhos, como [Gambogi \(2013\)](#), [Kaastra e Boyd \(1996\)](#) e [Nametala \*et al.\* \(2016\)](#).

Conforme pode ser observado na [Figura 17](#), o janelamento móvel foi amplamente empregado. Nesta figura não existe ainda uma separação dos módulos Extrator, Preditor e Negociador pois esta detalha apenas o fluxo das informações de modo geral, bem como a forma em que o robô perpassa ano a ano as séries. A separação dos eventos por módulo pode ser vista nas três subseções a seguir. Por isso recomenda-se ao leitor que, ao ler estas subseções, acompanhe em paralelo o diagrama mostrado na [Figura 17](#).

Figura 17 – Dinâmica de operação do robô (janelamento móvel).



Fonte: Elaborada pelo autor.

#### 4.1.5.1 Módulo Extrator

A seleção dos ativos é a primeira rotina executada pelo robô investidor. Para isso é feita uma análise da liquidez das principais séries temporais do mercado brasileiro nos anos de 2009, 2010 e 2011. São extraídos 10 ativos líquidos e o índice Bovespa. Nesse momento é realizada uma segunda análise acerca do efeito dos tratamentos de dados possíveis nas séries. O tratamento que melhor normalizar as séries é então selecionado. As séries são tratadas e, na sequência,



submetidas ao Módulo Preditor.

#### 4.1.5.2 Módulo Preditor

No Módulo Preditor estão implementados todos os preditores utilizados. No primeiro dia útil de 2011 dá-se início a realização das previsões. São geradas, para este ano, 248 valores com cada um dos 86 preditores, em cada um dos 11 ativos. Logo, somente em 2011, são gerados 234.608 valores. Para a geração das previsões, cada um dos preditores necessita de uma quantidade específica de dados históricos, no caso do SMA por exemplo são janelas que variam de 9 a 120 dias de comprimento; para o GARCH esse valor vai de 124 a 370, e; no caso da RNA de tendência, esse tamanho é definido a cada novo passo da janela móvel conforme tamanho do último *cluster* encontrado por um algoritmo K-médias. Os preditores paramétricos como SARIMA e GARCH ainda são otimizados, respectivamente, por um algoritmo BFGS e por uma busca exaustiva. As previsões realizadas em 2011 servem para apuração do POCID de cada um dos 86 preditores neste ano. Essa medida é então utilizada para analisar a melhor combinação possível de tipo de comitê de decisão e do tipo de momento de confiança dos preditores. O comitê de decisão é utilizado no Módulo Preditor para combinar os resultados dos preditores. Contudo, como será mostrado mais à frente, nem todos os preditores têm direito a participar do comitê selecionado. Antes eles são avaliados para averiguar se são confiáveis para o momento corrente. Esse método para definir qual a confiança no preditor é chamado de “momento de confiança”. As combinações possíveis de tipos de comitê de decisão e momentos de confiança são chamadas de “cenários”. Estes cenários, por sua vez, são então testados junto a objetivos de ganhos e perdas definidos por *stops* específicos em cada série. Essa composição é feita gerando-se uma estratégia otimizada que, por fim, será utilizada no ano seguinte, 2012. Ao fim de 2012 uma nova análise é desenvolvida para, por sua vez, gerar uma nova estratégia também otimizada que será aplicada a 2013.

Como observado, a definição dos cenários e dos *stops* acontecem em duas janelas lógicas móveis separadas, cada uma com passo de deslocamento feito anualmente. Já os preditores individualmente possuem janela móvel com passo diário, ou seja, no período de operação, a cada fechamento da bolsa, o algoritmo é inicializado e, com base nos dados históricos, antes da abertura do pregão no dia seguinte, é feita uma previsão de movimento para “amanhã”.

#### 4.1.5.3 Módulo Negociador

Após a geração da previsão para o dia seguinte, na abertura do mercado é realizada uma negociação que, caso a previsão esteja correta, gerará lucro ou, caso contrário, gerará prejuízo<sup>1</sup>. O Módulo Negociador, além de manipular as ordens, gera relatórios para análise de desempenho

<sup>1</sup> Prejuízo neste contexto pode significar perder dinheiro (manter/comprar um ativo e ele desvalorizar) ou deixar de ganhar dinheiro (vender/deixar de comprar um ativo e ele valorizar).

e fornece medidas importantes ao Módulo Preditor para que este se aprimore conforme o robô se desloca na série.

## 4.2 Detalhamento dos módulos

Postos os principais conceitos e decisões de implementação contidas no robô investidor, além da dinâmica geral de operação, cada um dos módulos já apresentados é detalhado na sequência.

### 4.2.1 Módulo Extrator

São atividades realizadas pelo Módulo Extrator:

- Montar uma carteira de investimento baseada em ativos de alta liquidez.
- Extrair as séries de um *homebroker* vinculado a uma corretora.
- Avaliar métodos para tratamento das séries na carteira.
- Aplicar os tratamentos selecionados às séries.
- Gerar o *dataset* e enviá-lo ao Módulo Preditor.

Estas são detalhadas nas subseções a seguir.

#### 4.2.1.1 Seleção de ativos por análise de liquidez

A primeira atividade a ser realizada pelo robô investidor é a seleção de ativos no mercado para construção de uma carteira de investimento. Um dos pontos importantes na operação do robô investidor é a garantia de que os ativos incluídos na carteira montada sejam líquidos. A liquidez é especialmente importante por dois motivos:

- o modelo de negociação adotado neste estudo segue o formato *daytrade*. Apesar de ser possível que não se opere em nenhum ativo selecionado em determinado dia durante a execução, isto é improvável, ou seja, na grande maioria das vezes o robô entra e sai do mercado com operações em vários ativos, todos os dias. Essa necessidade de disponibilidade de ações quando o robô resolve operar torna a liquidez uma característica necessária ao seu funcionamento.
- Um ativo com alta liquidez ameniza o efeito da chamada *slippage*. A *slippage* pode prejudicar a operação visto que esta diz respeito a diferença que pode existir entre o momento em que a ordem é submetida ao mercado e o momento em que ela entra no livro

de ofertas. Isso ocorre pois existe sempre uma diferença de preços entre a melhor oferta de venda e a melhor oferta de compra, intervalo também chamado de *spread*.

Com base nessa necessidade, foi desenvolvida uma metodologia que ranqueia os ativos com base na liquidez.

O método de avaliação da liquidez foi implementado por meio da linguagem de programação MQL embarcada no MT5. Antes da aplicação do *script* é necessário indicar quais ativos serão analisados. Para tanto, tomou-se como principais ativos as 50 maiores participações percentuais na carteira teórica do índice Bovespa (iBovespa) no ano de 2010. O ano de 2010 foi utilizado visando não gerar qualquer tipo de influência na seleção dos dados quando da montagem dos cenários, definição de *stops* e previsões que, segundo a dinâmica geral de operação do robô já vista, começam a ser realizadas em 2011. A carteira teórica do iBovespa para o ano de 2010 foi obtida por meio de solicitação feita ao sistema SAP BM&F BOVESPA (BM&F Bovespa, 2016c) em 03/08/2016 sob número de protocolo 20269721 e está disponível para consulta no Anexo A desta dissertação.

Após a definição dos 50 ativos principais, estes foram submetidos a três restrições:

- Não selecionar dois ativos correlatos ao mesmo tempo (*e.g.* PETR4 e PETR3), sendo que neste caso optou-se sempre pelo de maior participação percentual no índice.
- Selecionar somente os que tenham séries disponibilizadas pela corretora utilizada via MT5.
- Não considerar os ativos que não tenham séries disponíveis ao longo de todo o período definido para o estudo (primeiro dia de 2009 até o último dia de 2013).

Feita esta primeira triagem procedeu-se a execução do *script* no MT5. O *script* realiza os seguintes passos:

1. Coleta nos anos de 2009, 2010 e 2011 o somatório de volume financeiro e volume de *ticks* para cada ativo, separado por ano.
2. Cria dois *rankings* dos ativos por ano, um levando em conta o volume financeiro e outro o volume de *ticks*.
3. Contabiliza a quantidade de ocorrências dos ativos entre os 10 primeiros de cada *ranking* nos três anos analisados. Essa quantidade de ocorrências gerará um segundo tipo de *ranking*, o *ranking* de ocorrências de um ativo entre os 10 primeiros, em volume financeiro e volume de *ticks*.
4. Exclui da lista os ativos que não constam em nenhum dos *rankings* de ocorrências.

5. Por fim, seleciona apenas os ativos que se repetem em ambos os *rankings* de ocorrência levando-se em conta, primeiramente, o de volume por *ticks*.

Até o passo 4 foram filtrados os ativos mostrados na [Tabela 1](#) quanto a volume financeiro e na [Tabela 2](#) quanto a volume de *ticks*.

Tabela 1 – *Ranking* de ocorrências de ativos entre os 10 primeiros em 2009, 2010 e 2011 para volume financeiro.

<b>Ranking</b>	<b>Código do ativo</b>	<b>Número de ocorrências</b>
1	PETR4	3
2	VALE5	3
3	BVMF3	3
4	ITSA4	3
5	BBDC4	3
6	USIM5	3
7	GGBR4	3
8	GFSA3	2
9	BBAS3	2
10	LAME4	2
11	CSNA3	1
12	CMIG4	1

Fonte: Elaborada pelo autor.

Tabela 2 – *Ranking* de ocorrências de ativos entre os 10 primeiros em 2009, 2010 e 2011 para volume de *ticks*.

<b>Ranking</b>	<b>Código do ativo</b>	<b>Número de ocorrências</b>
1	PETR4	3
2	VALE5	3
3	BVMF3	3
4	GGBR4	3
5	ITSA4	3
6	BBDC4	3
7	USIM5	3
8	BBAS3	3
9	CSNA3	1
10	CYRE3	1

Fonte: Elaborada pelo autor.

Portanto, levando-se em conta o último passo (passo 5) selecionou-se com base nesta metodologia os ativos: PETR4, VALE5, BVMF3, GGBR4, ITSA4, BBDC4, USIM5, BBAS3, CSNA3 e CYRE3. Estes foram considerados os mais líquidos e, por este motivo, tomados para o estudo juntamente com BOVA11 (índice Bovespa).

#### 4.2.1.2 Seleção de tipo de tratamento de dados

A aplicação de tratamentos prévios aos dados das séries foi uma decisão de implementação que melhorou a qualidade das previsões no decorrer do projeto. Nesse sentido, para cada método, foi estabelecido um tipo de tratamento específico. Todos são comentados nas seções a seguir.

Os preditores SMA e Seletor SARIMA possuem por condição pré-estabelecida o uso da série de preços absolutos, ou seja, sem tratamento. Já ao GARCH deve-se aplicar uma integração na série de preços absolutos para obtenção dos retornos, que são posteriormente log-transformados. No caso das redes neurais artificiais, a atividade de pré-processamento e normalização de dados de entrada (amostra de treinamento) é importante pois tem a capacidade de reduzir ruídos e minimizar o tempo de processamento. Isso ocorre pois redes neurais artificiais com funções logísticas sigmóides nos neurônios da camada escondida comportam-se melhor quando os valores de entrada estão compreendidos fora da região de saturação destas funções, ou seja, entre 0 e 1 (SOLA; SEVILLA, 1997). Segundo Azadeh *et al.* (2008), o uso de dados transformados é útil na maioria dos métodos heurísticos, principalmente quando se lida com problemas de previsão, como nas séries temporais. O trabalho de Asadi *et al.* (2012) aplica o pré-processamento e normalização de dados como parte de uma abordagem envolvendo redes neurais artificiais na previsão de valores no mercado financeiro. Este mesmo autor em suas conclusões afirma que esta etapa apresentou significativo efeito na boa qualidade dos resultados. Por fim, outros estudos como em Oliveira e Meira (2006) e Niska *et al.* (2004) mostram que o uso do tratamento de dados em abordagens heurísticas é aplicável visto que os resultados são melhorados frente a quando esta etapa não é realizada.

No presente estudo foram desenvolvidas duas abordagens específicas para o tratamento de dados em cada uma das classes da categoria redes neurais artificiais, conforme discutido a seguir.

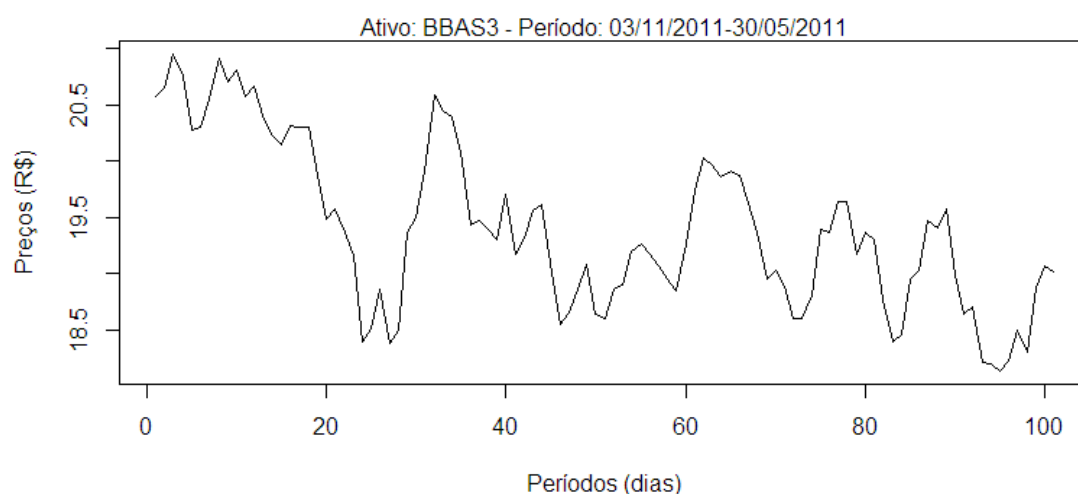
##### 4.2.1.2.1 Tratamento de dados para RNA de tendência

O tratamento realizado nos dados para a RNA de tendência teve por objetivo criar uma nova série, derivada da série de preço de fechamento, que fosse capaz de explicar acúmulos de tendência nos momentos em que fossem constatados movimentos na mesma direção. Nesse sentido, definiu-se o intervalo entre 0 e 1 como espaço de oscilação da tendência. Isto foi feito também pois, neste caso, já se padronizam os valores no mesmo intervalo em que está situada a região dinâmica das funções logísticas sigmóides presente nos neurônios da camada escondida. Na sequência, separou-se o subespaço existente entre 0.45 e 0.55 como uma área de indecisão, ou seja, nenhum valor é gerado nesta faixa. Este intervalo foi convencionado buscando-se garantir que apenas valores suficientemente altos (maiores que 0.55) ou baixos (menor que 0.45) quando previstos fossem considerados evidências consistentes de tendência. Portanto, definiu-se como regra para geração da série de tendência que:

1. Ao constatar-se uma reversão de alta para baixa na série de preço de fechamento gera-se na série de tendência um valor igual a 0.45.
2. Ao constatar-se uma reversão de baixa para alta na série de preço de fechamento gera-se na série de tendência um valor igual a 0.55.
3. Ao constatar-se uma alta seguida de alta, então adiciona-se 0.05 ao valor anterior. Dessa forma, altas consecutivas vão acumulando 0.05, dia a dia, até quando uma reversão ocorre. Neste momento o valor é convertido para 0.45 conforme regra 1.
4. Ao constatar-se uma baixa seguida de baixa, então subtrai-se 0.05 do valor anterior. Dessa forma, baixas consecutivas vão decrescendo 0.05 até quando uma reversão ocorre. Neste momento o valor é convertido para 0.55 conforme regra 2.

Como exemplo, pode-se ver a conversão da série de preço de fechamento, no ativo BBAS3 nos 100 primeiros dias de 2011 na [Figura 18](#), para a série de tendência, na [Figura 19](#).

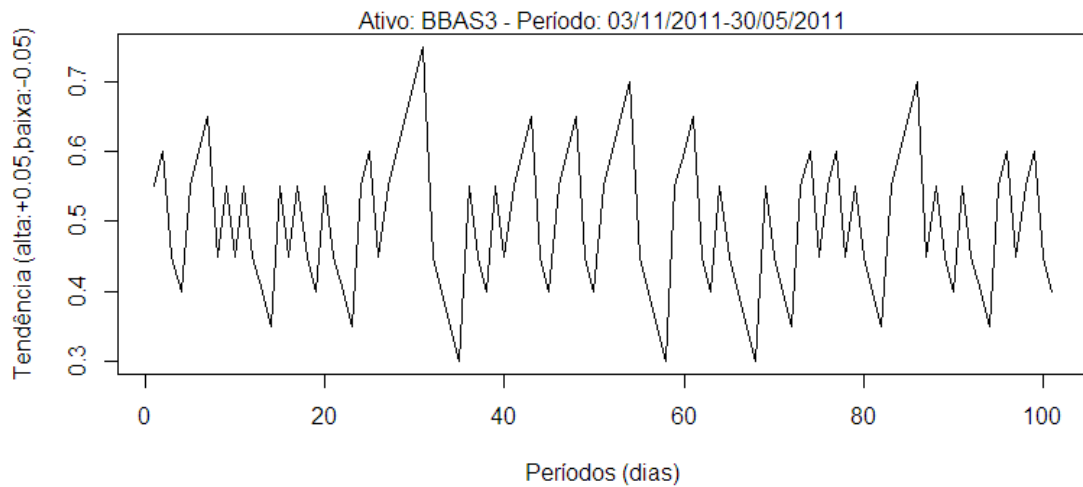
Figura 18 – Preço de fechamento para BBAS3 nos 100 primeiros dias de 2011.



Fonte: Elaborada pelo autor.

Pretendeu-se com a série de tendência criar uma estrutura que possa dar condição de previsão em uma dimensão não constante nas convencionais do *candle*. Além disso, a série de tendência é univariada, ou seja, não é composta de outras séries (como é o caso do *candle* que é formado de fechamento, abertura, mínima, máxima e volume). Isso facilita a definição do tamanho da janela móvel pois, como se trata apenas de um conjunto de dados, pode-se aplicar técnicas de clusterização e tomar como conjunto corrente apenas o último *cluster* encontrado. Outro ponto é o formato “comportado” da série de tendência frente a série de preço. Enquanto na série de preços existem grandes oscilações e, nesse sentido, dificuldades no desenvolvimento de padrões gráficos, na série de tendência o “desenho” que é construído ao longo do tempo é mais padronizado, sendo composto apenas de picos e vales curtos. Todas essas características foram motivo para o desenvolvimento de uma rede neural específica para este tipo de série.

Figura 19 – Série de tendências para BBAS3 nos 100 primeiros dias de 2011.



Fonte: Elaborada pelo autor.

Na revisão bibliográfica realizada não se observou nenhum trabalho onde é aplicado qualquer mecanismo similar a este proposto.

#### 4.2.1.2.2 Tratamento de dados para RNA de *candles*

A RNA de *candles* trabalha com padrões construídos a partir das cinco dimensões do *candle*. Portanto, buscou-se nesta fase do robô avaliar mecanismos que permitissem pré-processar e normalizar os dados contidos nas séries temporais de abertura, fechamento, máxima, mínima e volume. Para isso, baseado em alguns dos passos já comumente utilizados para métodos econométricos, procedeu-se a aplicação de estudos que levassem em conta as seguintes avaliações:

- Média e desvio padrão mantendo-se os mais constantes possíveis, numa análise entre os anos da amostra e, nesta também, a menor quantidade de *outliers* possível.
- Distribuição de dados da amostra com aderência a mais próxima possível a de uma normal baseada em análise gráfica de resíduos teóricos *vs.* resíduos estimados, gráfico de frequências e, aplicação de teste de normalidade de *Shapiro-Wilk*<sup>2</sup>.

Foram avaliados, sob a perspectiva destas duas análises, um conjunto de 14 diferentes tipos de tratamentos para a série de preço de fechamento, que foi utilizada como referência para as demais. Os mesmos são explicados a seguir.

Sendo  $s$  uma série de preços:

<sup>2</sup> A formulação deste teste pode ser vista em (YAP; SIM, 2011).

1. Preço absoluto (P), sendo a [Equação 4.2](#):

$$P = s \quad (4.2)$$

2. Preço absoluto log-transformado (PL), sendo a [Equação 4.3](#):

$$PL = \log(s) \quad (4.3)$$

3. Preço absoluto com remoção de tendência por clusterização (PC), sendo a [Equação 4.4](#). Neste caso,  $i$  é o índice do preço na série,  $c$  é o índice do *cluster* onde o preço está contido conforme clusterização realizada por um algoritmo K-médias com  $k$  definido via Método de *Elbow*,  $\mu_c$  é a média das observações do *cluster*  $c$  e  $\sigma_c$  é o desvio padrão das observações do *cluster*  $c$ :

$$PC = \frac{(s_i)_c - \mu_c}{\sigma_c} \quad (4.4)$$

4. Preço absoluto log-transformado com remoção de tendência por clusterização (PLC), sendo a [Equação 4.5](#) com os mesmo índices e variáveis mostrados na formulação da [Equação 4.4](#):

$$PLC = \frac{\log(s_i)_c - \log(\mu)_c}{\log(\sigma)_c} \quad (4.5)$$

5. Retornos do preço absoluto (RP), sendo a [Equação 4.6](#):

$$RP = s_i - s_{i-1} \quad (4.6)$$

6. Retornos do preço absoluto log-transformados (RPL), sendo a [Equação \(48\)](#):

$$RPL = PL_i - PL_{i-1} \quad (4.7)$$

7. Retornos do preço absoluto com remoção de tendência por clusterização (RPC), sendo a [Equação 4.8](#):

$$RPC = PC_i - PC_{i-1} \quad (4.8)$$

8. Retornos do preço absoluto log-transformado com remoção de tendência por clusterização (RPLC), sendo a [Equação 4.9](#):

$$RPLC = PLC_i - PLC_{i-1} \quad (4.9)$$



9. Retornos do preço absoluto log-transformados com detecção/ajuste de *outliers* (RPLSO).
10. Retornos do preço absoluto com remoção de tendência por clusterização e com detecção/ajuste de *outliers* (RPCSO).
11. Retornos do preço absoluto log-transformado com remoção de tendência por clusterização e com detecção/ajuste de *outliers* (RPLCSO).
12. Retornos do preço absoluto log-transformado com detecção/ajuste de *outliers* e com padronização no intervalo entre 0 e 1 (T1).
13. Retornos do preço absoluto com remoção de tendência por clusterização, com detecção/ajuste de *outliers* e com padronização no intervalo entre 0 e 1 (T2).
14. Retornos do preço absoluto log-transformado com remoção de tendência por clusterização, com detecção/ajuste de *outliers* e com padronização no intervalo entre 0 e 1 (T3).

A detecção e ajuste de *outliers* vista nos itens 9, 10, 11, 12, 13 e 14 na listagem anterior diz respeito a um método que foi empregado buscando suavizar a série e, assim, tratar observações que estivessem “fora do padrão” dos demais dados. Nesse sentido, foi considerado *outlier* toda e qualquer observação que estivesse posicionada no primeiro ou quarto quartil da distribuição amostral. Este método conhecido como *estudentização* faz o escalonamento dos dados considerando as possíveis diferenças existentes nas variâncias dos resíduos (CAMPELO, 2011) (WILCOX, 2010). *Outliers* detectados foram substituídos pelo resultado de uma média aritmética simples entre o valor “não *outlier*” imediatamente anterior e o valor “não *outlier*” imediatamente posterior a sua ocorrência. A formulação do método é a mostrada na Equação 4.10, onde  $s_i$  é um *outlier* detectado,  $i$  é o índice deste na amostra,  $k$  é a quantidade de defasagens até o primeiro valor válido antes da ocorrência de  $s_i$  e  $m$  a quantidade de defasagens até o primeiro valor válido após a ocorrência de  $s_i$ .

$$s_i = \frac{s_{i-k} + s_{i+m}}{2} \quad (4.10)$$

A padronização comentada nos itens 12, 13 e 14 trata-se da transformação linear dos dados para o intervalo entre 0 e 1. Isto é feito para as dimensões de fechamento, abertura, mínima e máxima, que são padronizadas em conjunto por estarem todas na mesma escala de preço. Na sequência é padronizado em separado o volume que está na escala de volume de *ticks*. O conjunto de dados é então montado concatenando todas as dimensões (mais detalhes sobre a construção do conjunto de dados na seção que trata do Módulo Preditor). Na Equação 4.11 é mostrado o processo de padronização adotado.

$$y_i = \frac{s_i - s_{min}}{s_{max} - s_{min}} \quad (4.11)$$

Levando-se em conta os 2 métodos de avaliação dos tratamentos e os 14 tipos de tratamento a serem avaliados, a seguir é feita uma exemplificação da forma de aplicação para o ativo BBAS3 no período histórico (2009 a 2011). Quanto a busca por média e desvio padrão constantes, pode-se ver nas tabelas 3 e 4 o desvio padrão destas duas medidas calculado com base nas três observações fornecidas para cada ano. Percebe-se neste ativo que os tratamentos RP, T1, T2 e T3 são praticamente similares quanto a capacidade de fixar uma média e uma variância constante ao longo do tempo. Vê-se também uma sutil vantagem dos métodos T1 e T2 nas médias e de T1 nos desvios.

Tabela 3 – Médias ano a ano no período histórico (2009 a 2011) de BBAS3 para os tratamentos P, RP, T1, T2 e T3 e respectivos desvios padrão das médias de cada.

Tratamento	2009	2010	2011	Desvio padrão
P	25,71	24,62	20,44	2,78
RP	0,05	-0,03	-0,02	0,04
T1	0,51	0,49	0,50	0,01
T2	0,51	0,49	0,50	0,01
T3	0,52	0,49	0,50	0,02

Fonte: Elaborada pelo autor.

Tabela 4 – Desvios padrão ano a ano no período histórico (2009 a 2011) de BBAS3 para os tratamentos P, RP, T1, T2 e T3 e respectivos desvios-padrão, dos desvios padrão, de cada.

Tratamento	2009	2010	2011	Desvio padrão
P	3,56	2,98	2,38	0,59
RP	0,51	0,43	0,35	0,08
T1	0,19	0,18	0,18	0,01
T2	0,16	0,20	0,19	0,02
T3	0,17	0,21	0,19	0,02

Fonte: Elaborada pelo autor.

Esse comportamento de sutil vantagem de T1, frente aos outros tratamentos, foi observado em quase todos os ativos tanto para a análise de média, quanto para o desvio padrão. Essa situação fica mais evidenciada quando gera-se um desvio padrão geral envolvendo todos os desvios padrão calculados em todos os ativos, conforme pode se ver nas tabelas 5 e 6. Para a média, o tratamento T1 leva vantagem sobre os outros acusando 0,2 de desvio médio quanto aos desvios padrão e, empata com T2 em 0,1 de desvio médio quanto às médias. Portanto, neste tipo de análise, pode-se dizer que o tratamento T1 (retornos do preço absoluto log-transformados com detecção/ajuste de *outliers* e com padronização no intervalo entre 0 e 1) se sobressaiu.

Quanto à preferência por métodos que diminuíssem a quantidade de *outliers* na amostra de dados, ainda se tomando como exemplo BBAS3, pode-se ver um comparativo que mostra o cruzamento das observações de cada tratamento frente aos resíduos de uma normal teórica na Figura 20. Mais uma vez o tratamento T1 se sobressaiu nesta análise. Neste gráfico também

Tabela 5 – Desvio médio para todos os ativos do *dataset* levando-se em conta os desvios padrão das medias nos anos de 2009, 2010 e 2011 em cada um dos tratamentos P, RP, T1, T2 e T3.

Ativo	P	RP	T1	T2	T3
BBAS3	2,95	0,03	0,02	0,01	0,01
BBDC4	2,37	0,01	0,01	0,01	0,01
BOVA11	6,97	0,09	0,02	0,01	0,02
BVMF3	1,04	0,06	0,01	0,02	0,02
CSNA3	3,09	0,04	0,02	0,03	0,02
CYRE3	2,82	0,04	0,02	0,01	0,01
GGBR4	3,50	0,04	0,02	0,02	0,02
ITSA4	0,86	0,01	0,01	0,02	0,01
PETR4	2,78	0,04	0,01	0,01	0,02
USIM5	4,11	0,04	0,02	0,03	0,03
VALE5	5,40	0,05	0,02	0,01	0,01
DESVIO MÉDIO	3,26	0,04	0,01	0,01	0,02

Fonte: Elaborada pelo autor.

Tabela 6 – Desvio médio para todos os ativos do *dataset* levando-se em conta os desvios padrão, dos desvios padrão, nos anos de 2009, 2010 e 2011 em cada um dos tratamentos P, RP, T1, T2 e T3.

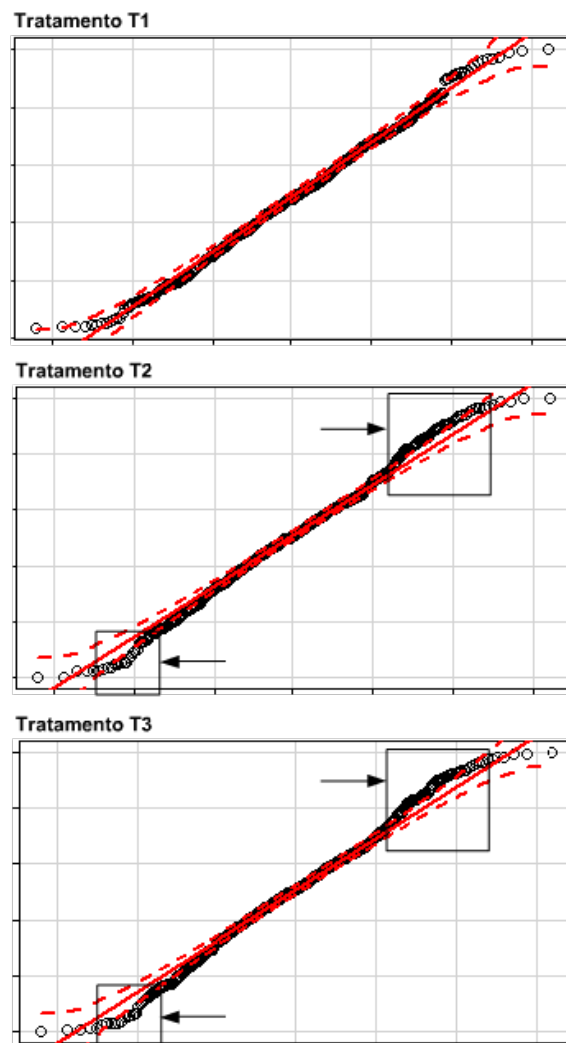
Ativo	P	RP	T1	T2	T3
BBAS3	1,43	0,01	0,03	0,06	0,06
BBDC4	0,76	0,02	0,02	0,05	0,05
BOVA11	3,42	0,05	0,01	0,05	0,04
BVMF3	0,57	0,02	0,02	0,03	0,03
CSNA3	1,11	0,05	0,02	0,02	0,01
CYRE3	2,22	0,07	0,03	0,04	0,04
GGBR4	1,28	0,09	0,02	0,03	0,03
ITSA4	0,20	0,01	0,02	0,04	0,02
PETR4	0,59	0,08	0,01	0,02	0,02
USIM5	0,67	0,07	0,02	0,00	0,01
VALE5	0,78	0,02	0,03	0,02	0,02
DESVIO MÉDIO	1,18	0,04	0,02	0,03	0,03

Fonte: Elaborada pelo autor.

é possível perceber que os dados oriundos de T1 possuem mais aderência a uma distribuição normal, pois estes não apresentam caudas muito evidentes. Este mesmo comportamento foi também observado na maioria dos ativos analisados<sup>3</sup>.

<sup>3</sup> Caso seja interesse do leitor, mais gráficos sobre este tipo de estudo estão disponíveis para consulta no endereço eletrônico da referência [Nametala \(2016\)](#).

Figura 20 – Comparativo entre os resíduos teóricos de uma distribuição normal frente aos gerados pelos tratamentos T1, T2 e T3 entre os anos de 2009 e 2011 para o ativo BBAS3. As caudas fora da área pontilhada vermelha nas imagens indicam a existência de caudas com possíveis *outliers*.



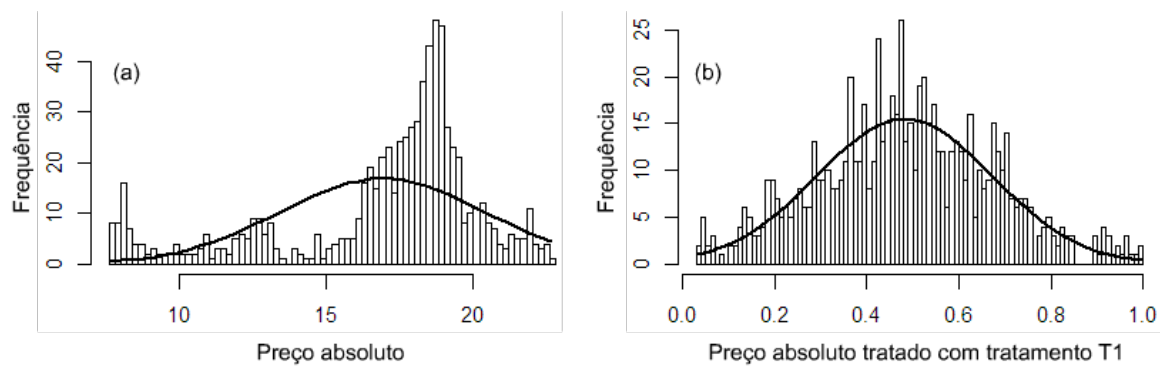
Fonte: Elaborada pelo autor.

Ainda sobre a capacidade destes tratamentos em transformar a série original em outra que tenha maior aderência a uma distribuição normal, foram realizadas averiguações com a aplicação do teste de *Shapiro-Wilk* à todas as séries e com todos os tratamentos. Considerando os valores obtidos para *p-valor* observou-se que o tratamento T1 leva vantagem ao indicar uma maior ocorrência de aceitação da hipótese nula de normalidade. Esse comportamento pode ser observado em todas as séries e não somente em BBAS3 que, neste caso, apenas foi utilizada como exemplo.

Desta forma, conforme até então discutido e, postos os resultados obtidos, optou-se pela utilização do tratamento T1 no robô investidor quando da utilização dos preditores da classe RNA de *candles*. Por fim, nas distribuições de frequência mostradas na [Figura 21](#), pode-se ver, respectivamente, o efeito do tratamento T1 quando converte a dimensão de preço absoluto P para

T1, qual na sequência, passa a ser submetida ao Módulo Preditor.

Figura 21 – Distribuição de preços absolutos (a) e distribuição de preços absolutos após tratamento T1 (b) no ativo BBAS3 entre 2009 e 2011 (inclusive).



Fonte: Elaborada pelo autor.

### 4.2.2 Módulo Negociador

São atividades realizadas pelo Módulo Negociador:

- Interpretar os sinais de operação gerados pelo Módulo Preditor.
- Realizar a simulação de alocação e execução de ordens com base no modelo de negociação definido.
- Gerar medidas de avaliação baseadas nas métricas de interesse.
- Realimentar o Módulo Preditor com as medidas feitas a fim de possibilitar a otimização do sistema como um todo.
- Gerar relatórios para o investidor.

Todas estas são detalhadas a seguir.

#### 4.2.2.1 Modelo de negociação

Apesar de gerarem previsões, os preditores econométricos e as redes neurais artificiais por si só não atuam diretamente no mercado, ou seja, não dão sinais de compra ou venda. A atuação do Módulo Preditor é justamente para fundir os valores preditos em um sinal único, cuja interpretação é feita via algum modelo de negociação pré-definido dentro de um Módulo Negociador.

Existem diversas estratégias para se operar no mercado financeiro e uma delas é a chamada arbitragem. Segundo [Siegel \(2009\)](#), a arbitragem consiste em avaliar as discrepâncias temporárias nos preços de séries de bens que sejam idênticos (como é o caso do dólar cheio com o mini dólar) ou bens que estejam altamente correlacionados, como papéis da mesma empresa (PETR3 e PETR4, por exemplo). Caso o valor de um bem caia ou aumente suficientemente em relação ao seu par entende-se que uma oportunidade de operação no mesmo sentido exista no ativo que se está operando.

Foi utilizada a estratégia de arbitragem no robô investidor, visto que, as operações executadas na série real dependem dos valores obtidos na série predita, ou seja, arbitra-se entre os sinais previstos e a série real. Para tanto são utilizadas como entradas no Módulo Negociador as séries de todos os ativos com suas respectivas cotações sem tratamento e o arquivo que contém os sinais de operação gerados pelo Módulo Preditor. Neste arquivo de sinais apenas três estados podem ser vinculados a uma determinada data (obrigatoriamente dia útil de operação na bolsa), sendo:

- Executar compra: Representado pelo sinal 1.
- Executar venda: Representado pelo sinal 0.

- Não executar nenhuma operação: Representado pelo sinal -1.

Estes estados são usados no modelo de negociação que opera da seguinte forma. Caso o sinal previsto para o dia seguinte seja 1, entende-se que, no dia seguinte haverá uma alta na série real. Ao contrário, caso o sinal previsto para o dia seguinte seja 0, entende-se então que, no dia seguinte haverá uma baixa no preço real. Com os sinais de alta e baixa definidos parte-se para a etapa de operação com lançamento de ordens. No caso de um sinal de alta no dia seguinte, executa-se uma ordem de compra a mercado na abertura do pregão. Ao fim do dia, caso não sejam atingidos pontos de *stops*, independentemente do valor da cotação no fechamento do pregão, fecha-se posição realizando-se uma ordem de venda. A situação é semelhante quando o sinal é de baixa: na abertura executa-se uma venda descoberta<sup>4</sup> e no fim do dia, mais uma vez caso não sejam atingidos pontos de *stops*, fecha-se a posição realizando uma compra para devolução do ativo. Caso o valor previsto seja -1 entende-se que, na data corrente, não deve ser realizado nenhum tipo de operação. Com isso ordens não serão lançadas até que uma nova data, com valor diferente de -1, seja identificada.

Como pode-se perceber, os rendimentos neste módulo corresponderão ao somatório dos lucros e prejuízos tidos com todas as operações, que neste caso podem contabilizar até um total máximo de 40 por mês e por ativo (considerando-se um mês sem feriados, ou seja, com 20 dias úteis). É um sistema de operações *daytrade*, pois, pode-se operar todos os dias, duas vezes ao dia. Existem também características menos evidentes de *swing trade*, pois, neste caso, pode-se operar apenas poucas vezes por semana dependendo dos sinais. Quanto aos rendimentos, tendo o robô um acerto no tipo de operação (no caso, 1 ou 0), o tamanho completo do *candle* pode ser integralizado como lucro, ou, caso contrário, também como prejuízo. Isso ocorre de formas diferentes dependendo do caso, pois a este processo existe atrelado um tratamento de riscos que abrange o posicionamento de pontos para *stoploss* e *takeprofit*. Estes são melhores detalhados a seguir.

#### 4.2.2.2 Simulação

A simulação de uma negociação no mercado tem início com a captura do sinal gerado pelo módulo preditor para uma data específica. Seguindo o diagrama da [Figura 22](#) pode-se tomar como exemplo o sinal do dia 01/02. Após a captura deste sinal o mesmo é então inserido no sub-módulo “Comparador” que compara o sinal previsto com o sinal real para a mesma data. Neste momento, 6 resultados são possíveis conforme visto na coluna “Tipo de operação” do [Quadro 5](#). As quatro primeiras possibilidades direcionam o processo para um dos 4 algoritmos

<sup>4</sup> A venda descoberta ou venda à descoberto trata da possibilidade de realizar uma operação à mercado sem necessariamente ter-se em mãos a ação que se deseja negociar. Neste caso, a ação é adquirida de forma “emprestada” do balcão de negócios e, assim que o investidor a possuir, esta será vendida. No momento em que então, uma compra for realizada, a ação será devolvida ao balcão pelo seu preço corrente. Esse movimento pode gerar lucros caso a venda seja realizada por um preço maior que o preço futuro de compra. Normalmente para se realizar este tipo de operação é necessário que exista depositado junto a corretora uma garantia financeira.

situados dentro do próximo sub-módulo, o “Simulador de ordens”. Caso o tipo de operação seja “Não opera” então neste ponto será encerrado o processo.

Quadro 5 – Resultados possíveis para tipo de operação.

Sinal previsto	Sinal real	Algoritmo
1	1	Compra certa
1	0	Compra errada
0	1	Venda errada
0	0	Venda certa
-1	1	Não opera
-1	0	Não opera

Os algoritmos do “Simulador de ordens” têm por objetivo simular as operações no mercado, levando-se em conta principalmente o posicionamento dos pontos de *stoploss* e *takeprofit*. Os mesmos são divididos entre compra certa ou errada, e, venda certa ou errada:

- Compra certa: Esse algoritmo é executado quando o sinal de previsão para compra (1) está correto, ou seja, é igual ao sinal real (1). Esse procedimento gerará um retorno positivo e pode ser visto no Algoritmo 1.
- Compra errada: Esse algoritmo é executado quando o sinal de previsão para compra (1) está errado, ou seja, é diferente do sinal real (0). Esse procedimento gerará um retorno negativo e pode ser visto no Algoritmo 2.
- Venda certa: Esse algoritmo é executado quando o sinal de previsão para venda (0) está correto, ou seja, é igual ao sinal real (0). Esse procedimento gerará um retorno positivo e pode ser visto no Algoritmo 3.
- Venda errada: Esse algoritmo é executado quando o sinal de previsão para venda (0) está errado, ou seja, é diferente do sinal real (1). Esse procedimento gerará um retorno negativo e pode ser visto no Algoritmo 4.

O “Simulador de ordens”, após acionado o algoritmo correspondente, gerará um valor de retorno que, dia a dia, irá sendo somado a um montante único. Esse montante único corresponderá aos rendimentos apurados no período da simulação.

Tanto os rendimentos obtidos quanto outras medidas importantes, como número de ordens executadas, taxas de acerto e POCID, são por sua vez, submetidas ao sub-módulo “Avaliador de Estratégia”. Este irá produzir análises que podem ser aproveitadas pelo investidor ou gerar dados que, como o POCID e rendimentos financeiros, podem ser utilizados para realimentar o Módulo Preditor visando acurar os processos de otimização.

O Módulo Preditor é o último a ser explicado e está detalhado na próxima seção.



---

**Algoritmo 1** Compra certa (Lucros)

---

```

1: função COMPRACERTA(takeprofit,fechamento,abertura,maxima)
2:   lucro  $\leftarrow$  0
3:   se takeprofit < fechamento então
4:     lucro  $\leftarrow$  (takeprofit – abertura)
5:   senão
6:     se takeprofit < maxima então
7:       lucro  $\leftarrow$  (takeprofit – abertura)
8:     senão
9:       lucro  $\leftarrow$  (fechamento – abertura)
10:    fim se
11:  fim se
12:  devolve lucro
13: fim função

```

---



---

**Algoritmo 2** Compra errada (Prejuízos)

---

```

1: função COMPRAERRADA(stoploss,fechamento,abertura,minima)
2:   prejuizo  $\leftarrow$  0
3:   se stoploss > fechamento então
4:     prejuizo  $\leftarrow$  (stoploss – abertura)
5:   senão
6:     se stoploss > minima então
7:       prejuizo  $\leftarrow$  (stoploss – abertura)
8:     senão
9:       prejuizo  $\leftarrow$  (fechamento – abertura)
10:    fim se
11:  fim se
12:  devolve prejuizo
13: fim função

```

---



---

**Algoritmo 3** Venda certa (Lucros)

---

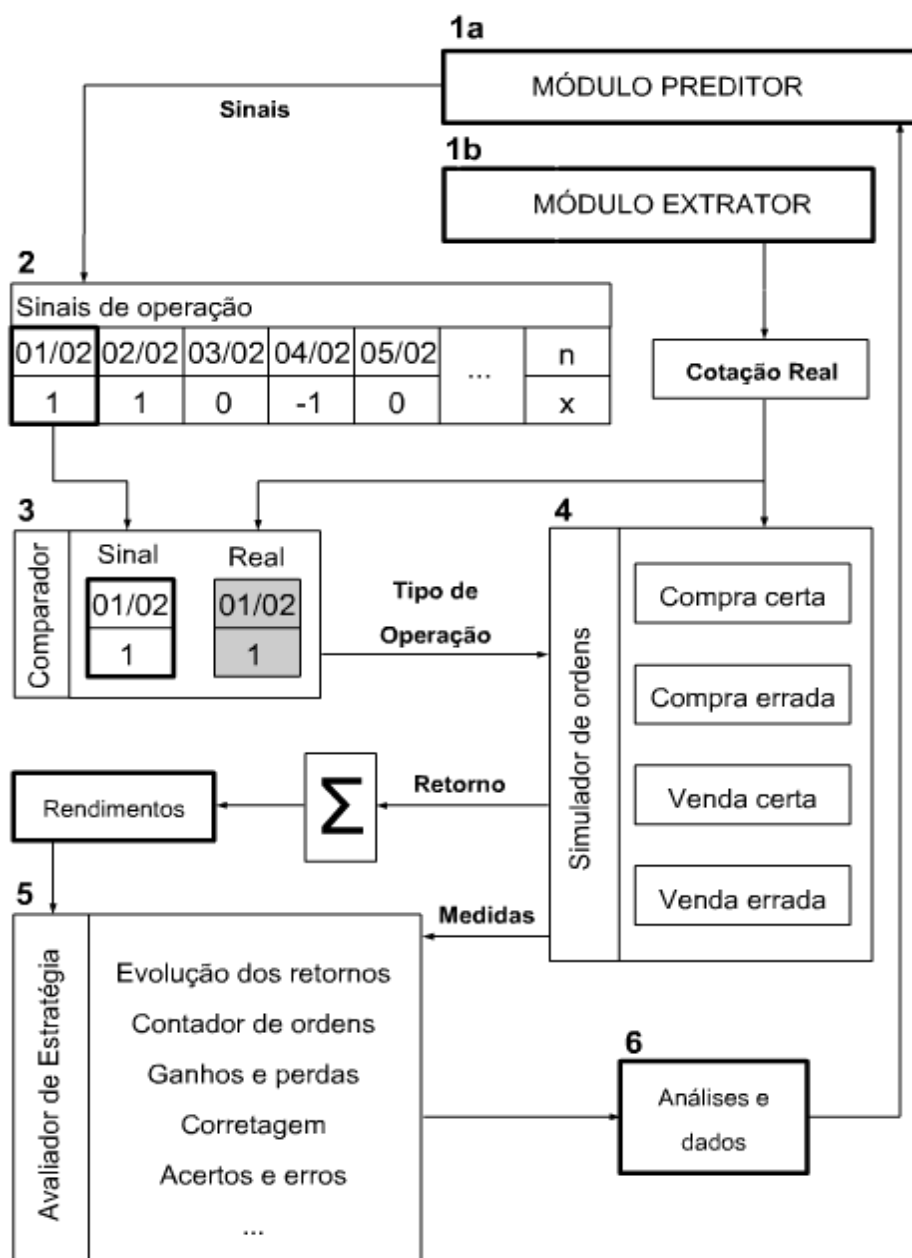
```

1: função VENDACERTA(takeprofit,fechamento,abertura,minima)
2:   lucro  $\leftarrow$  0
3:   se takeprofit > fechamento então
4:     lucro  $\leftarrow$  (takeprofit – abertura)
5:   senão
6:     se takeprofit > minima então
7:       lucro  $\leftarrow$  (takeprofit – abertura)
8:     senão
9:       lucro  $\leftarrow$  (fechamento – abertura)
10:    fim se
11:  fim se
12:  devolve (lucro * (–1))
13: fim função

```

---

Figura 22 – Detalhamento do fluxo de informações e sub-módulos do Módulo Negociador.



Fonte: Elaborada pelo autor.

### 4.2.3 Módulo Preditor

São atividades realizadas pelo Módulo Preditor:

- Capturar o *dataset* gerado pelo Módulo Extrator.
- Otimizar os preditores de forma a obter as melhores configurações no segmento de tempo corrente.
- Avaliar os preditores otimizados e definir quais são confiáveis para o uso no segmento de tempo corrente.

**Algoritmo 4** Venda errada (Prejuízos)

---

```

1: função VENDAERRADA(stoploss, fechamento, abertura, maxima)
2:   prejuízo  $\leftarrow 0$ 
3:   se stoploss < fechamento então
4:     prejuízo  $\leftarrow$  (stoploss – abertura)
5:   senão
6:     se stoploss < maxima então
7:       prejuízo  $\leftarrow$  (stoploss – abertura)
8:     senão
9:       prejuízo  $\leftarrow$  (fechamento – abertura)
10:    fim se
11:  fim se
12:  devolve (prejuízo * (–1))
13: fim função

```

---

- Combinar as previsões geradas pelos preditores confiáveis.
- Definir pontos de *stoploss* e *takeprofit*.
- Otimizar a estratégia de negociação avaliando cenários de operação que envolvam os *stops* definidos, os métodos para avaliação da confiança nos preditores e os métodos para combinação de previsões.
- Gerar sinais de compra e venda para todos os ativos do *dataset* baseado na melhor estratégia obtida por meio do processo de avaliação de estratégias.
- Gerar arquivo de sinais e submetê-lo ao Módulo Negociador.

Estas estão descritas nas subseções a seguir.

#### 4.2.3.1 Otimização dos preditores

Após o Módulo Extrator realizar o tratamento das séries, o *dataset* completo é enviado ao Módulo Preditor. De posse deste *dataset*, cada classe de preditor será otimizada de uma forma específica a fim de gerar previsões que, mais tarde, serão avaliadas para definir quando cada preditor deverá ser utilizado. Essa otimização é realizada com janelamento móvel. Nesse sentido, em qualquer uma das classes de preditores, o Módulo Preditor constrói conjuntos de dados específicos baseados nos intervalos das janelas e, deslocamento a deslocamento, os utiliza como entrada para os preditores. Na [Figura 23](#) é mostrado um diagrama que apresenta, de forma geral, o fluxo das informações nos módulos Extrator e Preditor. Todos os componentes deste fluxograma localizados a partir das janelas móveis fazem parte do Módulo Preditor. Dentro de uma mesma classe aplica-se a mesma forma de otimização e previsão. Cada uma destas formas é detalhada a seguir, por categoria.

#### 4.2.3.1.1 Preditores econométricos

Os preditores da classe SMA recebem como entrada apenas a dimensão “Preço de Fechamento” do *candle*, sem qualquer tipo de tratamento – preço absoluto (P). Como o tamanho das janelas móveis é fixo, este é utilizado para identificar os preditores. Portanto, são utilizadas 6 SMA's com os seguintes tamanhos de janela móvel: 9, 21, 30, 45, 60 e 120 dias. O resultado da predição é “preço de fechamento previsto para o dia seguinte”.

Já os preditores da classe Seletor SARIMA podem mudar de acordo com a janela móvel. Neste sentido, deu-se a esta classe de preditor a denominação “Seletor” justamente pelo fato de que, conforme o resultado da otimização dos seus parâmetros, pode-se gerar modelos derivados do ARMA, do ARIMA ou do SARIMA. Para tanto é aplicado o algoritmo de otimização BFGS que minimiza o resultado da métrica AIC obtendo, por fim, para a janela móvel corrente, os valores que denotam melhor ajustamento do modelo nos parâmetros  $p$ ,  $d$ ,  $q$ ,  $P$ ,  $D$  e  $Q$  com uma frequência  $f$  de 20 dias. O cálculo das diferenças para estacionariedade é feita segundo o método KPSS. Vale ressaltar que, em todos estes seis parâmetros, são possíveis variações que vão de 0 a 5 termos. Portanto, será sempre selecionado um modelo dentre 46.656 possíveis, dia a dia. No [Quadro 6](#) podem ser vistas as combinações mais comuns e os respectivos modelos que são gerados quando estas ocorrem. Assim como nas SMA's, os preços de fechamento absoluto (P) são utilizados como entradas no Seletor SARIMA. Os tamanhos das janelas também são fixos, sendo estes 31, 62, 124, 186 e 248 dias. A saída destes 5 preditores corresponde a “preço de fechamento previsto para o dia seguinte”.

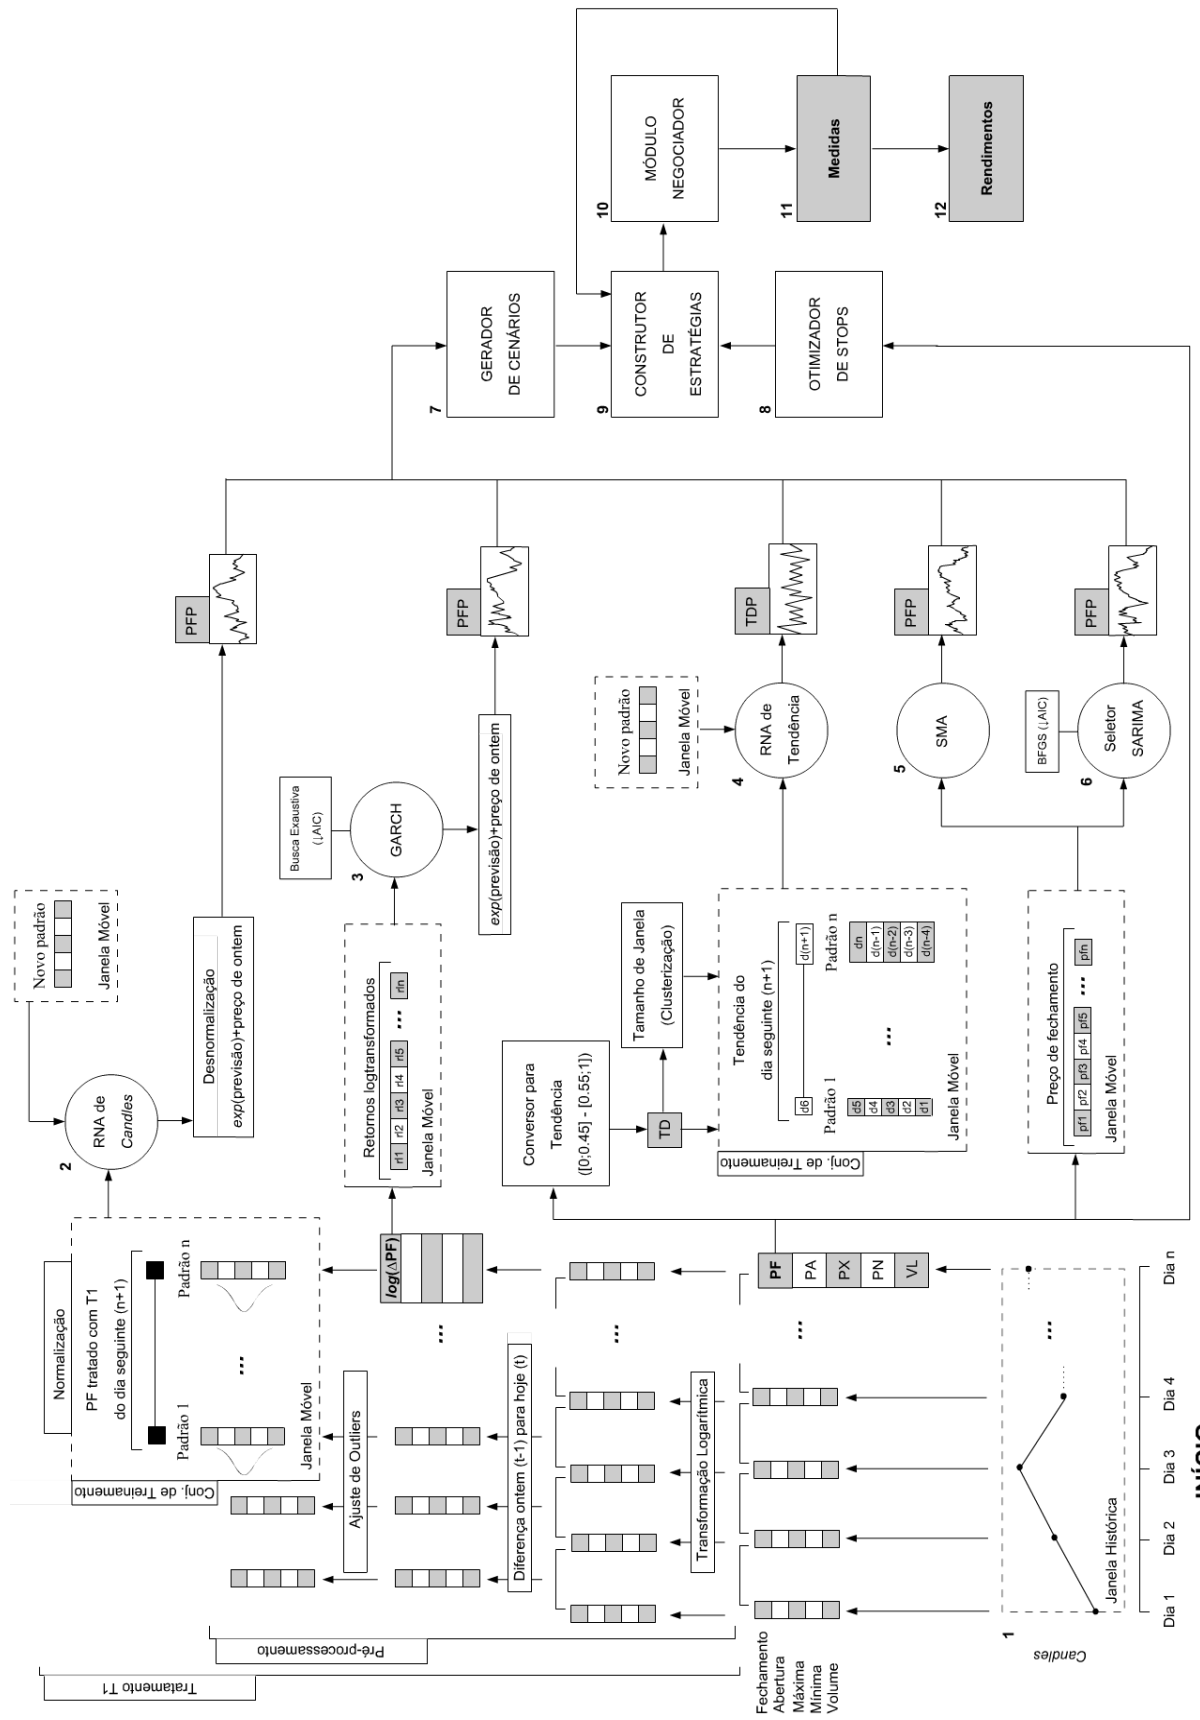
No GARCH a dimensão utilizada para as entradas é retornos dos preços log-transformados (RPL). As janelas móveis no GARCH são fixas, sendo estas de 124, 248 e 370 dias. A definição dos parâmetros  $p$  e  $q$  é mantida com um termo cada, ou seja,  $GARCH(1, 1)$ . Após a detecção dos agrupamentos de volatilidade para cada grupo é estimado um modelo  $ARMA(p, q)$  que é otimizado por meio da minimização do AIC testando-se exaustivamente todas as 36 combinações possíveis levando-se em conta que os termos do ARMA, neste caso, foram configurados para variar de 0 a 5. O valor predito pelo GARCH trata-se de um retorno log-transformado, que é convertido em “preço de fechamento previsto para o dia seguinte”.

Quadro 6 – Tipos de modelos adotados conforme otimização dos parâmetros no Seletor SARIMA.

$p$	$q$	$d$	$P$	$Q$	$D$	Modelo adotado
$> 0$	$= 0$	$= 0$	$= 0$	$= 0$	$= 0$	AR
$= 0$	$> 0$	$= 0$	$= 0$	$= 0$	$= 0$	MA
$> 0$	$> 0$	$= 0$	$= 0$	$= 0$	$= 0$	ARMA
$> 0$	$> 0$	$> 0$	$= 0$	$= 0$	$= 0$	ARIMA
$> 0$	$> 0$	$> 0$	$> 0$	$> 0$	$> 0$	SARIMA*

Nota – \*Pelo menos um dos valores  $P$ ,  $Q$  ou  $D$  é maior do que 0.

Figura 23 – Fluxo de dados e blocos que compõe os módulos do robô investidor. Neste diagrama estão detalhados os componentes dos módulos Extrator e Predictor.



Fonte: Elaborada pelo autor.

#### 4.2.3.1.2 Preditores baseados em Redes Neurais Artificiais

Os preditores baseados em redes neurais artificiais foram concebidos para se ajustar às séries disponíveis. Para tanto, foram avaliadas algumas topologias diferentes de redes neurais artificiais e seus impactos na qualidade da previsão. Foram testadas redes dos tipos MLP, RBF, *Elman* e *Jordan* como disponíveis na biblioteca *R Stuttgart Neural Network Simulator* (RSNNS) desenvolvida por [Bergmeir e Benitez \(2012\)](#) com correção por *Backpropagation* padrão. Os testes foram conduzidos nas séries de retornos log-transformados para um período de 100 dias, selecionado aleatoriamente, em todos os ativos, sendo este de 03/01/2011 a 30/05/2011. Para cada uma das topologias variou-se empiricamente os valores das configurações até se obter uma configuração inicial adequada. Essa variação foi feita com base nos valores padrões sugeridos pelo manual da biblioteca Stuttgart Neural Network Simulator (SNNS) ([University of Stuttgart, 2008](#)). Foram utilizadas janelas móveis com 10, 20, 30, 35, 40, 50 e 60 observações e, quanto a neurônios, 5, 10, 15, 30 e 45 unidades. As redes foram treinadas na primeira janela móvel e realizaram previsões para o dia seguinte tomando-se por base o novo conjunto de entrada desconhecido. Após a previsão, a janela é deslocada em um dia, seguido de novo treinamento, nova captura do padrão de entrada desconhecido e geração de uma nova previsão. Esses passos foram realizados sucessivamente até que o último passo da janela móvel fosse atingido. Finalmente, durante a realização dos experimentos observou-se que com quantidade suficiente de neurônios na camada escondida e observações na janela móvel, todas as topologias acabavam por convergir para resultados muito similares quando submetidas a mesma série. Nesse sentido, optou-se pelo uso da rede MLP por se mostrar de mais simples implementação e, conforme bibliografias consultadas, mais difundida que as demais.

Definida a escolha da MLP, passou-se a análise referente as configurações individuais desta, em especial, a seleção do algoritmo de correção de erros. Foram testados *Backpropagation* padrão (BP), *Backpropagation* resiliente (BRS), *Backpropagation* com termo de *momentum* (BM) e *Backpropagation* com algoritmo *Levenberg-Marquardt* (LM). Com cada um destes a MLP foi submetida ao mesmo tipo de experimento e intervalo de tempo citados no parágrafo anterior. Neste estudo, onde foram considerados todos os ativos, foram avaliadas as seguintes métricas: (i) quantidade média de épocas necessárias à convergência; (ii) média dos EQM's e; (iii) média do tempo de processamento. Foram configuradas topologias com a combinação de janelas de 10, 30 e 50 dias e, quantidade de neurônios com 5, 15 e 30 unidades. Definiu-se 20.000 como a quantidade máxima de épocas. A configuração dos parâmetros foi determinada empiricamente sendo que os pesos iniciais para todas as redes foram aleatorizados com valores entre -0.3 e 0.3. Todas as redes também foram testadas com funções logísticas sigmóides nos neurônios da camada escondida e lineares nas camadas de saída. A MLP com BP foi configurada com taxa de aprendizagem de 0.07 e tolerância mínima para convergência em 0.03. A MLP com BRS teve passo inicial setado em 0.1, intervalo limite de passo em 10 e taxa de decaimento valorada em 4. Já na MLP com BM a taxa de aprendizagem foi de 0.07, o termo *momentum*

de 0.3, a constante *flat* em 0.1 e a tolerância mínima para convergência em 0.03. Por fim, os dois passos iniciais ( $\sigma_1$  e  $\lambda_1$ ) da MLP com LM (MLP-LM) foram determinados como  $10^{-4}$  e  $10^{-6}$ , a tolerância mínima para convergência em 0.03 e, no caso específico desta biblioteca, foi configurado também a MLP-LM para atuar em formato de dupla precisão com ponto flutuante (8 *bytes*). Quanto ao conjunto de dados não foi realizada mistura das observações antes dos treinamentos, pois, se tratando de séries temporais, preferiu-se levar em conta a sequência dos valores como dispostos.

Os gráficos (a), (b) e (c) da [Figura 24](#) mostram de forma sintética os resultados obtidos nos testes com estas configurações e com estes quatro algoritmos de correção. Neste caso, podem ser vistas as médias obtidas dos 100 treinamentos referentes aos 100 passos da janela móvel em todos os 11 ativos.

Pode-se dizer que, para o Gráfico (a) que trata das médias de épocas necessárias à convergência, venceu o algoritmo LM com grande diferença para os demais. No Gráfico (b) vê-se que, quanto a erros quadráticos médios, levando-se em conta que estes valores dizem respeito ao obtido após a convergência, os algoritmos são bastante equivalentes, com diferença de apenas 0,4 entre o maior e o menor. Por fim, quanto ao tempo médio de processamento, o Gráfico (c) mostra que o algoritmo LM venceu mais uma vez, com média de 1.58 segundos. Postos os resultados, tomou-se por padrão o uso do algoritmo LM.

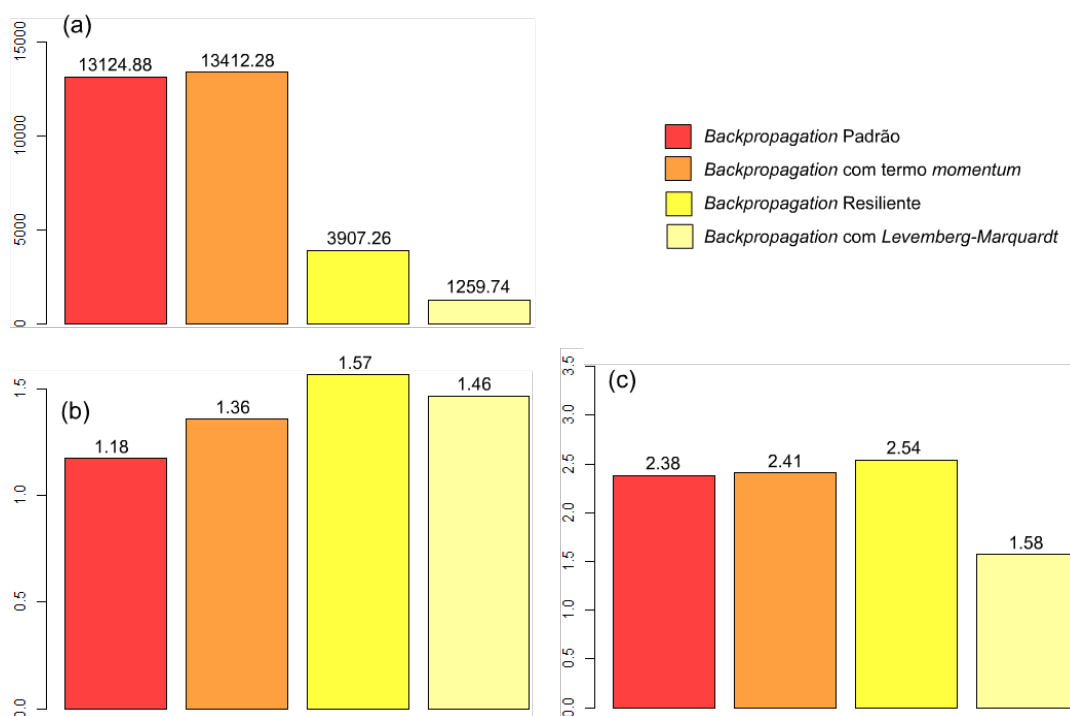
Após a definição do algoritmo de correção de erros, foi averiguada qual execução dos experimentos com a MLP-LM que mais épocas necessitou para convergir. Constatou-se que no ativo CSNA3, operando-se uma rede com 30 neurônios e janela com 50 dias, foram necessárias, em média, 3.045 épocas. No gráfico da [Figura 25](#) pode ser observada a convergência de erros quando da realização do treinamento da rede na primeira janela móvel deste experimento. Visando não haver qualquer problema quanto a quantidade máxima de épocas, optou-se por arredondar este valor para o múltiplo de 500 mais próximo e, então, dobrar o valor arredondado, resultando em 7.000 épocas. Este valor foi utilizado como máximo de épocas na configuração final das redes neurais artificiais no robô.

Por fim, a topologia e as configurações finais decididas para utilização no robô investidor, tanto para a RNA de *candles* quanto para a de tendência, após realizados os experimentos, estão sumarizadas no [Quadro 7](#).

Diversos gráficos que dão possibilidade de análises mais analíticas quanto a estes testes, com segmentação por ativo por exemplo, podem ser consultados no *link* da referência [Nametala \(2016\)](#).


**Geração de previsões com RNA de tendência** A MLP-LM que gera as previsões de tendência é treinada na transformação da série de preço de fechamento para série de tendência já discutida na [subseção 4.2.1.1](#). Portanto, todos os conjuntos de treinamento são compostos de valores que variam entre 0 e 1 e dentro deste mesmo intervalo não existem observações contidas

Figura 24 – Análise de algoritmos de correção de erros para a rede neural MLP. (a) Média de épocas necessárias à convergência, (b) média dos erros quadráticos médios e (c) tempo de processamento médio (segundos).



Fonte: Elaborada pelo autor.

Figura 25 – Convergência do erro quadrático médio ponderado ao longo de 20000 épocas para o ativo CSNA3 (usada como exemplo, visto que o comportamento foi similar em todas as séries) com uma MLP-LM em janela de 50 dias e 30 neurônios na camada escondida.



Fonte: Elaborada pelo autor.

entre 0.45 e 0.55.

Conforme pode ser observado na [Figura 26](#), a RNA de tendência é uma rede que trabalha com memória. Com isso, cada janela móvel é um conjunto de treinamento que leva em conta não somente as observações mais recentes, como também, as antigas. Este conjunto de treinamento é montado de maneira que as observações fiquem dispostas de forma sequencial do primeiro ao quinto valor na janela móvel. O padrão é então associado a saída esperada contida no dia



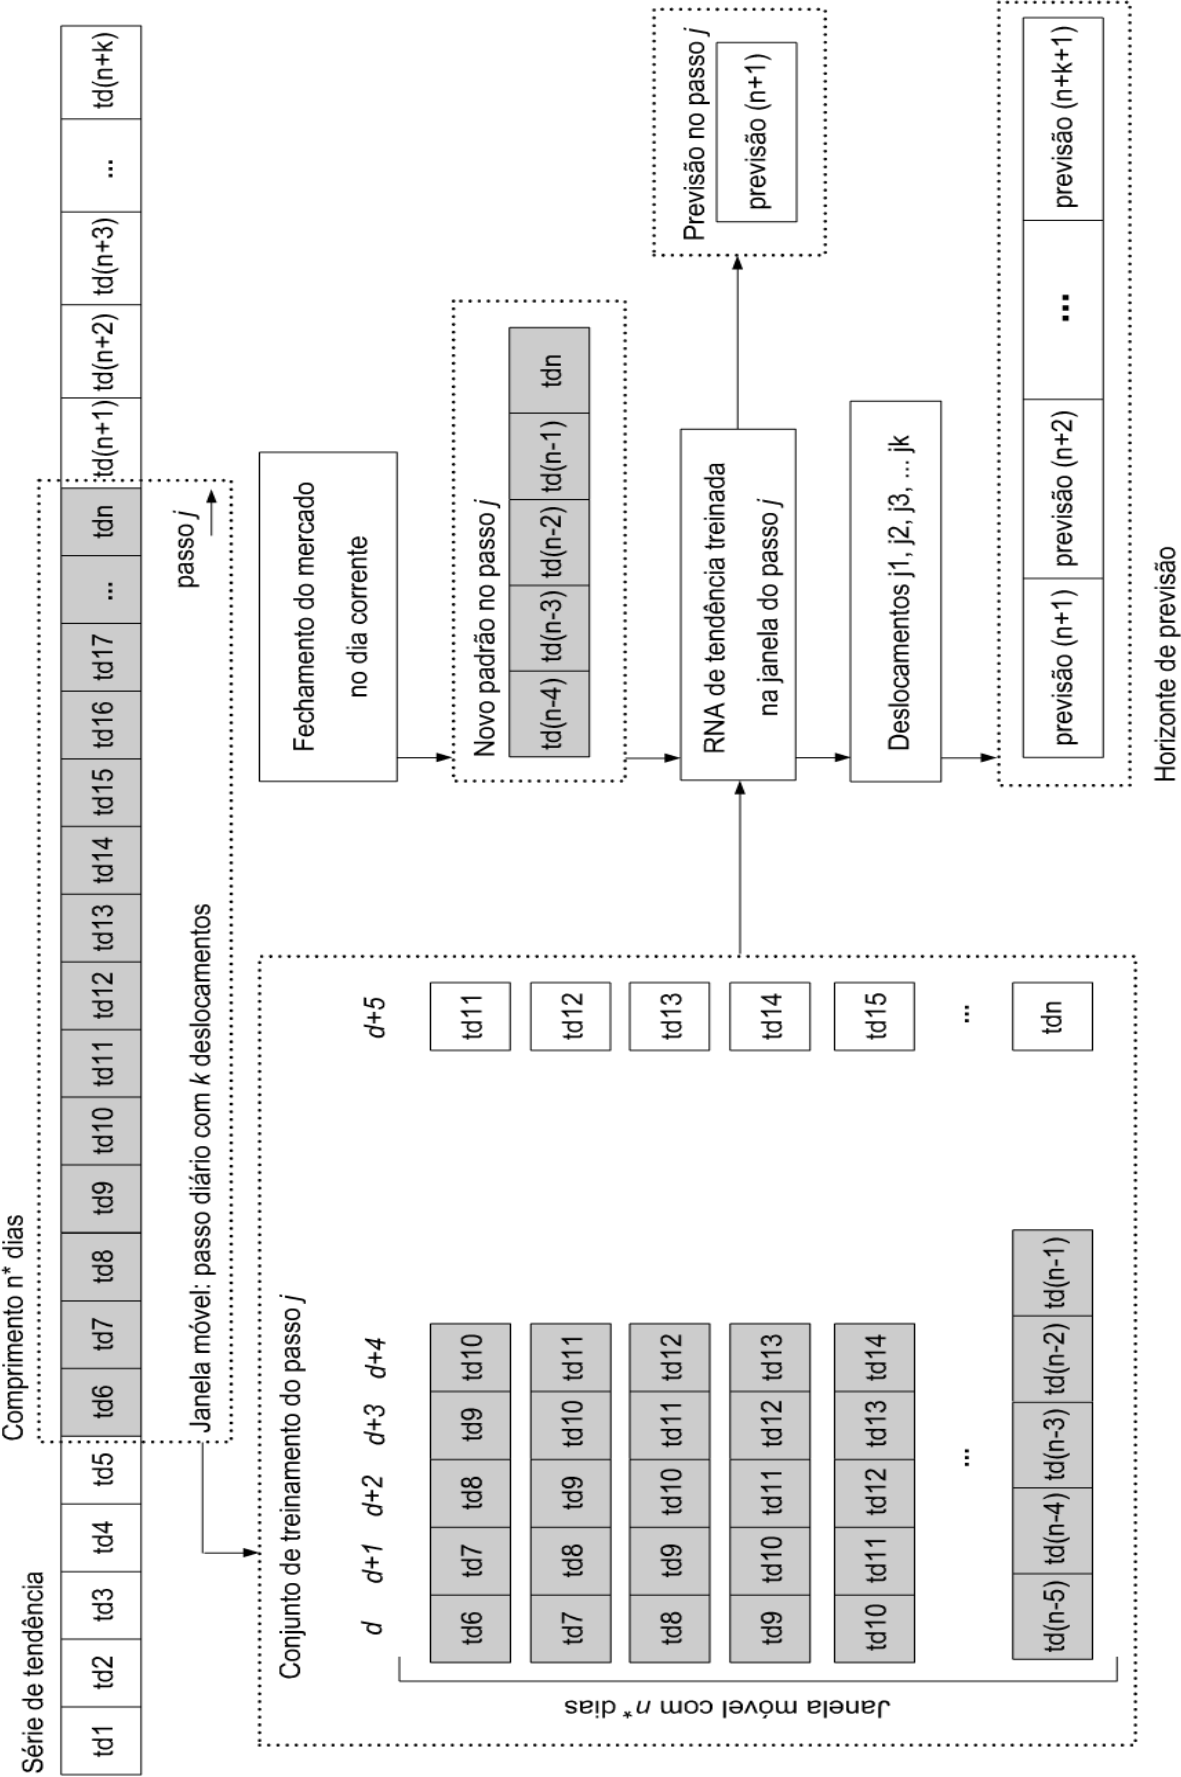
Quadro 7 – Configuração e topologia definida, após experimentos, para as redes neurais artificiais do robô.

Característica	Valor
Topologia	<i>Multilayer Perceptron</i>
Algoritmo de correção de erros	<i>Backpropagation</i> com <i>Levenberg-Marquardt</i>
Máximo de épocas	7000
Intervalo de aleatorização de pesos sinápticos	[-0.3;0.3]
Função nos neurônios da camada escondida	Logística sigmoide
Função nos neurônios da camada de saída	Linear
Embaralhamento de observações	Não
$\sigma_1$	$10^{-4}$
$\lambda_1$	$10^{-6}$
Tolerância de erro para convergência	0.03
Precisão	Duplo ponto flutuante (8 bytes)

seguinte, ou seja, o sexto valor. Na sequência, para construção do próximo padrão, desloca-se um dia, gerando então um conjunto que vai do segundo ao sexto valor, este terá por saída esperada o sétimo valor. Isso é feito sucessivamente até o tamanho total do horizonte de previsão.

A cada observação da janela, essa manipulação é realizada a fim de que a RNA de tendência seja treinada com a capacidade de realizar a previsão do valor de tendência sempre para o próximo dia. O tamanho da janela móvel  $n^*$  é calculado com base na clusterização dos 248 dias anteriores ao qual se pretende prever. O valor é determinado tomando-se a quantidade de elementos contidos no último *cluster*, identificado conforme um valor de  $k$  estabelecido pelo método de *Elbow* em um algoritmo K-médias. Variou-se  $k$  de 2 a 12 neste caso.

Figura 26 – Construção do conjunto de treinamento da RNA de tendência baseado nos passos da janela móvel.



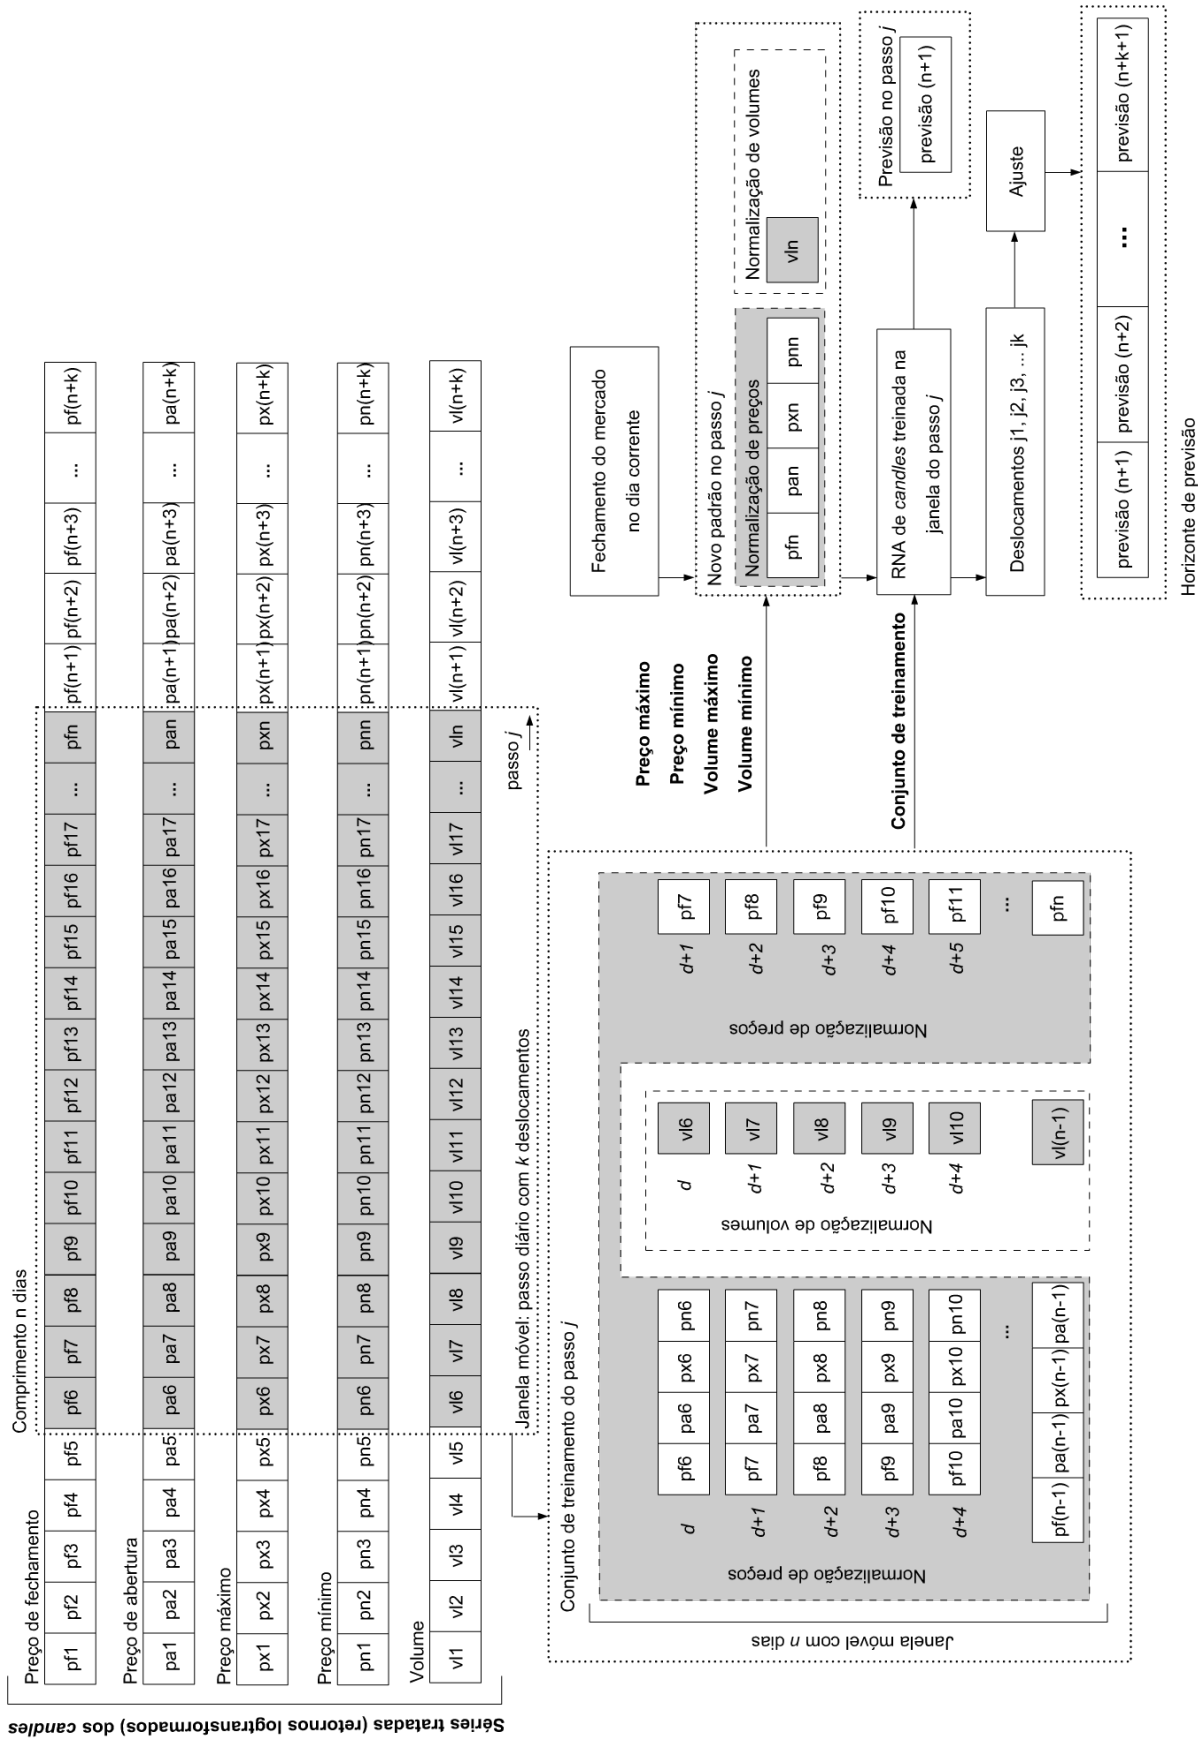
Fonte: Elaborada pelo autor.

Por possuir tamanho de janela determinado dinamicamente, esta rede neural tem por única configuração a quantidade de neurônios na camada escondida, que podem ser 5, 10, 15, 20, 25, 30, 35 ou 40.

Após o treinamento, toma-se como novo padrão a sequência dos últimos cinco valores de tendência ocorridos após o fechamento do mercado no dia corrente, este incluso. Ao se inserir esse novo padrão na RNA de tendência, esta então irá realizar a previsão de tendência para o próximo dia. Esse mesmo método é repetido tantas vezes quanto necessário, até se completar o horizonte de previsão desejado. Por fim, pode-se dizer que esta rede neural possui como saída a “tendência prevista para o dia seguinte”.

**Geração de previsões com RNA de *candles*** A RNA de *candles* possui dois parâmetros que distinguem os preditores desta classe. O primeiro é o tamanho de janela, onde utilizou-se 10, 20, 30, 35, 40, 45, 50 e 60 dias. Já o segundo trata da quantidade de neurônios na camada escondida, sendo 5, 10, 15, 20, 25, 30, 35 e 40 unidades. Todas as combinações destes dois parâmetros foram utilizadas, totalizando 64 RNA's de *candles* diferentes. Esta classe é chamada de “RNA de *candles*” pois as previsões por ela realizadas são baseadas nas dimensões do *candle* que lhe servem de entrada. Na [Figura 27](#) pode ser visualizado um diagrama desta RNA.

Figura 27 – Construção dos conjuntos de treinamento da RNA de *candles* baseado nos passos da janela móvel.



Fonte: Elaborada pelo autor.

Inicialmente, levando-se em conta a janela móvel de comprimento  $n$  corrente, são capturados todos os valores das dimensões de volume, fechamento, abertura, mínima e máxima já tratadas pelo tratamento T1 discutido na [subseção 4.2.1.2](#). Os valores do *candle* do dia  $d$  são utilizados então como padrão. Já o valor esperado é o preço de fechamento do dia seguinte ( $d + 1$ ). Antes de se proceder ao treinamento da RNA com um dado conjunto de treinamento, os valores deste são padronizados entre 0 e 1. As dimensões que estão na escala “preço” são padronizadas juntas, enquanto que o volume, que está na escala “volume de *ticks*,” é padronizada em separado. O conjunto de treinamento final é composto da união das dimensões preço e volume antes em escalas diferentes, agora já padronizadas todas entre 0 e 1, num conjunto único. O método de padronização é o já apresentado na [Equação 4.11](#).

Após o treinamento da rede parte-se para a etapa de previsão. No fechamento do mercado, seleciona-se o *candle* do dia como novo padrão. Utilizando-se os valores de preço e volume máximos e mínimos detectados durante o processo de padronização no treinamento, padroniza-se as dimensões do *candle* corrente para a mesma escala entre 0 e 1 na qual a rede foi treinada. Esse *candle* padrão é então submetido a RNA que gera a previsão. Neste caso a previsão dirá respeito, por enquanto, a um retorno log-transformado normalizado.

Por fim, a previsão é submetida a um procedimento de ajuste com duas etapas: (a) desnormalização, conforme [Equação 4.12](#) e; (b) conversão para preço absoluto, conforme [Equação 4.13](#) onde  $pf_{anterior}$  é o último preço de fechamento conhecido. A saída gerada pelas RNA's de *candles* corresponde ao “preço de fechamento previsto para o dia seguinte”.

$$s_i = y(s_{max} - s_{min}) + s_{min} \quad (4.12)$$

$$pf_{previsto} = e^{s_i} + pf_{anterior} \quad (4.13)$$

#### 4.2.3.2 Momentos de confiança

Até o momento discutiu-se como cada preditor de cada uma das cinco classes de preditores gera suas previsões. Como apresentado, podem ser geradas previsões com 6 SMA's, 5 Seletores SARIMA, 3 GARCH's, 8 RNA's de tendência e 64 RNA's de *candles*, totalizando 86 preditores distintos. Entretanto, como será mostrado a seguir, estes 86 preditores não são utilizados necessariamente a todo tempo e ao mesmo tempo. Antes de se utilizar um preditor é necessário que este esteja em momento confiável, ou seja, é realizada uma análise prévia da sua capacidade de previsão por meio da taxa de acerto. Esta análise é chamada de “momento de confiança” e foi criada para tentar garantir duas propriedades aos comitês de decisão: (ii) evitar o uso de uma quantidade muito grande de preditores, o que pode aumentar o erro de previsão, e; (b) desconsiderar preditores historicamente ruins na série, visto que, neste caso, as previsões

destes podem influenciar negativamente os resultados. Portanto, para a aferição do POCID e também da taxa de acerto, se faz necessário que todas as previsões estejam na mesma escala.

Como foi visto, SMA, Seletor SARIMA, GARCH e RNA de *candles* geram previsões na escala “preço de fechamento para o dia seguinte”. Já a RNA de tendência gera previsões no formato “tendência para o dia seguinte”. Devido a essa diferença de tipo de previsão, todas as previsões de todos os preditores são transformadas para uma escala única chamada de “sinal de operação”. Um sinal de operação, com já discutido anteriormente, é obtido por meio da arbitragem entre a série prevista e a série real. Por consequência, nas séries de preço, compara-se o preço de fechamento real do dia corrente ao preço de fechamento previsto para o dia seguinte, caso exista um aumento no preço, considera-se sinal de alta no dia seguinte (1), caso contrário, sinal de baixa (0). Na série de tendência, a ideia é a mesma. A única diferença neste caso é que transforma-se também a série real de preço em uma série de tendência, obtendo-se assim uma série de tendência real. Após isto, caso a tendência prevista para o dia seguinte seja maior do que o último valor conhecido na série de tendência real, então têm-se uma alta prevista para o dia seguinte (1), senão, baixa (0).


Foram utilizados três tipos de técnicas para se avaliar o momento de confiança. Cada uma delas se utiliza dos sinais de operação dos preditores, conforme discutido na sequência.

#### 4.2.3.2.1 Evolução da taxa de acerto (ETA)

A evolução da taxa de acerto (ETA) trata-se de uma análise onde é avaliada a taxa de acerto continuamente em um período histórico pré-determinado. Para entendimento da mesma pode-se observar o gráfico da [Figura 28](#). Neste gráfico estão dispostos os valores diários da taxa de acerto apresentada por uma RNA de *candles* com janela de 60 dias e 40 neurônios na camada escondida (*rna1nc\_j60\_n40*). As taxas dizem respeito ao ativo BBAS3 no ano de 2011 levando-se em conta sempre a última semana de operação, ou seja, são taxas de acerto dos últimos 5 dias tomadas diariamente. Percebe-se que, neste caso, existem grandes oscilações, ou seja, utilizar-se um preditor como este levando-se em conta apenas a taxa de acerto apresentada por ele na última semana não é uma boa estratégia. Isso ocorre, pois, não existem evidências de que o mesmo funcionará com qualidade no próximo dia ou sequer na próxima semana, já que existem variações que vão de 100% de acerto para até 0% de acerto em menos de 20 dias.

Aumentando-se o intervalo da avaliação da taxa de acerto, por exemplo, para 15 dias, como mostrado agora no gráfico da [Figura 29](#), pode-se notar que uma maior suavidade é obtida. Isso ocorre pois, levando-se em conta que mais observações são avaliadas na composição do cálculo da taxa de acerto, esta série tende a ser amortizada. Esse comportamento, no período analisado, dá evidências de que este preditor possui capacidade de manter períodos mais definidos e consistentes com taxa de acerto acima de 50% e, da mesma forma, períodos também duradouros com taxa de acerto abaixo de 50%. Buscando-se aproveitar desta característica no estudo, pode-se ver no gráfico da [Figura 30](#) um período maior, com 31 dias, juntamente de uma média móvel


Figura 28 – Evolução da taxa de acerto do preditor *rna1nc\_j60\_n40* (RNA de *candle* com janela de 60 dias e 40 neurônios na camada escondida) ao longo dos 248 dias de 2011 levando-se em conta a taxa de acerto dos últimos 5 dias (semana).



Fonte: Elaborada pelo autor.

exponencial (EMA) aplicada sobre este de 15 dias. Nota-se que a média exponencial apresenta melhores características do que a taxa de acerto em si quando se quer avaliar a capacidade contínua deste preditor em manter sua taxa de acerto acima ou abaixo de 50%. Isso acontece pois a EMA não sofre com as pequenas oscilações diárias apresentadas pela taxa de acerto. Entretanto, existem períodos onde as oscilações da EMA podem ser maiores, como por exemplo na presença de grandes volatilidades na taxa de acerto. Neste sentido, pode-se ver, já no gráfico da [Figura 31](#), uma outra estratégia complementar que ajuda a eliminar ainda mais estas oscilações. Neste caso, o valor obtido de taxa de acerto nos últimos 31 dias é utilizado como referência para os 10 dias seguintes, ou seja, a taxa de acerto é tomada apenas de 10 em 10 dias. Essa forma de gerar a série retira da EMA as oscilações pequenas e, neste caso, vê-se apenas movimentos bem estabelecidos de alta e depois de baixa.

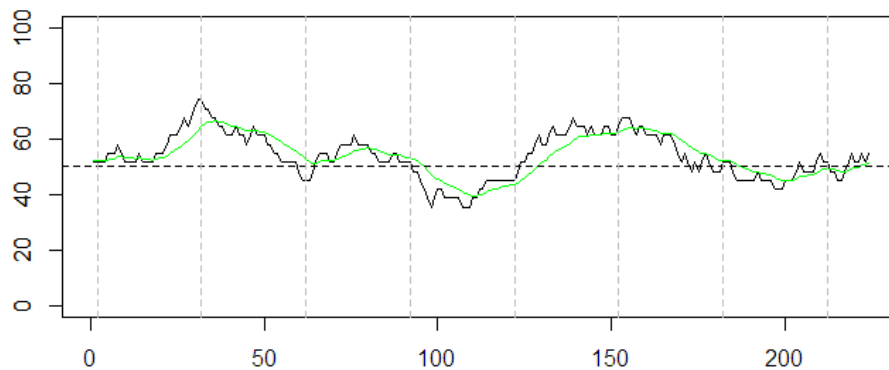
Figura 29 – Evolução da taxa de acerto do preditor *rna1nc\_j60\_n40* (RNA de *candle* com janela de 60 dias e 40 neurônios na camada escondida) ao longo dos 248 dias de 2011 levando-se em conta a taxa de acerto dos últimos 15 dias (duas semanas).



Fonte: Elaborada pelo autor.

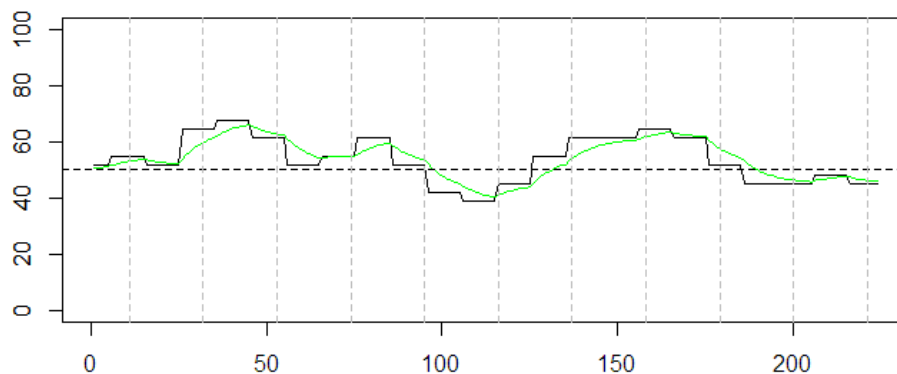
Por fim, agora, uma última análise estendendo-se o período com 248 observações em 2011 para um período maior com 867 observações indo de 02/07/2010 até 30/12/2013. Neste,

Figura 30 – Evolução da taxa de acerto do preditor *rnaInc\_j60\_n40* (RNA de *candle* com janela de 60 dias e 40 neurônios na camada escondida) ao longo dos 248 dias de 2011 levando-se em conta a taxa de acerto dos últimos 31 dias (um mês e meio) e com média exponencial (EMA) de 15 dias.



Fonte: Elaborada pelo autor.

Figura 31 – Evolução da taxa de acerto do preditor *rnaInc\_j60\_n40* (RNA de *candle* com janela de 60 dias e 40 neurônios na camada escondida) ao longo dos 248 dias de 2011 levando-se em conta a taxa de acerto dos últimos 31 dias (um mês e meio) avaliada de 10 em 10 dias e com média exponencial (EMA) de 15 dias.



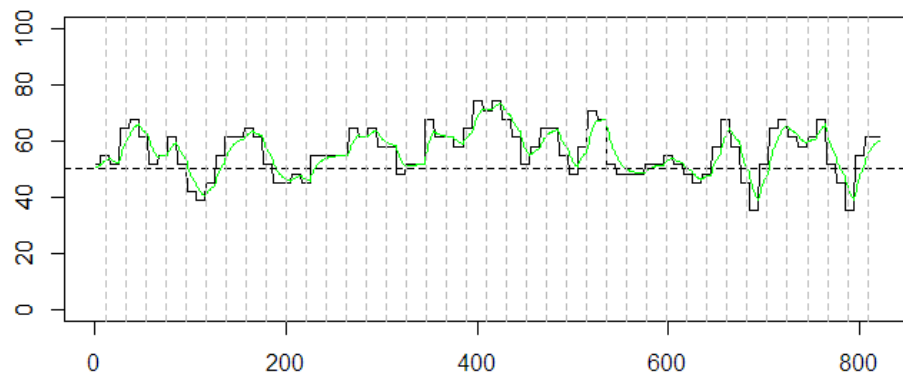
Fonte: Elaborada pelo autor.

nota-se conforme gráfico da [Figura 32](#), que a característica de manter períodos bem estabelecidos com alta e baixa qualidade de previsão é constante para este preditor ao longo de toda a série BBAS3 (usada como exemplo, visto que o comportamento foi similar em todas as séries). O momento de confiança ETA, baseado na evolução da taxa de acerto conforme apresentada, foi definido de forma a permitir ou não permitir que um preditor participe de um dado comitê de decisão. Essa análise é feita sob uma EMA com período de 15 dias, da taxa de acerto dos últimos 31 dias, tomada apenas de 10 em 10 dias (referenciada a partir deste ponto do texto apenas como ETA). Por fim, a regra que dá direito a participação, neste caso e para todos os demais ativos, foi estabelecida de forma que um preditor é “ligado” quando o mesmo possui ETA crescente por necessariamente mais que dois dias e, também, ETA no dia corrente maior que 50.1%.

O momento de confiança ETA pode, portanto, gerar um estado 1 (confiável) ou um estado 0 (não confiável). A combinação destes estados com o sinal de operação pode permitir que o



Figura 32 – Evolução da taxa de acerto do preditor *rna1nc\_j60\_n40* ao longo de 867 dias compreendidos entre o último semestre de 2010 até o último dia 2013. Levando-se em conta a taxa de acerto dos últimos 31 dias (um mês e meio) avaliada de 10 em 10 dias e com EMA de 15 dias.



Fonte: Elaborada pelo autor.

Quadro 8 – Combinação de sinais e estados para os momentos de confiança ETA e CMTA.

Sinal de operação	Estado de confiança	Sinal da operação ajustado
0 (baixa)	1 (confiável)	0 (baixa)
1 (alta)	1 (confiável)	1 (alta)
0 (baixa)	0 (não confiável)	-1 (não opera)
1 (alta)	0 (não confiável)	-1 (não opera)

Quadro 9 – Combinação de sinais e estados para o momento de confiança MTA.

Sinal de operação	ETA	CMTA	Sinal da operação ajustado
0 (baixa)	1 (confiável)	1 (confiável)	0 (baixa)
1 (alta)	1 (confiável)	1 (confiável)	1 (alta)
0 (baixa)	0 (não confiável)	1 (confiável)	0 (baixa)
1 (alta)	0 (não confiável)	1 (confiável)	1 (alta)
0 (baixa)	1 (confiável)	0 (não confiável)	0 (baixa)
1 (alta)	1 (confiável)	0 (não confiável)	1 (alta)
0 (baixa)	0 (não confiável)	0 (não confiável)	-1 (não opera)
1 (alta)	0 (não confiável)	0 (não confiável)	-1 (não opera)

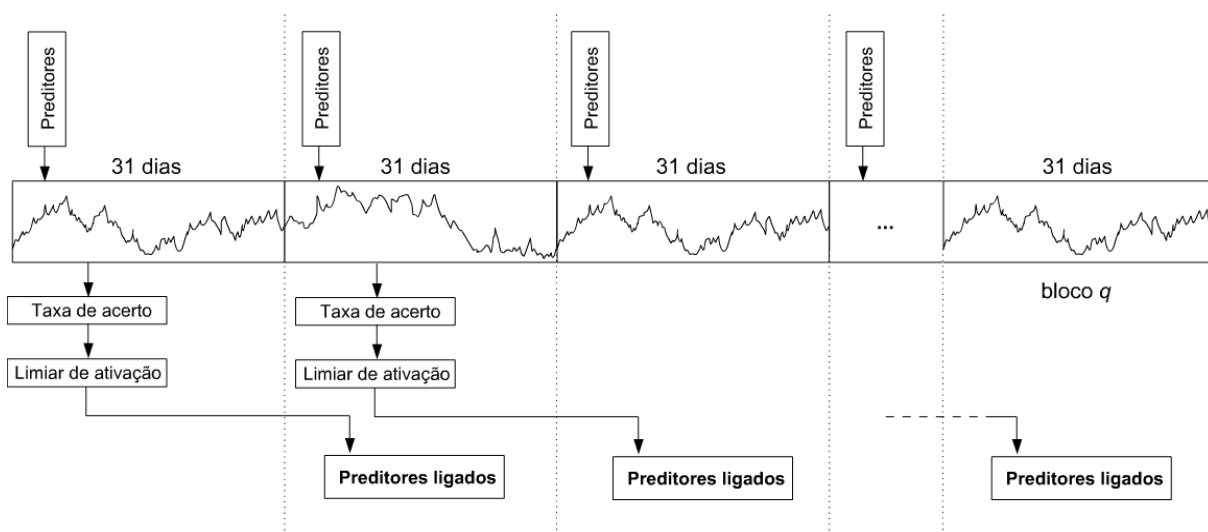
preditor seja ou não seja considerado. No [Quadro 8](#) estão as combinações possíveis entre os sinais de operação e os estados de confiança gerados pelo momento de confiança ETA. Nota-se que, neste caso, existe também o estado “Não opera” (-1) que indica quando um dado preditor não deve ser utilizado.

#### 4.2.3.2.2 Capacidade de manutenção da taxa de acerto (CMTA)

A capacidade de manutenção da taxa de acerto (CMTA) de um preditor, ao contrário do ETA, não avalia continuamente uma série específica, mas sim, usa períodos fixos para, vez a vez, tomar decisões sobre ligar ou desligar um dado preditor. Neste sentido, o mesmo período de 31 dias utilizado para o cálculo da taxa de acerto em ETA foi utilizado em CMTA, mas de

forma fixa. Pode-se observar no diagrama da [Figura 33](#) a dinâmica de operação deste tipo de momento de confiança. Percebe-se pela imagem que os preditores são aplicados a um bloco inicial de 31 dias gerando previsões. Neste primeiro bloco é aferida a taxa de acerto de cada um dos 86 preditores. Após esta etapa, a taxa de acerto de cada um é então comparada a um limiar de ativação. O limiar de ativação, neste caso, foi estabelecido depois de testes empíricos a um nível de 55%. Por fim, o preditor que superar positivamente este limiar ficará ligado nos próximos 31 dias seguintes ao bloco corrente, garantindo assim direito a voto em qualquer comitê de decisão até nova análise ser realizada, 31 dias depois.

Figura 33 – Dinâmica de operação do momento de confiança CMTA.



Fonte: Elaborada pelo autor.

No [Quadro 8](#) são mostradas as combinações possíveis entre os sinais previstos pelos preditores e os estados gerados pelo momento de confiança CMTA, que são os mesmos já apresentados para ETA.

#### 4.2.3.2.3 Combinação de momentos ETA e CMTA (MTA)

A combinação dos dois tipos de momento de confiança discutidos até aqui é denominada de momento misto da taxa de acerto (MTA). O MTA leva em conta o estado de confiança gerado tanto por ETA quanto por CMTA ao mesmo tempo. Nesta situação, caso haja concordância entre ETA e CMTA de que um dado preditor é confiável, então o sinal de operação previsto por este é mantido. Caso pelo menos um dos preditores considere o preditor confiável, o sinal mais uma vez será mantido. Contudo, caso ambos os momentos de confiança concordem no fato de que o preditor não é confiável, então, neste caso, o mesmo é desligado gerando-se um sinal “Não operar” (-1). O [Quadro 9](#) traz as combinações possíveis entre os sinais previstos pelos preditores e os estados gerados pelo momento de confiança MTA.

Como pode-se perceber, esse tipo de momento de confiança é mais permissivo que os outros dois aplicados individualmente, fato que pode gerar, durante a operação, uma maior quantidade de ordens no mercado.

#### 4.2.3.3 Comitês de decisão

Os sinais de operação ajustados pelos momentos de confiança discutidos nas subseções anteriores indicam, para cada preditor, um de três estados: alta (1), baixa (0) ou não operar (-1). A cada passo da janela, os valores das previsões ou os sinais de operação dos preditores ligados, podem ser combinados por um de três tipos de comitês de decisão, detalhados a seguir.

##### 4.2.3.3.1 Comitê de decisão por média (CM)

O comitê baseado em média (CM) tem por objetivo criar uma regra que permita combinar as previsões realizadas pelos preditores ligados utilizando-se uma média aritmética simples de todos os valores previstos. Dessa forma é importante destacar que com o CM não são usados os sinais de operação e, sim, os valores previstos. O principal problema nesta situação é que a RNA de tendência não faz previsão de preço de fechamento, portanto, o cálculo da média das suas previsões precisa ser feito de forma separada dos preditores das outras classes. Somente após esta etapa torna-se possível a geração de um sinal de operação combinado. Nesse sentido, procedeu-se ao uso da seguinte estratégia.

Dos 86 preditores existentes, para a janela móvel corrente, separa-se apenas aqueles que estão em momento confiável segundo um dado momento de confiança utilizado (ETA, CMTA ou MTA). Estes preditores ligados são então separados entre preditores que fazem previsão de tendência e preditores que fazem previsão de preço de fechamento. É realizada uma média aritmética simples dos preços de fechamento previstos, o que resulta em apenas um preço médio e, da mesma forma, é feita uma média também simples dos valores de tendência previstos, gerando-se um valor médio único para tendência. Estes valores, quando existem ou não, podem ser utilizados nas seguintes situações:

1. Nos casos em que nenhum dos preditores (nem de preço e nem de tendência) estiverem ligados, então os valores médios não existem, logo gera-se um sinal “Não opera” (-1).
2. Existem momentos durante o processo de previsão que nenhum preditor de preço é ligado, mas, existem preditores de tendência ligados. Neste caso, dá-se preferência a tendência média prevista. Para isso gera-se um sinal de operação baseado na diferença entre a tendência média prevista para o dia seguinte e a tendência real apresentada no dia corrente. Caso constata-se uma alta, então adota-se um sinal de alta (1), caso baixa, então um sinal de baixa (0) é adotado.

3. Caso nenhum preditor de tendência esteja ligado, mas, existam preditores de preços ligados, então usa-se o preço médio previsto. O sinal de alta (1) será gerado caso o preço médio previsto seja maior do que o preço de fechamento real do dia corrente, caso contrário, sinal de baixa (0).
4. Por fim, para a situação onde existem preditores de preços ligados e também, ao mesmo tempo, preditores de tendência ligados, então procede-se a combinação dos dois valores médios. Esta combinação é feita de modo que, caso as duas médias concordem, seja para um sinal de alta (1) ou um de baixa (0), então este sinal será mantido. Caso as duas médias discordem, ou seja, qualquer uma indicando alta ao mesmo tempo em que a outra indique baixa, então gera-se um sinal “Não opera” (-1).

As situações contidas nesta listagem estão sumarizadas no [Quadro 10](#), que mostra como as combinações podem influenciar na construção do sinal que será saída deste comitê decisão. No [Quadro 11](#) é mostrado o caso específico da combinação de médias (situação detalhada no item 4).

Quadro 10 – Situações de uso do comitê média (CM) ou no comitê voto majoritário (CV)

Situação	Preditores de preço	Preditores de tendência	Construção de sinal
1	Nenhum ligado	Nenhum ligado	-1 (não opera)
2	Ao menos um ligado	Nenhum ligado	Sinal baseado em preço médio
3	Nenhum ligado	Ao menos um ligado	Sinal baseado em tendência média
4	Ao menos um ligado	Ao menos um ligado	Combinação

Quadro 11 – Combinação de sinais por preço ou tendência nos comitês CM ou CV

Sinal do preço	Sinal da tendência	Combinação de sinais
0 (baixa)	0 (baixa)	0 (baixa)
0 (baixa)	1 (alta)	-1 (Não opera)
1 (alta)	0 (baixa)	-1 (Não opera)
1 (alta)	1 (alta)	1 (alta)

#### 4.2.3.3.2 Comitê de decisão por voto majoritário (CV)

O comitê baseado em voto majoritário (CV) é um contador de votos que leva em conta os sinais de operação. Portanto, diferente de CM, este comitê não se utiliza dos valores previstos. A ideia é simples, uma vez que nesta contabilização toma-se como sinal de operação aquele mais votado pelos preditores ligados. Neste caso, é importante ressaltar também que, como no comitê CM, é feita uma separação dos preditores de tendência e dos de preços. São possíveis as seguintes situações:

1. Caso nenhum preditor esteja ligado então toma-se por sinal de operação -1 (“Não opera”).

2. Caso estejam ligados apenas preditores de preço, contabilizam-se a quantidade de preditores que previram alta (1) e a quantidade de preditores que previram baixa (0). Toma-se por sinal de operação dentre estas duas possibilidades a que tiver mais ocorrências na contagem. Em caso de empate o sinal será “Não operar” (-1).
3. Mesma situação do item 2 anterior, contudo neste caso, levando-se em conta que nenhum preditor de preço esteja ligado, mas, um ou mais de tendência estejam. Mais uma vez, em caso de empate o sinal será “Não operar” (-1).
4. Quando existirem tanto preditores de preço quanto de tendência ligados é realizada uma combinação dos sinais. Caso o voto majoritário dos preditores de preço concorde com o mesmo voto majoritário dos preditores de tendência, então o sinal para o qual ambos concordam é mantido. Caso contrário, gera-se um sinal -1 (“Não opera”). Esta combinação é mostrada no [Quadro 11](#).

#### 4.2.3.3.3 Comitê de decisão por média e voto majoritário (CMV)

A junção dos comitês CM e CV foi utilizada para criar o comitê por média e voto majoritário (CMV) que leva em conta as duas abordagens. Neste caso, o sinal da operação será ajustado conforme o sinal de saída de ambos os comitês.

Nesta análise é dada preferência sempre ao comitê que tiver sinal válido (0 ou 1). Portanto, no caso de um dos comitês emitir sinal -1 (“Não opera”) mas o do outro for válido, então irá ser utilizado o sinal válido. No caso de concordância entre os sinais (0, 1 ou -1) então mantém-se o sinal. Por fim, no caso de discordância é mantido o sinal de não operação (-1). As combinações descritas podem ser visualizadas no [Quadro 12](#).

Este tipo de comitê permite uma maior realização de operações.

Quadro 12 – Combinação de sinais dos comitês CM e CV com o uso do comitê híbrido de média e voto majoritário (CMV)

Sinal CM	Sinal CV	Sinal da operação ajustado por CMV
0 (baixa)	-1 (“Não opera”)	0 (baixa)
1 (alta)	-1 (“Não opera”)	1 (alta)
-1 (“Não opera”)	0 (baixa)	0 (baixa)
-1 (“Não opera”)	1 (alta)	1 (alta)
0 (baixa)	0 (baixa)	0 (baixa)
1 (alta)	1 (alta)	1 (alta)
-1 (“Não opera”)	-1 (“Não opera”)	-1 (“Não opera”)
1 (alta)	0 (baixa)	-1 (“Não opera”)
0 (baixa)	1 (alta)	-1 (“Não opera”)

#### 4.2.3.4 Gerador de cenários

O gerador de cenários nada mais é do que um algoritmo que combina todas as possibilidades de momentos de confiança com comitês de decisão, gerando assim 9 cenários possíveis:

- Comitê por Média com momento de confiança baseado em Evolução da Taxa de Acerto (CM-ETA).
- Comitê por Média com momento de confiança baseado em Capacidade de Manutenção da Taxa de Acerto (CM-CMTA).
- Comitê por Média com momento de confiança baseado em análise Mista da Taxa de Acerto (CM-MTA).
- Comitê por Voto Majoritário com momento de confiança baseado em Evolução da Taxa de Acerto (CV-ETA).
- Comitê por Voto Majoritário com momento de confiança baseado em Capacidade de Manutenção da Taxa de Acerto (CV-CMTA).
- Comitê por Voto Majoritário com momento de confiança baseado em análise Mista da Taxa de Acerto (CV-MTA).
- Comitê por Média e Voto Majoritário com momento de confiança baseado em Evolução da Taxa de Acerto (CMV-ETA).
- Comitê por Média e Voto Majoritário com momento de confiança baseado em Capacidade de Manutenção da Taxa de Acerto (CMV-CMTA).
- Comitê por Média e Voto Majoritário com momento de confiança baseado em análise Mista da Taxa de Acerto (CMV-MTA).

Estes cenários serão utilizados em conjunto com os *stops* definidos pelo otimizador de *stops* para a construção de estratégias avaliadas financeiramente e submetidas ao Módulo Negociador.

#### 4.2.3.5 Otimizador de stops

Conforme já demonstrado nos algoritmos de negociação do Módulo Negociador, o robô investidor trabalha com gestão de riscos baseada em objetivos de perdas e ganhos para cada operação realizada. Isso quer dizer que existem estratégias pré-estabelecidas para o momento de saída de uma operação, visto que a entrada, quando ocorrer, será sempre realizada na abertura de um pregão (seja operação de compra visando alta ou de venda visando baixa). Nesse sentido é possível que uma operação de venda seja encerrada ao fechar posição no final do dia, comprando

no preço de fechamento<sup>5</sup>, ou, ao atingir-se um ponto de *takeprofit* ou um ponto de *stoploss*. Já em uma operação de compra a posição pode ser encerrada, também no final do dia, com uma venda no preço de fechamento, ou, mais uma vez ao se atingir *takeprofit* ou *stoploss*.

A utilização de pontos de *stop* individualizados e otimizados para cada série de cada ativo é importante pois as variações dos preços são muito específicas à cada ação. Isso é particularmente nítido quando se observa a distribuição dos retornos de cada ativo. Segundo Silva (2008), o uso de *stops* é útil pois permite limitar os prejuízos em investimentos de renda variável. Assim, pode-se dizer por consequência que, ao se estabelecer uma meta para perdas, protege-se o investimento de grandes oscilações, ao passo que da mesma forma, ao se estabelecer uma meta para ganhos, garantem-se lucros antes que o ativo se sobrevalorize e volte a cair (ABE, 2009).


A otimização dos pontos de *takeprofit* e *stoploss* foi realizada da seguinte forma:

1. Coleta do *tick* mínimo: Antes de se estabelecer os pontos de *stop* coletou-se a mínima variação de preços possível nas operações diárias em cada ativo. Para isso, foi utilizado um *script* MQL que acessa a base de dados da BOVESPA e, no ativo de interesse, coleta essa mínima variação chamada de *tick* mínimo. Todos os ativos negociados neste caso possuem por *tick* mínimo o valor de R\$ 0,01. Essa medida é importante pois por meio dela pode-se calcular a distribuição dos retornos dos preços em uma escala fixa.
2. Após saber o valor do *tick* mínimo, procede-se a geração de um gráfico de frequências que denota a distribuição dos retornos, levando-se em conta os últimos dois anos anteriores a fase de operação. Neste caso, montou-se uma distribuição com os dados de 2010 e 2011, gerando-se assim *stops* para serem utilizados em 2012. Na sequência, montou-se nova distribuição com dados de 2011 e 2012, esta gerando valores de *stop* para o ano de 2013.
3. Em cada uma das distribuições foi estabelecida uma proporção fixa visando limitar as perdas e maximizar os ganhos. Para isso, a partir do ponto médio da distribuição dos retornos, definiu-se como tamanho do *stoploss* o ponto onde contabilizou-se 15% da distribuição na cauda de desvalorizações. Já para o *takeprofit*, fez-se o mesmo, contudo levou-se em conta neste caso a cauda de valorizações e um valor de 45%. Como pode-se perceber, trata-se de uma proporção 1:3, ou seja, o objetivo de ganhos é três vezes superior ao objetivo de perdas.
4. Definidos os tamanhos dos *stops* para cada ano e em cada ativo, a cada operação realizada, estes são então somados para mais e para menos no preço de entrada da operação, definindo-se assim, dia a dia, o valor de *stoploss* e o valor de *takeprofit* por ordem.

<sup>5</sup> Este preço de fechamento diz respeito apenas ao ambiente simulado. Em ambiente real deve-se levar em conta o horário da operação, neste caso, o mais próximo possível do encerramento das atividades no dia.

Para ilustrar, pode-se ver nos gráficos das Figuras 34 e 35, respectivamente, as distribuições dos retornos em 2010-2011 e 2011-2012 para o ativo BVMF3. A linha pontilhada preta denota a média da distribuição, a linha vermelha marca o ponto de *stoploss* (15% abaixo da média na cauda de desvalorizações) e a linha azul o ponto de *takeprofit* (45% acima da média na cauda de valorizações). Neste exemplo em específico, o tamanho do *stoploss* utilizado nas operações deste ativo foram em 2012 de R\$ 0,11 centavos e em 2013 de R\$ 0,07 centavos. Os valores de *takeprofit*, por sua vez, foram de R\$ 0,42 centavos em 2012 e R\$ 0,28 centavos no ano de 2013.

Figura 34 – Distribuição dos retornos no ativo BVMF3 entre 04/01/2010 a 29/12/2011. Definição de tamanho de *stops* com proporção 1:3, sendo 15% para perdas e 45% para ganhos.



Fonte: Elaborada pelo autor.


O uso desta estratégia para definição dos *stops* baseia-se no fato de que as variações dos retornos, ao longo do tempo e no período histórico, não se mostraram bruscas na maioria das vezes. Ou seja, pode-se aproveitar a existência de uma grande densidade de probabilidade abaixo da curva de distribuição dos retornos, 15% a partir da média na cauda de perdas e, da mesma forma, 45% a partir da média na cauda de ganhos. O ponto principal, nesta abordagem é que, desta forma, espera-se que com mais operações certas do robô, as situações de ganhos sejam valorizadas, gerando-se assim maiores lucros. Nas situações de perda que devem acontecer em menor quantidade, os prejuízos são, por sua vez, limitados. Por fim, na Tabela 7 são mostrados todos os tamanhos de *stop* definidos por meio da técnica proposta em cada um dos ativos.

#### 4.2.3.6 Construtor de estratégias

O sub-módulo “construtor de estratégias” é responsável por realizar a combinação dos cenários gerados pelo “gerador de cenários” e os pontos de *stop* definidos pelo “otimizador de



Figura 35 – Distribuição dos retornos no ativo BVMF3 entre 03/01/2011 a 28/12/2012. Definição de tamanho de *stops* com proporção 1:3, sendo 15% para perdas e 45% para ganhos.



Fonte: Elaborada pelo autor.

Tabela 7 – Tamanhos de *stop* definidos para cada um dos ativos nas distribuições dos retornos com proporção 1:3. Os valores 2010-2011 foram usados em 2012 e os valores 2011-2012 foram usados em 2013.

Ativo	2010-2011		2011-2012	
	Stoploss	Takeprofit	Stoploss	Takeprofit
BBAS3	0,14	0,52	0,16	0,5
BBDC4	0,21	0,53	0,21	0,53
BOVA11	0,69	1,31	0,69	1,22
BVMF3	0,11	0,42	0,07	0,28
ITSA4	0,07	0,15	0,07	0,15
GGBR4	0,21	0,51	0,18	0,54
USIM5	0,17	0,69	0,15	0,64
CSNA3	0,19	0,49	0,19	0,45
CYRE3	0,19	0,58	0,18	0,57
PETR4	0,22	0,52	0,27	0,54
VALE5	0,41	0,92	0,41	0,88

Fonte: Elaborada pelo autor.

stops” criando as “estratégias de operação”. Uma estratégia de operação, portanto, trata-se da combinação de um tipo de momento de confiança, de um tipo de comitê de decisão e dos pontos de *stop* otimizados em cada ativo. São possíveis, anualmente, até 9 estratégias por ativo.

Após a construção das estratégias, todas elas são submetidas ao Módulo Negociador que, baseado no modelo de negociação (já discutido na [subseção 4.2.2.1](#)), realiza simulações

de operações com 5 lotes de 100 ações cada (500 ações) e uma taxa de corretagem<sup>6</sup> de R\$ 3,80 por ordem executada. Os resultados da simulação são as seguintes medidas: (a) Quantidade de operações totais, certas e erradas; (b) evolução diária dos retornos; (c) retornos absolutos e percentuais sem corretagem; (d) POCID e; (e) taxa de acerto.

Dentre estas medidas, a que trata de retornos percentuais sem corretagem é a utilizada para selecionar a estratégia mais rentável, chamada aqui de melhor estratégia. Esta melhor estratégia é inicialmente gerada levando-se em conta as previsões feitas no ano de 2011, para ser utilizada então no ano seguinte de 2012. Em 2012, após o primeiro ano de operação do robô, a análise é repetida e uma nova melhor estratégia é, por fim, selecionada para ser aplicada em 2013. Como pode-se ver, o passo da janela móvel do construtor de estratégias, neste caso, é anual.

Como exemplo, pode-se ver os gráficos das figuras 36, 37 e 38. Estes dizem respeito ao período que vai de 03/01/2011 a 29/12/2011 no ativo VALE5 e tratam, respectivamente, de quantidade de operações certas e erradas neste ano, das taxas de acerto e dos retornos percentuais com e sem corretagem, discriminados por estratégia de operação.

Conforme pode-se perceber, em 2011 para VALE5, duas estratégias se destacaram quanto a taxa de acerto, como mostrado no gráfico da Figura 37: CV-CMTA e CMV-CMTA. Ambas tiveram, respectivamente, taxas de acerto de 63,1% com 112 operações corretas e 63,2% com 105 operações corretas. No entanto, percebe-se pelo gráfico da Figura 38, que a estratégia mais rentável não foi nenhuma destas duas, mas sim a CM-MTA que obteve um retorno percentual sem corretagem de 46,5% com uma taxa de acerto de 60,8% em 113 operações corretas. Logo esta estratégia foi selecionada para operar VALE5 em 2012 apesar da menor taxa de acerto. A escolha do retorno percentual sem corretagem como métrica que determina o melhor cenário dentre os 9 possíveis se baseia no fato de que, como os pontos de *stop* são valores que estão em escala monetária, o seu uso altera a qualidade dos cenários mesmo que estes acusem boas taxas de acerto percentual. Neste sentido, métricas baseadas em POCID tornam-se insuficientes para o processo de avaliação da qualidade dos retornos, portanto, prefere-se, neste caso, esta métrica que possui viés financeiro.


Finalmente, no Quadro 13 podem ser vistas as melhores estratégias identificadas por ano e suas respectivas colocações, com base no retorno percentual, no ano seguinte. Como percebe-se, não existem garantias de que uma estratégia rentável em um dado ano continue rentável no ano seguinte. Entretanto, no período de operação cega do robô, em 20 de 22 oportunidades, a estratégia mais rentável de um ano estava, pelo menos, entre as cinco mais rentáveis do ano seguinte.

No Quadro 14 estão dispostas quantas vezes cada uma das estratégias ficou em primeiro lugar nos anos de 2011, 2012 e 2013. Destas 33 oportunidades o robô investidor capturou “a melhor” em apenas 4 ocasiões, sendo, CNSA3 (2012), CYRE (2013), BBAS (2013) e BVMF3

<sup>6</sup> Para determinação do preço por ordem ver Capítulo 5


(2013). Isto mostra que conseguir identificar a melhor estratégia dentre todas não é uma tarefa trivial.

Figura 36 – Quantidade de operações certas e erradas por estratégia no ativo VALE5 no ano de 2011. Em 2011 foram 249 dias úteis na bolsa, logo, 249 oportunidades de operação.




Fonte: Elaborada pelo autor.

Figura 37 – Taxas de acerto por estratégia no ativo VALE5 no ano de 2011.



Fonte: Elaborada pelo autor.

Figura 38 – Retornos percentuais por estratégia com e sem corretagem no ativo VALE5 no ano de 2011.



Fonte: Elaborada pelo autor.

Quadro 13 – Melhores estratégias por ano e colocação das melhores estratégias no ano seguinte, por ativo.

Ativo	Ano	Melhor retorno no ano	Colocação no ano seguinte
BBAS3	2011	CV-CMTA	6 <sup>o</sup>
	2012	CV-MTA	1 <sup>o</sup>
BBDC4	2011	CV-CMTA	4 <sup>o</sup>
	2012	CMV-MTA	2 <sup>o</sup>
BOVA11	2011	CMV-CMTA	3 <sup>o</sup>
	2012	CV-CMTA	3 <sup>o</sup>
BVMF3	2011	CV-MTA	5 <sup>o</sup>
	2012	CV-CMTA	1 <sup>o</sup>
CSNA3	2011	CMV-CMTA	1 <sup>o</sup>
	2012	CMV-CMTA	2 <sup>o</sup>
CYRE3	2011	CV-CMTA	4 <sup>o</sup>
	2012	CV-MTA	1 <sup>o</sup>
CCBR4	2011	CV-CMTA	5 <sup>o</sup>
	2012	CM-MTA	5 <sup>o</sup>
ITSA4	2011	CV-MTA	4 <sup>o</sup>
	2012	CV-CMTA	4 <sup>o</sup>
PETR4	2011	CM-MTA	5 <sup>o</sup>
	2012	CM-CMTA	5 <sup>o</sup>
USIM5	2011	CV-CMTA	2 <sup>o</sup>
	2012	CM-ETA	7 <sup>o</sup>
VALE5	2011	CM-MTA	3 <sup>o</sup>
	2012	CMV-MTA	5 <sup>o</sup>

Quadro 14 – Total de ocorrências das estratégias como mais rentáveis (1º lugar) nos ativos por ano.

<b>Estratégia</b>	<b>Ocorrências</b>	<b>Ativo e Ano</b>
CM-ETA	1	USIM5 (2012)
CM-CMTA	1	PETR4 (2012)
CM-MTA	5	BBDC4 (2013), GGBR4 (2012), PETR4 (2011), PETR4 (2013), VALE5 (2011)
CV-ETA	0	Nenhum ativo
CV-CMTA	11	BBAS3 (2011), BBDC4 (2011), BOVA11 (2012), BVMF3 (2012), BVMF3 (2013), CYRE3 (2011), GGBR4 (2011), GGBR4 (2013), ITSA4 (2012), USIM5 (2011), VALE5 (2013)
CV-MTA	8	BBAS3 (2012), BBAS3 (2013), BVMF3 (2011), CSNA3 (2013), CYRE3 (2012), CYRE3 (2013), ITSA4 (2012), ITSA4 (2013)
CMV-ETA	0	Nenhum ativo
CMV-CMTA	5	BOVA11 (2011), BOVA11 (2013), CSNA3 (2011), CSNA3 (2013), USIM5 (2013)
CMV-MTA	2	BBDC4 (2012), VALE5 (2012)

#### 4.2.3.7 Considerações finais

Neste capítulo foram apresentados os conceitos necessários ao entendimento do arcabouço que compõe o robô investidor. Foram feitas explanações acerca dos motivos que levaram as decisões de implementação e como cada um dos componentes, distribuídos entre os módulos, interagem de forma a gerar sinais que podem ser utilizados para simular negociações no mercado.

Dois pontos menos relevantes que a metodologia em si, mas que também são importantes ao completo entendimento desta pesquisa, foram inseridos como apêndices nesta dissertação. O primeiro, situado no [Apêndice A](#), trata-se de uma breve caracterização de cada uma das 11 séries envolvidas no estudo. Neste é também discutida brevemente a situação do mercado durante o período de simulação e, de um ponto de vista mais geral, são feitas também comparações entre os ativos. Esta parcela do estudo se faz importante pois pretende-se mostrar ao leitor a representatividade do *dataset* utilizado, mesmo com a aplicação da seleção dinâmica da carteira de investimento. O segundo ponto, situado no [Apêndice B](#), apresenta conceituações sobre as ferramentas e plataformas tecnológicas utilizadas para o desenvolvimento do robô investidor, tanto de *software* quanto de *hardware*.

O próximo capítulo irá apresentar os resultados obtidos pelas simulações realizadas no período de operação cega do robô, além de análises e comparativos diversos.



---

## APRESENTAÇÃO E ANÁLISE DE RESULTADOS

---

Os resultados relatados neste capítulo dizem respeito a 494 dias de pregão situados no período que vai de 02/01/2012 a 30/12/2013. Em todos os experimentos foram utilizados 5 lotes de 100 ações (500 ações). Quanto a taxa de corretagem por ordem, quando esta foi considerada, utilizou-se o valor de R\$ 3,80. Este custo foi selecionado levando-se em conta um levantamento realizado junto a três corretoras nacionais para pacotes de transação com 1000 ordens. Tomou-se o preço mais alto encontrado entre estas. Os pacotes podem ser consultados em [Clear CTVM \(2016\)](#), [Rico CTVM S.A. \(2016\)](#) e [XP Investimentos \(2016\)](#).

As análises estão separadas por tipo de medida e, em cada seção, são feitas considerações acerca do desempenho individual do robô investidor, bem como a sua comparação, quando conveniente, frente a:

- Os melhores preditores individualmente identificados após o período de operação em cada classe. Por melhores preditores entende-se aqui, os que demonstraram maior rentabilidade.
- A média entre todos os preditores existentes em cada classe.
- Ao índice Bovespa, e;
- A técnica de mercado *Buy and Hold*.


Um ponto bastante importante a se destacar é que os melhores preditores (citados no primeiro item da listagem anterior) são de fato, os preditores que geraram maiores lucros após a simulação já realizada. Em outras palavras, o robô tem seu desempenho (em ambiente desconhecido) comparado ao melhor preditor de uma classe após já se conhecer o seu desempenho individual ao final da simulação em cada ativo. Ou seja, compara-se o robô aos melhores concorrentes possíveis como se já fosse sabido no futuro quais apresentariam os maiores ganhos.

Esse tipo de comparação deve ser reforçada pois os resultados obtidos denotam a capacidade do algoritmo em combinar preditores e suas previsões a fim de que seja dispensada a tomada de decisão sobre qual dos 86 utilizar. O objetivo com este capítulo é mostrar ao leitor que o robô investidor proposto, nas condições como detalhadas a seguir, apresentou evidências significativas de que pode produzir resultados melhores ou, pelo menos, equivalentes aos seus concorrentes.

## 5.1 Oportunidades de operação

Tanto em 2012 quanto em 2013 houveram 247 dias úteis de pregão na BOVESPA. Logo, para este período selecionado, o robô investidor gerou 494 sinais de operação em 11 ativos, resultando em 5434 sinais. Entre estes sinais, a cada dia, o robô poderia incidir em uma de cinco situações: compra certa, compra errada, venda certa, venda errada ou não operar. Baseado nestas situações, conforme pode ser visto no gráfico da [Figura 39](#), em todos os ativos operados, o robô obteve maior quantidade de sinais emitidos de forma certa do que errada, sendo 2234 sinais corretos frente a 1599 errados. O robô, também, preferiu não operar em 1601 oportunidades. Neste sentido, pode-se dizer que, de 100% das operações, 41,1% corresponderam a previsões corretas, 29,4% a previsões erradas e 29,5% a momentos de indefinição. Levando-se em conta que, segundo o modelo de negociação, o sinal sempre corresponde a execução de uma ordem na abertura e, na sequência, fechamento da posição no mesmo dia do pregão conforme a variação dos preços, pode-se dizer que, para cada um dos sinais definidos (corretos ou errados) sempre duas ordens são executadas. Logo, neste experimento foram realizadas 7666 transações, o que, segundo o valor de corretagem por ordem utilizado, gerou um custo total de R\$ 29.130,80 em dois anos de operação (aproximadamente, R\$ 1.214,00 por mês).

Figura 39 – Quantidade de operações certas e erradas por ativo em 494 oportunidades de pregões entre os anos de 2012 e 2013.



Fonte: Elaborada pelo autor.



Comparando-se agora o desempenho médio do robô, em todos os ativos, frente ao desempenho médio dos preditores mais rentáveis de cada classe, pode-se ver que, conforme os dados expostos na [Tabela 8](#), este se sobressai sendo que, para cada operação correta existe uma proporção de 0,72 erradas (1:0,72). Esse valor é melhor que o encontrado nas melhores SMA's que acusaram 1:0,91, aos melhores Seletores SARIMA e GARCH que demonstraram 1:0,92, as RNA's de *candles* com 1:0,85 e, por fim, as RNA's de tendência com 1:0,89. Nesta tabela, pode-se observar também que RNA's de tendência com menores quantidades de neurônios se saíram melhor no experimento, visto que nenhuma com mais que 25 neurônios foi elencada entre as mais acuradas, em nenhum dos ativos. Uma provável evidência de *overfitting* em quantidades maiores que 25. Já nas outras classes de preditores, percebe-se diversidade tanto em tamanho de janela quanto em quantidade de neurônios.

Tabela 8 – Quantidades de operações certas e erradas por ativo. Robô investidor contra os preditores mais rentáveis de cada classe de preditores.


Ativo	ROBÔ		SMA (Janela)	Seletor SARIMA (Janela)	GARCH (Janela)	RNA de Candles (Janela- Neurônios)	RNA de Tendência (Neurônios)
BBAS3	210	132	<b>21</b>	<b>31</b>	<b>370</b>	<b>20-35</b>	<b>10</b>
			263   231	283   211	278   216	288   206	272   222
BBDC4	214	138	<b>9</b>	<b>124</b>	<b>248</b>	<b>10-5</b>	<b>20</b>
			260   234	264   230	268   226	278   216	265   229
BOVA11	200	144	<b>30</b>	<b>248</b>	<b>248</b>	<b>35-5</b>	<b>10</b>
			260   234	267   227	263   231	267   227	262   232
BVMF3	210	138	<b>120</b>	<b>186</b>	<b>124</b>	<b>20-40</b>	<b>5</b>
			259   235	256   238	260   234	265   229	273   221
CSNA3	195	125	<b>30</b>	<b>62</b>	<b>370</b>	<b>10-5</b>	<b>20</b>
			276   218	258   236	257   237	275   219	260   234
CYRE3	187	144	<b>9</b>	<b>31</b>	<b>124</b>	<b>30-30</b>	<b>5</b>
			251   243	248   246	255   239	260   234	259   235
GGBR4	209	154	<b>60</b>	<b>186</b>	<b>124</b>	<b>10-20</b>	<b>10</b>
			252   242	249   245	255   239	269   225	245   249
ITSA4	227	160	<b>9</b>	<b>186</b>	<b>124</b>	<b>60-10</b>	<b>25</b>
			250   244	262   232	262   232	245   219	255   239
PETR4	184	163	<b>21</b>	<b>186</b>	<b>370</b>	<b>30-35</b>	<b>5</b>
			247   247	237   257	237   257	253   241	260   234
USIM5	184	134	<b>21</b>	<b>31</b>	<b>370</b>	<b>35-10</b>	<b>10</b>
			267   227	250   244	240   254	261   233	266   228
VALE5	214	167	<b>9</b>	<b>124</b>	<b>124</b>	<b>60-20</b>	<b>10</b>
			255   239	254   240	255   239	266   228	258   236
<b>MÉDIA</b>	203	145	258   236	257   237	257   237	266   225	261   233
<b>PROPORÇÃO DE ERRADAS PARA UMA CORRETA</b>	0,72		0,91	0,92	0,92	0,85	0,89

Fonte: Elaborada pelo autor.

## 5.2 Taxas de acerto

A taxa de acerto no período simulado diz respeito a quantidade de sinais previstos de forma correta. Como pode ser visto no gráfico da [Figura 40](#), o robô apresentou taxas de acerto superiores a 60% em 4 dos 11 ativos, sendo BBAS3, BBDC4, BVMF3 e CSNA3. Outros 6 ativos ficaram com taxas entre 55% e 59% sendo BOVA11, CYRE3, GGBR4, ITSA4, USIM5 e VALE5. Por fim, apenas PETR4 apresentou taxa de acerto inferior a 55%. A taxa de acerto média, portanto, foi de 58,3%.

Figura 40 – Taxas de acerto obtidas pelo robô nas previsões geradas no período simulado em todos os ativos.



Fonte: Elaborada pelo autor.

Comparando-se as taxas de acerto obtidos pelo robô investidor frente aos melhores preditores de cada classe (já apresentados na [Tabela 8](#)) obteve-se os dados contidos na [Tabela 9](#). Como pode-se perceber o robô apresentou melhores previsões em todos os ativos. O mesmo aconteceu quando da comparação da média geral do robô contra as médias em cada classe e, contra as médias em cada categoria.

Nesta análise vale dar destaque as RNA's de *candles* que se sobressaíram frente aos demais preditores (exceto o robô) devido, especialmente, ao seu desempenho nos ativos BBAS3, BBDC4, ITSA4 e CSNA3. Não por coincidência, 3 destes 4 ativos são os mesmos nos quais o robô investidor também apresentou suas maiores taxas de acerto. Neste caso, vê-se uma possível evidência de que as RNA's rentáveis podem ter sido aproveitadas pelo robô durante a construção das estratégias que foram executadas no período simulado. Outro ponto importante é que as classes Seletor SARIMA, GARCH e RNA de *candles*, como o robô, apresentaram melhores resultados quando operando BBAS3. A RNA de tendência apresentou o segundo melhor resultado em BBAS3 e, apenas a SMA, um tipo de preditor que não trabalha com padrões, mas sim tendências, é que apresentou melhor resultado em outro ativo, no caso, em CSNA3. Esta observação pode evidenciar que o ativo BBAS3 possui características que lhe conferem maior

facilidade na execução de previsões. Estas características podem ser sazonalidades, padrões gráficos mais estabelecidos, menor variância nas volatilidades ou até melhor ajustamento aos modelos econométricos. A média de todos os preditores neste ativo, por exemplo, foi de 56%, um valor maior do que o próprio robô obteve em PETR4 e o mesmo obtido por ele em CYRE3 e VALE5. Esta nuance sobre as séries poderia ser melhor investigada para, porventura, dar amparo a uma possível estratégia com ativos “mais previsíveis”.

Tabela 9 – Comparativo das taxas de acerto do robô investidor frente aos preditores mais rentáveis em cada classe de preditor.

ATIVO	ROBÔ	SMA	Seletor SARIMA	GARCH	RNA de Candles	RNA de Tendência}
BBAS3	61,4	53,24	57,29	56,28	58,3	55,06
BBDC4	60,8	52,63	53,44	54,25	56,28	53,64
BOVA11	58,14	52,63	54,05	53,24	54,05	53,04
BVMF3	60,34	52,43	51,82	52,63	53,64	55,26
ITSA4	58,66	50,61	53,04	53,04	55,67	51,62
GGBR4	57,58	51,01	50,4	51,62	54,45	49,6
USIM5	57,86	54,05	50,61	48,58	52,83	53,85
CSNA3	60,94	55,87	52,23	52,02	55,67	52,63
CYRE3	56,5	50,81	50,2	51,62	52,63	52,43
PETR4	53,03	50	47,98	47,98	51,21	52,63
VALE5	56,17	51,62	51,42	51,62	53,85	52,23
<b>MÉDIA NA CLASSE</b>	58,31	52,26	52,04	52,08	54,42	52,91
<b>MÉDIA NA CATEGORIA</b>	58,31	52,13			53,67	

Fonte: Elaborada pelo autor.

Outra comparação que também foi realizada é a do robô investidor frente as médias e desvios dos preditores por classe, ou seja, a média aritmética simples e o desvio padrão das taxas de acerto obtidas separadamente pelas 6 SMA's, pelos 5 Seletores SARIMA, pelos 3 GARCH's, pelas 64 RNA's de *candles* e pelas 8 RNA's de tendência, por ativo.

Observando-se as linhas correspondentes ao desvio padrão na [Tabela 10](#), pode-se perceber que o desvio das taxas no caso do robô investidor é sempre zero. Isso ocorre, pois o robô investidor em si corresponde a apenas um preditor, ao passo que, todos os outros, fazem parte de alguma classe onde mais de um preditor existe. Portanto, quanto a desvio padrão, no caso específico desta comparação, o robô sempre será superior. Já no caso das médias, vê-se que, em todas as classes, existe uma proximidade grande do valor médio a 50%. Este fato se dá, pois, durante o período de simulação, dentro de uma mesma classe, alguns preditores podem se mostrar adequados ao mesmo tempo em que outros não. Esse equilíbrio tende a criar um balanceamento entre preditores que são capazes de gerar lucros com preditores que apenas geram prejuízos. Na média, os valores acabam assim por convergir. Mesmo assim, pode-se notar que, em todas as

classes, inclusive na RNA de *candles* que possui 64 preditores, as taxas de acerto médias foram superiores a 50%.

Mais uma vez vale ressaltar que, no ativo BBAS3, houveram melhores taxas de acerto do que as observadas em todos os outros ativos, para a maioria das classes de preditores do estudo.


Tabela 10 – Comparativo das taxas de acerto do robô investidor frente as medias de todos os preditores e desvio padrão, separados por classe.

Ativo	Medida	ROBÔ	SMA	Seletor SARIMA	GARCH	RNA de <i>candles</i>	RNA de Tendência
BBAS3	Média	61,4	50,64	56,52	55,94	54,75	53,16
	Desvio	0	2,26	0,48	0,42	2,17	1,31
BBDC4	Média	60,8	51,15	52,67	52,43	50,89	51,42
	Desvio	0	1,23	0,97	1,58	1,59	1,39
BOVA11	Média	58,14	50,37	51,86	52,09	50,99	51,59
	Desvio	0	2,11	1,31	1,12	1,45	1,37
BVMF3	Média	60,34	49,33	50,52	51,62	50,11	53,54
	Desvio	0	1,56	1,33	1,26	1,71	1,15
CSNA3	Média	60,94	54,69	51,58	50,94	50,7	52,02
	Desvio	0	0,88	0,58	1,38	1,77	0,5
CYRE3	Média	56,5	49,09	49,15	50,74	50,39	47,77
	Desvio	0	1,86	0,93	1,35	1,4	2,27
GGBR4	Média	57,58	49,26	49,55	50,34	50,39	47,9
	Desvio	0	1,81	0,61	1,11	1,47	0,8
ITSA4	Média	58,66	49,59	52,55	52,23	51,95	49,72
	Desvio	0	0,9	0,47	0,93	1,71	1,78
PETR4	Média	53,03	49,09	47	47,17	47,12	50,73
	Desvio	0	0,84	0,71	1,07	1,47	1,13
USIM5	Média	57,86	52,87	49,31	48,04	50,2	51,95
	Desvio	0	1,24	0,77	0,47	1,08	1,58
VALE5	Média	56,17	49,23	50,81	51,28	50,18	50,35
	Desvio	0	1,61	0,43	0,58	1,39	1,03
<b>MÉDIAS DAS MÉDIAS</b>		58,31	50,48	51,05	51,17	50,70	50,92
<b>DESVIO MÉDIO</b>		0,00	1,48	0,78	1,02	1,56	1,30

Fonte: Elaborada pelo autor.

Finalmente, pode-se ver na [Figura 41](#) um gráfico de barras que mostra as taxas de acerto médias obtidas pelo robô investidor, pelos melhores preditores de cada classe e, também, por todos os preditores da mesma classe. Fica claro que o robô é superior a estes *benchmarks*, seguido pela RNA de *candles*, RNA de tendência, SMA, GARCH e, por fim, o Seletor SARIMA.

Figura 41 – Taxa de acerto media do robô investidor, das classes e dos melhores preditores em cada classe.



Fonte: Elaborada pelo autor.

### 5.3 Retornos financeiros

Os retornos financeiros tratam da magnitude de ganhos ou perdas obtidas pelo robô investidor durante o período de simulação em moeda brasileira (R\$). Como no estudo sempre foram negociados 5 lotes, o investimento necessário para uma negociação no dia corrente, em cada ativo, correspondeu sempre a compra ou venda à descoberto de 500 ações no preço unitário de abertura do pregão. Neste sentido, dentre os valores necessários à primeira operação em todos os ativos, o mais caro foi o observado em BOVA11 custando R\$ 28.010,00. Com base nisto, utilizou-se então R\$ 50.000,00 como valor de caixa para cada ativo no primeiro dia, ou seja, R\$ 550.000,00 levando-se em conta toda a carteira. Este valor foi estabelecido pretendendo-se manter uma margem que permitisse que o robô continuasse a negociar mesmo em períodos de prejuízo. Entretanto, conforme poderá ser visto na seção seguinte sobre a evolução dos retornos, em nenhum momento a margem foi consumida nas análises sem corretagem. Ao contrário disto, os retornos, na maioria dos casos, se mantiveram em ascensão. Na [Tabela 11](#) podem ser vistos diversos valores financeiros e percentuais de forma consolidada, sendo, o investimento inicial referente ao primeiro dia de operação em 2012 para cada um dos ativos. Na sequência o primeiro retorno obtido, resultado da primeira operação de 2012. Os rendimentos do robô ao final de 2012 e 2013 e, por fim, o retorno total líquido e total percentual sobre o primeiro retorno. A amostra de dados desta tabela trata dos retornos sem a aplicação da taxa de corretagem de R\$ 3,80. Na [Tabela 12](#) pode ser visto o mesmo conjunto de dados, contudo com a incidência da corretagem por ordem.

Tabela 11 – Retornos financeiros e percentuais para todos os ativos sem corretagem.

Ativo	Investimento Inicial	Primeiro retorno	Rendimentos (2012)	Rendimentos (2013)	Retorno total líquido	Retorno total percentual
BBAS3	R\$ 8.415,00	R\$ 8.555,00	R\$ 8.455,00	R\$ 9.750,00	R\$ 18.205,00	212,80%
BBDC4	R\$ 8.915,00	R\$ 8.810,00	R\$ 5.140,00	R\$ 5.830,00	R\$ 10.970,00	124,52%
BOVA11	R\$ 28.010,00	R\$ 27.665,00	R\$ 11.805,00	R\$ 11.850,00	R\$ 23.655,00	85,51%
BVMF3	R\$ 4.005,00	R\$ 4.005,00	R\$ 4.570,00	R\$ 3.805,00	R\$ 8.375,00	209,11%
CSNA3	R\$ 2.780,00	R\$ 5.845,00	R\$ 4.200,00	R\$ 4.260,00	R\$ 8.460,00	144,74%
CYRE3	R\$ 6.745,00	R\$ 6.670,00	R\$ 7.380,00	R\$ 3.260,00	R\$ 10.640,00	159,52%
GGBR4	R\$ 4.905,00	R\$ 6.745,00	R\$ 5.430,00	R\$ 5.400,00	R\$ 10.830,00	160,56%
ITSA4	R\$ 5.780,00	R\$ 2.745,00	R\$ 1.605,00	R\$ 1.275,00	R\$ 2.880,00	104,92%
PETR4	R\$ 6.380,00	R\$ 9.740,00	R\$ 5.730,00	R\$ 2.260,00	R\$ 7.990,00	82,03%
USIM5	R\$ 9.480,00	R\$ 5.090,00	R\$ 6.145,00	R\$ 1.530,00	R\$ 7.675,00	150,79%
VALE5	R\$ 14.850,00	R\$ 14.850,00	R\$ 7.075,00	R\$ 4.815,00	R\$ 11.890,00	80,07%
<b>TOTAL</b>	R\$ 100.265,00	R\$ 100.720,00	R\$ 67.535,00	R\$ 54.035,00	R\$ 121.570,00	
<b>TOTAL (%)</b>		100%	67,05%	53,65%	120,70%	

Fonte: Elaborada pelo autor.

Tabela 12 – Retornos financeiros e percentuais para todos os ativos com corretagem por ordem.

Ativo	Primeiro retorno com corretagem	Sinais válidos	Total de ordens	Custo da corretagem	Retorno total líquido com corretagem	Retorno total percentual com corretagem
BBAS3	R\$ 8.551,20	342	684	R\$ 2.599,20	R\$ 15.605,80	182,50%
BBDC4	R\$ 8.806,20	352	704	R\$ 2.675,20	R\$ 8.294,80	94,19%
BOVA11	R\$ 27.661,20	344	688	R\$ 2.614,40	R\$ 21.040,60	76,07%
BVMF3	R\$ 4.001,20	348	696	R\$ 2.644,80	R\$ 5.730,20	143,21%
CSNA3	R\$ 5.841,20	320	640	R\$ 2.432,00	R\$ 6.028,00	103,20%
CYRE3	R\$ 6.666,20	331	662	R\$ 2.515,60	R\$ 8.124,40	121,87%
GGBR4	R\$ 6.741,20	363	726	R\$ 2.758,80	R\$ 8.071,20	119,73%
ITSA4	R\$ 2.741,20	387	774	R\$ 2.941,20	-R\$ 61,20	-2,23%
PETR4	R\$ 9.736,20	347	694	R\$ 2.637,20	R\$ 5.352,80	54,98%
USIM5	R\$ 5.086,20	318	636	R\$ 2.416,80	R\$ 5.258,20	103,38%
VALE5	R\$ 14.846,20	381	762	R\$ 2.895,60	R\$ 8.994,40	60,58%
<b>TOTAL</b>	R\$ 100.678,20	3833	7666	R\$ 29.130,80	R\$ 92.439,20	92,19%

Fonte: Elaborada pelo autor.

Como pode-se perceber o robô se mostrou lucrativo, mesmo com a corretagem, em 10 dos 11 ativos que compuseram a carteira de investimento. O lucro total na carteira sem a incidência da corretagem foi de R\$ 121.570,00 e, com corretagem, de R\$ 92.439,40. Um valor positivo percentual, em relação ao primeiro retorno, respectivamente de 120,7% e 92,19%.

Apesar dos lucros observados, as taxas que incidem sobre as operações no mercado ainda são maiores do que apenas a taxa de corretagem por ordem. Neste sentido, outro estudo possível é o que leva em conta também todas estas outras taxas existentes. Tomando-se por base

a mesma corretora utilizada como referência para o valor da taxa de corretagem adotada, foram observadas ainda as seguintes tarifas:

- Impostos sobre Serviços (ISS): Este imposto corresponde a 5% do valor de corretagem cobrado.
- Emolumentos em 0,005% e liquidação em 0,02% conforme valores definidos pela BOVESPA para operações *daytrade* por operação.
- Taxa de custódia: O valor da taxa de custódia, nesta corretora em específico, não é cobrado para casos em que mais de duas operações sejam feitas por mês, situação deste estudo.
- Taxa sobre o valor de custódia: Esta taxa incide apenas quando existem posições em aberto no último dia do mês, o que não é o caso no robô investidor pois as posições são fechadas diariamente.
- Imposto de renda: O imposto de renda é aplicado por operação, entretanto, com a finalidade de simplificar o cálculo, adotou-se neste estudo o valor de 15% sobre o rendimento líquido total e 1% como valor retido na fonte para antecipação. Estes dois custos foram extraídos de [BM&F Bovespa \(2016c\)](#).

Levando-se em conta estas novas tarifas pode-se ver o cálculo dos custos por ativo na [Tabela 13](#).

Tabela 13 – Cálculo de custos de negociação por ativo no período simulado.

Ativo	Corretagem	ISS	Emolumentos	Liquidação	IR (sobre rendimentos)	IR (retido na fonte)
BBAS3	R\$ 2.599,20	R\$ 129,96	R\$ 0,91	R\$ 3,64	R\$ 2.730,75	R\$ 182,05
BBDC4	R\$ 2.675,20	R\$ 133,76	R\$ 0,55	R\$ 2,19	R\$ 1.645,50	R\$ 109,70
BOVA11	R\$ 2.614,40	R\$ 130,72	R\$ 1,18	R\$ 4,73	R\$ 3.548,25	R\$ 236,55
BVMF3	R\$ 2.644,80	R\$ 132,24	R\$ 0,42	R\$ 1,68	R\$ 1.256,25	R\$ 83,75
CSNA3	R\$ 2.432,00	R\$ 121,60	R\$ 0,42	R\$ 1,69	R\$ 1.269,00	R\$ 84,60
CYRE3	R\$ 2.515,60	R\$ 125,78	R\$ 0,53	R\$ 2,13	R\$ 1.596,00	R\$ 106,40
GGBR4	R\$ 2.758,80	R\$ 137,94	R\$ 0,54	R\$ 2,17	R\$ 1.624,50	R\$ 108,30
ITSA4	R\$ 2.941,20	R\$ 147,06	R\$ 0,14	R\$ 0,58	R\$ 432,00	R\$ 28,80
PETR4	R\$ 2.637,20	R\$ 131,86	R\$ 0,40	R\$ 1,60	R\$ 1.198,50	R\$ 79,90
USIM5	R\$ 2.416,80	R\$ 120,84	R\$ 0,38	R\$ 1,54	R\$ 1.151,25	R\$ 76,75
VALE5	R\$ 2.895,60	R\$ 144,78	R\$ 0,59	R\$ 2,38	R\$ 1.783,50	R\$ 118,90
<b>TOTAL</b>	<b>R\$ 29.130,80</b>	<b>R\$ 1.456,54</b>	<b>R\$ 6,08</b>	<b>R\$ 24,31</b>	<b>R\$ 18.235,50</b>	<b>R\$ 1.215,70</b>

Fonte: Elaborada pelo autor.

Totalizando-se todos os custos num custo único para cada ativo no período simulado, pode-se refazer os cálculos gerando o valor aproximado para os retornos líquidos e percentuais conseguidos com as operações. A [Tabela 14](#) resume esta análise.

Tabela 14 – Retornos líquidos e percentuais com subtração de todas as taxas existentes em operações no mercado.

Ativo	Investimento Inicial	Primeiro retorno com corretagem	Custo total de taxas por ativo	Retorno total líquido com todas as taxas	Retorno percentual total com todas as taxas
BBAS3	R\$ 8.415,00	R\$ 8.551,20	R\$ 5.646,51	R\$ 12.558,49	146,86%
BBDC4	R\$ 8.915,00	R\$ 8.806,20	R\$ 4.566,90	R\$ 6.403,10	72,71%
BOVA11	R\$ 28.010,00	R\$ 27.661,20	R\$ 6.535,83	R\$ 17.119,17	61,89%
BVMF3	R\$ 4.005,00	R\$ 4.001,20	R\$ 4.119,13	R\$ 4.255,87	106,36%
CSNA3	R\$ 2.780,00	R\$ 5.841,20	R\$ 3.909,32	R\$ 4.550,69	77,91%
CYRE3	R\$ 6.745,00	R\$ 6.666,20	R\$ 4.346,44	R\$ 6.293,56	94,41%
GGBR4	R\$ 4.905,00	R\$ 6.741,20	R\$ 4.632,25	R\$ 6.197,75	91,94%
ITSA4	R\$ 5.780,00	R\$ 2.741,20	R\$ 3.549,78	-R\$ 669,78	-24,43%
PETR4	R\$ 6.380,00	R\$ 9.736,20	R\$ 4.049,46	R\$ 3.940,54	40,47%
USIM5	R\$ 9.480,00	R\$ 5.086,20	R\$ 3.767,56	R\$ 3.907,44	76,82%
VALE5	R\$ 14.850,00	R\$ 14.846,20	R\$ 4.945,75	R\$ 6.944,25	46,77%
<b>TOTAL</b>	<b>R\$ 100.265,00</b>	<b>R\$ 100.678,20</b>	<b>R\$ 50.068,93</b>	<b>R\$ 71.501,07</b>	<b>71,02%</b>


Fonte: Elaborada pelo autor.

Como pode-se notar, o robô investidor, mesmo com todas as taxas incluídas, ainda se mostrou rentável, com um retorno líquido de R\$ 71.501,07 (71,02% de lucro sobre o primeiro retorno). O gráfico da [Figura 42](#) resume as análises sem corretagem, com corretagem e com todas as taxas, por meio dos rendimentos percentuais em cada abordagem. Fica nítido que as taxas praticadas pelo mercado financeiro influenciam fortemente nos rendimentos, neste caso, evidenciando uma queda de 121% sem corretagem para 71% com todas as taxas, ou seja, uma perda de 50% no desempenho médio.

Levando-se em conta o pior caso, com o percentual de 71% alcançado e, dividindo-se este de forma igual nos dois anos de simulação, obtém-se um hipotético rendimento médio aproximado de 35% ao ano. Tomando-se por base este valor, pode-se dizer que o robô, como aplicado, seria mais rentável do que quase todos os fundos de renda fixa ou variável brasileiros listados no *ranking* de fundos da Revista Exame do ano de 2012 ([WILTGEN, 2012](#)), perdendo apenas para as NTN-B's (Tesouro direto atrelado a inflação). Este seria também mais rentável que todos os fundos de aplicação, baseado no *ranking* da mesma revista, contudo levando-se em conta agora a versão de 2013 ([YAZBEK, 2013](#)).



Figura 42 – Retornos percentuais do robô para análises sem corretagem, com corretagem e com todas as taxas de operação.



Fonte: Elaborada pelo autor.

Outro ponto que pode ser destacado é que dos 4 ativos que apresentaram taxas de acerto superiores a 60% (BBAS3, BBDC4, BVMF3 e CSNA3), apenas 2 estavam também entre os quatro com maiores rendimentos percentuais (BBAS3, BVMF3, GGBR4 e USIM5). Em outras palavras, as taxas de acerto combinadas aos mecanismos de avaliação financeira para os cenários e estratégias, possuem capacidade de melhorar resultados mesmo em ativos em que a previsão

não esteve necessariamente entre as melhores do estudo. Dado que o objetivo primordial de um robô investidor não é o de ter boas taxas de acerto, mas sim bons rendimentos financeiros, entende-se que com estes resultados, o esforço necessário para se implementar análises que buscaram maximizar lucros como a definição de pontos de *stops* ou a seleção de cenários por meio dos lucros foi, portanto, acertada e justificável.


Falando-se ainda exclusivamente do robô, pode-se citar também a situação observada no ativo ITSA4. Este, dentre todos, foi o único que não apresentou lucros após a incidência de taxas, situação observada dada a baixa volatilidade de preços encontrada em sua série nos anos de 2012 e 2013. Este fato é relevante para o bom desempenho do robô investidor, pois, dado que o mesmo integraliza lucros na diferença existente entre o preço de abertura e, o fechamento ou um ponto de *stop*, baixas diferenças entre estes pontos representam, consequentemente, baixos lucros. Em outras palavras, quanto maiores os *candles* nas operações acertadas, maiores os rendimentos ao final de todo o processo. Se os *candles* são pequenos, como é no caso da série de ITSA4, os lucros são consumidos pelas taxas de corretagem que, em dados momentos, podem inclusive, superar os lucros. Este problema pode ser solucionado operando-se uma maior quantidade de ações. Entretanto, como o padrão foi definido em 5 lotes, não se pôde obter nenhum rendimento positivo neste ativo, mesmo com taxa de acerto de 58,66% e o bom rendimento sem corretagem de 104,92%.

Fazendo-se agora uma análise comparativa quanto aos rendimentos sem corretagem obtidos pelo robô frente aos melhores preditores de cada classe (já mostrados na [Tabela 8](#)), ao índice Bovespa e a técnica de mercado *Buy and Hold*, podem ser observados os valores percentuais da [Tabela 15](#). Como visto, o robô foi superior a todos os *benchmarks* em todos os ativos, com exceção de ITSA4. Neste, o melhor resultado foi o de 106,02% conseguido por uma RNA de *candles* com janela de 60 dias e 10 neurônios. A comparação com o índice Bovespa deixa claro que, mesmo com o mercado em queda no período de simulação, o robô ainda assim conseguiu apresentar lucros. Quanto a técnica *Buy and Hold*, o melhor valor foi visto no ativo USIM5 que apresentou 35,76% de rendimento, porém sendo superado em 115% pelo robô. Observando-se agora os valores médios das classes, vê-se que as RNA's de *candles* tiveram destaque com 66,63% de rendimento, seguida pelas RNA's de tendência com 40,70%. Já nos preditores econométricos, a única classe lucrativa na média foi a SMA. Entretanto cabe ressaltar que os resultados do Seletor SARIMA e GARCH foram bastante expressivos em BBAS3 com 133,14% e 144,48% respectivamente. No gráfico da [Figura 43](#) é mostrada a dispersão dos resultados obtidos em todos os ativos. Já na [Figura 44](#) pode-se ver um comparativo entre as médias de cada classe e o robô.

Tabela 15 – Rendimentos percentuais sem corretagem do robô investidor contra os melhores preditores em cada classe, ao índice Bovespa e a técnica de mercado *Buy and Hold*.


Ativo	ROBÔ	SMA	Seletor SARIMA	GARCH	RNA de Candles	RNA de Tendência	Índice Bovespa	Buy and Hold
BBAS3	212,80	147,43	133,14	144,48	141,99	78,08	-11,91	19,11
BBDC4	124,52	53,34	80,75	96,83	120,95	69,65	-11,91	11,44
BOVA11	85,51	33,49	57,62	40,08	51,81	33,70	-11,91	-11,91
BVMF3	209,11	24,09	-29,34	-2,37	8,61	87,77	-11,91	24,22
ITSA4	104,92	73,54	90,69	61,13	106,02	-2,74	-11,91	6,02
GGBR4	160,56	-23,31	-10,84	51,97	87,19	-15,89	-11,91	29,47
USIM5	150,79	91,74	27,97	3,18	2,95	73,48	-11,91	35,76
CSNA3	144,74	107,36	73,23	72,18	107,53	49,36	-11,91	12,77
CYRE3	159,52	26,26	-12,79	-31,69	69,78	37,62	-11,91	-1,87
PETR4	82,03	74,00	24,91	22,09	-6,98	26,79	-11,91	-16,19
VALE5	80,07	5,77	14,09	35,66	43,12	9,90	-11,91	-5,54
<b>MÉDIA DOS MELHORES DA CLASSE</b>	137,69	55,79	40,86	44,87	66,63	40,70	-11,91	9,39
<b>MÉDIA DOS MELHORES DA CATEGORIA</b>	137,69	47,17			53,67		-11,91	9,39

Fonte: Elaborada pelo autor.

Figura 43 – Gráfico de dispersão dos retornos percentuais sem corretagem obtidos pelo robô, pelos melhores preditores de cada classe, pelo índice Bovespa e pela técnica de mercado *Buy and Hold*.

Fonte: Elaborada pelo autor.

Figura 44 – Rendimentos percentuais médios do robô, dos melhores preditores de cada classe, do índice Bovespa e da técnica de mercado *Buy and Hold*.



Fonte: Elaborada pelo autor.

Na [Tabela 16](#), mais uma vez quanto aos rendimentos percentuais sem corretagens, podem ser vistas as médias e desvios padrões em cada uma das classes frente ao robô investidor. Nota-se que nesta situação as RNA's apresentam menores rendimentos do que os preditores econométricos. Neste caso, as RNA's obtiveram na média geral um valor de 18,63% contra 28,98% dos econométricos. O desvio padrão médio das RNA's também foi pior do que o apresentado pelos econométricos sendo 27,57% frente a 22,43%. Deve-se lembrar mais uma vez que, neste caso, são levadas em conta os 72 tipos de redes neurais artificiais possíveis, ao passo que, para os preditores econométricos, são apenas 14 preditores. Por fim, ainda na [Tabela 16](#), pode-se perceber que tanto nas médias quanto nos desvios, o robô venceu.

Os retornos financeiros quando observados de forma totalizada podem evidenciar o sucesso de uma estratégia, contudo, no decorrer da simulação estes podem variar denotando períodos de ganhos e períodos de perdas. Na seção a seguir são exibidos gráficos de evolução dos retornos. Esta análise visual é especialmente útil pois pode mostrar quando uma determinada estratégia possui estabilidade ao conseguir manter sua capacidade de gerar retornos de forma consistente ao longo do tempo.

Tabela 16 – Médias e desvios padrão dos preditores por classe frente ao robô investidor.

Ativo	Tipo	ROBÔ	SMA	Seletor SARIMA	GARCH	RNA de Candles	RNA de Tendência
BBAS3	Média	212,80	88,27	136,20	146,82	117,01	56,51
	Desvio	0,00	77,93	10,07	5,09	43,09	20,85
BBDC4	Média	124,52	30,59	68,97	69,12	39,58	25,75
	Desvio	0,00	12,59	18,53	25,46	30,13	23,27
BOVA11	Média	85,51	11,16	36,93	38,00	26,32	19,95
	Desvio	0,00	30,17	11,78	3,94	15,48	16,52
BVMF3	Média	209,11	-4,08	-43,52	-20,77	-13,04	67,39
	Desvio	0,00	26,10	23,06	21,28	37,92	19,15
CSNA3	Média	144,74	102,02	69,17	61,10	52,08	34,82
	Desvio	0,00	18,35	10,11	18,59	26,40	14,02
CYRE3	Média	159,52	-32,09	-35,56	-25,94	6,88	-46,77
	Desvio	0,00	42,95	21,83	25,57	48,40	49,26
GGBR4	Média	160,56	-17,86	-3,47	16,08	10,66	-31,66
	Desvio	0,00	32,10	18,64	31,39	34,95	20,36
ITSA4	Média	104,92	34,31	84,20	67,82	49,15	-15,88
	Desvio	0,00	24,15	10,11	6,41	22,25	26,62
PETR4	Média	82,03	10,16	4,11	6,70	-27,29	15,91
	Desvio	0,00	47,35	14,18	7,80	23,43	16,64
USIM5	Média	150,79	51,16	2,96	-26,77	-1,16	31,66
	Desvio	0,00	44,06	23,59	32,32	35,40	42,37
VALE5	Média	80,07	-3,67	11,47	22,86	7,61	-15,71
	Desvio	0,00	21,86	9,15	13,71	22,83	17,10
<b>MÉDIAS DAS MÉDIAS</b>		137,69	24,54	30,13	32,27	24,35	12,91
<b>DESVIO MÉDIO</b>		0,00	34,33	15,55	17,41	30,93	24,20

Fonte: Elaborada pelo autor.

## 5.4 Evolução dos retornos

Os gráficos exibidos da figura 45 a 55 mostram a evolução dos retornos sem corretagem ao longo de todo o período de simulação. Os mesmos estão ajustados para terem início em 1. Isto foi feito visando facilitar a visualização e a comparação entre ativos dado que os preços médios entre estes são bastante diferentes.


Como pode-se ver em BBAS3, BVMF3, GGBR4 e CYRE3, a evolução dos retornos do robô destoa dos demais concorrentes de forma positiva. A ascensão dos lucros é contínua ao longo do tempo em todo o período de simulação. Já em USIM5 existe um decaimento da qualidade a partir de 2013. Mesmo assim, graças aos resultados deste ativo no ano de 2012, os rendimentos finais foram positivos. Em BBDC4, ITSA4 e PETR4, o robô apresentou poucas diferenças para os melhores preditores, principalmente frente as redes neurais artificiais e ao GARCH. Por fim, em VALE5, CSNA3 e BOVA11 o robô se mostrou mais rentável ao longo do

tempo, no entanto, pouco melhor que os melhores preditores.

Quando se compara qualquer preditor ao índice Bovespa, pode-se notar que poucos não superaram o mesmo no período analisado. Já o *Buy and Hold* apresentou prejuízos em 4 dos 11 ativos e, mesmo assim, nos ativos em que se observaram lucros, estes foram muito pequenos em relação também a qualquer um dos melhores preditores, inclusive o robô.


Finalmente, quanto aos retornos, pode-se perceber que uma das boas características observadas no robô é que o mesmo, na maioria dos ativos, possui estabilidade, uma vez que nenhuma queda brusca durante o período de operação foi constatada. Essa observação dá evidências da qualidade dos *stops* associada às taxas de acerto positivas.

Figura 45 – Evolução dos retornos sem corretagem ajustados com o ativo BBAS3.




Fonte: Elaborada pelo autor.

Figura 46 – Evolução dos retornos sem corretagem ajustados com o ativo BBDC4.




Fonte: Elaborada pelo autor.

Figura 47 – Evolução dos retornos sem corretagem ajustados com o ativo BOVA11.




Fonte: Elaborada pelo autor.

Figura 48 – Evolução dos retornos sem corretagem ajustados com o ativo BVMF3.




Fonte: Elaborada pelo autor.

Figura 49 – Evolução dos retornos sem corretagem ajustados com o ativo CSNA3.




Fonte: Elaborada pelo autor.

Figura 50 – Evolução dos retornos sem corretagem ajustados com o ativo CYRE3.




Fonte: Elaborada pelo autor.

Figura 51 – Evolução dos retornos sem corretagem ajustados com o ativo GGBR4.



Fonte: Elaborada pelo autor.


Figura 52 – Evolução dos retornos sem corretagem ajustados com o ativo ITSA4.



Fonte: Elaborada pelo autor.




Figura 53 – Evolução dos retornos sem corretagem ajustados com o ativo PETR4.




Fonte: Elaborada pelo autor.

Figura 54 – Evolução dos retornos sem corretagem ajustados com o ativo USIM5.



Fonte: Elaborada pelo autor.

Figura 55 – Evolução dos retornos sem corretagem ajustados com o ativo VALE5.




Fonte: Elaborada pelo autor.

## 5.5 Avaliação estatística

Nesta seção será apresentada uma breve avaliação estatística dos valores obtidos para as taxas de acerto e os retornos percentuais sem corretagem. Nestas duas medidas, separadamente, foram considerados os valores obtidos em cada ativo de forma totalizada ao fim do período de simulação como sendo observações das amostras. Logo, um dado grupo amostral referente a um dado preditor (melhor preditor de cada classe), neste caso, possuiu 11 observações, uma para cada ativo.


Inicialmente pode-se ver no gráfico *boxplot* da [Figura 56](#) a dispersão dos retornos percentuais sem corretagem em todos os grupos amostrais (resultados de todos os ativos obtidos pelo robô e concorrentes). Como pode-se notar, os valores no grupo amostral referente ao robô investidor estão mais dispersos do que na maioria dos outros preditores. Este também está acima da média de todos os concorrentes. Esse fato se repete de forma similar quando se tratando das taxas de acerto, conforme [Figura 57](#).

Figura 56 – Dispersão dos retornos percentuais sem corretagem em todos os ativos para os melhores preditores em cada classe, a técnica de mercado *Buy and Hold*, o índice Bovespa e o robô investidor.



Fonte: Elaborada pelo autor.

Figura 57 – Dispersão das taxas de acerto em todos os ativos para os melhores preditores em cada classe e o robô investidor.



Fonte: Elaborada pelo autor.

Com a magnitude das dispersões, principalmente observando-se o posicionamento das médias amostrais do robô acima dos primeiros quartis vistos nos concorrentes, julgou-se não necessária a condução de mais testes comparativos como Análise de Variância (ANOVA) e correlatos.

Com base em todas estas análises, pode-se dizer que nas métricas avaliadas de quantidade de operações, taxas de acerto, retornos financeiros (com e sem corretagem) e evolução dos retornos, o robô investidor se mostrou poucas vezes inferior aos *benchmarks* selecionados. Isso mostra o potencial desta ferramenta.

No capítulo seguinte são feitas as considerações finais sobre o estudo na forma de conclusões, contribuições para a área, sugestões de continuidade do estudo e limitações identificadas durante a pesquisa.



---

## CONCLUSÕES

---

Nesta dissertação foi apresentado um trabalho de pesquisa que teve por objetivo principal o desenvolvimento de um robô investidor baseado em redes neurais artificiais e preditores econométricos que, frente aos *benchmarks* selecionados, apresentasse capacidade de gerar lucros a partir de previsões acertadas. Este objetivo foi atingido, visto que, em poucos dos experimentos realizados foram observados resultados desfavoráveis frente aos métodos concorrentes.

Inicialmente foram discutidos os fundamentos necessários ao entendimento dos conceitos de mercado e da negociação algorítmica. Isto foi realizado por meio de uma revisão das principais bibliografias históricas a fim de se mostrar ao leitor o contexto no qual a pesquisa está inserida. Todos estes conceitos foram fundamentais no desenvolvimento do robô investidor dado o fato de que, a partir destes, pôde-se perceber que diversas soluções boas e aplicáveis são, em muitas das vezes, mais relacionadas a finanças e negócios do que necessariamente à matemática e estatística.

Foram tratados também os desafios existentes em se operar no mercado, percorrendo principalmente quanto a possível validade da Hipótese dos Mercados Eficientes. Pode-se dizer que, ao menos nos experimentos realizados, esta não se mostrou legítima.

Pode-se perceber de forma geral, em relação às classes de preditores, um destaque para o GARCH e as RNA's frente a SMA, ARMA e Seletor SARIMA. Uma evidência de que a aplicação de métodos não lineares pode ser mais adequada às séries temporais financeiras.

Diversos métodos foram levantados nas vertentes de mercado, computação, estatística e híbridos. Uma revisão bibliográfica foi empreendida acerca dos trabalhos mais recentes que tentam, de alguma forma, usar esses métodos para melhorar individualmente uma fase específica do processo de negociação algorítmica ou, de fato, desenvolver aplicações focando todas as fases e, dessa forma, buscar desempenho positivo nas operações na bolsa de valores. Esta etapa foi importante pois, a partir da identificação do cenário atual, foi possível vislumbrar diversas possibilidades que acabaram por ser incluídas no robô investidor. Pode-se citar como contribuições: (i) a forma de escolha dos métodos econométricos; (ii) a seleção de métricas

financeiras mistas às de direção dos movimentos dos preços para a seleção de estratégias; (iii) a otimização dos *stops* por meio das distribuições passadas dos retornos; (iv) alguns tipos de tratamentos aplicados as séries temporais (como a série de tendência); (v) o uso de mais de um tipo de comitê de decisão; (vi) o conceito introduzido para os chamados momentos de confiança e, finalmente; (vii) todos os algoritmos e técnicas que foram aplicados de forma combinada, como as redes neurais artificiais, o BFGS, o K-médias, ARMA, SARIMA, GARCH, SMA, EMA e outros apresentados no decorrer do texto.

Todo o arcabouço projetado para o robô investidor foi implementado nas plataformas de programação R e *Metatrader*. Diversos testes puderam ser desenvolvidos e sistematizados ao longo do processo, em especial, quanto a validação das diversas formas de aplicação das redes neurais artificiais. Neste sentido, algumas das informações produzidas acabaram por não figurar no texto final, visto que, várias destas não faziam parte diretamente do escopo do projeto. No entanto, estas etapas marginais influenciaram positivamente em diversos momentos quanto às decisões de implementação. Todos estes aspectos relacionados a construção propriamente dita do arcabouço computacional envolvendo *software* e *hardware*, culminaram na melhoria dos resultados e, também, no atendimento das metas estabelecidas.

Por fim, como conclusão geral deste trabalho, pode-se dizer que, certamente não é tarefa simples a realização de operações no mercado financeiro a partir de tentativas de previsão em séries temporais. O estudo estatístico de séries temporais por si só é uma ciência consolidada há várias décadas e, mesmo assim, não existem até o momento quaisquer fórmulas estabelecidas para gerar ganhos quando essas são submetidas a situações reais. O desenvolvimento de um arcabouço que permita simular estas situações de forma computacional é benéfico, pois pode dar evidências de que, com esforço contínuo, métodos podem ser aprimorados a fim de que se tornem maleáveis ao ponto de se adaptarem as constantes mudanças observadas no mercado financeiro. No ponto de vista deste autor, esta é a principal direção para a qual as pesquisas devem apontar, visto que, métodos numéricos com teorias absolutas não possuem durabilidade no mercado, dado que este muda constantemente. Logo estratégias adaptativas e que se apoiem amplamente em janelas históricas otimizadas podem ser as mais adequadas.

## 6.1 Limitações e propostas de continuidade

Apesar do robô investidor ter se mostrado rentável e apresentar em sua arquitetura diversos módulos com soluções para etapas importantes de um *trading system* como seleção de carteira, tratamento de dados, previsão, avaliação de cenários, negociação e gestão de riscos, outras não puderam ser empreendidas. Os desafios enfrentados durante as fases de testes demonstraram que certos pontos podem ser delicados neste tipo de pesquisa. Para tanto, pode-se citar, principalmente, a influência exercida por diversas variáveis como a profundidade do livro de ofertas, séries com maior granularidade (*tick by tick*), humor de mercados, valores de *spreads*,

relação entre horários e liquidez dos ativos, dentre outras. Por consequência destas limitações, não foi pretensão deste estudo desenvolver um método algorítmico que se mostrasse perfeitamente acabado e garantidamente rentável para o mercado financeiro real, mas sim, nesta direção, desenvolver-se uma ferramenta que provesse evidências de potencial na aplicação um robô investidor como o produzido. Assim, como propostas de continuidade para próximas etapas da pesquisa, podem ainda ser empreendidos esforços nas simulações de *backtests* com a plataforma *Metatrader* que embarca mais variáveis de mercado real a simulação, inclusão de novos tipos de preditores ao robô (como outras redes neurais ou até outros tipos de regressores universais), testes com outros tipos de comitê de decisão, aplicação do robô em séries não necessariamente financeiras (de outras áreas ou artificiais) para averiguação da qualidade em outros contextos, análise dos dados aos quais o robô está sendo submetido a fim de identificar-se características que denotem mais “facilidade” ou “propensão” para acertos, além da realização de novos estudos na literatura buscando-se por métodos que possam melhorar a capacidade de obter ganhos de estabilidade ou simplesmente maiores retornos.

Um outro ponto é a pretensão de levar-se esta solução a uma conta real que possa ser operada com dinheiro real. Essa situação é crítica e deve, como proposta de continuidade, ser empreendida após aplicação do robô em um *dataset* maior (quanto a tempo) e mais diverso (como em séries de ativos negociados em bolsas internacionais). A consistência entre resultados obtidos nas simulações do algoritmo em R, nas contas simuladas em *backtests* na plataforma *Metatrader* e numa conta real seriam a principal evidência de que a ferramenta estaria pronta para se tornar um produto comercial.

Os resultados gerados nas fases de testes puderam demonstrar que o robô investidor, como implementado, mostrou-se uma alternativa promissora para a continuidade dos estudos. Isto ocorreu principalmente pois nenhuma das técnicas utilizadas foi aplicada sem fundamentação empírica ou teórica. Neste contexto, pode-se observar que para a grande maioria dos cenários testados a resposta foi positiva. Fato que se traduziu em evidências de lucros e, na mais pessimista das hipóteses, pelo menos em vantagem frente aos melhores preditores de cada classe identificados no pós-simulação individualmente, à média das classes dos preditores, ao índice Bovespa e à técnica de mercado *Buy and Hold*.

## 6.2 Produção bibliográfica

Até o momento, esse trabalho possibilitou a publicação de três artigos científicos, sendo um artigo em periódico internacional e outros dois em eventos científicos, como segue:

1. Pimenta, A.; Nametala, C. A. L.; Guimarães, F. G.; Carrano, E. G.. An Automated Investing Method for Stock Market Based on Multiobjective Genetic Programming. *Computational Economics*, v. 49, p. 1-20, 2017.

2. Nametala, C. A. L.; Pimenta, A.; Pereira, A. C. M.; Carrano, E. G.. Uma estratégia automatizada de investimento por meio de redes neurais artificiais e preditores econométricos. In: *XII Brazilian Symposium on Information Systems*, 2016, Florianópolis, Santa Catarina. Proceedings of the XII Brazilian Symposium on Information Systems, 2016. v. 12. p. 152-159.
3. Pimenta, A.; Guimarães, F. G.; Carrano, E. G.; Nametala, C. A. L.; Takahashi, R. H. C.. Goldminer: A genetic programming based algorithm applied to Brazilian Stock Market. In: *2014 IEEE Symposium on Computational Intelligence and Data Mining (CIDM)*, 2014, Orlando. 2014 IEEE Symposium on Computational Intelligence and Data Mining (CIDM).

Se encontram em fase de redação outros dois artigos para submissão em periódicos internacionais. O primeiro apresenta o estudo qualitativo dos modelos econométricos e redes neurais artificiais para previsão de séries de tendência. Já o segundo apresenta o robô propriamente dito, com todos os módulos que o compõem.



## REFERÊNCIAS

---

ABE, M. **Manual da Análise Técnica**. São Paulo: Novatec, 2009. Citado 4 vezes nas páginas 29, 30, 32 e 113.

ADELBIYI, A. A.; AYO, C. K.; O., A. M.; OTOKITI, S. O. Stock price prediction using neural network with hybridized market indicators. **Journal of Emerging Trends in Computing and Information Sciences**, v. 3, n. 1, p. 1–9, 2012. Disponível em: <<http://eprints.covenantuniversity.edu.ng/id/eprint/4112>>. Acesso em: 13.10.2016. Citado na página 19.

ALDRIDGE, I. **High-Frequency Trading: A Practical Guide to Algorithmic Strategies and Trading Systems**. 2. ed. New Jersey: Wiley, 2013. Citado 3 vezes nas páginas 10, 11 e 67.

AMORIM, A. J.; ZANE, A. P. de S.; GUILLEN, A.; AMARAL, D.; SILVA, R. O. de Menezes da; TOLEDO, L. A. Home broker e bm&f bovespa: Um estudo de caso. **Revista Eletrônica da Administração**, Porto Alegre, Rio Grande do Sul, v. 10, n. 18, 2011. Citado 2 vezes nas páginas 3 e 6.

ANDERSEN, A. C.; MIKELSEN, S. **A Novel Algorithmic Trading Framework Applying Evolution and Machine Learning for Portfolio Optimization**. Tese (Doutorado) — Norwegian University of Science and Technology, Trondheim, Noruega, 2012. Citado na página 20.

ARAÚJO, A. C. de; MONTINI, A. de Ávila. High frequency trading: Abordagem clássica para análise de preço-volume em uma nova microestrutura de mercado. In: UNIVERSIDADE DE SÃO PAULO. **XVI Seminários de Administração (SemeAd)**. São Paulo, Brasil: Faculdade de Economia, Administração e Contabilidade, 2013. Citado na página 10.

ASADI, S.; HADAVANDI, E.; MEHMANPAZIR, F.; NAKHOSTIN, M. M. Hybridization of evolutionary levenberg-marquardt neural networks and data pre-processing for stock market prediction. **Knowledge-Based Systems**, v. 35, p. 245–258, 2012. Citado na página 79.

ATSALAKIS, G. S.; VALAVANIS, K. P. Surveying stock market forecasting techniques - part ii: Soft computing methods. **Expert Systems with Applications**, v. 36, n. 3, p. 5932–5941, 2009. Citado 4 vezes nas páginas 22, 33, 34 e 39.

AZADEH, M.; SABERI, M.; GHADERI, S.; GITIFOROUZ, A.; EBRAHIMPOUR, V. Improved estimation of electricity demand function by integration of fuzzy system and data mining approach. **Energy Covers Manage**, v. 49, p. 2165–2177, 2008. Citado na página 79.

AZEVEDO, C. R. B. **Anticipation in Multiple Criteria Decision-Making Under Uncertainty**. Tese (Doutorado) — Universidade Estadual de Campinas, 2014. Citado na página 72.

BACHELIER, L. Théorie de la spéculation. In: VILLARDS, G. (Ed.). **Annales scientifiques de l'É.N.S.** Paris: [s.n.], 1900. v. 17, p. 21–86. Reedição em inglês, *Theory of Speculation*, in Coorner, 2000, p.19-91. Citado na página 14.

- BAHRAMY, F.; CRONE, S. F. Forecasting foreign exchange rates using support vector regression: An empirical evaluation of mean reversion using bollinger bands. In: **Proceedings of the 2013 IEEE Conference on Computational Intelligence for Financial Engineering and Economics, CIFEr 2013**. [S.l.]: IEEE, 2013. (2013 IEEE Symposium Series on Computational Intelligence, SSCI 2013), p. 34–41. Citado na página 35.
- BAKOS, Y.; JR., H. C. L.; OH, W.; SIMON, G.; VISWANATHAN, S.; WEBER, B. The impact of eletronic commerce on the retail brokerage industry. **Information Systems Research**, v. 16, n. 4, p. 352–371, 2005. Citado na página 6.
- BALLINGS, M.; POEL, D. V.; HESPEELS, N.; GRYP, R. Evaluating multiple classifiers for stock price direction prediction. **Expert Systems with Applications**, v. 42, n. 20, p. 7046–7056, 2015. Citado na página 40.
- Banco do Brasil S.A. **Glossário financeiro do Banco do Brasil S.A.** 2016. Disponível em: <<http://www.bb.com.br/docs/pub/voce/dwn/GlossarioC.pdf>>. Acesso em: 10/10/2016. Citado na página 3.
- BERGMEIR, C.; BENITEZ, J. M. Neural networks in r using the stuttgart neural network simulator. **Journal of Statistical Software**, v. 46, n. 7, p. 1–26, 2012. Disponível em: <<http://www.jstatsoft.org/v46/i07/>>. Acesso em: 13.10.2016. Citado na página 96.
- Berkshire Hathaway Inc. **Annual Report**. Omaha, Nebraska, 2008. Disponível em: <<http://www.berkshirehathaway.com/2008ar/2008ar.pdf>>. Acesso em: 18/10/2016. Citado na página 33.
- BLACKLEDGE, J.; MURPHY, K. Forex trading using metatrader 4 with the fractal market hypothesis. In: **The Third International Conference on Resource Intensive Applications and Services**. Veneza, Itália: Dublin Institute of Technology, 2011. v. 978-1-61208-006-2, p. 1–9. Citado na página 20.
- BM&F Bovespa. **Manual de Procedimentos Operacionais do Mercado de Balcão Organizado - Segmento Bovespa**. 2010. Disponível em: <<http://www.bmfbovespa.com.br/lumis/portal/file/fileDownload.jsp?fileId=8A828D294F270E45014FE2426F3C3945>>. Acesso em: 10/10/2016. Citado 2 vezes nas páginas 3 e 5.
- \_\_\_\_\_. **Programa de Incentivo para HFT**. 2010. Disponível em: <[http://www.bmfbovespa.com.br/pt\\_br/servicos/tarifas/derivativos/programa-de-incentivo-para-hft/](http://www.bmfbovespa.com.br/pt_br/servicos/tarifas/derivativos/programa-de-incentivo-para-hft/)>. Acesso em: 11/10/2016. Citado 2 vezes nas páginas 6 e 11.
- \_\_\_\_\_. **Relatório Anual 2013 - Apresentações**. 2013. Disponível em: <<http://ri.bmfbovespa.com.br/ptb/s-20-ptb.html?idioma=ptb>>. Acesso em: 12/10/2016. Citado na página 11.
- \_\_\_\_\_. **Perfil e Histórico da BM&F Bovespa**. 2015. Disponível em: <<http://ri.bmfbovespa.com.br/static/ptb/perfil-historico.asp?idioma=ptb>>. Acesso em: 11/10/2016. Citado 3 vezes nas páginas 1, 4 e 7.
- \_\_\_\_\_. **Acesso Direto ao Mercado DMA**. 2016. Disponível em: <[http://www.bmfbovespa.com.br/pt\\_br/servicos/negociacao/acesso-direto-ao-mercado-dma/sobre-dma/](http://www.bmfbovespa.com.br/pt_br/servicos/negociacao/acesso-direto-ao-mercado-dma/sobre-dma/)>. Acesso em: 13/10/2016. Citado na página 11.
- \_\_\_\_\_. **Apresentações - Relações com Investidores**. 2016. Disponível em: <<http://ri.bmfbovespa.com.br/ptb/s-5-ptb.html?idioma=ptb>>. Acesso em: 13/10/2016. Citado na página 13.

- \_\_\_\_\_. **Canais de Atendimento**. 2016. Disponível em: <[http://www.bmfbovespa.com.br/pt\\_br/canal-de-atendimento/](http://www.bmfbovespa.com.br/pt_br/canal-de-atendimento/)>. Acesso em: 08/08/2016. Citado 2 vezes nas páginas 77 e 129.
- \_\_\_\_\_. **Relatório Anuais - Relações com Investidores**. 2016. Disponível em: <<http://ri.bmfbovespa.com.br/ptb/s-20-ptb.html?idioma=ptb>>. Acesso em: 13/10/2016. Citado na página 13.
- BOLLERSLEV, T. Generalized autoregressive conditional heteroskedasticity. **Journal of Econometrics**, p. 307–327, 1986. Citado 2 vezes nas páginas 17 e 59.
- BORGES, R. **Eficiência e o Mercado de Renda Variável Brasileiro**. Dissertação (Mestrado) — Universidade Cândido Mendes, Rio de Janeiro, Brasil, 2010. Citado 6 vezes nas páginas 14, 15, 16, 18, 29 e 33.
- BOTELHO, F. A. **Análise técnica e estratégia operacional**. São Paulo: Enfoque gráfico sistemas, 1999. Citado na página 29.
- BOX, G. E. P.; JENKINS, G. **Time Series Analysis Forecasting and Control**. [S.l.]: John Wiley & Sons, 1970. Citado na página 56.
- BRAGA, A. de P.; CARVALHO, A. P. L. F.; LUDERNIR, T. B. **Redes Neurais Artificiais: Teoria e Aplicações**. Rio de Janeiro: LTC Editora, 2007. Citado na página 60.
- BREALEY, R.; MYERS, S. **Princípios de finanças empresariais**. 3º. ed. Portugal: McGraw Hill, 1992. Citado na página 29.
- Bússola do Investidor. **Como usar o Book de Ofertas**. 2016. Disponível em: <<http://blog.bussoladoinvestidor.com.br/como-usar-o-book-de-ofertas/>>. Acesso em: 11/10/2016. Citado na página 5.
- BUENO, R. de Losso de S. **Econometria de Séries Temporais**. 2º. ed. São Paulo: Cengage Learning, 2011. Citado 6 vezes nas páginas 21, 48, 51, 53, 57 e 58.
- BUSCARIOLLI, B.; EMERICK, J. **Econometria com Eviews: Guia essencial de conceitos e aplicações**. São Paulo: Saint Paul, 2011. Citado na página 20.
- CAMPBELL, J. Y.; LO, A. W.-C.; MACKINLAY, A. C. **The econometrics of financial markets**. Nova Jersey: Princeton University Press, 1997. v. 2. Citado 2 vezes nas páginas 58 e 59.
- CAMPELO, F. **Planejamento de Análise de Experimentos - Notas de Aula**. 2011. Disponível em: <<http://cpdee.ufmg.br/~fcampelo/files/disciplinas/EEE933/2011-2/Aulas/PAE-aula09.pdf>>. Acesso em: 11/03/2017. Citado na página 83.
- CATALAO, J. P. S.; MARIANO, S. J. P. S.; MENDES, V. M. F.; FERREIRA, L. A. F. M. Short-term electricity prices forecasting in a competitive market: A neural network approach. **Electric Power Systems Research**, v. 77, n. 10, p. 1297–1304, 2007. Citado na página 37.
- CAVALCANTE, R. C.; BRASILEIRO, R. C.; SOUZA, V. L. F.; NOBREGA, J. P.; OLIVEIRA, A. L. I. Computational intelligence and financial markets: A survey. **Expert Systems With Applications**, v. 55, p. 194–211, 2016. Citado 8 vezes nas páginas 22, 33, 34, 39, 40, 41, 67 e 68.
- CAVALCANTE, R. C.; OLIVEIRA, A. L. I. An autonomous trader agent for stock market based on online sequential extreme learning machine ensemble. In: **International joint conference on neural networks**. [S.l.]: IEEE, 2014. p. 1424–1431. Citado na página 40.

CHAKRABORTY, S. **High-Frequency Trading Chief Lashes Out at Proposed India Probe**. 2016. Disponível em: <<http://www.bloomberg.com/news/articles/2016-04-18/high-frequency-trading-chief-lashes-out-at-proposed-india-probe>>. Acesso em: 15/10/2016. Citado na página 11.

CHAREF, F.; AYACHI, F. A comparison between neural networks and garch models in exchange rate forecasting. **International Journal of Academic Research in Accounting, Finance and Management Sciences**, v. 6, n. 1, p. 94–99, 2016. Citado na página 38.

CHLISTALLA, M. High-frequency trading - better than its reputation? **Economics & politics - Research Briefing (Deutsche Bank Research)**, Frankfurt, p. 1–7, 2011. Disponível em: <[https://www.dbresearch.de/PROD/DBR\\_INTERNET\\_EN-PROD/PROD0000000000269468.pdf](https://www.dbresearch.de/PROD/DBR_INTERNET_EN-PROD/PROD0000000000269468.pdf)>. Acesso em: 12.10.2016. Citado na página 10.

Clear CTVM. **Pacotes**. 2016. Disponível em: <<https://www.clear.com.br/site/pacotes>>. Acesso em: 24/11/2016. Citado na página 121.

COBEL, R. W. **The Encyclopedia of Technical Market Indicators**. New York: McGraw-Hill, 2003. Citado 2 vezes nas páginas 20 e 32.

Comissão de Valores Mobiliários. **Corretoras e Distribuidoras**. 2016. Disponível em: <[http://www.cvm.gov.br/menu/regulados/corretoras/corretoras\\_dist.html](http://www.cvm.gov.br/menu/regulados/corretoras/corretoras_dist.html)>. Acesso em: 10/10/2016. Citado na página 4.

COOTNER, P. **The random character of stock market prices**. Cambridge: MIT Press, 1964. Citado 2 vezes nas páginas 14 e 15.

COSTA, A. M. de C.; JOIA, L. A. Critical success factors for stock brokerage over the internet: An exploratory study in the brazilian market under the perspective of the investor. In: **Proceedings of 16th Bled eCommerce Conference**. Bled, Eslovênia: AIS Electronic Library (AISeL), 2003. p. 249–266. Citado na página 6.

COVA, C. J. G. Finanças e mercado de capitais - mercados fractais: A nova fronteira das finanças. In: \_\_\_\_\_. São Paulo: Cengage Learning, 2011. cap. O declínio da hipótese de eficiência nos mercados financeiros e a emergência da hipótese fractal como novo paradigma descritivo do comportamento das séries temporais de retornos, p. 23–46. Citado 3 vezes nas páginas 14, 15 e 16.

COVA, C. J. G.; BASTOS, O. T.; MACHADO, A. T. Finanças e mercado de capitais - mercados fractais: A nova fronteira das finanças. In: \_\_\_\_\_. São Paulo: Cengage Learning, 2011. cap. Estratégias de investimento no mercado de capitais brasileiro sob a ótica de Warren Buffett, p. 107–126. Citado na página 21.

COVEL, M. **Trend following: How great traders make millions in up or down markets**. 1º. ed. New Jersey: Financial Times Prentice Hall Books, 2004. 336 p. Citado na página 31.

COX, C. A. **Technical Analysis of Financial Markets: A Critical Study**. Tese (Doutorado) — Northern Illinois University, 1993. Disponível em: <<http://commons.lib.niu.edu/bitstream/handle/10843/16610/12035%20Cox%2c%20Colin.pdf?sequence=1&isAllowed=y>>. Citado na página 9.

DAMORAN, A. **Avaliação de empresas**. São Paulo: Pearson Prentice Hall, 2007. Citado na página 33.

DASGUPTA, S. Eletronic contracting in online stock trading. **Eletronic Markets**, New Jersey, USA, v. 8, n. 3, p. 20–22, 1998. Disponível em: <<http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.107.6838&rep=rep1&type=pdf>>. Citado na página 6.

DAVIDSON, J. **Econometric Theory**. Reino Unido: Blackwell Publishers, 2000. 558-560 p. Citado na página 59.

DAVIDSON, P. **Macroeconomia moderna: Keynes e a Economia Contemporânea**. Rio de Janeiro: Campus, 1999. 55 p. Citado na página 50.

DEBASTIANI, C. A. **Candlestick - Um método para amplicar lucros na bolsa de valores**. São Paulo: Novatec, 2007. Citado na página 19.

\_\_\_\_\_. **Análise Técnica de Ações - Identificando oportunidades de compra e venda**. São Paulo: Novatec, 2008. Citado 2 vezes nas páginas 18 e 31.

DEMARCO, A. E. **A gritaria acabou: Do pregão viva-voz à negociação eletrônica**. 2016. Disponível em: <<http://vemprabolsa.com.br/2016/03/18/gritaria-acabou-do-pregao-viva-voz-negociacao-eletronica/>>. Acesso em: 10/10/2016. Citado na página 2.

DICKEY, D. D.; FULLER, W. A. Likelihood ratio statistics for autoregressive time series with a unit root. **Econometrica**, v. 49, n. 4, p. 1057–1072, 1981. Citado na página 53.

DIXON, B. S. Donchians 20 guides to trading commodities. **Commodities**, New York, p. 44–45, 1978. Disponível em: <<http://www.trendfollowing.com/whitepaper/donchian-commodities.pdf>>. Acesso em: 12.10.2016. Citado na página 9.

DUARTE, F. M. **Acurácia de previsões para vazão em redes: Um comparativo entre ARIMA, GARCH e RNA**. Dissertação (Mestrado) — Universidade Federal de Pernambuco, Pernambuco, Brasil, 2014. Citado na página 38.

ELDER, A. **Aprenda a operar no mercado de ações - Um guia completo para o trading**. Rio de Janeiro: Elsevier, 2006. Citado 2 vezes nas páginas 14 e 32.

ENGLE, R. F. Autoregressive conditional heteroscedasticity with estimates of the variance of united kingdom inflation. **Econometrica**, v. 50, n. 4, p. 987–1008, 1982. Citado 2 vezes nas páginas 17 e 59.

FAMA, E. F. Efficient capital markets: A review of theory and empirical work. **The Journal of Finance**, v. 25, n. 2, p. 383–417, 1969. Citado na página 14.

FAMA, E. F.; MILLER, M. H. **The Theory of Finance**. Hinsdale, Illinois: Dryden Press, 1972. Citado na página 14.

Federação Brasileira de Bancos. Bovespa: calmaria movida a tecnologia. **ciabFebraban 2006: A sociedade virtual**, São Paulo, Brasil, p. 8–10, 2006. Disponível em: <<http://www.ciab.org.br/ciab2010/pt/pdfs/04.%20Abril.06.pdf>>. Acesso em: 11/10/2016. Citado 2 vezes nas páginas 6 e 7.

FLETCHER, R.; POWELL, M. J. D. A rapidly convergent descent method for minimization. **The Computer Journal**, v. 6, n. 2, p. 163–168, 1963. Citado na página 64.



FLORIDIA, G. **Começar na Bolsa - Investir em Bolsa, sem mitos e sem milagres**. São Paulo: Independente, 2012. Citado 2 vezes nas páginas 2 e 3.

Forbes. **The World Billionaires**. 2016. Disponível em: <<http://www.forbes.com/billionaires/list/#version:static>>. Acesso em: 12/10/2016. Citado na página 9.

FRAENKLE, J.; RACHEV, S. T. Review: Algorithmic trading. **Investment Management and Financial Innovations**, Santa Barbara, California, v. 6, n. 1, p. 7–20, 2009. Citado na página 22.

GALVAO, A. **Mercado financeiro: Um abordagem prática dos principais produtos e serviços**. Rio de Janeiro: Elsevier, 2006. Citado na página 14.

GAMBOGI, J. A. **Aplicação de Redes Neurais na Tomada de Decisão no Mercado de Ações**. Dissertação (Mestrado) — Universidade de São Paulo, São Paulo, Brasil, 2013. Citado 4 vezes nas páginas 33, 35, 39 e 73.

George Soros Philanthropy. **The Life of George Soros**. 2016. Disponível em: <<https://www.georgesoros.com/the-life-of-george-soros/>>. Acesso em: 12/10/2016. Citado na página 9.

GIACOMEL, F.; GALANTE, R.; PEREIRA, A. An algorithmic trading agent based on a neural network ensemble: A case of study in north american and brazilian stock markets. In: **International Conference on Web Intelligence and Intelligent Agent Technology (WI-IAT)**. [S.l.]: IEEE/WIC/ACM, 2015. p. 230–233. Citado na página 36.

GIACOMEL, F. S. **Um método algorítmico para operações na bolsa de valores baseado em ensembles de redes neurais para modelar e prever os movimentos do mercado de ações**. Dissertação (Mestrado) — Universidade Federal do Rio Grande do Sul, Porto Alegre, Brasil, 2016. Citado na página 36.

GOLDBERG, A. S. **Econometric Theory**. Nova York: John Wiley & Sons, 1964. 1 p. Citado na página 43.

GOLDBERG, J.; NITZSCH, R. **Behavioral Finance**. Nova York: John Wiley & Sons, 2001. Citado 2 vezes nas páginas 31 e 44.

GOMES, D. T. **Modelos de redes neurais recorrentes para previsão de series temporais de memorias curta e longa**. Dissertação (Mestrado) — Universidade de Campinas, São Paulo, Brasil, 2005. Disponível em: <<http://www.bibliotecadigital.unicamp.br/document/?code=vtls000375744>>. Citado na página 37.

GOOIHHER, J. G.; HYNDMAN, R. J. 25 years of time series forecasting. **International Journal of Forecasting**, v. 22, n. 44, p. 443–473, 2006. Citado na página 34.

GROSSMAN, S. J.; STIGLITZ, J. E. On the impossibility of informationally efficient markets. **The American Economic Review**, v. 70, n. 3, p. 393–408, 1980. Citado na página 15.

GUJARATI, D. N.; PORTER, D. C. **Econometria Básica**. Nova York: McGraw Hill & Bookman, 2008. Citado 12 vezes nas páginas 43, 44, 45, 46, 48, 49, 51, 52, 54, 55, 56 e 58.

GURESEN, E.; KAYAKUTLU, G. Using artificial neural network models in stock market index prediction. **Expert Systems with Applications**, v. 38, n. 8, p. 10389–10397, 2011. Citado na página 19.

- GUTMAN, L. F. D.; JOIA, L. A.; JUNIOR, V. A. M. Antecedentes da intenção de uso de sistemas home broker sob a ótica dos investidores do mercado acionário. **Revista de Administração da Universidade de São Paulo**, São Paulo, v. 49, n. 2, 2014. Citado na página 6.
- HARTIGAN, P.; WONG, M. A. A k-means clustering algorithm: algorithm as 1366. **Applied Statistics**, v. 28, p. 126–130, 1979. Citado na página 63.
- HARTLE, T. Ed seykota of technical tools. **Stocks & Commodities Magazine**, Seattle, v. 10, n. 8, p. 328–331, 1992. Citado na página 9.
- HAYKIN, S. **Redes Neurais: Princípios e Prática**. Porto Alegre: Bookman, 2001. Citado 2 vezes nas páginas 60 e 61.
- HENDERSHOTT, T.; RIORDAN, R. Algorithmic trading and information. **Journal of Financial and Quantitative Analysis (JFQA)**, 2012. Citado na página 10.
- HOLTON, G. A. **History of Value-at-Risk: 1922-1988**. [S.l.], 2002. Disponível em: <<http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.161.7403&rep=rep1&type=pdf>>. Citado na página 8.
- HOTHORN, T.; BRETZ, F.; WESTFALL, P. Simultaneous inference in general parametric models. **Biometrical Journal**, v. 50, n. 3, p. 346–363, 2008. Nenhuma citação no texto.
- HU, Y.; FENG, B.; ZHANG, X.; NGAI, E. W. T.; LIU, M. Stock trading rule discovery with an evolutionary trend following model. **Expert Systems with Applications**, v. 42, p. 212–222, 2014. Citado na página 10.
- HU, Y.; LIU, K.; ZHANG, X.; SU, L.; NGAI, E. W. T.; LIU, M. Application of evolutionary computation for rule discovery in stock algorithmic trading: A literature review. **Applied Soft Computing**, v. 36, p. 535–549, 2015. Citado 5 vezes nas páginas 12, 22, 32, 33 e 34.
- Investopedia. **What is Volatility?** 2016. Disponível em: <<http://www.investopedia.com/terms/v/volatility.asp>>. Acesso em: 15/10/2016. Citado na página 3.
- JURICEK, J. The use of artificial intelligence in building automated trading systems. **International Journal of Computer Theory and Engineering**, v. 6, n. 4, 2014. Citado na página 32.
- KAASTRA, I.; BOYD, M. Designing a neural network for forecasting financial and economic time series. **Neurocomputing**, v. 10, p. 215–236, 1996. Citado na página 73.
- KAHNEMAN, D. Maps of bounded rationality: psychology for behavioral economics. **The American Economic Review**, p. 1449–1473, 2003. Citado na página 16.
- KAMO, T.; DAGLI, C. Hybrid approach to the japanese candlestick method for financial forecasting. **Expert Systems with Applications**, v. 36, n. 3, p. 5023–5030, 2009. Citado na página 19.
- KARA, Y.; ACAR, B.; BAYKAN, O. K. Predicting direction of stock price index movement using artificial neural networks and support vector machine: The sample of the istambul stock exchange. **Expert Systems with Applications**, v. 38, n. 5, p. 5311–5319, 2011. Citado na página 14.

- KARSTEN, J. A relutância dos investidores em realizar seus prejuízos. **Valor Econômico**, São Paulo, 2009. Disponível em: <<http://www.fundamenta.adm.br/arquivos/artigos/arelutanciadoinvestidoresemrealizarseusprejuizos.pdf>>. Acesso em: 14/10/2016. Citado na página 16.
- KASSAI, L. Entenda como funcionam os minicontratos na bm&f. **Revista Exame**, 2008. Disponível em: <<http://exame.abril.com.br/mercados/noticias/entenda-como-funcionam-os-minicontratos-na-bm-f-m0151097>>. Acesso em: 15/10/2016. Citado na página 18.
- KOURENTZES, N.; BARROW, D. K.; CRONE, S. F. Neural network ensemble operator for time series forecasting. **Expert Systems with Applications**, v. 41, n. 9, p. 4235–4244, 2014. Citado na página 40.
- KROLAK, P. D.; LINDAHL, C. E.; HERNDON, J. M. The construction of a robot investor. **Simulation - Transactions of The Society for Modeling and Simulation Internacional**, v. 21, p. 97–109, 1973. Citado na página 10.
- KROLLNER, B.; FINNIE, G. Financial time series forecasting with machine learning techniques: A survey. In: **European Symposium on Artificial Neural Networks: Computational and Machine Learning**. [S.l.: s.n.], 2010. v. 2-930307-10-2, p. 25–30. Citado na página 34.
- LABADIE, M.; LEHALLE, C. A. **Optimal algorithmic trading and market microstructure**. Dissertação (Mestrado) — Université Paris-Dauphine, Paris, França, 2010. Citado na página 67.
- LAM, M. Neural network techniques for financial performance prediction: integrating fundamental and technical analysis. **Decision Support Systems**, v. 37, n. 4, p. 567–581, 2004. Citado na página 20.
- LEITE, R. O. **Modelo de Markowitz Parametrizado por Indicadores de Análise Técnica**. Dissertação (Mestrado) — Universidade Federal do Paraná, Curitiba, Brasil, 2014. Citado na página 67.
- LI, D.-H.; FUKUSHIMA, M. A modified BFGS method and its global convergence in nonconvex minimization. **Journal of Computational and Applied Mathematics**, Elsevier BV, v. 129, n. 1-2, p. 15–35, apr 2001. Citado na página 65.
- LIANG, X.; ZHANG, H.; XIAO, J.; CHENG, Y. Improving option price forecasts with neural networks and support vector regressions. **Neurocomputing**, v. 72, n. 13, p. 3055–3065, 2009. Citado na página 40.
- LOWE, J. **Warren Buffet - Lições do maior de todos os investidores**. Rio de Janeiro: Campus Elsevier, 2008. 93 p. Citado na página 17.
- MABU, S.; OBAYASHI, M.; KUREMOTO, T. Ensemble learning of rule-based evolutionary algorithm using multi-layer perceptron for supporting decisions in stock trading problems. **Applied Soft Computing**, v. 36, p. 357–367, 2015. Citado na página 40.
- MADEO, R. C. B.; FERREIRA, F.; RAMALHO, N.; FANTINATO, M. Papel estratégico e impacto dos sistemas de informação no mercado de ações: Um estudo envolvendo brasil e estados unidos. **Revista Eletrônica de Sistemas de Informação**, v. 11, n. 2, p. 1–22, 2012. Citado 3 vezes nas páginas 8, 11 e 12.



MALHEIROS, R. S. **Operando com trading systems na bolsa de valores**. São Paulo: Évora, 2012. Citado 2 vezes nas páginas 11 e 12.

MANDELBROT, B. B.; RICHARD, H. **Mercados financeiros fora de controle: A teoria dos fractais explicando o comportamento dos mercados** [Tradução por Afonso Celso da Cunha Cerra]. Rio de Janeiro: Elsevier, 2004. Citado na página 15.

MANSUKHANI, S. The hurst exponent: Predictability of time series. **Analytics driven better business decisions**, 2012. Disponível em: <<http://analytics-magazine.org/the-hurst-exponent-predictability-of-time-series/>>. Acesso em: 25/10/2016. Citado na página 35.

MARTINEZ, L. C.; HORA, D. N. da; PALOTTI, J.; PAPPA, G. L. From an artificial neural network to a stock market day-trading system: A case study on the bm&f bovespa. In: **International Joint Conference on Neural Networks (IJCNN)**. Georgia, EUA: [s.n.], 2009. p. 14–19. Citado 5 vezes nas páginas 20, 31, 32, 34 e 39.

MetaQuotes Software Corporation. **Sobre a MetaQuotes**. 2016. Disponível em: <<http://www.metatrader5.com/pt/company>>. Acesso em: 15/10/2016. Citado na página 20.

MINGOTI, S. A. **Análise de Dados através de Métodos de Estatística Multivariada - Uma abordagem aplicada**. Belo Horizonte: Editora UFMG, 2013. Citado 2 vezes nas páginas 62 e 63.

MIRANDA, A. P.; CERETTA, P. S.; LOPES, L. F. D. Estratégias de mercado acionário utilizando previsão de redes neurais em comparação com modelos autorregressivos. **Revista da Administração**, v. 8, n. 1, p. 42–59, 2012. Citado na página 37.

MITSA, T. **Temporal Data Mining**. Chapman & Hall/CRC Data Mining and Knowledge Discovery Series. [S.l.]: Taylor & Francis, 2010. Citado na página 72.

MOHAMED, R. A. A comparison between the models arima/garch and artificial neural networks in modeling financial returns to the arab republic of egypt market securities. **Advances and Applications in Statistics**, v. 36, n. 2, p. 131–150, 2013. Citado na página 37.

MOREIRA, R. R. Relativizando o dilema estabilidade versus instabilidade: Keynes, o mainstream e o conceito de bifurcação em economia. **Revista Economica**, p. 189–216, 2006. Disponível em: <[http://www.anpec.org.br/revista/vol7/vol7n1p189\\_216.pdf](http://www.anpec.org.br/revista/vol7/vol7n1p189_216.pdf)>. Acesso em: 08/11/2016. Citado na página 50.

MORETTIN, P. A.; TOLOI, C. M. C. **Análise de Séries Temporais**. 2º. ed. São Paulo: Blucher, 2006. Citado 8 vezes nas páginas 20, 21, 45, 48, 50, 51, 52 e 58.

Mundo Trade. **O que são ações?** 2016. Disponível em: <<http://www.mundotrade.com.br/aprendizado/o-que-sao-acoes>>. Acesso em: 10/10/2016. Citado na página 2.

MUREKACHIRO, D. A review of artificial neural networks application to stock. **Network and Complex Systems**, v. 6, n. 4, p. 1–4, 2016. Citado na página 34.

MURPHY, J. J. **Technical analysis of the financial markets: A comprehensive guide to trading methods and applications**. [S.l.]: Penguin, 1999. Citado 2 vezes nas páginas 18 e 20.

NAKAMURA, Y.; HASEGAWA, T. **Humans Lose Out as Robots Take Tokyo Stock Exchange**. 2015. Disponível em: <<https://www.bloomberg.com/news/articles/2015-03-05/robots-take-tokyo-as-high-frequency-equity-infiltration-hits-70->>. Acesso em: 13/10/2016. Citado na página 11.

NAMETALA, C. A. L. **Repositório de arquivos da dissertação Construção de um Robô Investidor baseado em Redes Neurais Artificiais e Preditores Econométricos**. 2016. Disponível em: <<https://github.com/ciniro/dissertacaorobo>>. Citado 3 vezes nas páginas 27, 85 e 97.

NAMETALA, C. A. L.; PIMENTA, A.; PEREIRA, A. C. M.; CARRANO, E. G. Uma estratégia automatizada de investimento por meio de redes neurais artificiais e preditores econométricos. In: **XII Brazilian Symposium on Information Systems**. Florianópolis, Santa Catarina: [s.n.], 2016. p. 152–159. Citado 2 vezes nas páginas 38 e 73.

Nanex LCC. **The Rise of the HFT Machines**. 2013. Disponível em: <<http://www.nanex.net/aqck/2804.html>>. Citado na página 13.

NAYAK, R. K.; MISHRA, D.; RATH, A. K. A naive svm-knn based stock market trend reversal analysis for indian benchmark indices. **Applied Soft Computing**, v. 35, p. 670–680, 2015. Citado na página 40.

NETO, A.; TAVARES, G.; ALVES, V. M.; CAVALCANTI, G. D.; REN, T. I. Improving financial time series prediction using exogenous series and neural networks committees. In: **International joint conference on neural networks**. [S.l.]: IEEE, 2010. p. 1–8. Citado na página 40.

NETO, M. C. de A. **Previsão de Séries Temporais usando Séries Exógenas e Combinação de Redes Neurais Aplicada ao Mercado Financeiro**. Dissertação (Mestrado) — Universidade Federal de Pernambuco, Recife, Brasil, 2008. Citado na página 72.

NISKA, H.; HILTUNEN, T.; KARPPINEN, A.; RUUSKANEN, J.; KOLEHMAINENA, M. Evolving the neural network model for forecasting air pollution time series. **Engineering Applied Artificial Intelligence Journal**, v. 17, p. 159–167, 2004. Citado na página 79.

NYSE. **NYSE Group Volume Records - Top 10 Years**. 2016. Disponível em: <[http://www.nyxdata.com/nyxdata/asp/factbook/viewer\\_edition.asp?mode=table&key=3003&category=3](http://www.nyxdata.com/nyxdata/asp/factbook/viewer_edition.asp?mode=table&key=3003&category=3)>. Acesso em: 12/10/2016. Citado na página 8.

Octafinance. **Top 50 Hedge Fund Returns & Strategies – Historical Annual Performance Overview of James Simons, David Tepper, John Overdeck and David Siegel**. 2015. Disponível em: <<http://www.octafinance.com/top-50-hedge-fund-returns-strategies-historical-annual-performance-overview-of-james-simons-david-tepper-john-overdeck-and-david-siegel>>. Acesso em: 12/10/2016. Citado na página 9.

ODEAN, T.; BRAD, B.; LEE, Y. tsung; YU-JANE, L. Is the aggregate investor reluctant to realize losses: Evidence from taiwan. **European Financial Management**, v. 13, n. 3, p. 433–447, 2007. Citado 2 vezes nas páginas 15 e 16.

OGAWA, K. An approach to simultaneous estimation and segmentation in conjoint analysis. **Marketing Science**, p. 66–81, 1987. Citado na página 63.

OLIVEIRA, A. L. I.; MEIRA, S. R. L. Detecting novelties in time series through neural networks forecasting with robust confidence intervals. **Neurocomputing**, v. 70, p. 79–92, 2006. Citado na página 79.

OLIVEIRA, M. A. de. **Aplicação de redes neurais artificiais na análise de séries temporais econômico-financeiras**. Tese (Doutorado) — Universidade de São Paulo, São Paulo, Brasil, 2007. Citado 2 vezes nas páginas 46 e 59.

OSBORNE, M. F. M. Periodic structure in the brownian motion of stock prices. **Operations Research**, v. 10, n. 3, p. 345–379, 1962. Disponível em: <<http://www.e-m-h.org/Osborne1962.pdf>>. Citado 2 vezes nas páginas 14 e 15.

PADHIARY, P. K.; MISHRA, A. P. Development of improved artificial neural network model for stock market prediction. **International Journal of Engineering Science and Technology**, v. 3, n. 2, p. 1576–1581, 2011. Citado na página 20.

PAIVA, F. D. **Redes Neurais para Decisões no Mercado de Ações Brasileiro**. Tese (Doutorado) — Universidade Federal de Lavras, Lavras, Brasil, 2014. Citado 4 vezes nas páginas 14, 20, 35 e 72.

PALIWAL, M.; KUMAR, U. A. Neural networks and statistical techniques: A review of applications. **Expert Systems with Applications**, v. 36, n. 1, p. 2–17, 2009. Citado na página 34.

PATEL, M. B.; YALAMALLE, S. R. Stock price prediction using artificial neural network. **International Journal of Innovative Research in Science, Engineering and Technology**, v. 3, n. 6, p. 13755–13762, 2014. Citado na página 20.

PATEL, P. B.; MARWALA, T. Forecasting closing price indices using neural networks. In: **IEEE Conference on Systems, Man and Cybernetics**. Taipei, Taiwan: IEEE, 2006. p. 2351–2356. Citado na página 34.

PATTERSON, S. **The Quants: How a new breed of math whizzes conquered Wall Street and nearly destroyed it**. Nova York: Crown Books, 2011. Citado na página 9.

\_\_\_\_\_. **How Math Whizzes Helped Sink the Economy**. 2012. Disponível em: <<https://www.scientificamerican.com/article/quants-book/>>. Acesso em: 12/10/2016. Citado na página 10.

PAULOS, J. A. **A lógica do mercado de ações: Uma análise prática do funcionamento das bolsas de valores**. Rio de Janeiro: Elsevier, 2004. Citado na página 15.

PETERS, E. E. **Chaos and order in the Capital Markets, a new view of cycles, prices and market volatility**. Nova York: John Wiley & Sons, Inc., 1991. Citado na página 14.

PHILLIPS, P. C. B.; PERRON, P. Testing for a unit root in time series regression. **Biometrika**, v. 75, n. 2, p. 335–346, 1986. Citado na página 54.

PIMENTA, A.; GUIMARÃES, F. G.; CARRANO, E. G.; NAMETALA, C. A. L.; TAKAHASHI, R. H. Goldminer: A genetic programming based algorithm applied to brazilian stock market. In: **Proceedings of IEEE Symposium on Computational Intelligence and Data Mining (CIDM)**. Orlando, EUA: IEEE, 2014. p. 9–24. Citado 2 vezes nas páginas 17 e 20.

PLANTING, S. **Will high frequency traders cause market crashes?** 2015. Disponível em: <<http://www.moneyweb.co.za/news/markets/will-high-frequency-traders-cause-market-crashes/>>. Acesso em: 12/10/2016. Citado na página 11.

POMMERANZENBAUM, I. R. **Redes Neurais Artificiais na predição das principais séries do índice Bovespa e suas aplicações em sistemas automatizados de negociação**. Dissertação (Mestrado) — Universidade Federal do Rio de Janeiro, Rio de Janeiro, Brasil, 2014. Citado 3 vezes nas páginas 33, 35 e 39.

PORTNOY, K. High frequency trading and the stock market: A look at the effects of trade volume on stock price changes. **The Park Place Economist**, v. 19, n. 1, 2011. Disponível em: <<http://digitalcommons.iwu.edu/parkplace/vol19/iss1/15>>. Citado na página 10.

QIAN, B.; RASHEED, K. Hurst exponent and financial market predictability. In: **IASTED Conference on Financial Engineering and Applications**. [S.l.: s.n.], 2004. p. 203–209. Citado na página 35.

QIU, M.; SONG, Y.; AKAGI, F. Application of artificial neural network for the prediction of stock market returns: The case of the japanese stock market. **Chaos, Solitons and Fractals (Nonlinear Science, and Nonequilibrium and Complex Phenomena)**, v. 85, p. 1–7, 2016. Citado na página 36.

Renaissance Technologies. **About Renaissance**. 2016. Disponível em: <<https://www.rentec.com>>. Acesso em: 12/10/2016. Citado na página 9.

RHEA, R. **The Dow Theory: An explanation of its development and an attempt to define its usefulness as an aid in speculation**. [S.l.]: Fraser Publishing Company, 1993. Citado na página 29.

Rico CTVM S.A. **Planos de corretagem**. 2016. Disponível em: <<https://www.rico.com.vc/servicos/planos-de-corretagem>>. Acesso em: 24/11/2016. Citado na página 121.

ROMAN, J.; JAMEEL, A. Backpropagation and recurrent neural networks in financial analysis of multiple stock market returns. In: **Proceedings of the 29th Annual Hawaii International Conference on System Sciences**. [S.l.]: IEEE, 1996. p. 454–460. Citado na página 34.

ROSENBLATT, F. The perceptron: a probabilistic model for information storage and organization in the brain. **Psychological Review**, v. 3, p. 386–408, 1958. Citado na página 60.

ROSHAN, W.; GOPURA, R.; JAYASEKARA. Financial forecasting based on artificial neural networks: Promising directions for modeling. In: **International Conference on Industrial and Information Systems**. [S.l.]: IEEE, 2011. p. 322–327. Citado na página 34.

RUBIN, R.; COLLINS, M. **How an Exclusive Hedge Fund Turbocharged its Retirement Plan**. 2015. Disponível em: <<http://www.bloomberg.com/news/articles/2015-06-16/how-an-exclusive-hedge-fund-turbocharged-retirement-plan>>. Acesso em: 12/10/2016. Citado na página 9.

RUMELHART, D. E.; HILTON, G. E.; WILLIAMS, R. J. Parallel distributed processing. In: \_\_\_\_\_. Cambridge, Massachusetts: MIT Press, 1986. v. 1, cap. Learning internal representations by error propagation, p. 317–362. Citado na página 61.

SAMUELSON, P. A.; KOOPMANS, T. C.; STONE, J. R. N. Report of the evaluative committee for econometrica. **Econometrica**, v. 22, n. 2, p. 141–146, 1954. Citado na página 43.

- SANTOS, M. A.; SOUZA, D. H. S. de; PENEDO, A. S. T.; MARTINS, E. S. Aplicação de redes neurais no brasil: Um estudo bibliométrico. **Biblionline**, João Pessoa, v. 12, n. 2, p. 101–116, 2016. Disponível em: <<http://www.biblionline.ufpb.br/ojs/index.php/biblio/article/view/27738/15511>>. Acesso em: 25/10/2016. Citado 3 vezes nas páginas 33, 34 e 39.
- SATHE, S.; PURANDARE, S.; PUJARI, P.; SAWANT, S. Share market prediction using artificial neural network. **Internacional Education and Research Journal**, v. 2, p. 74–75, 2016. Citado na página 36.
- SCHWAGER, J. **Market Wizards**. Nova York: HarperCollins, 1989. Citado 2 vezes nas páginas 8 e 9.
- SHABRI, A. Comparison of time series forecasting methods using neural networks and box-jenkins model. **Matematika**, v. 17, p. 25–32, 2001. Citado na página 36.
- SHAN, K. The dow theory. **Aweshkar Research Journal**, v. 13, n. 1, p. 77–82, 2012. Citado 2 vezes nas páginas 29 e 31.
- SHANNO, D. F. On broyden-fletcher-goldfarb-shanno method. **Journal of Optimization Theory and Applications**, v. 46, p. 87–94, 1985. Citado na página 64.
- SHARMA, M. K.; BINGI, P. The growth of web-based investment. **Journal of Information Systems Management**, v. 17, n. 2, p. 54–60, 2006. Citado na página 6.
- SHIN, Y.; SCHMIDT, P. The kpss stationarity test as a unit root test. **Economic Letters**, v. 38, n. 4, p. 387–392, 1992. Citado na página 54.
- SIEGEL, J. **Investindo em ações no longo prazo**. 4º. ed. Rio de Janeiro: Elsevier, 2009. Citado 3 vezes nas páginas 3, 4 e 88.
- SILVA, I. N. da; SPATTI, D. H.; FLAUZINO, R. A. **Redes Neurais Artificiais para Engenharia e Ciências Aplicadas - Curso Prático**. São Paulo: Artliber, 2010. Citado na página 60.
- SILVA, L. L. B. S. **Sistema de negociação de ações utilizando indicadores de análise técnica otimizados por algoritmos genéticos**. Rio de Janeiro: PUC-Rio, 2008. Citado na página 113.
- Simons Foundation. **Simons Foundation - About Us**. 2016. Disponível em: <<https://www.simonsfoundation.org>>. Acesso em: 12/10/2016. Citado na página 9.
- SMITH, R. D. **Is high-frequency trading inducing changes in market microstructure and dynamics?** [S.l.], 2010. Disponível em: <<https://arxiv.org/abs/1006.5490>>. Acesso em: 12/10/2016. Citado 2 vezes nas páginas 10 e 11.
- SOLA, J.; SEVILLA, J. Importance of input data normalization for the application of neural networks to complex industrial problems. **IEEE Transactions of Nuclear Science**, v. 44, n. 3, p. 1464–1468, 1997. Citado na página 79.
- SONI, S. Applications of anns in stock market prediction: A survey. **International Journal of Computer Science and Engineering Technology**, v. 2, n. 3, p. 71–83, 2011. Citado na página 34.
- SOUZA, A. P.; MENEZES, J. E. Box-jenkins e rede neural artificial para previsão de séries temporais: Estudo comparativo entre modelos. **Conjuntura Econômica - Instituto Mauro Borges de Estatística e Estudos Econômicos**, p. 89–102, 2013. Disponível em: <<http://www.imb.go.gov.br/pub/conj/conj24/artigo08.pdf>>. Acesso em: 27/10/2016. Citado na página 37.



- STRAUSS, R. **Último negócio no pregão viva voz da BM&F**. 2009. Disponível em: <[https://www.youtube.com/watch?v=ykIfT\\_iDETA](https://www.youtube.com/watch?v=ykIfT_iDETA)>. Acesso em: 10/10/2016. Citado na página 7.
- TAKAHASHI, R. H. C. **Otimização Escalar e Vetoria - Notas de Aula**. 2007. Disponível em: <<http://mat.ufmg.br/~taka>>. Acesso em: 11/03/2017. Citado na página 64.
- The Richard Davoud Donchian Foundation. **Founder Biography**. 2002. Disponível em: <<http://www.rddonchian.org/>>. Acesso em: 12/10/2016. Citado na página 9.
- THIELE, C. C.; ADAMI, A. G. Previsão de séries temporais financeiras: modelo baseado em redes neurais artificiais. **Revista Brasileira de Computação Aplicada**, v. 8, n. 2, p. 113–128, 2016. Citado na página 35.
- TINTNER, G. **Methodology of mathematical economics and econometrics**. Chicago: The University of Chicago Press, 1968. 74 p. Citado na página 43.
- TOM, K. E.; AVRAMOVIC, A.; LIN, V.; BUCHANAN, M. **Market Structure Are ETFs Hurting Stock Volumes?** Zurich, 2015. Disponível em: <<https://edge.credit-suisse.com/edge/Public/Bulletin/Servefile.aspx?FileID=26683&m=198744576>>. Acesso em: 13/10/2016. Citado 2 vezes nas páginas 12 e 13.
- TRELEAVEN, P.; GALAS, M.; LALCHAND, V. Algorithmic trading review. **Communications of the ACM**, v. 56, n. 11, p. 76–85, 2013. Citado 2 vezes nas páginas 22 e 32.
- TURNER, A. L.; WEIGEL, E. J. Daily stock market volatility: 1928–1989. **Management Science**, v. 38, n. 11, p. 1586–1609, 1992. Citado na página 16.
- UEMATSU, A. A. de M. G. **Algoritmos de Negociação de Dados de Alta Frequência**. Dissertação (Mestrado) — Universidade de São Paulo, São Paulo, Brasil, 2012. Disponível em: <[www.teses.usp.br/teses/disponiveis/45/45133/tde-28042012.../tese\\_06\\_PADRAO.pdf](http://www.teses.usp.br/teses/disponiveis/45/45133/tde-28042012.../tese_06_PADRAO.pdf)>. Citado 2 vezes nas páginas 2 e 4.
- University of Stuttgart. **Stuttgart Neural Network Simulator**. 2008. Disponível em: <<http://www.ra.cs.uni-tuebingen.de/SNNS/>>. Acesso em: 18/11/2016. Citado na página 96.
- U.S. Securities and Exchange Commission. **Organizational Study and Reform (The Boston Consulting Group, Inc.)**. Bethesda, EUA, 2011. Disponível em: <<http://www.sec.gov/news/studies/2011/967study.pdf>>. Acesso em: 13/10/2016. Citado 2 vezes nas páginas 12 e 13.
- VANSTONE, B.; FINNIE, G. Enhancing stockmarket trading performance with anns. **Expert System with Applications**, v. 37, n. 9, p. 6602–6610, 2010. Citado na página 67.
- Warren Buffet. **History of Warren Buffet**. 2016. Disponível em: <<http://www.warrenbuffett.com/history/>>. Acesso em: 12/10/2016. Citado na página 9.
- WERBOS, P. J. Generalization of backpropation with application to a recurrent gas market model. **Neural Networks**, n. 1, p. 339–356, 1988. Citado na página 36.
- WILCOX, R. R. **Fundamentals of modern statistical methods: Substantially improving power and accuracy**. [S.l.]: Springer Science & Business Media, 2010. Citado na página 83.
- WILSON, J.; WIESMANN, G. **Traders warn Germany on HFT licensing: Fear that over-zealous regulation will deter traders**. 2013. Disponível em: <<https://www.ft.com/content/b87f4ac4-5e62-11e2-8780-00144feab49a>>. Acesso em: 13/10/2016. Citado na página 11.

WILTGEN, J. **Seu dinheiro - Os melhores e os piores investimentos do ano de 2012**. 2012. Disponível em: <<http://exame.abril.com.br/seu-dinheiro/os-melhores-e-os-piores-investimentos-do-ano-de-2012/>>. Acesso em: 29/11/2016. Citado na página 130.

WU, L.; SHAHIDENPOUR, M. A hybrid model for day-ahead price forecasting. **IEEE Transactions on Power Systems**, v. 25, n. 3, p. 1519–1530, 2010. Citado na página 40.

XAVIER, A. **Estratégias estatísticas em investimentos**. São Paulo: Novatec, 2009. Citado 2 vezes nas páginas 8 e 18.

XP Investimentos. **Custos Operacionais**. 2016. Disponível em: <<https://www.xpi.com.br/comece-a-investir/custos-operacionais/custos-operacionais.html>>. Acesso em: 24/11/2016. Citado na página 121.

YAP, B. W.; SIM, C. H. Comparisons of various types of normality tests. **Journal of Statistical Computation and Simulation**, v. 81, n. 12, p. 2141–2155, 2011. Citado na página 81.

YAZBEK, P. **Seu dinheiro: Os melhores e os piores investimentos de 2013**. 2013. Disponível em: <<http://exame.abril.com.br/seu-dinheiro/os-melhores-e-os-piores-investimentos-de-2013/>>. Acesso em: 26/11/2016. Citado na página 130.

YILDIZ, B.; YALAMA, A.; COSKUN, M. Forecasting the istambul stock exchange national 100 index using an artificial neural network. **International Journal of Social, Behavioral, Educational, Economic, Business and Industrial Engineering**, v. 2, n. 10, p. 1063–1066, 2008. Citado na página 35.

YUAN, G.; WEI, Z. Convergence analysis of a modified BFGS method on convex minimizations. **Computational Optimization and Applications**, Springer Nature, v. 47, n. 2, p. 237–255, nov 2008. Citado na página 65.

YUAN, Y.-X. A modified BFGS algorithm for unconstrained optimization. **IMA Journal of Numerical Analysis**, Oxford University Press (OUP), v. 11, n. 3, p. 325–332, 1991. Citado na página 65.

ZEILEIS, A.; HOTHORN, T. Diagnostic checking in regression relationships. **R News**, v. 2, n. 3, p. 7–10, 2002. Nenhuma citação no texto.

ZHANG, D.; JIANG, Q.; LI, X. Application of neural networks in financial data mining. **International Journal of Computer, Electrical, Automation, Control and Information Engineering**, v. 1, n. 1, p. 225–228, 2007. Citado na página 35.

ZHANG, G.; HU, M. Y. **Neural Network forecasting of the british pound/us dollar exchange rate**. [S.l.]: Elsevier, 1998. v. 26. 495–506 p. Citado na página 34.

ZHANG, G.; PATUWO, M. Y. H. Forecasting with artificial neural networks: The state of the art. **Internacional Journal of Forecasting**, v. 14, p. 35–62, 1998. Citado 2 vezes nas páginas 34 e 39.

ZHU, B.; WEI, Y. Carbon price forecasting with a novel hybrid arima and least squares support vector machines methodology. **Omega**, v. 41, n. 3, p. 517–524, 2013. Citado na página 40.





---

## CARACTERIZAÇÃO DAS SÉRIES

---

Este apêndice está dividido em três seções:

- Situação do mercado no período da simulação: Esta seção traz os principais acontecimentos ocorridos no mercado financeiro nos anos de 2012 e 2013, além de destacar em alguns pontos as influências observadas no comportamento real das ações utilizadas no estudo.
- Séries de preços: Breve descrição da companhia, seus dados e gráficos que mostram a série de preços de fechamento absoluta e sua distribuição, o volume negociado e os retornos em cada um dos ativos operados.
- Comparativo das séries do *dataset* a fim de demonstrar a sua representatividade mesmo que certas companhias estejam incluídas no mesmo setor.

### A.1 Situação do mercado no período de simulação

Nos dois anos de operação do robô alguns acontecimentos afetaram o mercado de ações brasileiro.

Em 2012, dá-se destaque à crise da Grécia que atingiu todo o mercado europeu devido a possibilidade de sua retirada da zona do euro. Este fato refletiu-se na bolsa brasileira ocasionando a maior queda do índice Bovespa (BOVA11) desde 2001. Ainda em 2012, todos os setores de exportação, especialmente as mineradoras e petrolíferas (como PETR4, GGBR4 e CYRE3), acusaram quedas devido a uma série de intervenções por parte do governo brasileiro no setor de energia. A OGX, empresa do ramo de petróleo, em junho deste ano acusou queda de 25%, um descenso que continuou de forma ininterrupta até o final de 2013 quando o preço da ação já havia se reduzido a menos que R\$ 0,30 centavos <sup>1</sup>. Outra intervenção foi a redução forçada da taxa

---

<sup>1</sup> UOL Economia, “Ação da OGX, de Eike Batista, fecha a R\$ 0,28, menor valor da história”, 2013. [Online].

de juros que influenciou negativamente o desempenho dos bancos Banco do Brasil (BBAS3), Bradesco (BBDC4) e Itaú (ITSA4). No final de 2012 o governo anunciou medidas protecionistas que aumentaram os impostos para diversos produtos da indústria siderúrgica externa. Ações das companhias nacionais Usiminas (USIM5) e Companhia Siderúrgica Nacional (CSNA3) neste período acusaram altas, respectivamente, de 19,6% e 8,1%. O ano de 2012 terminou com a falência do Banco Cruzeiro do Sul e a reeleição de *Barack Obama* ao cargo de presidente dos EUA<sup>2</sup>.

Em 2013, o mercado brasileiro apresentou movimento predominantemente de queda. O índice Bovespa (BOVA11, juntamente com BVMF3) não apresentou nenhuma alta significativa no primeiro semestre acumulando desempenho ruim de 22,14%, com destaque para o mês de junho onde houve uma queda de 11,3%. No segundo semestre houve uma recuperação entre julho e outubro, mas novas quedas ocorreram no final do ano. Em 2013, a OGX mudou o nome para OG Participações, a fim de tentar recuperar-se do desempenho ruim de 2012, a estratégia não surtiu efeito, esta acabou sendo retirada do cálculo de composição do índice Bovespa, o preço da ação caiu para R\$ 0,13 centavos e teve assim queda de 97,03% em relação ao seu preço mais alto até então. A situação da OGX refletiu-se no mercado influenciando outras companhias do mesmo ramo como PETR4 e VALE5. Em março, o governo brasileiro divulgou a taxa de crescimento do PIB nacional em 0,9%, entretanto, esta havia sido anunciada com projeção para entre 2% e 2,5%. Além disso, em 2013 ocorreram as chamadas “pedaladas fiscais”, quando o governo se utilizou de métodos contábeis não convencionais para calcular o valor do superávit brasileiro e, dessa forma, não gerar dados que estivessem longe da meta estipulada para o mesmo ano. Com a inflação tendo rompido o teto estabelecido em 6,5% (atingiu 6,7% em julho) e mais todos estes outros fatores, o mercado internacional iniciou um processo de questionamento acerca das finanças brasileiras. Em julho, a agência de classificação de risco *Standard & Poor's* colocou o *rating* brasileiro em perspectiva negativa. A Petrobrás, no segundo semestre, começou um processo de queda ininterrupta devido ao acúmulo de dívidas relacionadas ao preço praticado na venda da gasolina, abaixo do valor de mercado. As ações PETR4 e PETR3 caíram respectivamente 18,47% e 9,79%. O Real, moeda nacional, ainda sofreu desvalorização frente ao dólar que subiu 16,77% chegando a R\$ 2,45. O final do ano foi marcado por grande volatilidade dos mercados devido a um impasse envolvendo a política americana quanto ao teto da dívida nos EUA<sup>3</sup>.

---

Disponível em <http://economia.uol.com.br/cotacoes/noticias/redacao/2013/09/27/acao-da-ogx-de-eike-batista-fecha-a-r-028-menor-valor-da-historia.htm>

<sup>2</sup> InfoMoney, “Retrospectiva 2012: Relembre 10 dias marcantes para os investidores”, 2012. [Online]. Disponível em <http://www.infomoney.com.br/mercados/acoes-e-indices/noticia/2641506/retrospectiva-2012-relembre-dias-marcantes-para-investidores>

<sup>3</sup> InfoMoney, “2013 não deixará saudades para quem investiu na bolsa brasileira, relembre”, 2013. [Online]. Disponível em <http://www.infomoney.com.br/onde-investir/acoes/noticia/3099450/2013-nao-deixara-saudades-para-quem-investiu-bolsa-brasileira-relembre>

## A.2 Séries de preços

A seguir são feitas descrições de cada uma das companhias utilizadas no estudo. Os dados foram extraídos da página de companhias da agência de notícias *InfoMoney*<sup>4</sup>.

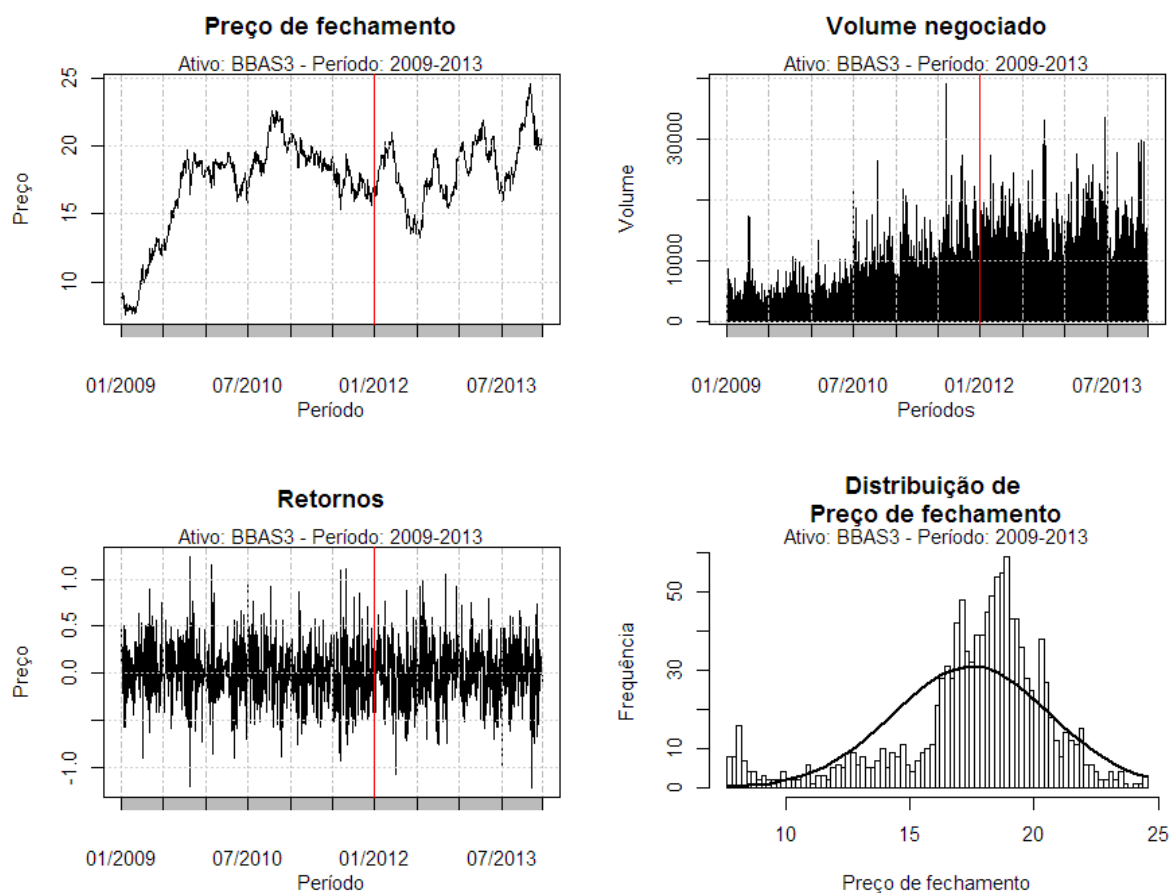
### A.2.1 BBAS3: Ação ordinária do Banco do Brasil

**Setor:** Financeiro.

**Descrição:** Maior instituição financeira do país que possui R\$ 720 bilhões em ativos negociados em bolsas. Ver [Figura 58](#).

**Índices:** IBOVESPA, IBRASIL, IBRX BRASIL, IBRX 50, ICO2, I DIVIDENDOS, IFINANCEIRO, IGOVERNANCA, IGC TRADE, IGC, NM, ISUSTENTABIL, ITAG ALONG e MIDLARGE CAP.

Figura 58 – Gráficos descritivos do preço de fechamento do ativo BBAS3.



Fonte: Elaborada pelo autor.

<sup>4</sup> InfoMoney, “Página InfoMoney”, 2016. [Online]. Disponível em <http://www.infomoney.com.br/>

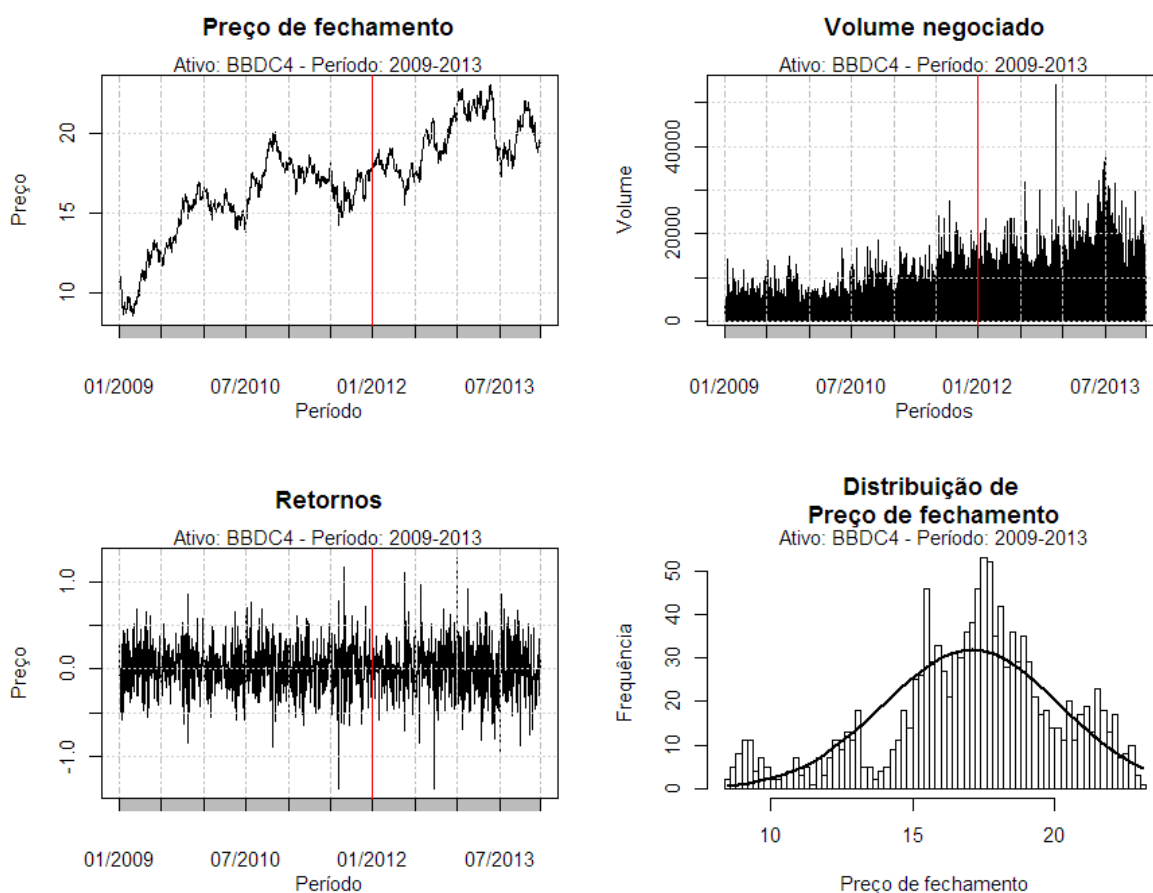
### A.2.2 BBDC4: Ação preferencial do Bradesco

**Setor:** Financeiro

**Descrição:** Ação do Banco Bradesco. Segundo maior banco privado e terceira maior instituição do setor financeiro do Brasil em termos de ativos detidos. Ver [Figura 59](#).

**Índices:** IBOVESPA, IBRASIL, IBRX BRASIL, IBRX 50, ICO2, IFINANCEIRO, IGOVERNANCA, IGC TRADE, ISUSTENTABIL, ITAG ALONG e MIDLARGE CAP.

Figura 59 – Gráficos descritivos do preço de fechamento do ativo BBDC4.

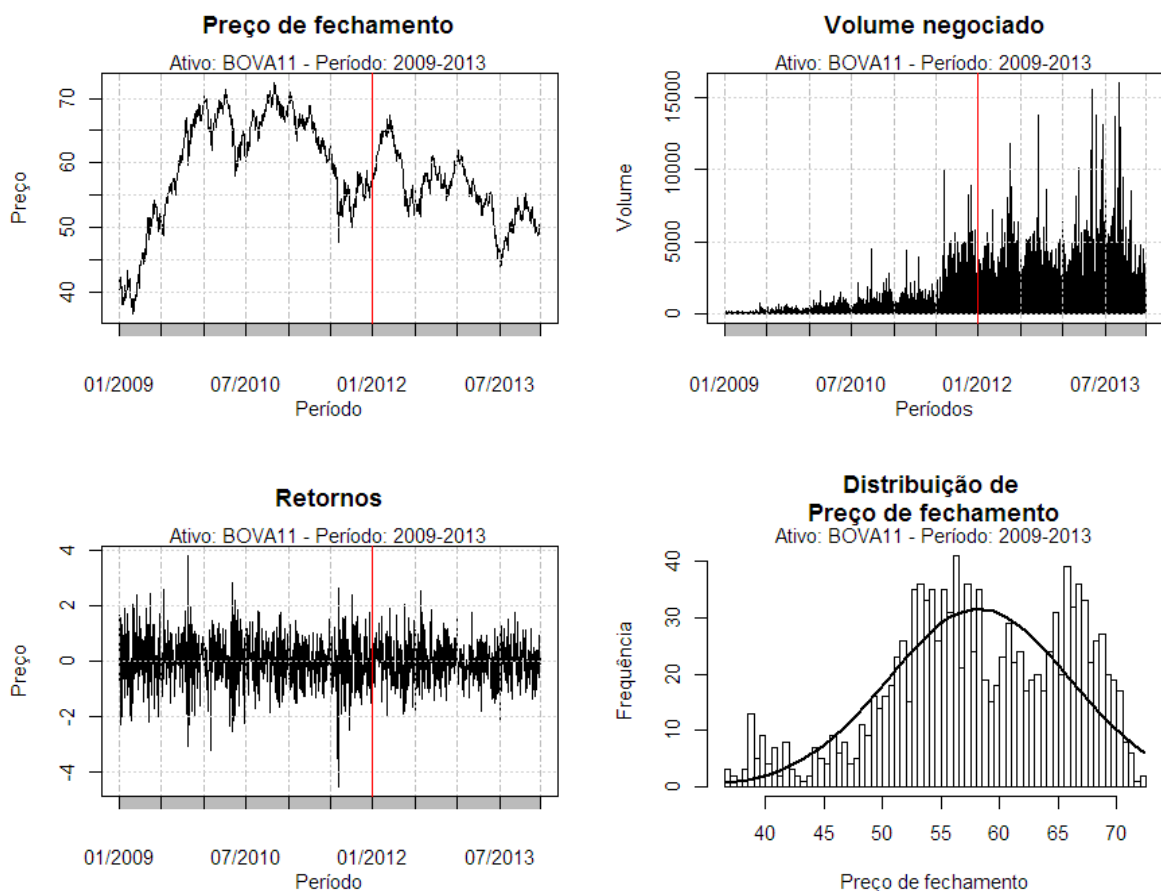


Fonte: Elaborada pelo autor.

### A.2.3 BOVA11: Índice Bovespa

**Descrição:** O índice BOVESPA é um indicador teórico que é composto de uma carteira de investimentos elaborada de acordo com critérios estabelecidos no chamado Manual do Índice Bovespa. Também conhecido como iBovespa é caracterizado por ser um índice de retorno total. Tem por objetivo ser um indicador de desempenho médio das cotações dos ativos mais representativos quanto a volume de negociações no mercado brasileiro. Ver [Figura 60](#).

Figura 60 – Gráficos descritivos do preço de fechamento do ativo BOVA11.



Fonte: Elaborada pelo autor.

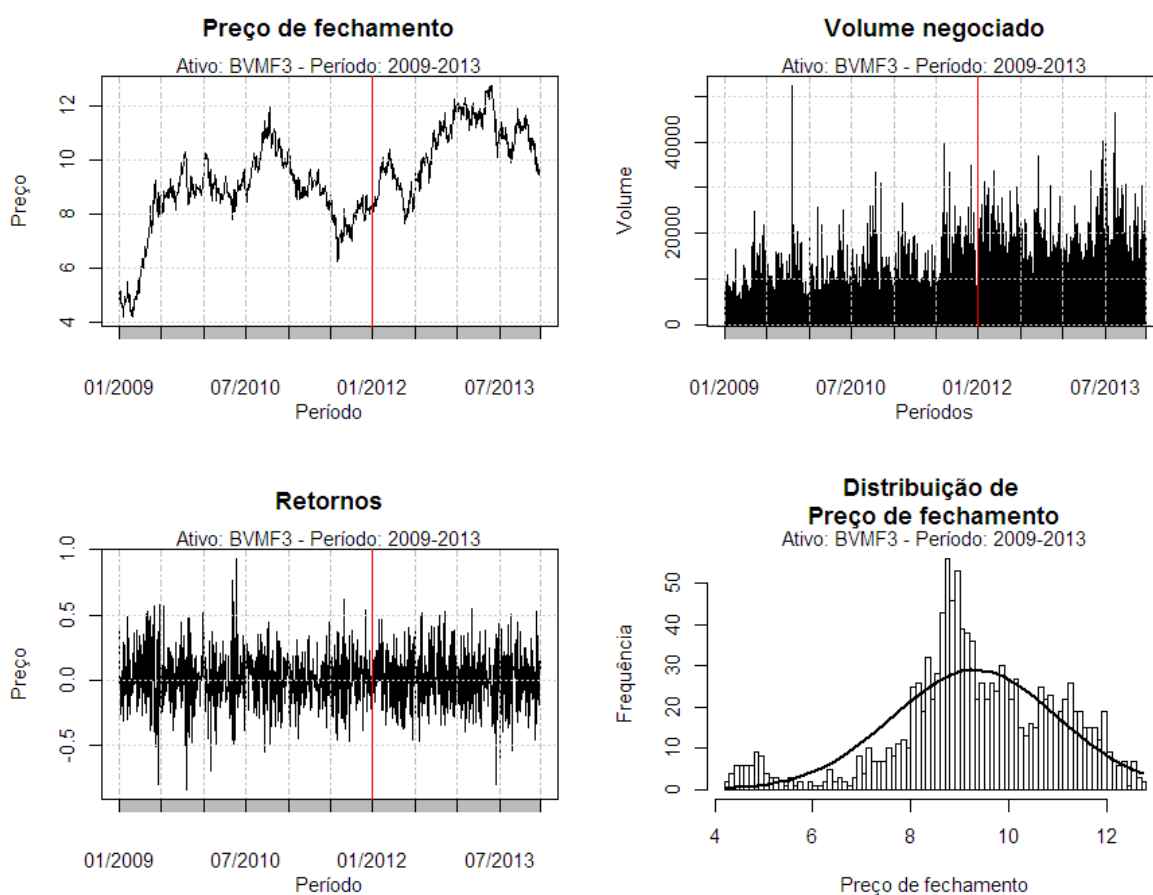
### A.2.4 BVMF3: Ação ordinária da BM&F BOVESPA

**Setor:** Financeiro

**Descrição:** Ação da própria bolsa de valores brasileira. Ver [Figura 61](#).

**Índices:** IBOVESPA, IBRX 50, IBRX BRASIL, IBRASIL, MIDLARGE CAP, I DIVIDENDOS, IFINANCEIRO, ICO2, IGOVERNANCA, IGC TRADE, IGC, NM, ITAG ALONG, IBOVESPA, IBRX 50, IBRX BRASIL, IBRASIL, IFINANCEIRO, ICO2, MIDLARGE CAP, I DIVIDENDOS, IGOVERNANCA, IGC TRADE, IGC, NM e ITAG ALONG.

Figura 61 – Gráficos descritivos do preço de fechamento do ativo BVMF3.



Fonte: Elaborada pelo autor.

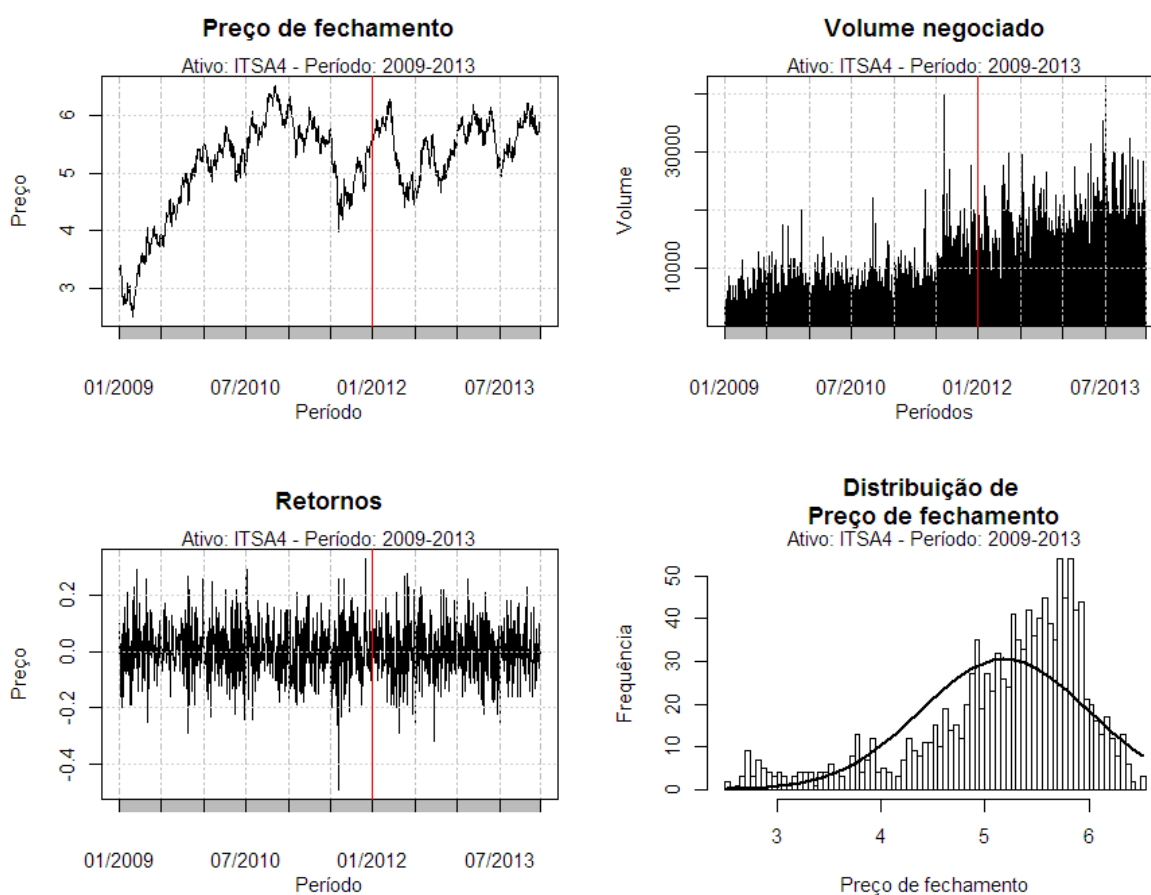
### A.2.5 ITSA4: Ação preferencial do Itaú

**Setor:** Holding.

**Descrição:** Ação do setor de *holding* do Banco Itaú. Esta ação do Itaú não se restringe a apenas um segmento de atuação no mercado, envolve também, indústrias de painéis de madeira, louças e materiais sanitários, química e eletrônica. Ver [Figura 62](#).

**Índices:** IBOVESPA, IBRASIL, IBRX BRASIL, IBRX 50, ICO2, IFINANCEIRO, IGOVERNANCA, IGC TRADE, ISUSTENTABIL, ITAG ALONG e MIDLARGE CAP.

Figura 62 – Gráficos descritivos do preço de fechamento do ativo ITSA4.



Fonte: Elaborada pelo autor.

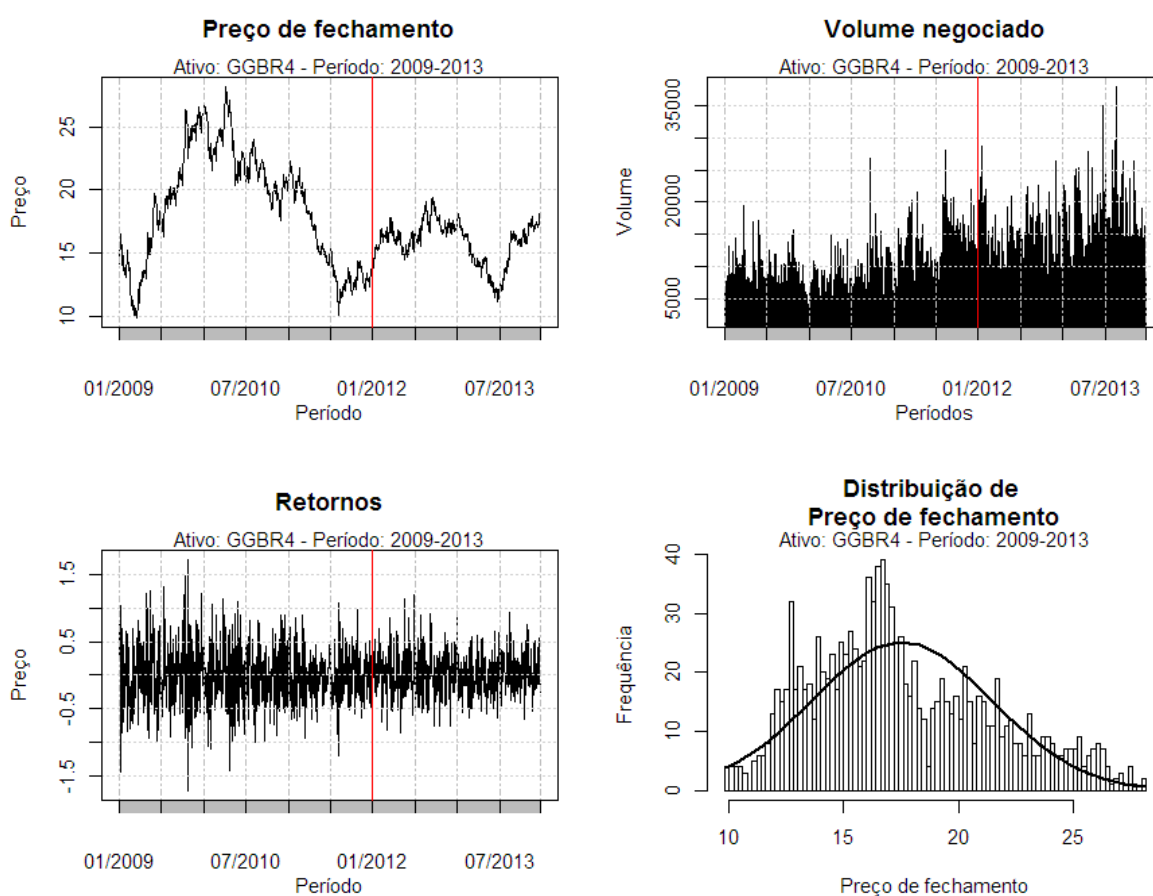
### A.2.6 GGBR4: Ação preferencial da Gerdau

**Setor:** Siderúrgico.

**Descrição:** Ação do Grupo Gerdau. Empresa que possui operações industriais em 14 países sendo a maior recicladora do mundo transformando sucata em aço. Ver [Figura 63](#).

**Índices:** IBOVESPA, IBRASIL, IBRX BRASIL, IBRX 50, IGOVERNANCA, IGC TRADE, IMAT BASICOS, INDUSTRIAL, ISUSTENTABIL, ITAG ALONG, IVBX2 e MIDLARGE CAP.

Figura 63 – Gráficos descritivos do preço de fechamento do ativo GGBR4.



Fonte: Elaborada pelo autor.



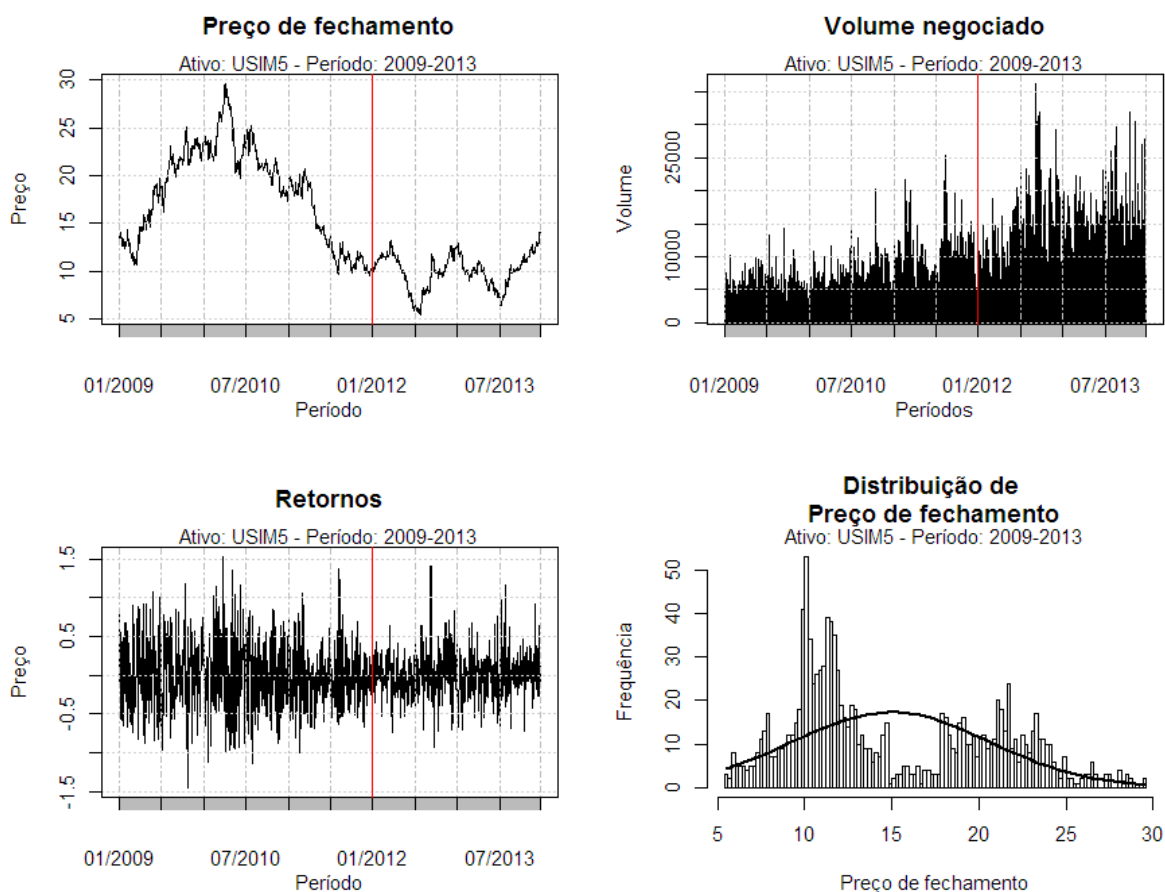
### A.2.7 USIM5: Ação preferencial classe A da Usiminas

**Setor:** Siderúrgico.

**Descrição:** Ação da empresa Usiminas (Usinas Siderúrgicas de Minas Gerais). Empresa com ações desenvolvidas para o fornecimento de matéria prima na forma de aço laminado a frio e a quente para componentes eletro e eletrônicos de aparelhos da linha branca e indústria automotiva. Ver [Figura 64](#).

**Índices:** IBOVESPA, IBRASIL, IBRX BRASIL, IBRX 50, IGOVERNANCA, IGC TRADE, IMAT BASICOS, INDUSTRIAL, IVBX2 e MIDLARGE CAP.

Figura 64 – Gráficos descritivos do preço de fechamento do ativo USIM5.



Fonte: Elaborada pelo autor.

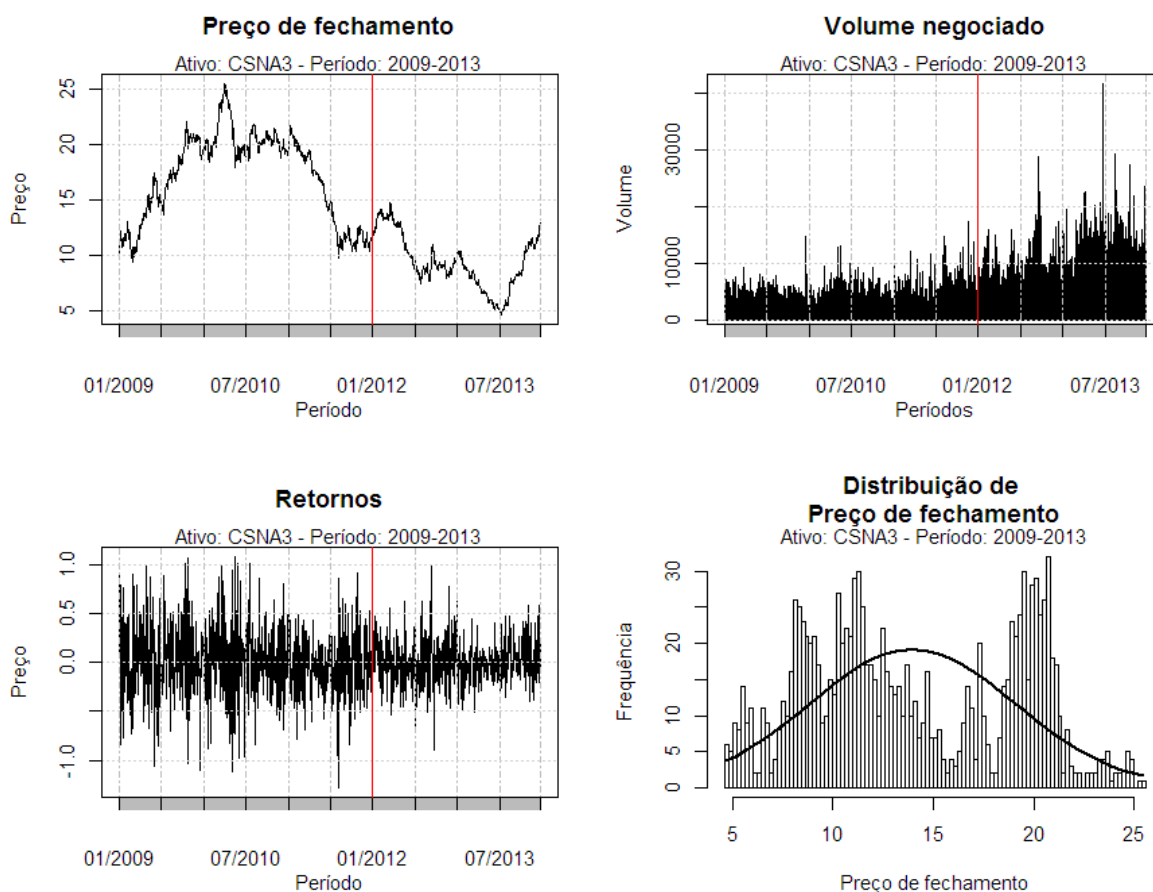
### A.2.8 CSNA3: Ação ordinária da Companhia Siderúrgica Nacional

**Setor:** Siderúrgico.

**Descrição:** Ação da CSN (Companhia Siderúrgica Nacional). Usina situada no sul do estado do Rio de Janeiro com minas instaladas nos estados de Minas Gerais e Santa Catarina. Produz aproximadamente 6 milhões de toneladas de aço bruto e mais 5 milhões de aço laminado por ano. Ver [Figura 65](#).

**Índices:** IBOVESPA, IBRX BRASIL, IVBX2, IBRX 50, INDUSTRIAL, MIDLARGE CAP, I DIVIDENDOS, IBRASIL e IMAT BASICOS.

Figura 65 – Gráficos descritivos do preço de fechamento do ativo CSNA3.



Fonte: Elaborada pelo autor.

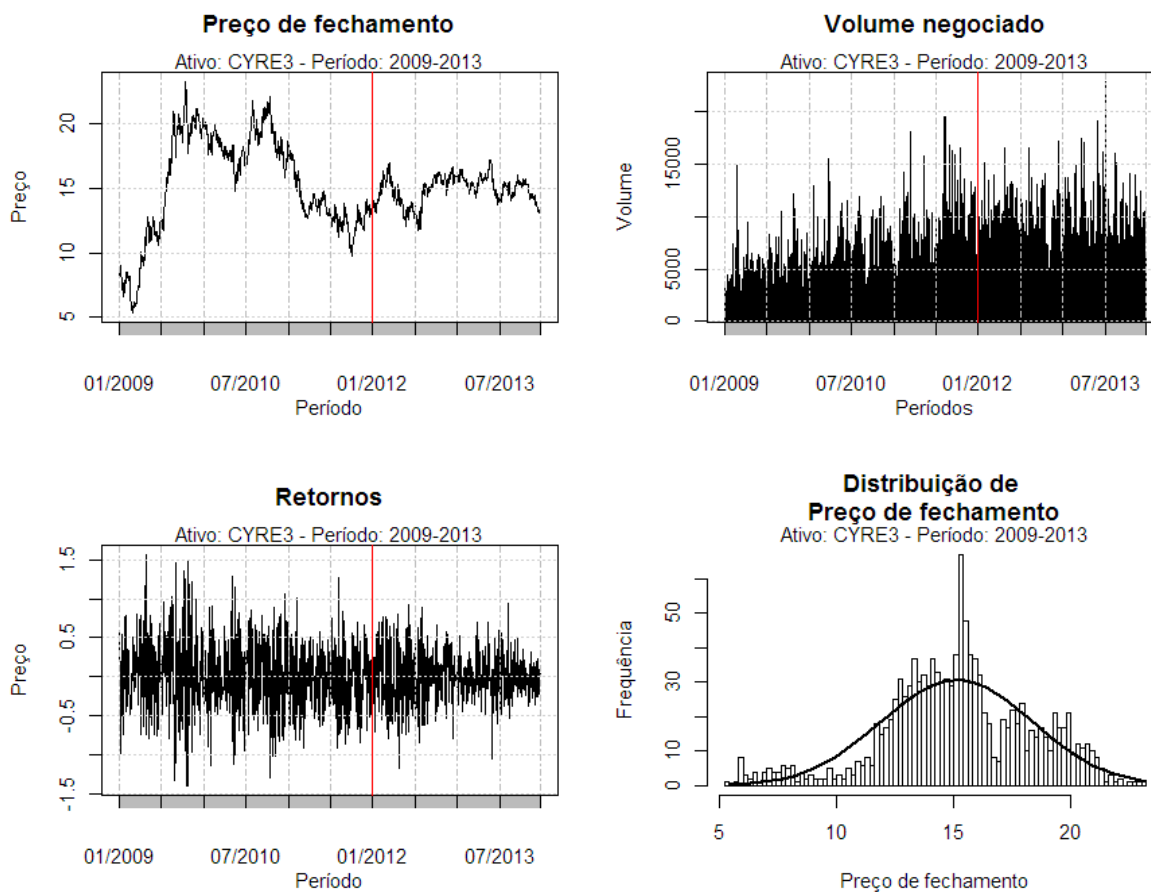
### A.2.9 CYRE3: Ação ordinária da Cyrela Realton

**Setor:** Imobiliário e de construção.

**Descrição:** Ação da empresa *Cyrela Realton*. Uma das maiores empresas de construção civil brasileiras que desenvolve atividades em incorporação, vendas, construção e serviços. Ver Figura 66.

**Índices:** IBOVESPA, IBRX BRASIL, IVBX2, IGOVERNANCA, IBRX 50, ITAG ALONG, INDUSTRIAL, MIDLARGE CAP, IMOBILIARIO, IGC TRADE, IBRASIL, IGC e NM.

Figura 66 – Gráficos descritivos do preço de fechamento do ativo CYRE3.



Fonte: Elaborada pelo autor.

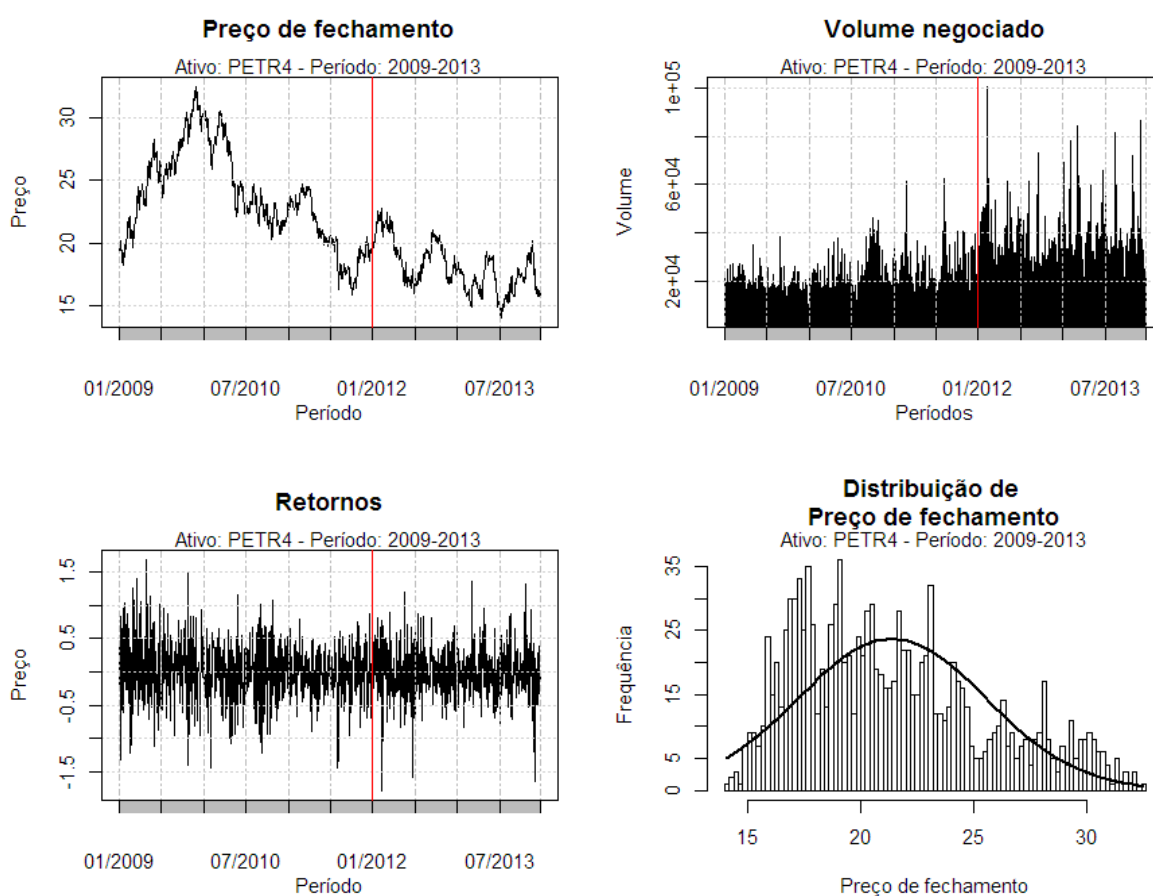
### A.2.10 PETR4: Ação preferencial da Petrobrás

**Sector:** Petróleo e Gás.

**Descrição:** Ação da Petrobrás. Empresa estatal que atua na exploração, extração e produção de petróleo, além de, refino e distribuição do produto e seus derivados para outras empresas. Ver [Figura 67](#).

**Índices:** IBOVESPA, IBRASIL, IBRX BRASIL, IBRX 50, I DIVIDENDOS e MIDLARGE CAP.

Figura 67 – Gráficos descritivos do preço de fechamento do ativo PETR4.



Fonte: Elaborada pelo autor.

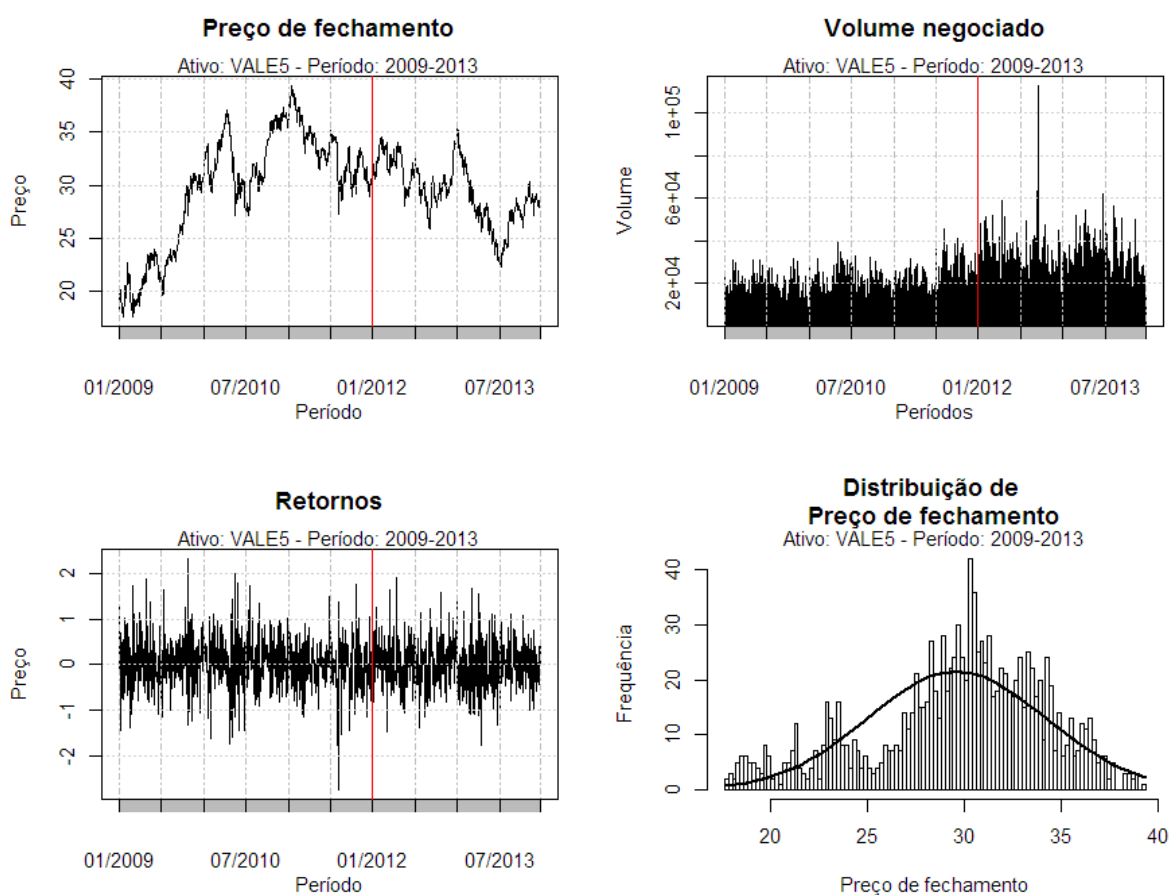
### A.2.11 VALE5: Ação preferencial classe A da companhia Vale

**Setor:** Mineração

**Descrição:** Ação da companhia Vale. Mineradora multinacional brasileira, uma das maiores operadoras logísticas do país. Terceira maior empresa de mineração do mundo, maior produtora de minério de ferro e segunda maior exploradora de níquel. Ver [Figura 68](#).

**Índices:** IBOVESPA, IBRASIL, IBRX BRASIL, IBRX 50, ICO2, I DIVIDENDOS, IGOVERNANCA, IGC TRADE, IMAT BASICOS, ISUSTENTABIL e MIDLARGE CAP.

Figura 68 – Gráficos descritivos do preço de fechamento do ativo VALE5.




Fonte: Elaborada pelo autor.

### A.3 Comparativo entre as séries do *dataset*

Inicialmente, conforme pode-se ver na [Figura 69](#), que trata da comparação dos retornos sem corretagem acumulados em todos os ativos, as séries são bastante heterogêneas entre si. Enquanto algumas possuem períodos onde descrevem movimentos de alta, outras, neste mesmo momento, descrevem movimentos de baixa ou de lateralização. Quase todas as ações acusaram uma breve alta no início de 2012 seguida de queda, entretanto, após esta fase, a maioria descreve desenhos diferentes entre si ao longo do período.

Figura 69 – Comparação da evolução dos retornos acumulados sem corretagem entre 2012 e 2013 (período de operação) entre todos os ativos.



Fonte: Elaborada pelo autor.

A [Figura 70](#) apresenta um correlograma entre as séries de todos os ativos para o período de 2012 a 2013. Os círculos azuis grandes apresentam correlação linear próxima de 1 e, os vermelhos, correlação inversa próxima de -1. Quanto menores e transparentes, mais próximos de 0, logo menor a correlação. Ao ficarem claros em demasia são marcados com um “xis” que, neste caso, indica pares de séries onde não houve significância estatística para o valor obtido no teste com um intervalo de confiança de 95%. O tipo de teste de correlação, de significância estatística e outras configurações possíveis para este gráfico podem ser consultadas na fonte referente a biblioteca *corrgram* da linguagem R<sup>5</sup>.

Como pode-se notar, a maioria dos pares de séries apresenta certa quantidade de correlação seja linear ou inversa, no entanto, apenas poucos pares como BBAS3-BOVA11, VALE5-CYRE3 e VALE5-CSNA3 apresentam alta ou baixa correlação. Alguns possuem ainda nenhuma correlação, tanto que, em alguns dos testes, não se pode constatar significância estatística. Fato observado em 8 pares.

<sup>5</sup> M. Friendly, “Corrgrams: Exploratory displays for correlation matrices”, *The American Statistician*, vol. 56, pp. 316–324, 2002.

Figura 70 – Significância estatística da correlação entre séries de preço de fechamento dos ativos.



**Significância da correlação com um intervalo de confiança de 95%**

Figura 71 – Frequências das correlações.



Colocando-se os valores de correlação entre as séries dispostos em dois gráficos de frequências (ver Figura 71), um tratando-se dos coeficientes absolutos e, outro, dos módulos dos coeficientes, pode-se notar que a correlação entre as séries está bem distribuída e privilegiando

pares não correlacionados. Isto fica evidenciado no gráfico dos módulos que mostra 28 pares com correlação menor que 0.4, 14 com correlação entre 0.4 e 0.6, e, apenas, 13 pares com correlação acima de 0.6.

A partir destas análises percebe-se que o *dataset*, apesar de ter sido selecionado através de um método dinâmico, por conveniência, se mostrou também representativo com companhias de vários segmentos, algumas correlacionadas, mas a maioria não.



---

## PLATAFORMAS TECNOLÓGICAS

---

Algumas plataformas específicas durante a pesquisa tornaram-se necessárias ao processo de implementação do robô investidor. Estas plataformas, em geral constituídas de suítes de programação e análises de dados, por sua vez, exigiram equipamentos de *hardware* que suportassem todos os experimentos realizados. Neste apêndice é feita uma breve descrição de cada uma dessas ferramentas e *hardwares*, na maioria das vezes, segundo informações fornecidas pelos próprios fabricantes.

### B.1 *Metatrader 5*

O *Metatrader 5* (MT5) é um *homebroker* algorítmico pois, por meio da linguagem de programação MQL, permite ao usuário construir e gerenciar estratégias de negociação automatizadas. Foi desenvolvido pela empresa *MetaQuotes* e está atualmente na versão 5 lançada em 2005. A ferramenta é licenciada para corretoras de valores que, por sua vez, podem habilitar sob determinadas condições aos seus clientes o uso da mesma. A interface principal do sistema pode ser vista na [Figura 72](#). O link para *download* é o constante na referência do rodapé<sup>1</sup>.

Segundo informações do fabricante, o MT5 é baseado exclusivamente em plataforma *Windows* e possui as seguintes funcionalidades:

- Sistemas de negociação nativo que permite implementar estratégias de diversos níveis de complexidade incluindo até 3 formas de execução de ordens, 2 tipos de ordens de mercado, 4 tipos de ordens pendentes e 2 tipos de ordens de *stop* e *trailing-stop*.
- Cotações *online*, gráficos que permitem interação e 9 tipos de *timeframes* que permitem analisar analiticamente as cotações de forma a possibilitar resposta rápida ao movimento dos preços.

---

<sup>1</sup> M. S. Corporation, “Plataforma de Negociação MetaTrader 5”, 2016. [Online]. Disponível em <http://www.metatrader5.com/pt/trading-platform>

Figura 72 – Interface de trabalho do *Metatrader 5*

Fonte: Elaborada pelo autor.

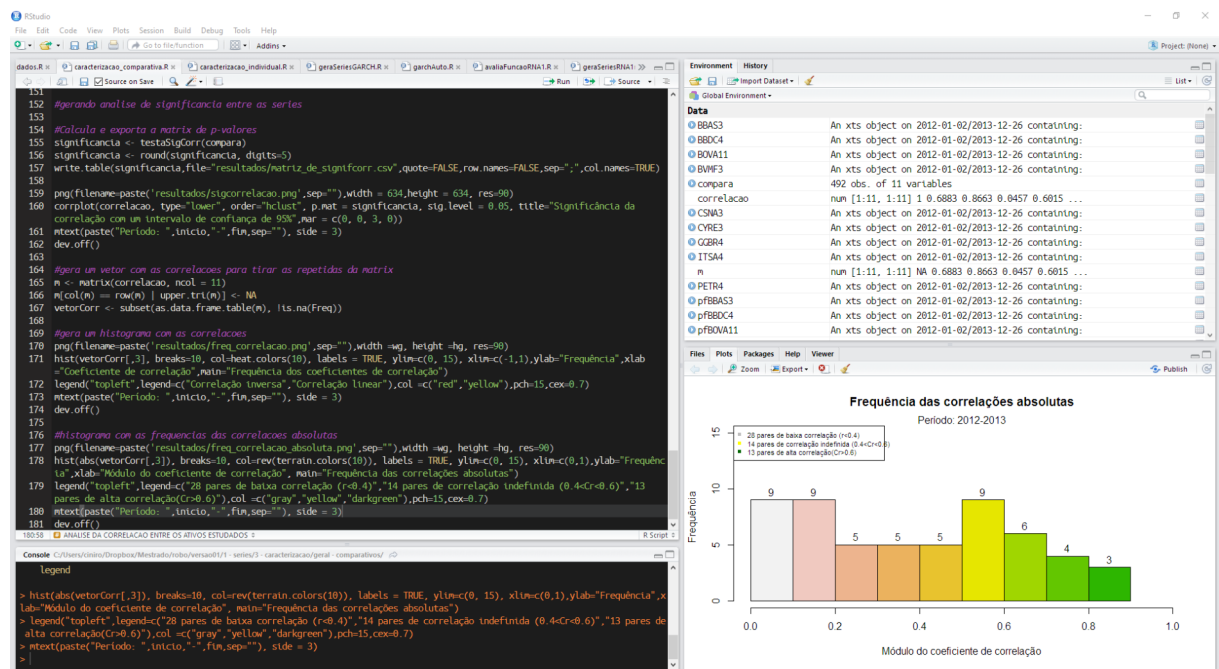
- Possui 23 objetos analíticos e 30 indicadores técnicos embutidos.
- Possibilidade de adição de bibliotecas que dão acesso a outros tipos de indicadores.
- Possibilidade de consumo de sinais de outros operadores por meio de provedores de sinais. O usuário paga o preço referente ao acesso as estratégias contidas em algum provedor e, por meio destas, pode operar sua própria conta.
- Venda de robôs prontos dentro da própria ferramenta.
- Ambientes de desenvolvimento, testes e otimização de estratégias algorítmicas por meio da linguagem de programação MQL, da IDE *MetaEditor*, do gerenciador de *backtests* e da biblioteca de robôs.
- Suporte a dispositivos móveis com sistemas *iOS* e *Android*.
- Análises e alertas financeiros configuráveis.

## B.2 Linguagem de programação R

Para desenvolvimento do trabalho optou-se pela utilização da linguagem de programação R na versão, até aqui mais recente, 3.2.2, aliada ao ambiente *RStudio* na sua versão 0.99.

Ambos foram utilizados sob plataforma *Windows*, para implementação, e *Linux*, para testes e simulação. O R consiste de um ambiente para a realização de análise estatística e matemática, manipulação de dados, programação de software e geração facilitada de gráficos. A mesma, além de prover facilidades para o desenvolvimento de software científico, possibilita que o usuário desenvolva suas próprias bibliotecas estendendo assim as funcionalidades do ambiente. R é gratuita e de código livre, possui uma comunidade de colaboradores ativa que não somente atualiza periodicamente a ferramenta como mantém também disponíveis várias bibliotecas para as mais diversas finalidades. Nesse contexto é importante ressaltar que a linguagem R, apesar do foco, não é um ambiente para fins puramente e necessariamente estatísticos, visto que apresenta elementos que a caracterizam como uma linguagem de programação sólida como outras já existentes no mercado<sup>2</sup>. A IDE *RStudio* é a mostrada na Figura 73.

Figura 73 – Interface de trabalho do *RStudio*



Fonte: Elaborada pelo autor.

Além da linguagem R propriamente dita, foram utilizadas também, algumas bibliotecas fornecidas por terceiros agregadas a linguagem, sendo estas, *compiler*, *mclust*, *corrplot*, *corrgram*, *PerformanceAnalytics*, *car*, *xts*, *ggplot2*, *reshape2*, *scales*, *quantmod*, *nortest*, *forecast*, *fGarch*, *parallel*, *RSNNS*, *beepr*, *TTR*, *timeSeries*, *lattice*, *zoo*, *lmtest* e *multcomp*. Para consultar o manual de qualquer uma destas bibliotecas ou baixar a versão mais atualizada destas pode-se acessar o link da referência no rodapé<sup>3</sup>.

<sup>2</sup> R. C. Team, “R: A language and environment for statistical computing” in R Foundation for Statistical Computing, Vienna, Austria, 2016 [Online]. Disponível em <http://www.R-project.org>

<sup>3</sup> C. Packages, “Available R CRAN Packages by name”, 2016. [Online]. Disponível em [https://cran.r-project.org/web/packages/available\\_packages\\_by\\_name.html](https://cran.r-project.org/web/packages/available_packages_by_name.html)

O *R* foi também ajustado para ganhos de desempenho conforme os passos realizados a seguir:

- Utilização exclusiva de ambiente *Linux* para testes e simulação.
- Opção pelo *Microsoft R Open* (MRO) na versão 3.2.5 ao invés do núcleo *R* padrão do CRAN. Isto foi feito buscando-se utilização de todos os processadores quando possível a programação paralela.
- Compilações das bibliotecas por meio do *build-essentials* e *liblapack-dev*.
- Aplicação do MKL 3.2.5 associada ao MRO.
- Configuração do *RStudio* para uso do MRO.
- Código com funções sempre compiladas por meio de *cpmfun()*.
- Código paralelizado nos testes exaustivos do GARCH com *biblioteca parallel*.

### B.3 Plataformas de *hardware*

Foram utilizados 3 computadores para o desenvolvimento do robô investidor. Um ficou alocado para a implementação, outro para o desenvolvimento de testes e o terceiro para as simulações. A seguir é descrito o hardware de cada um destes.

- MÁQUINA 1 (Implementação): *Notebook Dell Inspiron 13* com *Windows 10 Home 64 bits*. Processador *Intel Core i5-4210U* com CPU 1.70-2.40 Ghz e memória RAM de 8 GB.
- MÁQUINA 2 (Testes): Computador *desktop* com *Lubuntu 16.4 LTS 64 bits*. Processador *Pentium Dual-Core CPU E5500* 2.80 GHz e memória RAM de 8 GB.
- MÁQUINA 3 (Simulação): Computador servidor com *Ubuntu 16.4 LTS 64 bits*. 2 processadores *Intel Xeon 24 cores i7 CPU E5-2640* e memória RAM de 96 GB.

## CARTEIRA TEÓRICA DO IBOVESPA

A tabela a seguir diz respeito a carteira teórica do índice Bovespa vigente de setembro de 2010 a janeiro de 2011. Traz as 70 empresas com maior participação na bolsa de valores brasileira neste período.

CÓDIGO	AÇÃO	TIPO	QUANTIDADE TEÓRICA*	PARTICIPAÇÃO PERCENTUAL**
VALE5	VALE	PNA N1	169,00680322588	10,748
PETR4	PETROBRAS	PN	242,69808596084	9,709
BVMF3	BMFBOVESPA	ON EDJ NM	194,50147659668	3,822
ITUB4	ITAUUNIBANCO	PN ED N1	65,32440584415	3,791
OGXP3	OGX PETROLEO	ON NM	116,98892696663	3,750
GGBR4	GERDAU	PN N1	86,16459614758	3,090
BBDC4	BRADESCO	PN N1	60,33816989291	2,821
USIM5	USIMINAS	PNA N1	40,77052602223	2,756
VALE3	VALE	ON N1	37,02080072401	2,664
PETR3	PETROBRAS	ON	56,89714879141	2,584
PDGR3	PDG REALT	ON NM	89,74526420522	2,485
BBAS3	BANCO DO BRASIL	ON NM	55,58803732717	2,430
CSNA3	SID NACIONAL	ON	57,34948887548	2,368
ITSA4	ITAUSA	PN ED N1	117,79051809945	2,221
CYRE3	CYRELA REALT	ON NM	56,95764115497	1,909
CIEL3	CIELO	ON NM	72,25834548599	1,664
GFS3	GAFISA	ON NM	84,23671321808	1,565
FIBR3	FIBRIA	ON NM	36,61356029089	1,521
MMXM3	MMX MINER	ON NM	73,40485837092	1,414
RDCD3	REDECARD	ON NM	38,31134540915	1,411
BRFS3	BRF FOODS	ON NM	38,70346522647	1,399

ALLL11	ALL AMER LAT	UNT N2	48,20006898537	1,198
CMIG4	CEMIG	PN N1	27,25635425951	1,171
MRVE3	MRV	ON NM	51,23923115854	1,152
JBSS3	JBS	ON NM	100,10257396161	1,145
RSID3	ROSSI RESID	ON NM	48,99842683581	1,140
LAME4	LOJAS AMERIC	PN INT	48,79075545760	1,108
SANB11	SANTANDER BR	UNT N2	31,03246195658	1,062
LREN3	LOJAS RENNER	ON NM	11,76583186676	1,024
GOLL4	GOL	PN N2	28,46587987739	0,992
ECOD3	ECODIESEL	ON NM	723,46607828457	0,966
TAMM4	TAM S/A	PN N2	17,85372052828	0,939
LLXL3	LLX LOG	ON NM	68,54580844313	0,936
TNLP4	TELEMAR	PN	24,69280289234	0,906
BRAP4	BRADESPAR	PN N1	16,07816547164	0,903
PCAR5	P.ACUCAR-CBD	PNA N1	9,06744902505	0,862
ELET3	ELETROBRAS	ON N1	26,14227220378	0,858
TCSL4	TIM PART S/A	PN	110,79247313942	0,844
AMBV4	AMBEV	PN	2,83483702008	0,842
NETC4	NET	PN N2	23,65630579471	0,809
NATU3	NATURA	ON NM	12,36455278422	0,803
GOAU4	GERDAU MET	PN N1	18,44535608302	0,798
CCRO3	CCR RODOVIAS	ON NM	12,13316245750	0,751
VIVO4	VIVO	PN	11,34981974310	0,735
CSAN3	COSAN	ON NM	20,71880843932	0,728
EMBR3	EMBRAER	ON NM	43,68027906525	0,724
ELET6	ELETROBRAS	PNB N1	18,39295221251	0,716
BTOW3	B2W VAREJO	ON NM	16,45222209238	0,707
CESP6	CESP	PNB N1	17,25006353342	0,676
BISA3	BROOKFIELD	ON NM	47,96178768122	0,667
MRFG3	MARFRIG	ON NM	25,04499087309	0,654
ELPL6	ELETROPAULO	PNB N2	12,47916801565	0,632
CPLE6	COPEL	PNB EJ N1	10,49128138212	0,619
USIM3	USIMINAS	ON N1	8,35798452436	0,592
DTEX3	DURATEX	ON NM	21,58175121172	0,590
BRKM5	BRASKEM	PNA N1	23,71378951348	0,563
LIGT3	LIGHT S/A	ON NM	16,10316283458	0,540
UGPA4	ULTRAPAR	PN N1	3,20179556540	0,474
CPFE3	CPFL ENERGIA	ON NM	7,59766073930	0,473
KLBN4	KLABIN S/A	PN N1	58,26022907098	0,438
CRUZ3	SOUZA CRUZ	ON	3,50072930123	0,435

BRT04	BRASIL TELEC	PN	22,09914643645	0,377
SBSP3	SABESP	ON NM	6,38758428955	0,328
TNLP3	TELEMAR	ON	5,52757179970	0,258
TRPL4	TRAN PAULIST	PN N1	2,93223250544	0,224
TMAR5	TELEMAR N L	PNA	3,24823321574	0,222
TLPP4	TELESP	PN	2,58354225190	0,160
TCSL3	TIM PART S/A	ON	12,78091457931	0,137
<b>QUANTIDADE TEÓRICA TOTAL</b>			3.674,29244720022	100,000

\*Quantidade teórica válida para o período de vigência da carteira, sujeita a alterações somente no caso de distribuição de proventos.

\*\*Participação relativa das ações da carteira, divulgada para a abertura dos negócios do dia 01/09/2010 sujeita a alterações em função das evoluções dos preços desses papéis.